

UNIVERSIDADE FEDERAL DE SANTA CATARINA

CAMPUS FLORIANÓPOLIS

CURSO DE GRADUAÇÃO EM CIÊNCIA DA COMPUTAÇÃO

Tális Breda

ESTUDO DA FAMÍLIA DE EMPARELHAMENTO EM GRAFOS

Florianópolis

2026

Tális Breda

ESTUDO DA FAMÍLIA DE EMPARELHAMENTO EM GRAFOS

Trabalho de Conclusão de Curso submetido ao Curso de Graduação em Ciência da Computação do Centro Tecnológico da Universidade Federal de Santa Catarina para obtenção do título de Bacharel em Ciência da Computação.

Orientador: Prof. Rafael de Santiago, Dr.

Florianópolis

2026

[Ficha catalográfica a ser gerada em <http://portalbu.ufsc.br/ficha>]

Tális Breda

ESTUDO DA FAMÍLIA DE EMPARELHAMENTO EM GRAFOS

Este Trabalho de Conclusão de Curso foi julgado adequado para obtenção do título de Bacharel em Ciência da Computação e aprovado em sua forma final pelo Curso de Graduação em Ciência da Computação.

Florianópolis, 10 de novembro de 2026.

_____

Profa. Lúcia Helena Martins Pacheco, Dra.
Coordenadora do Curso

Banca Examinadora:

_____

Prof. Rafael de Santiago, Dr.
Orientador
Universidade Federal de Santa Catarina

_____

Prof. Àlvaro Júnio Pereira, Dr.
Avaliador(a)
Universidade Federal de Santa Catarina

_____

Prof. Maicon Rafael Zatelli, Dr.
Avaliador(a)
Universidade Federal de Santa Catarina

RESUMO

Um emparelhamento em um grafo $G = (V, E)$ é definido como um conjunto de arestas $M \subseteq E$ tal que nenhum par de arestas em M compartilha um vértice comum. Os problemas de emparelhamento em grafos têm aplicações em diversas áreas, sendo úteis principalmente em tarefas que envolvem formar pares de elementos respeitando custos, preferências ou conflitos. Enquanto as formulações clássicas são solúveis eficientemente, variações com restrições adicionais pertencem frequentemente à classe NP-difícil, e suas soluções podem ser computacionalmente custosas. Este trabalho levanta sete problemas diferentes relacionados a emparelhamento em grafos, com métodos exatos, aproximados e heurísticos para cada um. O trabalho constrói um ambiente de testes unificado para que os algoritmos sejam comparados no mesmo cenário e com as mesmas entradas, medindo tempo de execução e qualidade da solução (para métodos não exatos). Os algoritmos utilizados incluem implementações presentes em repositórios públicos, métodos de bibliotecas consolidadas e implementações próprias baseadas na literatura. O crescimento do tempo foi, em geral, coerente com a complexidade teórica. Porém, em alguns casos, como o do problema da atribuição gargalo, a estrutura da entrada alterou drasticamente a eficiência dos métodos testados. Além disso, há casos de implementações diferentes do mesmo algoritmo que obtiveram desempenhos diferentes, como é o caso do método Húngaro. Por fim, a proximidade da solução exata obtida por métodos não exatos variou bastante de problema a problema, sendo muito próxima do ótimo em alguns casos, e muito longe em outros, mostrando que a escolha de um método aproximado ou heurístico depende do problema a ser atacado.

Palavras-chave: emparelhamento em grafos; algoritmos; grafos.

ABSTRACT

A matching in a graph $G = (V, E)$ is defined as a set of edges $M \subseteq E$ such that no two edges in M share a common vertex. Matching problems in graphs have applications in several areas and are mainly useful in tasks that involve pairing elements while respecting costs, preferences, or conflicts. While the classical formulations are efficiently solvable, variations with additional constraints often belong to the NP-hard class, and their solutions can be computationally expensive. This work surveys seven matching problems in graphs, with exact, approximation, and heuristic methods for each of them. It builds a unified testing environment in which the algorithms are compared in the same setting and on the same inputs, measuring running time and, for non-exact methods, solution quality. The algorithms include implementations from public repositories, methods from well-established libraries, and implementations written from the literature. In general, the growth of the running time was consistent with the theoretical complexity. However, in some cases, such as the bottleneck assignment problem, the structure of the input drastically changed the efficiency of the methods tested. Moreover, different implementations of the same algorithm achieved different performances, as in the case of the Hungarian method. Finally, how close non-exact methods came to the exact solution varied widely from problem to problem, being very close to the optimum in some cases and far from it in others, which shows that the choice of an approximation or heuristic method depends on the problem at hand.

Keywords: matching in graphs; algorithms; graphs.

LISTA DE ILUSTRAÇÕES

Figura 1 – Um emparelhamento M, um caminho M-aumentante P e o emparelhamento $M \ominus P$ 34
Figura 2 – Atribuição gulosa e atribuição ótima para a matriz de custos (3.2) . . 56
Figura 3 – Uma flor B com caule e base v_B, antes e depois da contração . . . 86
Figura 4 – Solução fracionária da relaxação linear em um triângulo 95
Figura 5 – Emparelhamento máximo e emparelhamento induzido máximo em um caminho, e os grafos $L(G)$ e $L(G)^2$ usados na redução ao conjunto independente 104
Figura 6 – Cardinalidade máxima bipartida, grafo 3 (denso, com emparelhamento perfeito): tempo de execução em escala log-log 141
Figura 7 – Atribuição linear, matriz 1 (densa uniforme, custos em $[1, 100]$): tempo de execução em escala log-log 142

LISTA DE TABELAS

Tabela 1 – Algoritmos para emparelhamento de cardinalidade máxima em grafos bipartidos 55
Tabela 2 – Algoritmos para problema de atribuição 69
Tabela 3 – Algoritmos para problema de atribuição gargalo 81
Tabela 4 – Algoritmos para problema de emparelhamento de cardinalidade máxima em grafos gerais 93
Tabela 5 – Algoritmos para problema de emparelhamento ponderado máximo em grafos gerais 102
Tabela 6 – Algoritmos para problema de emparelhamento induzido máximo em grafos gerais 110
Tabela 7 – Interface padrão de entrada e saída por problema 112
Tabela 8 – Famílias de instâncias por problema 113
Tabela 9 – Especificação da máquina de medição 122
Tabela 10 – Proveniência dos algoritmos avaliados 123
Tabela 11 – Cardinalidade máxima bipartida, grafo 1 (esparso, sem emparelhamento perfeito, máximo com $0{,}8n$ arestas): tempo de execução em Python (mediana, em ms) 126
Tabela 12 – Cardinalidade máxima bipartida, grafo 1 (esparso, sem emparelhamento perfeito, máximo com $0{,}8n$ arestas): qualidade da solução (cardinalidade) 127
Tabela 13 – Cardinalidade máxima bipartida, grafo 2 (esparso, com emparelhamento perfeito): tempo de execução em Python (mediana, em ms) . 127
Tabela 14 – Cardinalidade máxima bipartida, grafo 2 (esparso, com emparelhamento perfeito): qualidade da solução (cardinalidade) 127
Tabela 15 – Cardinalidade máxima bipartida, grafo 3 (denso, com emparelhamento perfeito): tempo de execução em Python (mediana, em ms) . 128
Tabela 16 – Cardinalidade máxima bipartida, grafo 3 (denso, com emparelhamento perfeito): qualidade da solução (cardinalidade) 128
Tabela 17 – Atribuição linear, matriz 1 (densa uniforme, custos em $[1, 100]$): tempo de execução em Python (mediana, em ms) 129
Tabela 18 – Atribuição linear, matriz 1 (densa uniforme, custos em $[1, 100]$): qualidade da solução (custo total) 129
Tabela 19 – Atribuição linear, matriz 2 (permutação barata, ótimo igual a n): tempo de execução em Python (mediana, em ms) 130
Tabela 20 – Atribuição linear, matriz 2 (permutação barata, ótimo igual a n): qualidade da solução (custo total) 130

Tabela 21 – Atribuição linear, matriz 3 (estruturada, custo $|i-j|+1$): tempo de execução em Python (mediana, em ms) 130
Tabela 22 – Atribuição linear, matriz 3 (estruturada, custo $|i-j|+1$): qualidade da solução (custo total) 130
Tabela 23 – Atribuição gargalo, matriz 1 (densa uniforme, custos em $[1, 100]$): tempo de execução em Python (mediana, em ms) 131
Tabela 24 – Atribuição gargalo, matriz 1 (densa uniforme, custos em $[1, 100]$): qualidade da solução (custo gargalo) 132
Tabela 25 – Atribuição gargalo, matriz 2 (estruturada, custo $|i-j|+1$): tempo de execução em Python (mediana, em ms) 132
Tabela 26 – Atribuição gargalo, matriz 2 (estruturada, custo $|i-j|+1$): qualidade da solução (custo gargalo) 132
Tabela 27 – Atribuição gargalo, matriz 3 (poucos valores distintos, muitos empates): tempo de execução em Python (mediana, em ms) 132
Tabela 28 – Atribuição gargalo, matriz 3 (poucos valores distintos, muitos empates): qualidade da solução (custo gargalo) 133
Tabela 29 – Casamento estável, perfil 1 (aleatório): tempo de execução em Python (mediana, em ms) 134
Tabela 30 – Casamento estável, perfil 1 (aleatório): qualidade da solução (pares bloqueantes e concordância com a referência) 134
Tabela 31 – Casamento estável, perfil 2 (correlacionado): tempo de execução em Python (mediana, em ms) 134
Tabela 32 – Casamento estável, perfil 2 (correlacionado): qualidade da solução (pares bloqueantes e concordância com a referência) 134
Tabela 33 – Casamento estável, perfil 3 (cíclico): tempo de execução em Python (mediana, em ms) 135
Tabela 34 – Casamento estável, perfil 3 (cíclico): qualidade da solução (pares bloqueantes e concordância com a referência) 135
Tabela 35 – Cardinalidade máxima em grafos gerais, grafo esparso (grau médio ≈ 3): tempo de execução em Python (mediana, em ms) 136
Tabela 36 – Cardinalidade máxima em grafos gerais, grafo esparso (grau médio ≈ 3): qualidade da solução (cardinalidade) 136
Tabela 37 – Cardinalidade máxima em grafos gerais, grafo denso ($p = 0{,}3$): tempo de execução em Python (mediana, em ms) 136
Tabela 38 – Cardinalidade máxima em grafos gerais, grafo denso ($p = 0{,}3$): qualidade da solução (cardinalidade) 136
Tabela 39 – Peso máximo em grafos gerais, grafo esparso (grau médio ≈ 3): tempo de execução em Python (mediana, em ms) 137

Tabela 40 – Peso máximo em grafos gerais, grafo esparso (grau médio ≈ 3): qualidade da solução (peso total) 137
Tabela 41 – Peso máximo em grafos gerais, grafo denso ($p = 0{,}3$): tempo de execução em Python (mediana, em ms) 137
Tabela 42 – Peso máximo em grafos gerais, grafo denso ($p = 0{,}3$): qualidade da solução (peso total) 138
Tabela 43 – Emparelhamento induzido máximo, grafo esparso (grau médio ≈ 3): tempo de execução em Python (mediana, em ms) 138
Tabela 44 – Emparelhamento induzido máximo, grafo esparso (grau médio ≈ 3): qualidade da solução (cardinalidade) 139
Tabela 45 – Emparelhamento induzido máximo, grafo médio (grau médio ≈ 6): tempo de execução em Python (mediana, em ms) 139
Tabela 46 – Emparelhamento induzido máximo, grafo médio (grau médio ≈ 6): qualidade da solução (cardinalidade) 139
Tabela 47 – Emparelhamento induzido máximo, grafo denso (grau médio ≈ 12): tempo de execução em Python (mediana, em ms) 139
Tabela 48 – Emparelhamento induzido máximo, grafo denso (grau médio ≈ 12): qualidade da solução (cardinalidade) 139
Tabela 49 – Cardinalidade máxima bipartida, grafo 3 (denso, com emparelhamento perfeito): expoente empírico de crescimento 142
Tabela 50 – Atribuição linear, matriz 1 (densa uniforme, custos em $[1, 100]$): expoente empírico de crescimento 143
Tabela 51 – Casamento estável, perfil 1 (aleatório): expoente empírico de crescimento 143
Tabela 52 – Atribuição gargalo, matriz 1 (densa uniforme, custos em $[1, 100]$): expoente empírico de crescimento 143
Tabela 53 – Peso máximo em grafos gerais, grafo esparso (grau médio ≈ 3): expoente empírico de crescimento 144

LISTA DE ALGORITMOS

1 Algoritmo de Dijkstra (CORMEN et al., 2009) 27

2 Algoritmo de Bellman-Ford (CORMEN et al., 2009) 28

3 Algoritmo de Ford-Fulkerson (CORMEN et al., 2009) 31

4 Algoritmo de caminhos aumentantes (MCBM) (HALIM; HALIM, 2013) . . 44

5 Algoritmo de Edmonds-Karp (HALIM; HALIM, 2013) 46

6 Algoritmo de Hopcroft-Karp: laço principal e grafo em camadas (BURKARD; DELL'AMICO; MARTELLO, 2009) 49

7 Algoritmo de Hopcroft-Karp: busca dos caminhos aumentantes disjuntos (BURKARD; DELL'AMICO; MARTELLO, 2009) 50

8 Método guloso simples (VAZIRANI, 2001) 52

9 Algoritmo de Karp-Sipser (KARP; SIPSER, 1981) 54

10 Algoritmo Húngaro (JUNGNICKEL, 2008) 59

11 Método AUGMENT (JUNGNICKEL, 2008) 60

12 Algoritmo de Jonker-Volgenant (LAPJV), em alto nível (JONKER; VOLGENANT, 1987) 62

13 Algoritmo de caminhos de custo mínimo sucessivos (JUNGNICKEL, 2008) 65

14 Adaptação do Algoritmo 13 utilizando Dijkstra com a técnica de potenciais (JUNGNICKEL, 2008; AHUJA; MAGNANTI; ORLIN, 1993) 67

15 Algoritmo *threshold* para o LBAP (BURKARD; DELL'AMICO; MARTELLO, 2009) 71

16 Dual_LBAP: algoritmo dual para o LBAP (BURKARD; DELL'AMICO; MARTELLO, 2009) 73

17 LBAP usando caminhos aumentantes (BURKARD; DELL'AMICO; MARTELLO, 2009) 75

18 Dijkstra modificado para caminhos aumentantes em LBAP (BURKARD; DELL'AMICO; MARTELLO, 2009) 76

19 Heurísticas gulosas para o LBAP: simples e por arrependimento (MARTELLO; TOTH, 1987) 79

20 Algoritmo de Gale-Shapley para o problema do emparelhamento estável (KLEINBERG; TARDOS, 2005) 83

21 Procedimento MAXMATCH (JUNGNICKEL, 2008) 89

22 Algoritmo de BLOSSOM (JUNGNICKEL, 2008) 90

23 Procedimento CONTRACT (JUNGNICKEL, 2008) 91

24 Procedimento AUGMENT (JUNGNICKEL, 2008) 91

25 Esquema primal-dual do algoritmo de Edmonds ponderado, em alto nível (LAWLER, 1976) 98

26 Algoritmo Path Growing (DRAKE; HOUGARDY, 2003) 101

27 Emparelhamento induzido máximo exato, via conjunto independente máximo em $L(G)^2$ (CAMERON, 1989) 106

28 Heurísticas gulosas aleatória e de grau mínimo para emparelhamento induzido (DUCKWORTH; WORMALD; ZITO, 2002; HALLDóRSSON; RADHAKRISHNAN, 1994) 108

29 Geradores de grafos bipartidos para cardinalidade máxima 114

30 Geradores de matrizes de custo para atribuição linear e gargalo 116

31 Geradores de perfis de preferência para o casamento estável 117

32 Gerador de grafos gerais aleatórios no modelo $G(n, p)$ 118

LISTA DE ABREVIATURAS E SIGLAS

BFS	Busca em largura (*Breadth-First Search*)
DFS	Busca em profundidade (*Depth-First Search*)
FIFO	Primeiro a entrar, primeiro a sair (*First In, First Out*)
LAPJV	Algoritmo de Jonker-Volgenant para o LAP
LBAP	Problema de atribuição gargalo linear (*Linear Bottleneck Assignment Problem*)
LIFO	Último a entrar, primeiro a sair (*Last In, First Out*)
MCBM	Emparelhamento bipartido de cardinalidade máxima (*Maximum Cardinality Bipartite Matching*)
MCM	Emparelhamento de cardinalidade máxima (*Maximum Cardinality Matching*)
MIM	Emparelhamento induzido máximo (*Maximum Induced Matching*)
MIS	Conjunto independente máximo (*Maximum Independent Set*)
MVC	Cobertura mínima de vértices (*Minimum Vertex Cover*)
NP	Tempo polinomial não determinístico (*Nondeterministic Polynomial time*)
P	Tempo polinomial (*Polynomial time*)
PL	Programação linear
QAP	Problema de atribuição quadrática (*Quadratic Assignment Problem*)
SMP	Problema do casamento estável (*Stable Marriage Problem*)
SSP	Caminhos mínimos sucessivos (*Successive Shortest Paths*)

LISTA DE SÍMBOLOS

$G = (V, E)$	Grafo com conjunto de vértices V e conjunto de arestas E
$D = (V, A)$	Grafo direcionado com conjunto de arcos A
$\{u, v\}$	Aresta não direcionada entre os vértices u e v
(u, v)	Arco direcionado de u para v
$G = (U, V; E)$	Grafo bipartido com partes U e V e conjunto de arestas E
$w(e)$	Peso (ou custo) da aresta e
M	Emparelhamento
$\|M\|$	Cardinalidade do emparelhamento M
$\nu(G)$	Cardinalidade máxima de um emparelhamento em G
$M \ominus P$	Diferença simétrica entre os conjuntos de arestas M e P
$\delta(u, v)$	Peso de um caminho mínimo de u a v
$\delta(v)$	Conjunto das arestas incidentes ao vértice v
$E(U)$	Conjunto das arestas com ambos os extremos em $U \subseteq V$
x_e	Variável de decisão associada à aresta e em um modelo de programação linear
y_v, z_B	Variáveis duais associadas ao vértice v e ao conjunto ímpar B
$c(u, v)$	Capacidade do arco (u, v) em uma rede de fluxo
G_f	Rede residual associada ao fluxo f
$c_f(u, v)$	Capacidade residual do arco (u, v)
s, t	Vértices fonte e sorvedouro de uma rede de fluxo
$L(G)$	Grafo de linha de G
$L(G)^2$	Quadrado do grafo de linha de G (grafo de conflitos do emparelhamento induzido)
$G[S]$	Subgrafo de G induzido pelo conjunto de vértices S

$N_H(v)$	Vizinhança do vértice v no grafo H
$O(\cdot)$	Limite assintótico superior
n	Tamanho da instância
k	Expoente empírico de crescimento
R^2	Coeficiente de determinação do ajuste do expoente empírico

SUMÁRIO

1 Introdução 19
1.1 Objetivos 20
1.1.1 Objetivo geral 20
1.1.2 Objetivos específicos 20
1.2 Delimitação do estudo 20
1.3 Organização do trabalho 21
2 Fundamentação teórica 23
2.1 Definições sobre grafos 23
2.1.1 Grafo direcionado 23
2.1.2 Grafo ponderado 24
2.1.3 Grafo bipartido 24
2.2 Busca em grafos 24
2.2.1 Representação computacional 25
2.2.2 Busca em largura 25
2.2.3 Busca em profundidade 25
2.3 Caminhos mais curtos 26
2.3.1 Algoritmo de Dijkstra 26
2.3.2 Algoritmo de Bellman-Ford 28
2.4 Redes de fluxo em grafos 29
2.4.1 Definições básicas 29
2.4.2 O problema do fluxo máximo 29
2.4.2.1 Corte 29
2.4.2.2 Redes residuais 30
2.4.2.3 Caminhos aumentantes em redes de fluxo 30
2.4.3 Fluxo de custo mínimo 32
2.4.3.1 Condições de otimalidade e ciclos negativos 32
2.4.3.2 Potenciais de vértices e custos reduzidos 33
2.5 Problema Geral do Emparelhamento 33
2.5.1 Caminhos alternantes e aumentantes 34
2.5.2 Emparelhamento em grafos bipartidos 35
2.6 Programação linear e dualidade 35
2.6.1 Modelo de programação linear 35
2.6.2 Programação inteira e relaxação linear 37
2.6.3 Dualidade e folga complementar 37
2.7 Métodos exatos, aproximados e heurísticos 38
3 Problemas de emparelhamento em grafos bipartidos 40

3.1 Emparelhamento de cardinalidade máxima 40
3.1.1 Propriedades 40
3.1.1.1 Emparelhamento máximo vs maximal 41
3.1.1.2 Caminhos aumentantes 41
3.1.1.3 Teorema de Kőnig 41
3.1.1.4 Teorema de Hall 42
3.1.1.5 Teorema de Gallai e Conjunto Independente Máximo . . 42
3.1.2 Algoritmos exatos 43
3.1.2.1 Algoritmo do caminho aumentante 43
3.1.2.2 Redução ao problema de fluxo máximo 45
3.1.2.3 Algoritmo de Edmonds-Karp 45
3.1.2.4 Algoritmo de Dinic 48
3.1.2.5 Algoritmo de Hopcroft-Karp 48
3.1.3 Algoritmos aproximados 51
3.1.3.1 Método guloso simples 51
3.1.3.2 Algoritmo de Karp-Sipser 53
3.2 Problema de atribuição (*Assignment Problem*) 55
3.2.1 Formulação como programação linear 56
3.2.2 Algoritmos exatos 58
3.2.2.1 Método Húngaro 58
3.2.2.2 Jonker-Volgenant 61
3.2.2.3 Redução para problema de fluxo de custo mínimo . . . 64
3.2.3 Heurísticas 68
3.2.3.1 Heurística gulosa ordenada 68
3.3 Problema de atribuição gargalo 69
3.3.1 Soluções exatas 70
3.3.1.1 Métodos de *threshold* 70
3.3.1.2 Método dual 72
3.3.1.3 Método de caminhos aumentantes 74
3.3.2 Heurísticas 77
3.3.2.1 Heurística gulosa simples 78
3.3.2.2 Heurística gulosa por arrependimento 78
3.4 Problema do emparelhamento estável 81
3.4.1 Propriedades 82
3.4.2 Algoritmo de Gale-Shapley 82
4 Problemas de emparelhamento em grafos gerais 85
4.1 Emparelhamento de cardinalidade máxima 85
4.1.1 Propriedades 85
4.1.1.1 Ciclos ímpares 85

4.1.1.2 Flor (*blossom*) 86
4.1.2 O algoritmo de Edmonds 86
4.1.2.1 Teorema de Tutte-Berge 92
4.1.3 Algoritmos aproximados 92
4.1.3.1 Algoritmo de crescimento de caminho (Path Growing) . 92
4.2 Emparelhamento ponderado máximo 93
4.2.1 Formulação poliédrica e desigualdades de flor 94
4.2.2 A abordagem primal-dual 96
4.2.3 O algoritmo de Edmonds Ponderado 97
4.2.4 Melhorias 100
4.2.5 Algoritmos aproximados 100
4.2.5.1 Algoritmo de Crescimento de Caminho (Path Growing) . 100
4.3 Emparelhamento induzido máximo 103
4.3.1 Definição 103
4.3.2 Complexidade computacional 104
4.3.3 Redução ao problema do conjunto independente 105
4.3.4 Abordagens de solução e heurísticas 106
4.3.4.1 Algoritmo exato 106
4.3.4.2 Heurísticas gulosas 107
4.3.4.3 Metaheurísticas 109
5 Metodologia 111
5.1 Arquitetura do ambiente de testes 111
5.2 Interface padrão dos problemas 111
5.3 Geradores de instância 112
5.3.1 Grafos bipartidos 113
5.3.2 Matrizes de custo 115
5.3.3 Perfis de preferência 117
5.3.4 Grafos gerais aleatórios 118
5.4 Protocolo de medição 119
5.5 Critérios de comparação 120
5.6 Ambiente de execução e reprodutibilidade 121
5.7 Origem, adaptação e verificação dos algoritmos 122
6 Resultados e discussão 125
6.1 Leitura das tabelas 125
6.2 Cardinalidade máxima em grafos bipartidos 126
6.3 Atribuição linear 129
6.4 Atribuição gargalo 131
6.5 Casamento estável 134
6.6 Emparelhamento em grafos gerais 136

6.7 Emparelhamento induzido máximo 138
6.8 Defeitos em implementações públicas 140
6.9 Crescimento empírico frente à complexidade teórica 141
7 Conclusões e trabalhos futuros 145
7.1 Objetivos alcançados 145
7.2 Principais resultados 146
7.3 Dificuldades encontradas 147
7.4 Trabalhos futuros 147

Referências 150

1 INTRODUÇÃO

Na teoria dos grafos e otimização combinatória, um emparelhamento em um grafo não-dirigido $G = (V, E)$ é definido formalmente como um subconjunto de arestas $M \subseteq E$ tal que nenhuma aresta em M compartilhe um vértice comum. Em termos precisos, para todo vértice $v \in V$, o grau de v no subgrafo induzido por M é no máximo 1. Esta definição fundamental é apresentada por Lovász e Plummer (1986) em sua obra seminal sobre a teoria dos emparelhamentos, onde também se estabelece a distinção clássica entre emparelhamentos em grafos bipartidos, cujos vértices podem ser divididos em dois conjuntos disjuntos U e V, e aqueles em grafos gerais.

Os problemas de emparelhamento têm aplicações significativas em várias áreas. Na biologia computacional, estruturas proteicas podem ser comparadas e classificadas emparelhando os elementos de estrutura secundária de duas proteínas, com o algoritmo do casamento estável ou com o método Húngaro (TAYLOR, 2002). Na alocação de residentes médicos a hospitais, o programa nacional de residência dos Estados Unidos usa um procedimento semelhante ao do casamento estável (KLEINBERG; TARDOS, 2005). O problema de atribuição modela a alocação de pessoas a tarefas e a designação de locomotivas a trens (BURKARD; DELL'AMICO; MARTELLO, 2009), o emparelhamento induzido modela a escolha de canais de comunicação seguros entre transmissores e receptores (GOLUMBIC; LEWENSTEIN, 2000), e emparelhamentos de peso máximo são usados em álgebra linear numérica e em algoritmos multinível sobre grafos (MANDULAK et al., 2024).

É crucial, no entanto, fazer uma distinção precisa quanto à complexidade computacional desses problemas. Ao contrário do que uma análise superficial poderia sugerir, o problema de encontrar um emparelhamento de cardinalidade ou peso máximo pertence à classe de complexidade **P** (tempo polinomial), sendo solúvel por algoritmos clássicos como o Método Húngaro ou o Algoritmo de *Blossom* de Edmonds (SCHRIJVER, 2004). O verdadeiro desafio computacional, frequentemente classificado como **NP-difícil**, surge em variações estruturais mais complexas, como o Emparelhamento Tridimensional ou o Problema da Atribuição Quadrática (QAP). Segundo Garey e Johnson (1990) e Burkard, Dell'Amico e Martello (2009), o QAP modela situações onde o custo depende da interação entre os pares escolhidos, tornando métodos exatos inviáveis para grandes instâncias e exigindo o uso de relaxações ou heurísticas avançadas.

Diante desse cenário, este trabalho visa sistematizar os principais problemas e métodos computacionais associados ao emparelhamento em grafos. Ele busca oferecer uma comparação detalhada entre suas aplicações e limitações, contribuindo para o

entendimento aprofundado dos algoritmos disponíveis e identificando oportunidades para o desenvolvimento de novas soluções. Essa abordagem torna-se ainda mais relevante à luz da importância prática desses algoritmos para resolver problemas reais em grande escala, conforme evidenciado por estudos recentes (MANDULAK et al., 2024).

1.1 OBJETIVOS

Os objetivos deste trabalho dividem-se em um objetivo geral, que expressa o propósito do estudo como um todo, e em objetivos específicos, que o decompõem nas etapas necessárias para alcançá-lo.

1.1.1 Objetivo geral

Este trabalho tem como objetivo principal levantar e organizar os principais problemas de emparelhamento em grafos e os métodos computacionais presentes na literatura para resolvê-los, implementando esses métodos e comparando-os experimentalmente quanto ao desempenho e à qualidade das soluções.

1.1.2 Objetivos específicos

a) mapear as variações e características dos principais problemas de emparelhamento em grafos presentes na literatura;

b) classificar esses problemas e os métodos computacionais que os resolvem, segundo critérios como a estrutura do grafo, o objetivo de otimização e o tipo de método (exato, aproximado ou heurístico);

c) implementar os algoritmos selecionados, adaptando implementações públicas ou, quando não houver implementação adequada, partindo da descrição bibliográfica;

d) criar um ambiente de testes unificado e, nele, comparar os algoritmos quanto ao tempo de execução, à complexidade assintótica de tempo e espaço e à qualidade das soluções encontradas;

e) organizar os resultados em um formato que facilite o acesso e a compreensão dos tópicos abordados por pesquisadores e profissionais.

1.2 DELIMITAÇÃO DO ESTUDO

Os problemas de emparelhamento em grafos podem ser classificados de diversas maneiras, como sendo em grafos bipartidos ou não-bipartidos, ponderados ou

não-ponderados, direcionados ou não-direcionados, problemas em multigrafos, problemas em hipergrafos, entre outros. Este trabalho focará em problemas que envolvem grafos menos complexos, excluindo multigrafos e hipergrafos. Também ficam fora do escopo outras variações do emparelhamento em grafos gerais, como o b-emparelhamento, o emparelhamento em matroides e o problema dos colegas de quarto estáveis (*Stable Roommates Problem*). Por fim, não são tratados os problemas de correspondência entre dois grafos.

Em visão computacional, o termo *graph matching* designa a busca de uma correspondência entre os vértices de dois grafos que preserve ao máximo seus atributos e suas relações (CAETANO et al., 2009), e não a escolha de um subconjunto de arestas de um único grafo, como nos problemas deste trabalho. Esse problema é formulado como um problema de atribuição quadrática: o ganho de associar um vértice de um grafo a um vértice do outro depende também das demais associações escolhidas, pois mede quantas relações entre os vértices são preservadas. Sem esse termo quadrático, resta o problema de atribuição linear (Seção 3.2), que tem solução em tempo polinomial; com ele, o problema se torna NP-difícil (CAETANO et al., 2009; BURKARD; DELL'AMICO; MARTELLO, 2009). Por isso, ele fica fora do escopo deste trabalho, em que o custo de cada associação nunca depende das demais.

1.3 ORGANIZAÇÃO DO TRABALHO

O restante deste trabalho está organizado da seguinte forma:

a) **capítulo 2:** apresenta a fundamentação teórica: definições sobre grafos, algoritmos de busca e de caminhos mais curtos, redes de fluxo, o problema geral do emparelhamento, programação linear e dualidade, e a classificação dos métodos em exatos, aproximados e heurísticos;

b) **capítulo 3:** descreve os problemas de emparelhamento em grafos bipartidos (cardinalidade máxima, atribuição, atribuição gargalo e emparelhamento estável), com suas propriedades, seus algoritmos em pseudocódigo e uma tabela-resumo por problema;

c) **capítulo 4:** faz o mesmo para os problemas em grafos gerais (cardinalidade máxima, peso máximo e emparelhamento induzido máximo);

d) **capítulo 5:** descreve o ambiente de testes construído para comparar os algoritmos: arquitetura, interface padrão, geradores de instâncias, protocolo de medição, critérios de comparação e origem de cada implementação;

e) **capítulo 6:** apresenta e discute os resultados obtidos no ambiente de testes, quanto ao tempo de execução, à qualidade das soluções e ao crescimento empírico frente à complexidade teórica;

f) **capítulo 7:** retoma os objetivos, resume os principais resultados e as dificuldades encontradas e aponta os trabalhos futuros.

2 FUNDAMENTAÇÃO TEÓRICA

Este capítulo reúne os conceitos de teoria dos grafos e de otimização combinatória sobre os quais os capítulos seguintes se apoiam. Inicia-se pelas definições básicas sobre grafos e suas variações (direcionados, ponderados e bipartidos). Em seguida, apresentam-se os algoritmos de busca em largura e em profundidade, usados pelos algoritmos de emparelhamento para encontrar caminhos aumentantes; os algoritmos de caminhos mais curtos, usados nas reduções do problema de atribuição a fluxo de custo mínimo; e as redes de fluxo, por meio das quais o emparelhamento bipartido pode ser resolvido. Em seguida, define-se o problema geral do emparelhamento e resumem-se as noções de programação linear e dualidade em que se apoiam os algoritmos primal-duais. Por fim, apresenta-se a classificação dos métodos de solução em exatos, aproximados e heurísticos, usada ao longo do trabalho.

2.1 DEFINIÇÕES SOBRE GRAFOS

Um **grafo** G é uma estrutura definida por um par $G = (V, E)$, consistindo de um conjunto finito V de elementos chamados **vértices** (ou **nós** ou **pontos**) e um conjunto (ou família) E de pares não ordenados de vértices, chamados de **arestas** (JUNGNICKEL, 2008). O conjunto V é o conjunto de vértices de G e E é a família de arestas de G.

Neste trabalho, assume-se que as arestas $e = \{u, v\}$ são pares não ordenados de vértices distintos. A notação de par ordenado (u, v) fica reservada aos arcos de grafos direcionados (Seção 2.1.1). Se uma aresta e conecta os vértices a e b, diz-se que a e b são **adjacentes** ou **vizinhos**, e que a aresta e é **incidente** a a e b (SCHRIJVER, 2004).

O conceito de grafo é amplamente utilizado como uma representação abstrata concisa para estruturas complexas e para codificar relações binárias entre um conjunto de objetos.

2.1.1 Grafo direcionado

Se as relações entre os vértices forem assimétricas, utiliza-se um **grafo direcionado** ou **dígrafo**, $D = (V, A)$. Neste caso, A é uma família de pares ordenados de vértices, chamados **arcos** (ou arestas direcionadas). Para um arco $e = (u, v)$, u é chamado o vértice inicial ou **cauda** (*tail*), e v é o vértice final ou **cabeça** (*head*) (MANBER, 1989)

2.1.2 Grafo ponderado

Um grafo $G = (V, E)$ é chamado **grafo ponderado** (ou com pesos) se uma **função de peso** (ou função de custo, ou função de comprimento) $w : E \to R$ está associada às arestas. Formalmente: $G = (V, E, w)$, onde $w : E \to R$. Geralmente, o peso $w(e)$ de uma aresta e é um valor real não negativo que representa o custo, comprimento ou capacidade associada àquela aresta (ROSEN; KREHER; STINSON, 1998).

Grafos ponderados podem ser representados por matrizes de adjacência de valor real A, onde a entrada A_{ij} é o peso w_{ij} da aresta (ZASLAVSKIY; BACH; VERT, 2009).

2.1.3 Grafo bipartido

Um grafo bipartido é um grafo não direcionado que pode ser facilmente colorido com apenas duas cores (MANBER, 1989).

Formalmente, um grafo é chamado **grafo bipartido** se o seu conjunto de vértices puder ser particionado em dois subconjuntos disjuntos U e V, chamados **partes** (ou classes de cor), de modo que todas as arestas conectam um vértice de U a um vértice de V. Ou seja, não existem arestas que conectem vértices dentro da mesma parte (DASGUPTA; VAZIRANI, 2006). Escreve-se, então,

$$G = (U, V; E), \quad \text{com} \quad U \cap V = \emptyset \quad \text{e} \quad E \subseteq \{\{u, v\} : u \in U,\, v \in V\}. \tag{2.1}$$

Essa é a notação de Burkard, Dell'Amico e Martello (2009), usada em todo o trabalho para grafos bipartidos. Nela, V denota apenas uma das partes; nas expressões de complexidade, porém, V continua denotando o número total de vértices do grafo, como em $O(E\sqrt{V})$. Nos problemas de atribuição, em que o grafo é representado por uma matriz de custos, U corresponde às linhas (por exemplo, trabalhadores) e V às colunas (por exemplo, tarefas).

Observações:

a) um grafo é bipartido se e somente se não contém ciclos de comprimento ímpar (SCHRIJVER, 2004);

b) o grafo bipartido completo $K_{m,n}$ possui m vértices em U e n vértices em V, e contém todas as arestas possíveis entre U e V (JUNGNICKEL, 2008).

2.2 BUSCA EM GRAFOS

A busca em grafos consiste em seguir as arestas do grafo para visitar os vértices, permitindo descobrir a estrutura da rede e propriedades de conectividade (CORMEN et

al., 2009). Neste trabalho, a busca em largura e a busca em profundidade são as sub-rotinas com que os algoritmos de emparelhamento procuram caminhos aumentantes: o algoritmo de caminhos aumentantes (Algoritmo 4), o de Edmonds-Karp (Algoritmo 5), o de Hopcroft-Karp (Algoritmos 6 e 7) e o Blossom (Algoritmo 21).

2.2.1 Representação computacional

A complexidade das buscas depende de como o grafo $G = (V, E)$ é representado (AHO; HOPCROFT; ULLMAN, 1974). Na **matriz de adjacência**, uma matriz A de dimensão $|V| \times |V|$ tem $A_{ij} = 1$ se existe uma aresta $\{i, j\} \in E$, e 0 caso contrário; verificar a existência de uma aresta custa $O(1)$, mas o espaço é $\Theta(V^2)$, o que a torna ineficiente para grafos esparsos. Na **lista de adjacência**, cada vértice u tem uma lista $Adj[u]$ com todos os vértices v tais que $\{u, v\} \in E$, e o espaço é $\Theta(V + E)$ (CORMEN et al., 2009). Os algoritmos de busca descritos a seguir assumem listas de adjacência, o que torna sua complexidade linear no tamanho do grafo.

2.2.2 Busca em largura

A **busca em largura**, ou *Breadth-First Search* (BFS), explora o grafo em camadas: dado um vértice fonte s, visita primeiro todos os vizinhos de s (camada L_1), depois os vizinhos desses vizinhos (camada L_2), e assim sucessivamente (KLEINBERG; TARDOS, 2005). Para isso, guarda a fronteira de exploração em uma fila (FIFO). Como consequência, a BFS calcula o caminho mais curto, em número de arestas, de s a todos os vértices alcançáveis (DASGUPTA; VAZIRANI, 2006), propriedade usada pelos algoritmos de Edmonds-Karp e de Hopcroft-Karp para encontrar os caminhos aumentantes mais curtos. Sua complexidade é $O(V + E)$, pois cada vértice entra na fila no máximo uma vez e cada lista de adjacência é percorrida uma única vez (CORMEN et al., 2009).

2.2.3 Busca em profundidade

A **busca em profundidade**, ou *Depth-First Search* (DFS), explora a cada passo as arestas do vértice descoberto mais recentemente que ainda tenha arestas inexploradas: aprofunda-se no grafo tanto quanto possível e, quando não há mais para onde ir, retrocede (*backtracking*) para explorar outros caminhos (MANBER, 1989). Pode ser implementada de forma recursiva ou com uma pilha (LIFO). É a estratégia do algoritmo de caminhos aumentantes e da segunda fase do Hopcroft-Karp, que seguem um caminho até o fim antes de tentar outro. Assim como a BFS, tem complexidade $\Theta(V + E)$ com listas de adjacência (CORMEN et al., 2009).

2.3 CAMINHOS MAIS CURTOS

O problema de encontrar o caminho mais curto entre dois vértices em um grafo é um dos problemas de otimização combinatória mais estudados, servindo como sub-rotina para diversas aplicações, incluindo roteamento de redes e algoritmos de fluxo. Neste trabalho, os caminhos mais curtos aparecem na solução do problema de atribuição por fluxo de custo mínimo: o algoritmo de caminhos mínimos sucessivos (Algoritmo 13) busca, a cada iteração, um caminho de custo mínimo na rede residual, com o algoritmo de Dijkstra sobre custos reduzidos (Algoritmo 14) ou com o de Bellman-Ford, quando há custos negativos. O algoritmo de Dijkstra é também a base do procedimento de caminhos aumentantes do problema de atribuição gargalo (Algoritmo 18).

Seja $G = (V, E)$ um grafo ponderado com uma função de peso $w : E \to \mathbb{R}$. O peso de um caminho $p = \langle v_0, v_1 \ldots, v_k \rangle$ é a soma dos pesos de suas arestas constituintes: $w(p) = \sum_{i=1}^{k} w(v_{i-1}, v_i)$. O **caminho mais curto** de um vértice u a um vértice v é definido como qualquer caminho p com peso mínimo $\delta(u, v)$ (CORMEN et al., 2009).

2.3.1 Algoritmo de Dijkstra

Os algoritmos de caminho mínimo baseiam-se na propriedade de **subestrutura ótima**, segundo a qual subcaminhos de um caminho mais curto são, por si mesmos, caminhos mais curtos, e na técnica de **relaxamento** (KLEINBERG; TARDOS, 2005). Para cada vértice v, mantém-se uma estimativa $v.d$, que é um limite superior para o peso do caminho mais curto da fonte s até v, e um predecessor $v.\pi$. Relaxar um arco (u, v) consiste em testar se o caminho até u seguido do arco (u, v) melhora a estimativa de v e, se melhorar, atualizá-la:

$$\text{se } v.d > u.d + w(u, v), \text{ então } v.d \leftarrow u.d + w(u, v) \text{ e } v.\pi \leftarrow u \tag{2.2}$$

Nos pseudocódigos a seguir, essa operação aparece como Relaxa(u, v, w) e custa $O(1)$. Seguindo os predecessores a partir de um vértice qualquer até a fonte, obtém-se o caminho mais curto encontrado até o momento. Os algoritmos de Dijkstra e de Bellman-Ford diferem apenas na ordem e na frequência com que relaxam os arcos (CORMEN et al., 2009).

Para grafos onde os pesos das arestas são não-negativos ($w(u, v) \geq 0$), o Algoritmo de Dijkstra é a abordagem mais eficiente. Ele utiliza uma estratégia gulosa, mantendo um conjunto de vértices cujos pesos finais dos caminhos mais curtos já foram determinados (AHO; HOPCROFT; ULLMAN, 1974).

O algoritmo seleciona repetidamente o vértice u com a menor estimativa de caminho mais curto $d[u]$ de uma fila de prioridade, adiciona-o ao conjunto de visitados e relaxa todas as arestas que saem de u. Dasgupta e Vazirani (2006) destacam que a eficiência do Dijkstra depende da estrutura de dados utilizada. Com um *heap* binário, a complexidade é $O((V + E) \log V)$. Cormen et al. (2009) apontam que, ao utilizar um *heap* de Fibonacci, a complexidade amortizada pode ser reduzida para $O(E + V \log V)$, o que é crucial para grafos densos. As duas complexidades são justificadas ao final da explicação do Algoritmo 1.

Algoritmo 1: Algoritmo de Dijkstra (CORMEN et al., 2009)

```
(1)  Procedimento Dijkstra(G, w, s)
(2)      Inicializa-Fonte(G, s)
(3)      S ← ∅
(4)      Q ← G.V
(5)      enquanto Q ≠ ∅ faça
(6)          u ← Extrai-Mínimo(Q)
(7)          S ← S ∪ {u}
(8)          para cada vértice v ∈ G.Adj[u] faça
(9)              Relaxa(u, v, w)
(10)         fim
(11)     fim
```

O Algoritmo 1 funciona da seguinte forma (CORMEN et al., 2009):

a) **inicialização (linhas 2–4):** Inicializa-Fonte atribui $v.d = \infty$ e $v.\pi =$ NIL a todo vértice, e $s.d = 0$ à fonte. O conjunto S dos vértices com distância final já determinada começa vazio, e a fila de prioridade Q, ordenada pelo atributo d, começa com todos os vértices;

b) **escolha gulosa (linhas 5–7):** a cada iteração, retira-se de Q o vértice u de menor estimativa $u.d$ e ele é incluído em S. Como os pesos são não-negativos, nenhum caminho que passe por outro vértice de Q pode chegar a u com peso menor, e por isso $u.d = \delta(s, u)$ nesse momento;

c) **relaxamento (linhas 8–9):** todos os arcos que saem de u são relaxados (Equação 2.2), o que pode diminuir a estimativa dos vizinhos de u ainda em Q e, com isso, alterar suas posições na fila;

d) **complexidade:** cada vértice é retirado de Q exatamente uma vez, totalizando V operações Extrai-Mínimo, e cada arco é relaxado exatamente uma vez, quando sua origem é retirada, totalizando até E diminuições de chave na fila. Com um *heap* binário, as duas operações custam $O(\log V)$, o que resulta em $O((V + E) \log V)$. Com um *heap* de Fibonacci, a diminuição de chave custa $O(1)$ amortizado, o que resulta em $O(E + V \log V)$.

2.3.2 Algoritmo de Bellman-Ford

Quando o grafo contém arestas com pesos negativos, o algoritmo de Dijkstra não garante a corretude. Nesses casos, utiliza-se o Algoritmo de Bellman-Ford. Segundo Manber (1989), este algoritmo baseia-se em programação dinâmica, relaxando todas as arestas do grafo $|V| - 1$ vezes.

A propriedade fundamental do Bellman-Ford é sua capacidade de detectar ciclos negativos. Se, após $|V| - 1$ iterações, ainda for possível relaxar alguma aresta, o grafo contém um ciclo com peso total negativo acessível a partir da fonte, o que implica que $\delta(s, v) = -\infty$ para alguns vértices (KLEINBERG; TARDOS, 2005). Sua complexidade é $O(VE)$.

Algoritmo 2: Algoritmo de Bellman-Ford (CORMEN et al., 2009)

```
(1)  Procedimento Bellman-Ford(G, w, s)
(2)      Inicializa-Fonte(G, s)
(3)      para i = 1 até |G.V| − 1 faça
(4)          para cada arco (u, v) ∈ G.E faça
(5)              Relaxa(u, v, w)
(6)          fim
(7)      fim
(8)      para cada arco (u, v) ∈ G.E faça
(9)          se v.d > u.d + w(u, v) então
(10)             retorne falso
(11)         fim
(12)     fim
(13)     retorne verdadeiro
```

O Algoritmo 2 funciona da seguinte forma (CORMEN et al., 2009):

a) **inicialização (linha 2):** igual à do algoritmo de Dijkstra: $s.d = 0$ e $v.d = \infty$ para os demais vértices;

b) **relaxamentos (linhas 3–5):** todos os arcos são relaxados, em qualquer ordem, $|V| - 1$ vezes. Após a i-ésima passagem, todo vértice cujo caminho mais curto a partir de s tem no máximo i arcos já tem sua distância correta. Como um caminho mais curto sem ciclos tem no máximo $|V|-1$ arcos, $|V|-1$ passagens bastam quando não há ciclo negativo;

c) **detecção de ciclo negativo (linhas 8–10):** uma passagem extra verifica se algum arco ainda pode ser relaxado. Se puder, existe um ciclo de peso negativo alcançável a partir de s, e o algoritmo retorna **falso**;

d) **retorno (linha 13):** caso contrário, retorna **verdadeiro**, e os atributos $v.d$ e $v.\pi$ descrevem os caminhos mais curtos;

e) **complexidade:** a inicialização custa $O(V)$; o laço principal faz $|V| - 1$ passagens por todos os E arcos, com relaxamento de custo $O(1)$, totalizando

$O(VE)$; a verificação final custa $O(E)$. O total é $O(VE)$.

2.4 REDES DE FLUXO EM GRAFOS

A teoria dos fluxos em redes modela o transporte de recursos através de uma rede. Esta seção define os conceitos preliminares e apresenta os teoremas centrais que sustentam os algoritmos utilizados neste trabalho. Neste trabalho, as redes de fluxo fundamentam duas reduções: a do emparelhamento bipartido de cardinalidade máxima a um problema de fluxo máximo, resolvido pelo algoritmo de Edmonds-Karp (Algoritmo 5), e a do problema de atribuição a um problema de fluxo de custo mínimo (Seção 3.2.2.3).

2.4.1 Definições básicas

Uma rede de fluxo é definida por um grafo direcionado $G = (V, E)$, onde V é o conjunto de vértices e E é o conjunto de arestas. Distinguem-se dois vértices especiais: a **fonte** $s \in V$. que produz o fluxo, e o **sorvedouro** $t \in V$, que o consome. Para cada aresta $(u, v) \in E$, associa-se uma capacidade não-negativa $c(u, v) \geq 0$, que limita a quantidade de fluxo que pode atravessar aquela aresta. Um **fluxo** em G é uma função $f : E \to \mathbb{R}^+$ que satisfaz as seguintes propriedades (CORMEN et al., 2009):

a) **restrição de capacidade:** o fluxo em uma aresta não pode exceder a sua capacidade:

$$0 \leq f(u, v) \leq c(u, v), \qquad \forall (u, v) \in E; \tag{2.3}$$

b) **conservação de fluxo:** para todo vértice $v \in V - \{s, t\}$, a quantidade total de fluxo que entra deve ser igual à que sai:

$$\sum_{v \in V} f(v, u) = \sum_{v \in V} f(u, v). \tag{2.4}$$

2.4.2 O problema do fluxo máximo

O **problema do fluxo máximo** consiste em encontrar um fluxo f tal que $|f|$ seja o maior possível. Para entender a limitação desse fluxo, é preciso entender os conceitos de corte, redes residuais e caminhos aumentantes.

2.4.2.1 Corte

Um **corte** (S, T) é uma partição do conjunto de vértices V em dois subconjuntos disjuntos S e T, tal que $s \in S$ e $t \in T$. A **capacidade do corte**, denotada por $c(S, T)$, é a soma das capacidades das arestas que partem de S para T (CORMEN et al., 2009):

$$c(S,T) = \sum_{u \in S, v \in T} c(u,v) \tag{2.5}$$

O **corte mínimo** de uma rede N é um corte cuja capacidade é a menor entre todos os cortes possíveis nessa rede (CORMEN et al., 2009). Daí decorre o **teorema do fluxo máximo e corte mínimo (*max-flow min-cut*)**

> *O valor máximo do fluxo de uma rede N é igual à capacidade do corte mínimo em N (JUNGNICKEL, 2008)*

Os algoritmos de caminhos aumentantes usam este teorema para provar que o fluxo final é máximo.

2.4.2.2 Redes residuais

A maioria dos algoritmos de resolução de problemas de fluxo máximo se baseia no conceito de redes residuais. Uma **rede residual** G_f consiste em arestas com capacidades que representam como se pode alterar o fluxo das arestas em G. A capacidade das arestas da rede residual G_f corresponde à diferença entre a capacidade da aresta original de G e o fluxo f que está passando pela aresta (CORMEN et al., 2009). Ou seja:

$$c_f(u,v) = c(u,v) - f(u,v) \tag{2.6}$$

Quando a aresta (u,v) possui fluxo igual à sua capacidade, então $c_f(u,v) = 0$ e a aresta não é incluída no grafo residual G_f

2.4.2.3 Caminhos aumentantes em redes de fluxo

Dado um grafo $G = (V,E)$ e um fluxo f, um **caminho aumentante** é um caminho de s para t na rede residual G_f. Por definição, pode-se aumentar o fluxo em uma aresta (u,v) de um caminho aumentante em até $c_f(u,v)$ sem violar a capacidade da aresta original em G (CORMEN et al., 2009). Esse conceito é diferente do caminho aumentante de um emparelhamento (Seção 2.5.1): aqui, trata-se de um caminho de s a t na rede residual, ao longo do qual o fluxo pode ser aumentado. Os dois se encontram na redução do emparelhamento bipartido a fluxo máximo (Seção 3.1.2.2), em que cada caminho aumentante de fluxo corresponde a um caminho aumentante do emparelhamento, acrescido dos arcos que saem de s e chegam a t.

O método de Ford-Fulkerson, que é base dos principais algoritmos de resolução do problema do fluxo máximo, iterativamente encontra um caminho aumentante, calcula

sua capacidade residual e adiciona esse fluxo à solução atual até que não existam mais caminhos aumentantes (AHUJA; MAGNANTI; ORLIN, 1993).

Algoritmo 3: Algoritmo de Ford-Fulkerson (CORMEN et al., 2009)

```
(1)  Procedimento FORD-FULKERSON(G, s, t)
(2)      para cada arco (u, v) ∈ G.E faça
(3)          (u, v).f ← 0
(4)      fim
(5)      enquanto existe um caminho p de s a t na rede residual G_f faça
(6)          c_f(p) ← min{c_f(u, v) : (u, v) está em p}
(7)          para cada arco (u, v) ∈ p faça
(8)              se (u, v) ∈ E então
(9)                  (u, v).f ← (u, v).f + c_f(p)
(10)             senão
(11)                 (v, u).f ← (v, u).f − c_f(p)
(12)             fim
(13)         fim
(14)     fim
```

O Algoritmo 3 funciona da seguinte forma (CORMEN et al., 2009):

a) **inicialização (linhas 2–3):** o fluxo começa nulo em todos os arcos, o que satisfaz trivialmente a restrição de capacidade e a conservação de fluxo;

b) **busca de caminho aumentante (linha 5):** enquanto houver um caminho p de s a t na rede residual G_f, o fluxo atual não é máximo. O método não especifica como o caminho é encontrado; qualquer busca, como BFS ou DFS, serve;

c) **capacidade residual do caminho (linha 6):** $c_f(p)$ é a menor capacidade residual entre os arcos de p, ou seja, o máximo de fluxo que se pode enviar por p sem violar nenhuma capacidade;

d) **aumento (linhas 7–11):** para cada arco de p, se ele pertence à rede original (linha 8), o fluxo nele aumenta em $c_f(p)$ (linha 9); caso contrário, ele é um arco reverso da rede residual, e enviar fluxo por ele equivale a cancelar fluxo do arco original (v, u) (linha 11). Em ambos os casos, o valor $|f|$ do fluxo aumenta em $c_f(p)$;

e) **complexidade:** com capacidades inteiras, cada iteração aumenta $|f|$ em pelo menos uma unidade, de modo que há no máximo $|f^*|$ iterações, em que f^* é o fluxo máximo. Cada iteração encontra o caminho e atualiza o fluxo em $O(E)$, o que resulta em $O(E \cdot |f^*|)$. Quando o caminho é sempre o mais curto em número de arcos, encontrado por BFS, obtém-se o algoritmo de Edmonds-Karp (Algoritmo 5), com complexidade $O(VE^2)$, independente das capacidades.

2.4.3 Fluxo de custo mínimo

Uma outra variação dos problemas em redes de fluxo em grafos é o problema do fluxo de custo mínimo. Essa variação considera, além das capacidades disponíveis, uma dimensão econômica. Seja $G = (V, E)$ uma rede direcionada onde cada aresta (u, v) possui uma capacidade $c(u, v)$ e um custo unitário $w(u, v)$. O objetivo é transmitir uma quantidade de fluxo pré-determinada F da fonte s ao sorvedouro t com o menor custo total possível.

A formulação linear do problema é dada por Ahuja, Magnanti e Orlin (1993). O primeiro objetivo é minimizar o custo total do fluxo, que segue a fórmula:

$$\text{Minimizar o custo do fluxo:} \quad z(f) = \sum_{(u,v)\in A} w(u, v) \cdot f(u, v) \tag{2.7}$$

A função a seguir assegura que o nó fonte s gere exatamente a demanda F, e que o nó sorvedouro t absorva-a integralmente.

$$\sum_{i,j\in V} f(i, j) - \sum_{k,i\in V} f(k, i) = \begin{cases} F & \text{se } i = s \\ -F & \text{se } j = t \\ 0 & \text{caso contrário} \end{cases} \tag{2.8}$$

Além desta, é importante lembrar da equação 2.3, que define que o fluxo em uma aresta não pode exceder a sua capacidade.

2.4.3.1 Condições de otimalidade e ciclos negativos

O critério fundamental para verificar se uma solução é ótima é o **teorema dos ciclos negativos**:

> Um fluxo f é uma solução viável para o problema do fluxo de custo mínimo se e somente se ele satisfaz a condição de otimalidade de ciclo negativo: a rede residual $G(f)$ não contém um ciclo de custo negativo (AHUJA; MAGNANTI; ORLIN, 1993)

Este teorema é a base dos algoritmos de **cancelamento de ciclos** (*cycle canceling*), que iterativamente identificam ciclos negativos na rede residual e enviam fluxo através deles para reduzir o custo total da função objetivo até que nenhum ciclo negativo reste.

2.4.3.2 Potenciais de vértices e custos reduzidos

Embora o cancelamento de ciclos seja teoricamente sólido, a detecção de ciclos negativos (via Bellman-Ford) pode ser computacionalmente custosa. Para permitir o uso de algoritmos mais eficientes como o de Dijkstra, a literatura introduz o conceito de **potenciais de vértices**, baseando-se na teoria de dualidade da programação linear (Seção 2.6): os potenciais são as variáveis duais associadas aos vértices.

A ideia é manter um **potencial** para cada vértice v do grafo, chamado de $h(v)$, com valor inicial 0. Define-se o **custo reduzido** de uma aresta (u, v) como $\bar{w}(u, v) = w(u, v) + h(u) - h(v)$. Se os potenciais forem escolhidos de forma adequada, todos os custos reduzidos podem ser garantidos como não-negativos, permitindo o uso do algoritmo de Dijkstra. Além disso, é garantido que os caminhos de custo mínimo no grafo original e no grafo com custos reduzidos são os mesmos. (JUNGNICKEL, 2008).

O conceito de potenciais e de custo reduzido será utilizado em algoritmos como o de caminhos sucessivos para resolução do problema de atribuição na seção 3.2.2.3.

2.5 PROBLEMA GERAL DO EMPARELHAMENTO

Esta seção define o emparelhamento e os conceitos associados a ele, usados em todo o restante do trabalho, e apresenta o caso bipartido, e sua versão ponderada, o problema de atribuição.

Um **emparelhamento** (*matching*) M em um grafo não-direcionado $G = (V, E)$ é um subconjunto de arestas $M \subseteq E$ tal que nenhum par de arestas em M compartilha um vértice comum (KLEINBERG; TARDOS, 2005). Em outras palavras, cada nó aparece em no máximo uma aresta de M. A **cardinalidade** de um emparelhamento M é a quantidade de arestas contidas dentro dele, e um dos problemas que serão mostrados posteriormente trata de encontrar o **emparelhamento de cardinalidade máxima** (*maximum matching*) de um grafo G, que é o emparelhamento M com o maior número possível de arestas (CORMEN et al., 2009). A cardinalidade máxima de um emparelhamento de um grafo G é denotada por $\nu(G)$ (SCHRIJVER, 2004).

Um vértice é chamado **coberto** (*matched*) se for incidente a uma aresta em M; caso contrário, é **descoberto** (*unmatched* ou *exposed*) (CORMEN et al., 2009). Um **emparelhamento perfeito** é um emparelhamento em que todos os vértices do grafo estão cobertos (KLEINBERG; TARDOS, 2005).

O **problema de emparelhamento ponderado** (*weighted matching problem*) envolve encontrar um emparelhamento para o qual a soma dos pesos das arestas é máxima. Em um grafo ponderado $G = (V, E, w)$, busca-se um $M \subseteq E$ que maximize $w(M)$ (MANDULAK et al., 2024).

2.5.1 Caminhos alternantes e aumentantes

Os algoritmos exatos de emparelhamento de cardinalidade máxima apresentados neste trabalho se apoiam em dois tipos de caminho, definidos em relação a um emparelhamento M (SCHRIJVER, 2004):

a) **caminho M-alternante:** caminho cujas arestas pertencem alternadamente a $E \setminus M$ e a M;

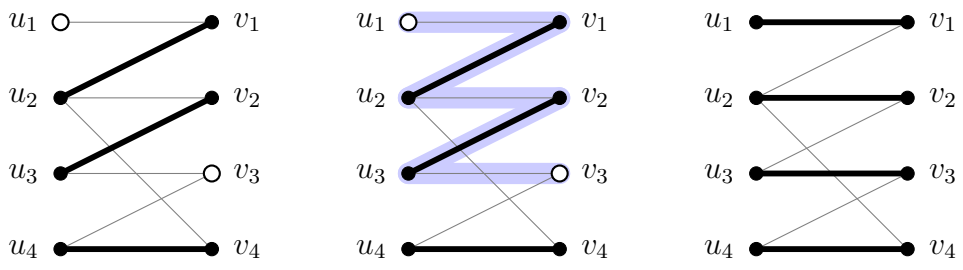
b) **caminho M-aumentante:** caminho M-alternante que começa e termina em vértices descobertos distintos. Como os dois extremos são descobertos, a primeira e a última aresta não pertencem a M; logo, o caminho tem um número ímpar $2k + 1$ de arestas, das quais k estão em M e $k + 1$ estão fora dele.

A utilidade dos caminhos aumentantes vem da **diferença simétrica**. Dado um caminho M-aumentante P, visto como um conjunto de arestas, o conjunto

$$M \ominus P = (M \setminus P) \cup (P \setminus M) \tag{2.9}$$

é obtido invertendo o papel das arestas de P: as que estavam em M saem, e as que estavam fora entram. O resultado continua sendo um emparelhamento, pois cada vértice interno de P troca uma aresta emparelhada por outra, e os dois extremos, antes descobertos, passam a ser cobertos. Como P tem uma aresta a mais fora de M do que dentro, $|M \ominus P| = |M| + 1$. A Figura 1 ilustra a operação em um grafo bipartido.

Figura 1 – Um emparelhamento M, um caminho M-aumentante P e o emparelhamento $M \ominus P$



(a) emparelhamento M $|M| = 3$ (b) caminho M-aumentante P (c) $M \ominus P$ $|M \ominus P| = 4$

Fonte: Elaborado pelo autor. Arestas grossas pertencem ao emparelhamento; vértices vazados estão descobertos; em (b), o caminho P aparece destacado.

Essa operação fundamenta o **lema de Berge**, base dos algoritmos exatos de emparelhamento de cardinalidade máxima deste trabalho (JUNGNICKEL, 2008):

> Um emparelhamento M em um grafo G é máximo se, e somente se, não existe caminho M-aumentante em G.

Uma das direções segue da diferença simétrica: se existe um caminho M-aumentante P, então $M \ominus P$ é um emparelhamento maior que M. Para a outra, suponha que M não seja máximo e seja M^* um emparelhamento máximo. No subgrafo formado pelas arestas de $M \ominus M^*$, cada vértice tem grau no máximo 2, de modo que ele se decompõe em caminhos e ciclos cujas arestas alternam entre M e M^*. Os ciclos têm tantas arestas de M quanto de M^*; como $|M^*| > |M|$, ao menos um dos caminhos tem mais arestas de M^* do que de M e é, portanto, um caminho M-aumentante (SCHRIJVER, 2004).

Os algoritmos exatos dos Capítulos 3 e 4 diferem, essencialmente, na forma de encontrar caminhos aumentantes: em grafos bipartidos, uma busca em largura ou em profundidade a partir dos vértices descobertos basta; em grafos gerais, os ciclos de comprimento ímpar exigem o tratamento de flores do algoritmo de Edmonds (Seção 4.1).

2.5.2 Emparelhamento em grafos bipartidos

O problema de **emparelhamento bipartido** é o caso clássico de encontrar um emparelhamento de cardinalidade máxima em um grafo bipartido $G = (U, V; E)$ (KLEINBERG; TARDOS, 2005). Pode ser utilizado para modelar situações de atribuição, como associar empregos (U) a máquinas (V), ou professores (U) a cursos (V), onde uma aresta indica uma capacidade de atribuição (KLEINBERG; TARDOS, 2005).

Quando aplicado em grafos ponderados, o emparelhamento bipartido é conhecido como **problema de atribuição** (LAWLER, 1976), que trata de encontrar uma combinação ótima de atribuições de forma a minimizar o custo total associado. Mais detalhes sobre esse problema serão vistos na Seção 3.2.

2.6 PROGRAMAÇÃO LINEAR E DUALIDADE

Vários algoritmos deste trabalho, como o método Húngaro (Seção 3.2) e o algoritmo de Edmonds para emparelhamento de peso máximo (Seção 4.2), são justificados por um modelo de programação linear e pelo seu dual. Esta seção resume os conceitos necessários, seguindo Cormen et al. (2009) e Schrijver (2004).

2.6.1 Modelo de programação linear

A programação linear (PL) é uma forma de descrever um problema de decisão. O modelo é dividido em três partes:

a) **variáveis de decisão:** um conjunto de variáveis $x_1, \ldots, x_m$, onde $x_j \in \mathbb{R}$ que representam as escolhas do problema;

b) **função objetivo:** uma função linear dependente das variáveis de decisão;

c) **restrições:** limites para as variáveis de decisão, como faixas de valores onde elas devem permanecer.

A ideia é manipular os valores das variáveis para maximizar ou minimizar a função objetivo, a depender do problema a ser resolvido, levando em consideração as restrições que também devem ser lineares. Esse modelo pode ser representado de forma matricial, com uma matriz A cujas linhas representam as restrições e cujas colunas representam as variáveis. Com m variáveis e k restrições, o modelo é escrito da seguinte forma:

$$\max\ c^\top x \quad \text{sujeito a} \quad Ax \leq b, \quad x \geq 0. \tag{2.10}$$

Nessa forma, $x \in \mathbb{R}^m$ é o vetor das variáveis, $c \in \mathbb{R}^m$ traz os coeficientes da função objetivo e $b \in \mathbb{R}^k$, os limites das restrições. Cada linha i de $Ax \leq b$ é uma desigualdade $\sum_j a_{ij}x_j \leq b_i$. Os valores de x que satisfazem todas as restrições, inclusive $x \geq 0$, são as **soluções viáveis**.

Como exemplo, considere o caminho de vértices a, b e c, com as arestas $e_1 = \{a, b\}$, de peso 2, e $e_2 = \{b, c\}$, de peso 1, e o problema de escolher arestas de peso total máximo sem que duas delas compartilhem um vértice. A cada aresta e_j associa-se uma variável x_j, que indica se ela é escolhida, e a cada vértice, uma restrição que permite escolher no máximo uma das arestas que o tocam:

$$\begin{aligned} \max\ 2x_1 + x_2 \quad \text{sujeito a} \qquad x_1 &\leq 1 \quad \text{(vértice } a\text{)} \\ x_1 + x_2 &\leq 1 \quad \text{(vértice } b\text{)} \\ x_2 &\leq 1 \quad \text{(vértice } c\text{)} \\ x_1, x_2 &\geq 0. \end{aligned} \tag{2.11}$$

Nesse modelo, $m = 2$, $k = 3$, $c = (2, 1)$, $b = (1, 1, 1)$ e

$$A = \begin{bmatrix} 1 & 0 \\ 1 & 1 \\ 0 & 1 \end{bmatrix},$$

em que cada linha corresponde a um vértice, cada coluna a uma aresta, e o valor 1 indica que a aresta toca o vértice. Essa é a **matriz de incidência** do grafo, que volta a aparecer na Seção 2.6.2. Note que, no PL, as variáveis podem assumir qualquer valor real que satisfaça as restrições, como $x_1 = x_2 = \frac{1}{2}$; a exigência de valores inteiros também é tratada na Seção 2.6.2.

Com duas variáveis, o modelo pode ser visualizado no plano. Cada restrição corresponde a um semiplano, e as soluções viáveis formam a interseção deles, que no exemplo é o triângulo de cantos $(0, 0)$, $(1, 0)$ e $(0, 1)$. Em geral, essa interseção é

um **poliedro** convexo, e seus cantos são chamados de **vértices do poliedro**, que não devem ser confundidos com os vértices do grafo. A função objetivo indica uma direção: aumentar o seu valor z equivale a deslocar a reta $2x_1 + x_2 = z$ nessa direção, e o maior valor viável é obtido no último ponto do poliedro que a reta toca. Por isso, quando existe solução ótima, ela é atingida em algum vértice do poliedro (CORMEN et al., 2009). No exemplo, os três vértices valem 0, 2 e 1, e o ótimo é $x = (1, 0)$, que corresponde a escolher apenas a aresta e_1.

Na solução $(1, 0)$, as restrições dos vértices a e b valem com igualdade, enquanto a do vértice c tem folga. Uma restrição satisfeita com igualdade por uma solução é dita **justa** nessa solução. As restrições justas são as que definem o vértice ótimo, e esse conceito é a base da folga complementar (Seção 2.6.3) e das arestas justas do método Húngaro.

Por fim, um PL pode ser resolvido em tempo polinomial no tamanho da entrada. O método simplex, o mais usado na prática, percorre os vértices do poliedro, passando sempre a um vértice vizinho de valor melhor, mas pode visitar um número exponencial deles no pior caso; algoritmos de tempo polinomial, como o dos elipsoides e os de pontos interiores, garantem esse limite (CORMEN et al., 2009).

2.6.2 Programação inteira e relaxação linear

Em problemas combinatórios, as variáveis costumam representar escolhas do tipo sim ou não, e o modelo exige $x_j \in \{0, 1\}$. Com essa exigência, o problema passa a ser de **programação linear inteira**, que é NP-difícil em geral. A **relaxação linear** do modelo troca $x_j \in \{0, 1\}$ por $0 \leq x_j \leq 1$. Como toda solução inteira continua viável, o ótimo da relaxação é um limitante superior para o ótimo inteiro (em maximização), mas pode ser atingido apenas por uma solução **fracionária**, que não corresponde a nenhuma escolha real.

Há, porém, casos em que todo vértice do poliedro da relaxação é inteiro; neles, resolver o PL resolve também o problema inteiro. Um caso clássico é o de matrizes **totalmente unimodulares**, em que toda submatriz quadrada tem determinante 0, 1 ou -1. A matriz de incidência entre vértices e arestas de um grafo bipartido tem essa propriedade, e por isso os problemas de emparelhamento bipartido e de atribuição podem ser resolvidos pela sua relaxação linear (SCHRIJVER, 2004). Em grafos gerais isso deixa de valer, como mostra a Seção 4.2.

2.6.3 Dualidade e folga complementar

A todo PL corresponde outro PL, o seu **dual**. Para o problema (2.10), chamado de **primal**, o dual tem uma variável $y_i \geq 0$ para cada restrição primal i e uma restrição

para cada variável primal j:

$$\min\ b^\top y \quad \text{sujeito a} \quad A^\top y \geq c, \quad y \geq 0. \tag{2.12}$$

Os dois problemas se relacionam por três resultados (CORMEN et al., 2009):

a) **dualidade fraca:** para quaisquer soluções viáveis x do primal e y do dual, $c^\top x \leq b^\top y$. Toda solução dual viável é, portanto, um limitante superior para o primal;

b) **dualidade forte:** se o primal tem ótimo, o dual também tem, e os dois valores ótimos são iguais;

c) **folga complementar:** soluções viáveis x e y são ambas ótimas se, e somente se, (i) toda variável primal positiva, $x_j > 0$, torna justa a restrição dual correspondente, e (ii) toda variável dual positiva, $y_i > 0$, torna justa a restrição primal correspondente.

As variáveis duais podem ser vistas como **preços** associados às restrições; em problemas sobre grafos, em que as restrições primais são associadas a vértices, elas são chamadas de **potenciais** dos vértices. A folga complementar é a base dos **algoritmos primal-duais**: eles mantêm uma solução dual viável e constroem uma solução primal usando apenas elementos justos; quando as duas soluções satisfazem a folga complementar, ambas são ótimas. É o caso do método Húngaro e do algoritmo de Edmonds para emparelhamento de peso máximo.

2.7 MÉTODOS EXATOS, APROXIMADOS E HEURÍSTICOS

Os métodos de solução apresentados nos capítulos seguintes são classificados em três tipos, de acordo com a garantia que oferecem sobre a qualidade da solução (VAZIRANI, 2001):

a) **exato:** sempre encontra uma solução ótima. É o caso, por exemplo, dos algoritmos de Hopcroft-Karp e Húngaro;

b) **aproximado:** encontra, em tempo polinomial, uma solução com qualidade garantida em relação ao ótimo. Em um problema de maximização, um algoritmo é dito uma ρ-aproximação, com $0 < \rho \leq 1$, se para toda instância a solução S encontrada satisfaz $\mathrm{val}(S) \geq \rho \cdot \mathrm{OPT}$, em que OPT é o valor da solução ótima. O método guloso simples para emparelhamento de cardinalidade máxima, por exemplo, é uma $\frac{1}{2}$-aproximação;

c) **heurístico:** encontra uma solução viável, geralmente de boa qualidade na prática, mas sem garantia provada de proximidade do ótimo.

A distinção entre aproximado e heurístico depende do problema, e não apenas do método: o método guloso ordenado tem garantia de $\frac{1}{2}$ no emparelhamento de

peso máximo, mas não tem garantia na atribuição de custo mínimo, como discutido na Seção 3.2.3.1.

3 PROBLEMAS DE EMPARELHAMENTO EM GRAFOS BIPARTIDOS

Este capítulo apresenta os quatro problemas de emparelhamento em grafos bipartidos estudados neste trabalho. Todos compartilham a mesma estrutura de entrada, um grafo cujos vértices se dividem em dois conjuntos disjuntos, com arestas apenas entre eles, e diferem quanto ao objetivo da otimização:

a) **emparelhamento de cardinalidade máxima:** maximizar o número de arestas do emparelhamento, sem pesos;

b) **problema de atribuição:** encontrar o emparelhamento perfeito de menor custo total;

c) **problema de atribuição gargalo:** encontrar o emparelhamento perfeito cuja aresta mais cara seja a mais barata possível;

d) **emparelhamento estável:** encontrar um emparelhamento em que nenhum par prefira estar junto a permanecer com os parceiros atuais, a partir de listas de preferências.

Cada problema é apresentado na mesma sequência: a definição e as propriedades necessárias aos algoritmos, os algoritmos exatos, os algoritmos aproximados e as heurísticas, classificados conforme a Seção 2.7, e uma tabela-resumo com a complexidade, o tipo e uma breve descrição de cada método.

3.1 EMPARELHAMENTO DE CARDINALIDADE MÁXIMA

Dado um grafo não-direcionado $G = (V, E)$, o problema de emparelhamento de cardinalidade máxima (MCM) busca encontrar um emparelhamento $M \subseteq E$ tal que o número de arestas em M seja maximizado, ou seja, $|M|$ é o maior entre todos os emparelhamentos possíveis em G.

Um caso especial, mas importante, do MCM é o **Emparelhamento perfeito**, que é um emparelhamento onde todos os vértices do grafo são cobertos por exatamente uma aresta do emparelhamento. Para que um emparelhamento perfeito exista, o grafo deve ter um número par de vértices e o emparelhamento máximo deve ter cardinalidade igual a $|V|/2$ (JUNGNICKEL, 2008).

3.1.1 Propriedades

Antes de continuar para os algoritmos e soluções, é necessário entender algumas propriedades importantes

3.1.1.1 Emparelhamento máximo vs maximal

Um emparelhamento máximo é aquele que contém o maior número possível de arestas, enquanto um emparelhamento maximal é aquele que não pode ser aumentado adicionando mais arestas, mas não necessariamente é o maior possível (MANBER, 1989).

3.1.1.2 Caminhos aumentantes

Os caminhos aumentantes, definidos na Seção 2.5.1 e ilustrados na Figura 1, são a base dos algoritmos exatos deste problema: pelo lema de Berge, um emparelhamento M é máximo se, e somente se, não existe caminho M-aumentante. Em um grafo bipartido com lados U e V, todo caminho M-aumentante liga um vértice descoberto de U a um vértice descoberto de V, pois o caminho alterna entre os dois lados e tem um número ímpar de arestas.

3.1.1.3 Teorema de Kőnig

O teorema de Kőnig relaciona emparelhamentos e coberturas em grafos bipartidos. Ele afirma que, em qualquer grafo bipartido, o tamanho do maior emparelhamento é igual ao tamanho da menor cobertura de vértices (JUNGNICKEL, 2008).

A cobertura de vértices é um conjunto de vértices tal que cada aresta do grafo é incidente a pelo menos um vértice desse conjunto. A seguir será detalhado um método algorítmico para encontrar a cobertura de vértices mínima a partir de um emparelhamento máximo.

O método é definido pelos seguintes passos (JUNGNICKEL, 2008):

1. identifica-se o conjunto de vértices livres (não saturados por M) na parte U;
2. a partir desses vértices, inicia-se uma travessia no grafo (utilizando Busca em Largura ou Profundidade) com regras estritas de alternância: transições do conjunto U para V devem ocorrer exclusivamente através de arestas que **não** pertencem ao emparelhamento ($E \setminus M$), enquanto as transições de V de volta para U devem utilizar obrigatoriamente as arestas do emparelhamento (M);
3. registra-se em um conjunto Z todos os vértices que foram alcançados durante essa busca, tanto da partição U quanto da partição V;
4. a Cobertura Mínima de Vértices C é construída selecionando-se os vértices de U que **não** foram visitados e os vértices de V que **foram** visitados. Matematicamente, a cobertura é dada por $C = (U \setminus Z) \cup (V \cap Z)$.

Essa extração algorítmica possui complexidade linear em relação ao tamanho do grafo, $O(V + E)$, visto que requer apenas uma travessia simples após o cálculo do emparelhamento. Ela é usada como sub-rotina em métodos exatos de outros problemas, como a atualização de limiares no Método Dual para o problema de atribuição gargalo (CORMEN et al., 2009).

3.1.1.4 Teorema de Hall

O Teorema de Hall, frequentemente referido como Teorema do Casamento de Hall, é outro resultado estrutural para grafos bipartidos. Enquanto o teorema de Kőnig determina a cardinalidade do emparelhamento máximo, o teorema de Hall estabelece a condição necessária e suficiente para a existência de um emparelhamento que cubra integralmente um dos subconjuntos da partição (SCHRIJVER, 2004).

Para um grafo bipartido $G = (U \cup V, E)$, o teorema afirma que existe um emparelhamento cobrindo todo o conjunto U se, e somente se, para qualquer subconjunto $S \subseteq U$, o tamanho de sua vizinhança $N(S)$ (o conjunto de vértices em V adjacentes a pelo menos um vértice em S) for maior ou igual ao tamanho de S. Matematicamente, exige-se que $|N(S)| \geq |S|$ para todo $S \subseteq U$ (JUNGNICKEL, 2008). Essa propriedade é conhecida como condição de Hall. Quando ela falha, um conjunto S com $|N(S)| < |S|$ mostra por que não existe emparelhamento que cubra U.

3.1.1.5 Teorema de Gallai e Conjunto Independente Máximo

Um conjunto independente em um grafo é um subconjunto de vértices no qual não existem duas extremidades adjacentes, ou seja, nenhuma aresta conecta dois vértices desse conjunto. O problema de encontrar o Conjunto Independente Máximo (*Maximum Independent Set* - MIS) é classicamente conhecido por pertencer à classe NP-difícil para grafos gerais (GAREY; JOHNSON, 1990). No entanto, quando o grafo é restrito à classe dos grafos bipartidos, o problema pode ser resolvido em tempo polinomial pelo Teorema de Gallai, descrito a seguir.

A base dessa resolução é o Teorema de Gallai, proposto em 1959. O teorema estabelece que, para qualquer grafo $G = (V, E)$ que não possua vértices isolados, a soma do tamanho da Cobertura Mínima de Vértices (MVC) com o tamanho do Conjunto Independente Máximo (MIS) é sempre igual ao número total de vértices do grafo (SCHRIJVER, 2004).

Matematicamente:

$$|MVC| + |MIS| = |V| \tag{3.1}$$

Pelo Teorema de Kőnig, detalhado anteriormente, sabe-se que em grafos bipartidos o tamanho da Cobertura Mínima de Vértices é exatamente igual ao tamanho do Emparelhamento Máximo ($|MVC| = |M|$). Consequentemente, o tamanho do Conjunto Independente Máximo pode ser deduzido diretamente do emparelhamento: $|MIS| = |V| - |M|$ (JUNGNICKEL, 2008).

Além da equivalência de cardinalidade, o Teorema de Gallai também fornece a dualidade estrutural: o Conjunto Independente Máximo é exatamente o complemento da Cobertura Mínima de Vértices. Portanto, para construir algoritmicamente o Conjunto Independente Máximo em um grafo bipartido, basta executar o seguinte procedimento:

1. calcula-se o Emparelhamento Máximo utilizando algoritmos como o de Hopcroft-Karp.
2. extrai-se a Cobertura Mínima de Vértices C através do método de busca por caminhos alternantes a partir dos vértices livres, definido na seção 3.1.1.3.
3. o Conjunto Independente Máximo I será composto por todos os vértices do grafo que não pertencem à cobertura. Ou seja, $I = V \setminus C$.

3.1.2 Algoritmos exatos

Por ser em um ambiente mais restrito, o problema de emparelhamento de cardinalidade máxima tem diversas soluções em tempo polinomial. A seguir listadas algumas delas:

3.1.2.1 Algoritmo do caminho aumentante

O algoritmo de caminho aumentante se baseia no lema de Berge (Seção 2.5.1), segundo o qual um emparelhamento M é máximo se, e somente se, não existe caminho M-aumentante em G. Este algoritmo é uma implementação direta deste lema, onde se busca repetidamente por caminhos aumentantes e se aumenta o emparelhamento até que nenhum caminho aumentante possa ser encontrado (LAWLER, 1976).

O algoritmo começa com um emparelhamento vazio $M = \emptyset$, escolhe um vértice livre $u \in U$ e tenta encontrar um caminho aumentante P que começa em u e termina em um vértice livre de V, respeitando a regra da alternância entre arestas em M e arestas fora de M. Se um caminho aumentante é encontrado, o emparelhamento M é atualizado pela inversão das arestas ao longo do caminho P. O processo se repete até que não seja possível encontrar mais caminhos aumentantes. O emparelhamento resultante será o emparelhamento de cardinalidade máxima (HALIM; HALIM, 2013).

Em seguida o algoritmo em pseudocódigo:

Algoritmo 4: Algoritmo de caminhos aumentantes (MCBM) (HALIM; HALIM, 2013)

```
(1)  Globais: match (vetor de emparelhamento), vis (vetor de visitados),
       ListaAdj
(2)  Procedimento Aum(l)
(3)      se vis[l] = 1 então
(4)          retorne 0
(5)      fim
(6)      vis[l] ← 1
(7)      para cada r ∈ ListaAdj[l] faça
(8)          se match[r] = −1 ou Aum(match[r]) então
(9)              match[r] ← l
(10)             retorne 1 [comentário: encontrou 1 emparelhamento]
(11)         fim
(12)     fim
(13)     retorne 0 [comentário: nenhum emparelhamento]
(14) Procedimento Algoritmo_MCBM(n)
(15)     MCBM ← 0
(16)     match ← −1 (para todo vértice de V)
(17)     para l ← 0 até n − 1 faça
(18)         vis ← 0 (reinicia antes de cada busca)
(19)         MCBM ← MCBM + Aum(l)
(20)     fim
(21)     retorne MCBM
```

O pseudocódigo é composto de um procedimento recursivo de busca e de um procedimento principal, explicados a seguir com referência às linhas do Algoritmo 4. Os vértices de U são numerados de 0 a $n-1$, e $match[r]$ guarda o parceiro, em U, de cada vértice $r \in V$ (-1 se r está livre):

a) **linhas 3–6:** o procedimento Aum(l) é uma busca em profundidade que tenta encontrar um caminho aumentante a partir do vértice $l \in U$. Se l já foi visitado na busca atual, a tentativa falha; caso contrário, l é marcado como visitado, o que impede que a busca entre em ciclo;

b) **linhas 7–8:** para cada vizinho r de l, há duas formas de usar a aresta $\{l, r\}$: se r está livre, o caminho aumentante termina em r; se r já está emparelhado com $match[r]$, a busca continua recursivamente a partir de $match[r]$, tentando realocá-lo para outro vértice. Essa recursão percorre o caminho alternante: a aresta $\{l, r\}$ está fora de M, e a aresta $\{r, match[r]\}$ está em M;

c) **linha 9:** se uma das duas condições é satisfeita, r passa a ser parceiro de l. Como essa atribuição é feita na volta da recursão, em cada nível do caminho, todas as arestas do caminho aumentante trocam de papel, o que

corresponde à diferença simétrica entre M e o caminho, e a cardinalidade de M aumenta em um;

d) **linha 13:** se nenhum vizinho leva a um caminho aumentante, a busca a partir de l falha;

e) **linhas 16–21:** o procedimento principal começa com todos os vértices livres (linha 16) e tenta, uma única vez, encontrar um caminho aumentante a partir de cada vértice de U (linha 17). Antes de cada tentativa, as marcas de visita são reiniciadas (linha 18). Cada busca bem-sucedida soma um ao tamanho do emparelhamento (linha 19), que é retornado ao final;

f) **complexidade:** cada chamada da linha 19 visita cada vértice no máximo uma vez e examina cada aresta no máximo uma vez, com custo $O(V + E)$. Como há uma chamada por vértice de U, o tempo total é $O(V(V + E))$, ou seja, $O(VE)$ em grafos sem vértices isolados, onde V é o número de vértices e E é o número de arestas do grafo bipartido (HALIM; HALIM, 2013).

3.1.2.2 Redução ao problema de fluxo máximo

O problema de emparelhamento de cardinalidade máxima em grafos bipartidos pode ser eficientemente resolvido através de uma redução ao problema de fluxo máximo em redes. A ideia central é construir uma rede de fluxo a partir do grafo bipartido original, onde cada aresta do grafo bipartido é convertida em uma aresta com capacidade unitária na rede de fluxo. (LAWLER, 1976)

Primeiro, adicionam-se à rede um vértice fonte s e um vértice sumidouro t. O vértice fonte s é conectado a todos os vértices de U por arestas de capacidade 1, e todos os vértices de V são conectados ao sumidouro t, também por arestas de capacidade 1. As arestas entre U e V são mantidas na rede de fluxo, cada uma com capacidade 1 (HALIM; HALIM, 2013).

Obtém-se, assim, uma rede de fluxo em que o objetivo é encontrar o fluxo máximo do vértice fonte s para o vértice sumidouro t. O valor do fluxo máximo encontrado nesta rede corresponde ao tamanho do emparelhamento máximo no grafo bipartido original. (LAWLER, 1976). Para encontrar o fluxo máximo, podem ser usados algoritmos clássicos como o de Edmonds-Karp.

3.1.2.3 Algoritmo de Edmonds-Karp

O algoritmo de **Edmonds-Karp** é o principal método para resolver esse tipo de problema. Ele é uma especialização do método de Ford-Fulkerson descrito na seção 2.4.2.3 que utiliza uma busca em largura (BFS) para encontrar sempre o caminho aumentante mais curto em número de arestas. Tem complexidade de tempo $O(VE^2)$:

Algoritmo 5: Algoritmo de Edmonds-Karp (HALIM; HALIM, 2013)

```
(1)  Globais: res (matriz de capacidade residual), mf, f, s, t, p (vetor de pais da
       BFS)

(2)  Procedimento BFS(s, t)
(3)      dist ← ∞;   dist[s] ← 0
(4)      Q ← {s};   p ← nulo (vetor iniciado com −1)
(5)      enquanto Q ≠ ∅ faça
(6)          u ← Q.frente(); Q.remove()
(7)          se u = t então
(8)              interrompa (encerra a BFS)
(9)          fim
(10)         para cada v ∈ V faça
(11)             se res_{u,v} > 0 e dist[v] = ∞ então
(12)                 dist[v] ← dist[u] + 1
(13)                 Q.insere(v)
(14)                 p[v] ← u
(15)             fim
(16)         fim
(17)     fim

(18) Procedimento Aumenta(v, menorAresta)
(19)     se v = s então
(20)         f ← menorAresta
(21)         retorne
(22)     senão
(23)         se p[v] ≠ −1 então
(24)             Aumenta(p[v], min(menorAresta, res_{p[v],v}))
(25)             res_{p[v],v} ← res_{p[v],v} − f
(26)             res_{v,p[v]} ← res_{v,p[v]} + f
(27)         fim
(28)     fim

(29) Procedimento EdmondsKarp(s, t)
(30)     mf ← 0
(31)     enquanto verdadeiro faça
(32)         f ← 0
(33)         BFS(s, t); [comentário: preenche o vetor de pais p]
(34)         Aumenta(t, ∞); [comentário: encontra o menor peso de aresta f
               no caminho]
(35)         se f = 0 então
(36)             interrompa (termina)
(37)         fim
(38)         mf ← mf + f
(39)     fim
(40)     retorne mf
```

O pseudocódigo divide-se em três procedimentos, explicados a seguir com

referência às linhas do Algoritmo 5. A rede residual é representada pela matriz res, em que $res_{u,v}$ é a capacidade residual do arco (u, v):

a) **BFS (linhas 3–14):** busca em largura a partir de s na rede residual. Todas as distâncias começam infinitas, exceto a de s (linha 3), e a fila Q começa só com s, com o vetor de pais vazio (linha 4). Enquanto houver vértices na fila (linha 5), retira-se o primeiro, u; se ele é o sorvedouro t, o caminho já foi encontrado e a busca para (linha 7). Caso contrário, percorrem-se todos os vértices v (linha 10) e consideram-se apenas os arcos com capacidade residual positiva que levam a um vértice ainda não alcançado (linha 11). Cada vértice alcançado pela primeira vez recebe sua distância (linha 12), entra na fila e tem seu pai registrado em p (linha 14). Como a busca é em largura, o caminho registrado até t é o de menor número de arcos;

b) **aumenta (linhas 19–26):** percorre o caminho encontrado de t até s, seguindo o vetor de pais, e carrega em menorAresta a menor capacidade residual vista até o momento. Ao chegar em s (linha 19), esse mínimo é o gargalo do caminho e é guardado em f. Se um vértice não tem pai (linha 23), t não foi alcançado pela BFS e nada é feito, de modo que f continua 0. A chamada recursiva (linha 24) desce até s antes de qualquer atualização; na volta da recursão, f é subtraído da capacidade residual de cada arco no sentido do caminho (linha 25) e somado à do arco reverso (linha 26), o que permite a uma iteração futura desfazer parte desse fluxo;

c) **EdmondsKarp (linhas 30–38):** o fluxo total mf começa em zero (linha 30). A cada iteração do laço (linha 31), f é zerado (linha 32), a BFS procura o caminho aumentante mais curto (linha 33) e o procedimento Aumenta envia por ele o fluxo do gargalo (linha 34). Quando a BFS não alcança t, nenhum fluxo é enviado ($f = 0$, linha 35) e o fluxo acumulado mf é máximo; caso contrário, f é somado a mf (linha 38);

d) **complexidade:** como a BFS escolhe sempre o caminho aumentante mais curto, a distância de s a cada vértice na rede residual nunca diminui. A cada aumento, pelo menos um arco do caminho é saturado (o arco gargalo), e um mesmo arco só pode voltar a ser gargalo depois que a distância até ele aumenta em pelo menos 2. Como a distância é limitada por V, cada arco é gargalo $O(V)$ vezes, e o número total de aumentos é $O(VE)$. Com listas de adjacência, cada BFS custa $O(E)$, o que leva ao total de $O(VE^2)$. Na versão com matriz do Algoritmo 5, o laço da linha 10 percorre todos os vértices, e cada BFS custa $O(V^2)$, o que dá $O(V^3E)$ (HALIM; HALIM, 2013). Na rede obtida pela redução do emparelhamento bipartido, as capacidades são unitárias e o fluxo máximo é no máximo $V/2$; como cada aumento envia

uma unidade de fluxo, há no máximo $V/2$ aumentos, e o tempo cai para $O(VE)$ com listas de adjacência.

3.1.2.4 Algoritmo de Dinic

Outra opção para resolver o problema de fluxo máximo é o algoritmo de Dinic, que é mais eficiente em muitos casos práticos, especialmente em grafos densos. O algoritmo de Dinic utiliza uma combinação de buscas em largura (BFS) para construir níveis na rede residual e buscas em profundidade (DFS) para encontrar caminhos aumentantes dentro desses níveis. O tempo de execução do algoritmo de Dinic é $O(V^2E)$ em redes gerais e cai para $O(E\sqrt{V})$ em redes de capacidade unitária, como a obtida na redução do emparelhamento bipartido, o que o torna uma escolha preferida para muitos problemas de fluxo máximo (HALIM; HALIM, 2013).

O algoritmo trabalha em fases. Em cada uma, uma BFS em $O(E)$ calcula a distância de s a cada vértice na rede residual e forma a **rede em níveis**, com os arcos que avançam exatamente um nível. Nela, buscam-se caminhos de s a t até obter um **fluxo bloqueante**, em que todo caminho da rede em níveis tem algum arco saturado. Cada caminho é encontrado em $O(V)$ amortizado e satura ao menos um arco, de modo que há no máximo E caminhos por fase e o fluxo bloqueante custa $O(VE)$. Como a distância de s a t aumenta estritamente a cada fase, há no máximo V fases, o que dá $O(V^2E)$ (AHUJA; MAGNANTI; ORLIN, 1993). Em redes de capacidade unitária em que cada vértice tem um único arco de entrada ou um único arco de saída, como a da redução do emparelhamento bipartido, cada fluxo bloqueante custa apenas $O(E)$, e o argumento usado adiante para o Hopcroft-Karp mostra que bastam $O(\sqrt{V})$ fases, o que dá $O(E\sqrt{V})$ (AHUJA; MAGNANTI; ORLIN, 1993).

Este trabalho não tem uma implementação do algoritmo de Dinic. Ao invés disso, será apresentado o algoritmo de Hopcroft-Karp, que é uma variação especializada do algoritmo de Dinic para o problema de emparelhamento em grafos bipartidos, oferecendo uma solução mais eficiente para este caso específico.

3.1.2.5 Algoritmo de Hopcroft-Karp

O algoritmo de Hopcroft-Karp é um algoritmo eficiente para encontrar o emparelhamento máximo em grafos bipartidos. Ele melhora o desempenho do algoritmo de caminhos aumentantes ao encontrar múltiplos caminhos aumentantes em cada iteração, em vez de apenas um. O tempo de execução do algoritmo de Hopcroft-Karp é $O(E\sqrt{V})$, o que o torna significativamente mais rápido do que o algoritmo de caminhos aumentantes simples, especialmente em grafos grandes (HALIM; HALIM, 2013).

O algoritmo consiste em duas fases principais: a fase de construção de níveis e a fase de busca de caminhos aumentantes. Na fase de construção de níveis, uma

busca em largura (BFS) é realizada a partir dos vértices livres de U para construir uma camada de níveis que ajuda a identificar os caminhos aumentantes mais curtos. Na fase de busca de caminhos aumentantes, uma busca em profundidade (DFS) é realizada para encontrar todos os caminhos aumentantes possíveis dentro da camada de níveis construída na fase anterior. Esses caminhos são então usados para aumentar o emparelhamento (HALIM; HALIM, 2013).

A seguir, o pseudocódigo do algoritmo de Hopcroft-Karp, dividido em duas partes: o Algoritmo 6 traz o laço principal e a construção do grafo em camadas, e o Algoritmo 7, a busca dos caminhos aumentantes disjuntos.

Algoritmo 6: Algoritmo de Hopcroft-Karp: laço principal e grafo em camadas (BURKARD; DELL'AMICO; MARTELLO, 2009)

(1) **seja** $G = (U, V; E)$ um grafo bipartido com emparelhamento inicial M (possivelmente vazio);
(2) **seja** U_0 o conjunto dos vértices livres de U;
(3) **seja** V_0 o conjunto dos vértices livres de V;
(4) **enquanto** $U_0 \neq \emptyset$ **faça**
(5) | Constroi_grafo_em_camadas;
(6) | Encontra_conjunto_ΔM;
(7) | $M := M \ominus \Delta M$;
(8) | atualize os conjuntos U_0, V_0 de vértices livres
(9) **fim**

(10) **Procedimento** *Constroi_grafo_em_camadas*
(11) | $L_0 := U_0, k^* := k := 0$;
(12) | **enquanto** $L_k \neq \emptyset$ **faça**
(13) | | **para cada** $i \in L_k$ **faça**
(14) | | | $N(i) := \{j : [i, j] \in E \setminus M, j \notin L_1 \cup L_3 \cup \cdots \cup L_{k-1}\}$;
(15) | | **fim**
(16) | | $L_{k+1} := \bigcup_{i \in L_k} N(i)$;
(17) | | **se** $L_{k+1} = \emptyset$ **então**
(18) | | | **pare [comentário:** M **é um emparelhamento máximo]**
(19) | | **fim**
(20) | | **se** $L_{k+1} \cap V_0 \neq \emptyset$ **então**
(21) | | | $k^* := k + 1$;
(22) | | | $L_{k+2} := \emptyset$
(23) | | **senão**
(24) | | | $L_{k+2} := \{\bar{i} : [\bar{i}, j] \in M, j \in L_{k+1}\}$;
(25) | | **fim**
(26) | | $k := k + 2$
(27) | **fim**

Algoritmo 7: Algoritmo de Hopcroft-Karp: busca dos caminhos aumentantes disjuntos (BURKARD; DELL'AMICO; MARTELLO, 2009)

```
(1)  Procedimento Encontra_conjunto_ΔM
(2)      [comentário: encontra um conjunto maximal ΔM de caminhos
          aumentantes disjuntos]
(3)      remova todos os vértices de L_{k*} \ V_0;
(4)      marque todos os vértices restantes como não visitados;
(5)      k := 1; [comentário: contador de caminhos]
(6)      enquanto L_0 ≠ ∅ faça
(7)          escolha x_0 := i ∈ L_0 e remova-o de L_0;
(8)          ℓ := 0;
(9)          enquanto ℓ ≥ 0 faça
(10)             enquanto x_ℓ tem vizinho não visitado em L_{ℓ+1} faça
(11)                 escolha um vizinho não visitado x_{ℓ+1};
(12)                 marque x_{ℓ+1} como visitado;
(13)                 ℓ := ℓ + 1;
(14)                 se ℓ = k* então
(15)                     P_k := (x_0, x_1, ..., x_{k*});
(16)                     k := k + 1
(17)                 fim
(18)             fim
(19)             se ℓ < k* então
(20)                 ℓ := ℓ − 1
(21)             senão
(22)                 ℓ := −1
(23)             fim
(24)         fim
(25)     fim
(26)     retorne ΔM := (P_1, P_2, ..., P_{k−1})
```

O pseudocódigo é organizado em um laço principal e dois procedimentos, explicados a seguir com referência às linhas dos Algoritmos 6 e 7:

a) **laço principal (Algoritmo 6, linhas 2–8):** U_0 e V_0 guardam os vértices livres de cada lado (linhas 2 e 3). Cada iteração do laço da linha 4 é uma *fase*: constrói-se o grafo em camadas (linha 5), encontra-se um conjunto maximal ΔM de caminhos aumentantes mínimos e disjuntos (linha 6) e o emparelhamento é atualizado pela diferença simétrica $M \ominus \Delta M$ (linha 7). Ao longo de cada caminho, as arestas emparelhadas e as não emparelhadas trocam de papel, de modo que $|M|$ aumenta em $|\Delta M|$;

b) **construção do grafo em camadas (Algoritmo 6):** é uma busca em largura que parte de todos os vértices livres de U ao mesmo tempo, que formam a camada L_0 (linha 11). As camadas de índice ímpar contêm vértices de V, alcançados por arestas *não* emparelhadas (linha 14); a restrição $j \notin L_1 \cup \cdots \cup L_{k-1}$ impede que um vértice seja revisitado. Se nenhum

vértice novo é alcançado (linha 17), não há caminho aumentante e, pelo lema de Berge, M é máximo. Se a nova camada contém um vértice livre de V (linha 20), foi encontrado o comprimento k^* dos caminhos aumentantes mais curtos, e a construção termina. Caso contrário, a camada seguinte é formada pelos parceiros, em M, dos vértices recém-alcançados (linha 24): o caminho segue obrigatoriamente pela aresta emparelhada, o que garante a alternância;

c) **busca dos caminhos disjuntos (Algoritmo 7):** primeiro, descartam-se os vértices da última camada que não são livres (linha 3), pois nenhum caminho aumentante termina neles. Em seguida, uma busca em profundidade parte de cada vértice livre $x_0 \in L_0$ (linha 7) e avança sempre para um vizinho ainda não visitado da camada seguinte (linha 10). Ao atingir a camada k^*, o caminho $P_k = (x_0, \ldots, x_{k^*})$ é registrado (linha 14) e a busca a partir dessa raiz termina; se a busca fica sem vizinhos antes disso, recua uma camada (linha 19). Como cada vértice é visitado no máximo uma vez por fase, os caminhos encontrados são disjuntos em vértices, e o conjunto ΔM é maximal;

d) **complexidade:** cada fase examina cada aresta um número constante de vezes, com custo $O(E)$. Após $\sqrt{V}$ fases, todo caminho aumentante restante tem mais de $\sqrt{V}$ arestas; como os caminhos aumentantes de $M \ominus M^*$ são disjuntos em vértices, restam menos de $\sqrt{V}$ deles, e cada fase seguinte elimina ao menos um. O número de fases é, portanto, $O(\sqrt{V})$, o que leva à complexidade total $O(E\sqrt{V})$ (BURKARD; DELL'AMICO; MARTELLO, 2009).

3.1.3 Algoritmos aproximados

Por mais que o algoritmo de Hopcroft-Karp descrito nos Algoritmos 6 e 7 seja considerado relativamente eficiente, com complexidade $O(E\sqrt{V})$, seu custo ainda cresce rapidamente em instâncias muito grandes do problema de emparelhamento de cardinalidade máxima. Por isso, foram propostos métodos que abrem mão da garantia de otimalidade para resolver o problema com complexidade linear $O(E)$. Os dois métodos desta seção garantem um emparelhamento com pelo menos metade da cardinalidade máxima e, por isso, são classificados como algoritmos aproximados (Seção 2.7).

3.1.3.1 Método guloso simples

Um método que itera sobre as arestas do grafo em ordem arbitrária. Se a aresta $\{u, v\}$ conecta dois vértices livres, adicione essa aresta ao emparelhamento e remova os vértices u e v. Tem complexidade de tempo linear e garante um emparelhamento

maximal, que conforme visto na seção 3.1.1.1, é um emparelhamento ao qual não é possível adicionar mais arestas, mas que não é necessariamente o de maior cardinalidade. A solução também garante um emparelhamento de pelo menos $1/2$ (metade) da cardinalidade máxima (VAZIRANI, 2001).

Algoritmo 8: Método guloso simples (VAZIRANI, 2001)

Entrada: grafo bipartido $G = (U, V; E)$
Saída: emparelhamento maximal M

```
(1) M := ∅
(2) para cada aresta {u, v} ∈ E, em ordem arbitrária faça
(3)     se u e v estão ambos livres então
(4)         M := M ∪ {{u, v}}
(5)         marque u e v como emparelhados
(6)     fim
(7) fim
(8) retorne M
```

O Algoritmo 8 funciona da seguinte forma:

a) **linha 1:** o emparelhamento começa vazio, com todos os vértices livres;

b) **linhas 2–3:** cada aresta é examinada uma única vez, em ordem arbitrária, verificando-se se seus dois extremos ainda estão livres;

c) **linhas 4–5:** se estão, a aresta entra no emparelhamento e seus extremos são marcados como emparelhados, o que exclui todas as demais arestas incidentes a eles. Uma aresta rejeitada nunca é reconsiderada;

d) **linha 8:** ao final, nenhuma aresta de G tem os dois extremos livres, pois ela teria sido aceita quando foi examinada. O emparelhamento retornado é, portanto, maximal;

e) **complexidade:** com um vetor de marcas por vértice, o teste da linha 3 e as atualizações das linhas 4–5 custam $O(1)$. Como o laço examina cada aresta uma vez, o tempo total é $O(V + E)$, ou seja, linear no tamanho do grafo;

f) **garantia de aproximação:** seja M o emparelhamento maximal retornado e M^* um emparelhamento máximo. Toda aresta de M^* tem pelo menos um extremo coberto por M, pois, caso contrário, ela poderia ser acrescentada a M, que não seria maximal. Cada aresta de M cobre 2 vértices, e cada vértice toca no máximo uma aresta de M^*, já que M^* é um emparelhamento. Logo, as arestas de M cobrem no máximo $2|M|$ arestas de M^*, e como todas as arestas de M^* são cobertas, $|M^*| \leq 2|M|$, ou seja, $|M| \geq \frac{1}{2}|M^*|$ (VAZIRANI, 2001).

3.1.3.2 Algoritmo de Karp-Sipser

Algoritmo descrito por Karp e Sipser (1981) para grafos esparsos que toma decisões com base na topologia do grafo ao invés de decisões aleatórias, tornando essas decisões mais seguras.

O algoritmo funciona reduzindo dinamicamente o grafo $G = (V, E)$ através da aplicação repetida de duas regras, nesta ordem de prioridade:

1. **redução de folhas de grau 1:** se existir algum vértice v no grafo atual com **grau 1** (apenas um vizinho u), a aresta $\{u, v\}$ é selecionada imediatamente para o emparelhamento. Isso é seguro pois, se u é o único vizinho de v, ele também é a única opção para emparelhar v. Se isso não for feito, v ficará isolado;

2. **escolha Aleatória:** se **não** existirem vértices de grau 1 (ou seja, todos os vértices têm grau ≥ 2), o algoritmo escolhe uma aresta $\{u, v\}$ aleatoriamente, adiciona ao emparelhamento e remove u e v do grafo.

   Em grafos esparsos, isso tende a quebrar ciclos e formar novas folhas (vértices de grau 1), permitindo que o algoritmo volte a usar a regra 1. Porém, em grafos densos, essa escolha aleatória pode comprometer a precisão da solução.

Para grafos esparsos, a regra 2 é raramente aplicada, pois a remoção de vértices na regra 1 frequentemente cria novas folhas, provocando um efeito cascata, fazendo com que a maior parte do grafo seja resolvida de maneira ótima. Com estruturas de dados adequadas, a complexidade do algoritmo é linear ($O(E)$). A implementação avaliada neste trabalho, por simplicidade, localiza os vértices de grau 1 por varredura, o que eleva sua complexidade a $O(V \cdot E)$.

Algoritmo 9: Algoritmo de Karp-Sipser (KARP; SIPSER, 1981)

Entrada: grafo bipartido $G = (U, V; E)$
Saída: emparelhamento maximal M

(1) $M := \emptyset$
(2) **enquanto** $E \neq \emptyset$ **faça**
(3) | **se** *existe um vértice* v *com* $\deg(v) = 1$ **então**
(4) | | **seja** u o único vizinho de v
(5) | | **[comentário: seguro: algum emparelhamento máximo contém** $\{u, v\}$**]**
(6) | **senão**
(7) | | escolha uma aresta arbitrária $\{u, v\} \in E$
(8) | | **[comentário: único passo que pode perder a otimalidade]**
(9) | **fim**
(10) | $M := M \cup \{\{u, v\}\}$
(11) | remova de G os vértices u e v e todas as arestas incidentes a eles
(12) **fim**
(13) **retorne** M

As etapas do Algoritmo 9 são as seguintes:

a) **linhas 1–2:** o emparelhamento começa vazio, e o laço principal se repete enquanto o grafo ainda tiver arestas;

b) **linhas 3–4:** regra 1. Se há um vértice v de grau 1, a aresta escolhida é a que o liga ao seu único vizinho u. Essa escolha nunca piora a solução: dado um emparelhamento máximo qualquer, se ele não contém $\{u, v\}$, então v está livre nele, e trocar a aresta que cobre u (se houver) por $\{u, v\}$ produz outro emparelhamento máximo que a contém;

c) **linha 7:** regra 2. Se não há vértices de grau 1, escolhe-se uma aresta arbitrária. É o único passo em que a otimalidade pode ser perdida;

d) **linhas 10–11:** a aresta escolhida entra no emparelhamento, e seus dois extremos são removidos do grafo com todas as arestas incidentes. A remoção reduz o grau dos vizinhos de u e v, o que pode criar novos vértices de grau 1 e reativar a regra 1 na próxima iteração;

e) **linha 13:** o laço só termina quando não restam arestas no grafo (linha 2). Como só são removidas arestas incidentes a vértices emparelhados, nenhuma aresta de G tem os dois extremos livres ao final. O emparelhamento retornado é, portanto, maximal e, pelo mesmo argumento do método guloso simples, tem pelo menos metade da cardinalidade máxima;

f) **complexidade:** cada iteração emparelha dois vértices, então há no máximo $V/2$ iterações, e cada aresta é removida uma única vez. Com uma estrutura que mantém os vértices de grau 1 em uma lista atualizada a cada remoção, encontrar o vértice da linha 3 custa $O(1)$, e o total é $O(V + E)$. Na implemen-

tação avaliada, a linha 3 varre todos os vértices a cada iteração, com custo $O(V + E)$ por iteração, o que resulta em $O(V(V + E))$, ou seja, $O(V \cdot E)$ em grafos sem vértices isolados.

Tabela 1 – Algoritmos para emparelhamento de cardinalidade máxima em grafos bipartidos

Algoritmo	**Complexidade**	**Tipo**	**Avaliado**	**Descrição**
Caminhos aumentantes	$O(VE)$	Exato	Sim	Busca iterativa (DFS/BFS) por caminhos alternantes entre vértices livres, invertendo arestas para aumentar a cardinalidade.
Edmonds-Karp	$O(VE^2)$	Exato	Sim	Implementação de Ford-Fulkerson que usa BFS para encontrar sempre o caminho aumentante mais curto (em nº de arestas) na rede residual.
Dinic	$O(V^2E)$	Exato	Não	Algoritmo de fluxo que constrói grafos de níveis (BFS) e satura múltiplos caminhos simultaneamente via fluxo de bloqueio (DFS). Em redes de capacidade unitária, como a do emparelhamento bipartido, cai para $O(E\sqrt{V})$.
Hopcroft-Karp	$O(E\sqrt{V})$	Exato	Sim	Busca múltiplos caminhos aumentantes disjuntos por fase usando BFS e DFS.
Guloso simples	$O(E)$	Aprox.	Sim	Itera sobre arestas arbitrariamente, selecionando aquelas que conectam dois vértices livres.
Karp-Sipser	$O(E)$	Aprox.	Sim*	Prioriza remoção de vértices de grau 1; usa escolha aleatória quando não há folhas.

Fonte: Elaborado pelo autor.

Aprox.: aproximado. *Avaliado*: incluído no ambiente de testes; a origem de cada implementação consta na Tabela 10. As complexidades são justificadas no texto de cada algoritmo. * A implementação avaliada localiza os vértices de grau 1 por varredura simples, com complexidade $O(V \cdot E)$.

3.2 PROBLEMA DE ATRIBUIÇÃO (*ASSIGNMENT PROBLEM*)

O problema de atribuição, também conhecido como problema do emparelhamento ponderado, consiste em atribuir n agentes a n tarefas, cada agente a exatamente uma tarefa e cada tarefa a exatamente um agente, minimizando a soma dos custos c_{ij} de atribuir o agente i à tarefa j (LAWLER, 1976). Em termos de grafos, procura-se um emparelhamento perfeito de custo mínimo entre os agentes (U) e as tarefas (V); em termos da matriz de custos $C = (c_{ij})$, escolhem-se n posições, uma em cada linha e uma em cada coluna (BURKARD; DELL'AMICO; MARTELLO, 2009).

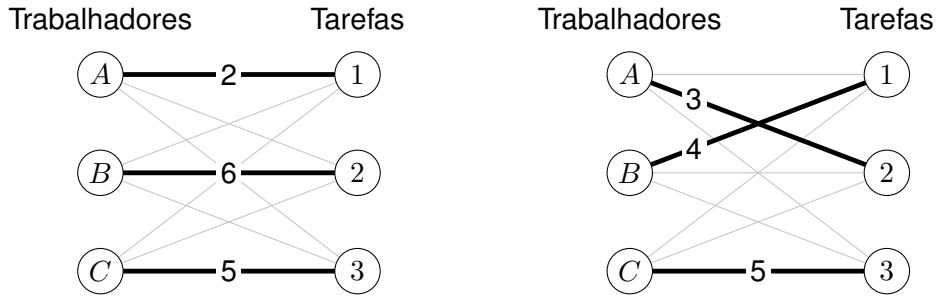
Por exemplo, sejam três trabalhadores, A, B e C, e três tarefas, com os tempos

de execução, em horas, dados pela matriz

$$C = \begin{bmatrix} 2 & 3 & 7 \\ 4 & 6 & 8 \\ 3 & 9 & 5 \end{bmatrix}, \tag{3.2}$$

com uma linha por trabalhador e uma coluna por tarefa. Escolher sempre a posição mais barata restante leva a $2 + 6 + 5 = 13$ horas, mas o ótimo é $3 + 4 + 5 = 12$ horas, sem usar a posição mais barata da matriz (Figura 2). Como há $n!$ atribuições possíveis, enumerá-las é inviável já para valores moderados de n; os algoritmos exatos desta seção encontram o ótimo em tempo polinomial.

Figura 2 – Atribuição gulosa e atribuição ótima para a matriz de custos (3.2)



(a) gulosa: $2 + 6 + 5 = 13$ (b) ótima: $3 + 4 + 5 = 12$

Fonte: Elaborado pelo autor. As arestas cinza são todas as atribuições possíveis entre um trabalhador e uma tarefa; as grossas formam a atribuição escolhida, com o custo de cada par.

O nome do problema vem da alocação de pessoal (*personnel assignment problem*), e ele modela também, por exemplo, a escalação de uma equipe de revezamento de natação, a designação de locomotivas a trens e o escalonamento de tarefas em máquinas paralelas, além de aparecer como subproblema do caixeiro-viajante assimétrico e da atribuição quadrática (Seção 1.2) (BURKARD; DELL'AMICO; MARTELLO, 2009).

3.2.1 Formulação como programação linear

O problema de atribuição pode ser escrito como um modelo de programação linear (Seção 2.6), e é dessa formulação que vêm os **potenciais** usados pelos algoritmos exatos desta seção (BURKARD; DELL'AMICO; MARTELLO, 2009). Considere uma matriz de custos $C = (c_{ij})$ de ordem n, em que as linhas formam a parte U e as colunas a parte V do grafo bipartido $G = (U, V; E)$:

a) **variáveis:** $x_{ij} \in \{0, 1\}$ para cada linha $i \in U$ e coluna $j \in V$, com $x_{ij} = 1$ se, e somente se, a linha i é atribuída à coluna j;

b) **função objetivo:** minimizar o custo total das atribuições, $\sum_{i \in U} \sum_{j \in V} c_{ij}\, x_{ij}$;

c) **restrições:** cada linha recebe exatamente uma coluna, e cada coluna recebe exatamente uma linha.

Em resumo:

$$\begin{aligned} \min \quad & \sum_{i\in U}\sum_{j\in V} c_{ij}\, x_{ij} \\ \text{sujeito a} \quad & \sum_{j\in V} x_{ij} = 1 \qquad \forall\, i \in U, \\ & \sum_{i\in U} x_{ij} = 1 \qquad \forall\, j \in V, \\ & x_{ij} \in \{0,1\} \qquad \forall\, i \in U,\ j \in V. \end{aligned} \tag{3.3}$$

Como a matriz de restrições é a matriz de incidência de um grafo bipartido, que é totalmente unimodular, a relaxação linear com $x_{ij} \geq 0$ já tem uma solução ótima inteira (Seção 2.6). Por isso, o problema pode ser tratado com as ferramentas da programação linear, em particular com a dualidade.

O dual de (3.3) tem uma variável para cada restrição primal: um **potencial** u_i para cada linha $i \in U$ e um potencial v_j para cada coluna $j \in V$. Como as restrições primais são igualdades, os potenciais podem ter qualquer sinal. O dual é

$$\max \quad \sum_{i\in U} u_i + \sum_{j\in V} v_j \quad \text{sujeito a} \quad u_i + v_j \leq c_{ij} \quad \forall\, i \in U,\ j \in V, \tag{3.4}$$

e a folga de cada posição (i, j) é o seu **custo reduzido**:

$$\bar{c}_{ij} = c_{ij} - u_i - v_j \geq 0. \tag{3.5}$$

Os potenciais funcionam como um certificado de otimalidade. Toda atribuição usa exatamente uma posição de cada linha e de cada coluna; somando $c_{ij} = u_i + v_j + \bar{c}_{ij}$ sobre as suas posições, o seu custo é $\sum_i u_i + \sum_j v_j$ mais a soma dos custos reduzidos usados, que é não negativa. Logo, nenhuma atribuição custa menos que $\sum_i u_i + \sum_j v_j$ (dualidade fraca), e uma atribuição que usa apenas posições de custo reduzido nulo atinge esse valor e é ótima. Essa é a **folga complementar** do problema: $x_{ij} = 1$ só onde $\bar{c}_{ij} = 0$. As posições de custo reduzido nulo formam o **subgrafo de igualdade**, sobre o qual os algoritmos procuram a atribuição.

Exemplo. Considere a matriz de custos e os potenciais

$$C = \begin{bmatrix} 4 & 1 & 3 \\ 2 & 0 & 5 \\ 3 & 2 & 2 \end{bmatrix}, \qquad u = (1, 0, 1), \qquad v = (2, 0, 1), \tag{3.6}$$

com u associado às linhas e v às colunas. Os custos reduzidos $\bar{c}_{ij} = c_{ij} - u_i - v_j$ são

$$\bar{C} = \begin{bmatrix} 1 & 0 & 1 \\ 0 & 0 & 4 \\ 0 & 1 & 0 \end{bmatrix}. \tag{3.7}$$

Todos são não negativos, de modo que os potenciais são viáveis, e nenhuma atribuição custa menos que $\sum_i u_i + \sum_j v_j = 2 + 3 = 5$. A atribuição que leva a linha 1 à coluna 2, a linha 2 à coluna 1 e a linha 3 à coluna 3 usa apenas posições de custo reduzido nulo e custa $1 + 2 + 2 = 5$; portanto, é ótima. Os potenciais dizem, sem enumerar as $3! = 6$ atribuições possíveis, que não há solução melhor. O método Húngaro e o algoritmo de Jonker-Volgenant constroem, ao mesmo tempo, uma atribuição e potenciais com essa propriedade.

Os potenciais da técnica de caminhos mínimos sucessivos (Seção 2.4.3.2) são o mesmo conceito, aplicado ao problema de fluxo de custo mínimo: variáveis duais associadas aos vértices, cujos custos reduzidos não negativos permitem usar o algoritmo de Dijkstra.

3.2.2 Algoritmos exatos

A seguir serão apresentados os principais algoritmos conhecidos com soluções exatas para o problema de atribuição.

3.2.2.1 Método Húngaro

O método Húngaro é um algoritmo eficiente para resolver o problema de atribuição em tempo polinomial. Ele foi desenvolvido por Harold Kuhn em 1955 e é baseado no trabalho de Dénes Kőnig e Jenő Egerváry sobre emparelhamentos em grafos bipartidos (JUNGNICKEL, 2008).

O método mantém potenciais viáveis, u_i para cada linha $i \in U$ e v_j para cada coluna $j \in V$ (Seção 3.2.1), e constrói uma atribuição usando apenas posições de custo reduzido nulo. Na versão de Jungnickel (2008), apresentada a seguir, o problema é escrito como maximização do peso $w_{ij} = -c_{ij}$. Com isso, as desigualdades se invertem, e a viabilidade dos potenciais passa a ser $u_i + v_j \geq w_{ij}$ para toda aresta $\{i, j\}$, que é a mesma condição $u_i + v_j \leq c_{ij}$ da Equação (3.4) com os sinais dos potenciais trocados.

Cria-se o subgrafo de igualdade $H_{u,v}$, formado apenas pelas arestas justas, em que $u_i + v_j = w_{ij}$. O algoritmo procura nele um emparelhamento que cubra todas as linhas de U. Se o encontra, esse emparelhamento é ótimo pela folga complementar: usa apenas arestas justas, e os potenciais são viáveis. Caso contrário, o algoritmo ajusta os potenciais, mantendo a viabilidade, para criar novas arestas justas, e repete o processo (JUNGNICKEL, 2008).

Em seguida o pseudocódigo do método Húngaro:

Algoritmo 10: Algoritmo Húngaro (JUNGNICKEL, 2008)

```
(1)  Procedimento HUNGARIAN(n, w; mate)
(2)      para v ∈ V faça mate(v) ← 0
(3)      para i = 1 até n faça u_i ← max{w_ij : j = 1, ..., n}; v_i ← 0
(4)      nrex ← n
(5)      enquanto nrex ≠ 0 faça
(6)          para i = 1 até n faça m(i) ← falso; p(i) ← 0; δ_i ← ∞
(7)          aug ← falso; Q ← {i ∈ U : mate(i) = 0}
(8)          repita
(9)              remova um vértice arbitrário i de Q; m(i) ← verdadeiro; j ← 1
(10)             enquanto aug = falso e j ≤ n faça
(11)                 se mate(i) ≠ j' então
(12)                     se u_i + v_j − w_ij < δ_j então
(13)                         δ_j ← u_i + v_j − w_ij; p(j) ← i
(14)                         se δ_j = 0 então
(15)                             se mate(j') = 0 então
(16)                                 AUGMENT(mate, p, j'; mate)
(17)                                 aug ← verdadeiro; nrex ← nrex − 1
(18)                             senão
(19)                                 Q ← Q ∪ {mate(j')}
(20)                             fim
(21)                         fim
(22)                     fim
(23)                 fim
(24)                 j ← j + 1
(25)             fim
(26)             se aug = falso e Q = ∅ então
(27)                 J ← {i ∈ U : m(i) = verdadeiro}; K ← {j' ∈ V : δ_j = 0}
(28)                 δ ← min{δ_j : j' ∈ V \ K}
(29)                 para i ∈ J faça u_i ← u_i − δ
(30)                 para j' ∈ K faça v_j ← v_j + δ
(31)                 para j' ∈ V \ K faça δ_j ← δ_j − δ
(32)                 X ← {j' ∈ V \ K : δ_j = 0}
(33)                 se mate(j') ≠ 0 para todo j' ∈ X então
(34)                     para j' ∈ X faça Q ← Q ∪ {mate(j')}
(35)                 senão
(36)                     escolha j' ∈ X com mate(j') = 0
(37)                     AUGMENT(mate, p, j'; mate)
(38)                     aug ← verdadeiro; nrex ← nrex − 1
(39)                 fim
(40)             fim
(41)         até que aug = verdadeiro
(42)     fim
```

Algoritmo 11: Método AUGMENT (JUNGNICKEL, 2008)

```
(1) Procedimento AUGMENT(mate, p, j'; mate)
(2)     repita
(3)         i ← p(j); mate(j') ← i; prox ← mate(i); mate(i) ← j'
(4)         se prox ≠ 0 então
(5)             j' ← prox
(6)         fim
(7)     até que prox = 0
```

Como dito acima, o algoritmo *maximiza* o peso $w_{ij} = -c_{ij}$. As linhas da matriz formam a parte $U = \{1, \ldots, n\}$ e as colunas, a parte $V = \{1', \ldots, n'\}$, em que j' denota a coluna j como vértice do grafo. A seguir, cada parte do Algoritmo 10 é explicada com referência às suas linhas:

a) **inicialização (linhas 2–4):** nenhum vértice começa emparelhado. Cada potencial de linha u_i recebe o maior peso da linha i, e os potenciais de coluna v_j recebem zero, o que satisfaz $u_i + v_j \geq w_{ij}$ para toda aresta. O contador $nrex$ guarda o número de linhas ainda livres;

b) **fases (linha 5):** cada iteração do laço externo aumenta o emparelhamento em uma aresta, até que todas as linhas estejam emparelhadas. No início da fase, as marcas são reiniciadas (linha 6): $m(i)$ indica se a linha i já entrou na árvore de busca, $p(j)$ guarda a linha pela qual a coluna j foi alcançada e δ_j guarda a menor folga $u_i + v_j - w_{ij}$ da coluna j em relação às linhas da árvore. A fila Q começa com as linhas livres, que são as raízes da busca (linha 7);

c) **busca no subgrafo de igualdade:** uma linha i é retirada da fila e entra na árvore (linha 9). Para cada coluna que não é a sua parceira atual (linha 11), calcula-se a folga da aresta $\{i, j\}$ e, se ela for menor que δ_j, a coluna passa a ter i como predecessora (linha 12). Folga nula significa que a aresta pertence ao subgrafo de igualdade $H_{u,v}$ (linha 14). Nesse caso, se a coluna está livre, foi encontrado um caminho aumentante, e o procedimento AUGMENT o aplica (linha 16); senão, a parceira da coluna entra na fila (linha 19), e a árvore cresce pela aresta emparelhada;

d) **ajuste dos potenciais (linhas 26–36):** se a fila esvazia sem que um caminho aumentante seja encontrado, as linhas e colunas da árvore formam os conjuntos J e K. Calcula-se δ, a menor folga entre as colunas fora da árvore (linha 28). Diminuir u_i em δ nas linhas da árvore e aumentar v_j em δ nas colunas da árvore preserva as arestas da árvore no subgrafo de igualdade e mantém a viabilidade dos potenciais. Ao mesmo tempo, a folga das colunas de fora diminui em δ (linha 31), o que coloca ao menos uma nova aresta no subgrafo de igualdade (o conjunto X, linha 32). Se todas as colunas de

X estão emparelhadas, suas parceiras entram na fila e a busca continua; senão, uma coluna livre de X completa um caminho aumentante (linha 36);

e) **aumento (Algoritmo 11):** a partir da coluna livre encontrada, o procedimento AUGMENT segue os predecessores p de volta até a raiz, invertendo o emparelhamento ao longo do caminho:
   - linha 3: $i = p(j)$ é a linha pela qual a coluna j' foi alcançada na busca. A coluna j' passa a ser parceira de i, e a antiga parceira de i é guardada em $prox$ antes de ser substituída. Essa troca é a inversão de uma aresta emparelhada e uma não emparelhada do caminho aumentante;
   - linhas 4–5: se i tinha parceira ($prox \neq 0$), essa coluna acabou de ficar livre e o processo continua a partir dela, um passo mais perto da raiz;
   - linha 7: o laço termina quando i não tinha parceira, ou seja, quando se chega à raiz da árvore, que era uma linha livre. Ao final, o emparelhamento tem uma aresta a mais;
   - como o caminho tem no máximo n arestas emparelhadas, o procedimento custa $O(n)$;

f) **complexidade:** em cada fase, cada linha entra na árvore no máximo uma vez, e sua varredura custa $O(n)$. Cada ajuste de potenciais custa $O(n)$ e acrescenta ao menos uma coluna à árvore, de modo que há no máximo n ajustes por fase. Cada fase custa, portanto, $O(n^2)$, e as n fases resultam em $O(n^3)$.

3.2.2.2 Jonker-Volgenant

O algoritmo de Jonker-Volgenant é uma evolução otimizada para a resolução do problema de atribuição linear, proposto por Roy Jonker e Anton Volgenant em 1987. Ele foi desenvolvido para superar o desempenho prático do método Húngaro, especialmente em grafos densos, combinando a teoria de dualidade com estratégias de inicialização e busca mais eficientes (JONKER; VOLGENANT, 1987).

Assim como o método Húngaro, este algoritmo mantém os potenciais u_i e v_j da formulação dual (Seção 3.2.1) e as condições de folga complementar. No entanto, sua principal distinção conceitual é o uso da estratégia de Caminho Aumentante Mais Curto (*Shortest Augmenting Path*). Ao invés de construir emparelhamentos máximos em fases distintas, o algoritmo foca em encontrar o caminho de custo mínimo que conecta uma linha não atribuída a uma coluna livre.

O processo inicia com heurísticas avançadas (conhecidas como redução de colunas e transferência de redução) para resolver rapidamente as atribuições triviais. Para os vértices restantes, o algoritmo realiza uma busca similar ao algoritmo de Dijkstra:

ele explora o grafo para encontrar o caminho aumentante mais curto, atualizando os potenciais duais simultaneamente durante a busca. Isso garante que, a cada iteração, o emparelhamento seja aumentado pelo menor custo possível até que a solução ótima completa seja atingida.

A implementação completa deste algoritmo é extensa; o Algoritmo 12 apresenta suas quatro fases em alto nível. Sua eficiência prática o torna uma escolha preferida para muitos problemas de atribuição em aplicações reais, especialmente quando comparado ao método Húngaro tradicional (JUNGNICKEL, 2008).

Algoritmo 12: Algoritmo de Jonker-Volgenant (LAPJV), em alto nível (JONKER; VOLGENANT, 1987)

Entrada: matriz de custos $C = (c_{ij})_{n \times n}$
Saída: atribuição ótima x (a linha i é atribuída à coluna x_i) e duais de coluna v

(1) **[comentário: fase 1: redução de colunas]**
(2) **para** $j := n$ **até** 1 **faça**
(3) $\quad i^* := \arg\min_i c_{ij}$; $v_j := c_{i^* j}$
(4) $\quad$ **se** *a linha* i^* *está livre* **então** atribua i^* a j
(5) **fim**
(6) **[comentário: fase 2: transferência de redução]**
(7) **para cada** *linha atribuída* i *que é o mínimo de uma única coluna* $j_1 = x_i$ **faça**
(8) $\quad v_{j_1} := v_{j_1} - \min_{j \neq j_1}(c_{ij} - v_j)$
(9) **fim**
(10) **[comentário: fase 3: redução de linhas aumentante (aplicada duas vezes)]**
(11) **para cada** *linha livre* i **faça**
(12) $\quad$ **seja** j_1, j_2 as colunas com o menor e o segundo menor valor $u_1 \leq u_2$ de $c_{ij} - v_j$
(13) $\quad$ **se** $u_1 < u_2$ **então**
(14) $\quad\quad v_{j_1} := v_{j_1} - (u_2 - u_1)$
(15) $\quad$ **senão**
(16) $\quad\quad$ **se** j_1 *está atribuída* **então** $j_1 := j_2$
(17) $\quad$ **fim**
(18) $\quad$ atribua i a j_1; a linha antes atribuída a j_1, se houver, fica livre
(19) **fim**
(20) **[comentário: fase 4: aumento por caminhos mínimos]**
(21) **para cada** *linha* i *ainda livre* **faça**
(22) $\quad$ encontre um caminho aumentante mínimo de i a uma coluna livre, com uma busca do tipo Dijkstra sobre os custos reduzidos $c_{kj} - v_j$
(23) $\quad v_j := v_j + d_j - \mu$ para toda coluna j examinada, sendo d_j sua distância e μ o comprimento do caminho
(24) $\quad$ aumente a atribuição ao longo do caminho
(25) **fim**
(26) **retorne** x, v

Diferentemente do Algoritmo 10, o LAPJV minimiza diretamente o custo e

mantém explícitos apenas os potenciais de coluna v_j; o potencial de cada linha fica implícito como o menor custo reduzido $\min_j(c_{ij} - v_j)$ da linha. Uma aresta $\{i, j\}$ é *justa* quando seu custo reduzido $c_{ij} - v_j$ é o mínimo da linha i. As fases 1 a 3 são heurísticas de inicialização, que atribuem rapidamente boa parte das linhas; apenas a fase 4 garante a otimalidade (JONKER; VOLGENANT, 1987):

a) **fase 1, redução de colunas (linhas 1–4):** as colunas são percorridas da última para a primeira (linha 2). Cada potencial v_j recebe o menor custo da coluna, e i^* é a linha onde ele ocorre (linha 3). Se essa linha ainda está livre, ela é atribuída à coluna (linha 4); se já foi atribuída a outra coluna, a coluna j fica livre por enquanto;

b) **fase 2, transferência de redução (linhas 6–8):** para cada linha atribuída na fase 1 cuja coluna j_1 só tem essa linha como mínimo (linha 7), o potencial v_{j_1} diminui pela menor diferença entre o custo reduzido da linha nas outras colunas e o de j_1 (linha 8). Isso transfere a folga da coluna para a linha: a atribuição atual continua justa, mas a coluna j_1 fica menos atrativa para as linhas livres, o que favorece a fase 3;

c) **fase 3, redução aumentante de linhas (linhas 10–18):** cada linha livre i (linha 11) busca as duas colunas de menor custo reduzido, j_1 e j_2 (linha 12). A fase é aplicada duas vezes, como recomendado pelos autores, pois as linhas desalojadas podem disputar as colunas indefinidamente. Em cada linha livre:

   – se o mínimo é estrito (linha 13), v_{j_1} diminui em $u_2 - u_1$ (linha 14), o que iguala o custo reduzido de j_1 ao de j_2 para a linha i e mantém a aresta $\{i, j_1\}$ justa;
   – em caso de empate e se j_1 já está atribuída, a linha escolhe j_2 (linha 16), para não desalojar outra linha sem necessidade;
   – a linha i é atribuída a j_1; a linha que ocupava j_1, se houver, volta a ser livre (linha 18) e será processada novamente, agora diante de um v_{j_1} menor;

d) **fase 4, aumento por caminhos mínimos (linhas 20–24):** para cada linha ainda livre (linha 21), uma busca semelhante ao algoritmo de Dijkstra sobre os custos reduzidos encontra o caminho aumentante mais barato até uma coluna livre (linha 22). Os custos reduzidos são não negativos, o que permite usar Dijkstra. Os potenciais das colunas examinadas são ajustados pela sua distância d_j em relação ao comprimento μ do caminho (linha 23), o que torna justas as arestas do caminho e mantém os demais custos reduzidos não negativos. Por fim, a atribuição é invertida ao longo do caminho, como no procedimento AUGMENT (linha 24);

e) **retorno (linha 26):** devolve a atribuição x e os potenciais de coluna v, que comprovam a otimalidade pela folga complementar;

f) **complexidade:** as fases 1 e 2 percorrem a matriz uma vez, em $O(n^2)$. A fase 3 tem custo limitado na prática por ser aplicada apenas duas vezes. Na fase 4, há no máximo n linhas livres, e cada busca de caminho mínimo em uma matriz densa custa $O(n^2)$, o que leva ao limite total de $O(n^3)$, o mesmo do método Húngaro. A vantagem do LAPJV é prática: a inicialização deixa poucas linhas para a fase 4, que é a mais cara.

3.2.2.3 Redução para problema de fluxo de custo mínimo

Similarmente ao que foi feito para o problema de emparelhamento de cardinalidade máxima, o problema de atribuição pode ser resolvido através de uma redução ao problema de fluxo de custo mínimo. Assim como para o problema anterior, essa redução é feita criando dois novos vértices: um vértice fonte s e um vértice sorvedouro t. Em seguida, são adicionadas arestas do vértice fonte s para cada vértice de U (as linhas), com capacidade 1 e custo 0. Também são adicionadas arestas de cada vértice de V (as colunas) para o vértice sorvedouro t, também com capacidade 1 e custo 0. Finalmente, as arestas do grafo bipartido original são adicionadas com capacidade 1 e custo igual ao custo de atribuição correspondente.

Para resolver problemas de fluxo, podem ser usados algoritmos como o de caminhos de custo mínimo sucessivos (*successive shortest paths*) ou o algoritmo de cancelamento de ciclos (*cycle canceling*) (SCHRIJVER, 2004).

O primeiro algoritmo, o de caminhos de custo mínimo sucessivos, foi inicialmente proposto por Jewell, Busacker e Gowen e é uma adaptação do algoritmo de Ford-Fulkerson para incorporar o custo das arestas. Em poucas palavras, ele encontra o caminho de s para t de custo mínimo, envia o máximo fluxo possível ao longo desse caminho, e repete esse processo até que não seja mais possível aumentar o fluxo sem violar as capacidades das arestas (SCHRIJVER, 2004).

Algoritmo 13: Algoritmo de caminhos de custo mínimo sucessivos (JUNGNICKEL, 2008)

```
(1)  Procedimento OPTFLOW(G, c, s, t, w, v; f, sol)
(2)      para e ∈ E faça f(e) ← 0
(3)      sol ← verdadeiro, val ← 0
(4)      enquanto sol = verdadeiro e val < v faça
(5)          construa a rede auxiliar N' = (G', c', s, t) com função de custo w'
(6)          se t não é alcançável a partir de s em G' então
(7)              sol ← falso
(8)          senão
(9)              determine um caminho mínimo P de s a t em (G', w')
(10)             δ ← min{c'(e) : e ∈ P}; δ' ← min(δ, v − val); val ← val + δ'
(11)             aumente f ao longo de P em δ'
(12)         fim
(13)     fim
```

O procedimento recebe a rede G com capacidades c, fonte s, sorvedouro t e custos w, além do valor de fluxo desejado v; devolve o fluxo f e o indicador sol, que diz se esse valor pôde ser atingido. As linhas do Algoritmo 13 funcionam da seguinte forma (JUNGNICKEL, 2008):

a) linhas 2–3: o fluxo começa nulo em todos os arcos, o que já é um fluxo de custo mínimo para o valor 0; val guarda o valor do fluxo atual;

b) linha 4: cada iteração aumenta o valor do fluxo, até atingir v ou até se descobrir que isso é impossível;

c) linha 5: constrói a rede auxiliar (residual) N'. Para cada arco (x, y) com $f(x, y) < c(x, y)$, há um arco (x, y) com capacidade residual $c(x, y) - f(x, y)$ e custo $w(x, y)$; para cada arco com $f(x, y) > 0$, há um arco reverso (y, x) com capacidade $f(x, y)$ e custo $-w(x, y)$, que representa a possibilidade de desfazer fluxo e recuperar seu custo;

d) linhas 6–7: se t não é alcançável a partir de s na rede auxiliar, o fluxo atual é máximo e o valor v não pode ser atingido; o algoritmo para com sol $=$ falso;

e) linha 9: encontra o caminho P de menor custo de s a t na rede auxiliar. Como há arcos de custo negativo, o método usado aqui precisa tratá-los (ver as opções a seguir);

f) linha 10: δ é a menor capacidade residual do caminho, o máximo que se pode enviar por ele; δ' limita esse valor ao que ainda falta para atingir v;

g) linha 11: aumenta o fluxo em δ' nos arcos de P que são arcos originais e o diminui nos que são reversos. Como P é um caminho mínimo, o novo fluxo continua sendo de custo mínimo para o seu valor, o que garante a otimalidade ao final;

h) **complexidade:** na redução do problema de atribuição, todas as capacidades são 1 e $v = n$, de modo que cada iteração envia uma unidade de fluxo e há no máximo n iterações. O custo de cada uma é dominado pela busca do caminho mínimo da linha 9; com Bellman-Ford, ela custa $O(VE)$, o que resulta em $O(nVE) \subseteq O(V^2E)$.

A complexidade do algoritmo é dependente do método utilizado para encontrar o caminho P. A implementação padrão utilizaria o algoritmo de Dijkstra, que tem uma complexidade de $O(E + V \log V)$ em uma implementação com filas de prioridade (Algoritmo 1), onde V é o número de vértices e E o número de arestas. Porém, como o grafo residual pode conter arestas com custos negativos, essa implementação não funcionaria corretamente. Para contornar esse problema, há duas opções principais:

a) **utilizar Bellman-Ford:** a solução mais simples e direta é utilizar, ao invés do algoritmo de Dijkstra, o algoritmo de Bellman-Ford para encontrar o caminho de custo mínimo P. O Bellman-Ford é mais lento, com uma complexidade de $O(VE)$ (Algoritmo 2), mas lida corretamente com arestas de custo negativo;

b) **utilizar a técnica de potenciais:** permite usar o algoritmo de Dijkstra mesmo na presença de arestas de custo negativo.

   A cada iteração do laço, encontra-se o caminho de custo mínimo P utilizando Dijkstra com os custos reduzidos. Após encontrar o caminho, os potenciais são atualizados para todos os vértices v alcançáveis a partir de s no grafo residual, ajustando-os conforme a distância mínima encontrada pelo Dijkstra, de acordo com a fórmula $h(v) \leftarrow h(v) + d(s, v)$, onde $d(s, v)$ é a distância mínima de s até v no grafo residual com custos reduzidos.

O Algoritmo 14 é uma adaptação do Algoritmo 13 que utiliza a técnica de potenciais:

Algoritmo 14: Adaptação do Algoritmo 13 utilizando Dijkstra com a técnica de potenciais (JUNGNICKEL, 2008; AHUJA; MAGNANTI; ORLIN, 1993)

```
(1)  Procedimento OPTFLOW_DIJKSTRA(G, c, s, t, w, v; f, sol)
(2)      para e ∈ E faça  f(e) ← 0
(3)      para x ∈ V faça  h(x) ← 0
(4)      sol ← verdadeiro, val ← 0
(5)      enquanto sol = verdadeiro e val < v faça
(6)          construa a rede auxiliar N' = (G', c', s, t)
(7)          para e = (u, v) ∈ E(G') faça
(8)              custo reduzido: w̄(e) ← w(e) + h(u) − h(v)
(9)          fim
(10)         execute Dijkstra em N' com os pesos w, obtendo as distâncias
              mínimas d(·) a partir de s
(11)         se t não é alcançável a partir de s (isto é, d(t) = ∞) então
(12)             sol ← falso
(13)         senão
(14)             para x ∈ V tal que d(x) < ∞ faça  h(x) ← h(x) + d(x)
(15)             identifique o caminho mínimo P de s a t a partir de d(·)
(16)             δ ← min{c'(e) : e ∈ P}; δ' ← min(δ, v − val); val ← val + δ'
(17)             aumente f ao longo de P em δ'
(18)         fim
(19)     fim
```

A estrutura é a mesma do Algoritmo 13; as diferenças estão no cálculo do caminho mínimo:

a) linhas 2–4: além do fluxo nulo, os potenciais h começam em 0. Isso é válido porque, na rede inicial, só há arcos originais, cujos custos de atribuição são não negativos;

b) linhas 5–6: como no Algoritmo 13, a cada iteração constrói-se a rede auxiliar, com seus arcos reversos de custo negativo;

c) linhas 7–8: cada arco (u, v) da rede auxiliar recebe o custo reduzido $\bar{w}(e) = w(e) + h(u) - h(v)$. Como os potenciais são as distâncias da iteração anterior, que respeitam a desigualdade triangular, esses custos são não negativos, inclusive nos arcos reversos;

d) linha 10: executa Dijkstra com os custos reduzidos, o que é correto por eles serem não negativos. Em todo caminho de s a t, os potenciais intermediários se cancelam, e o custo reduzido difere do custo original apenas pela constante $h(s) - h(t)$. Por isso, o caminho mínimo é o mesmo nos dois custos;

e) linhas 11–12: se $d(t) = \infty$, t não é alcançável e o algoritmo para, como antes;

f) linha 14: os potenciais dos vértices alcançados são somados às distâncias encontradas. Com isso, os arcos do caminho mínimo passam a ter custo reduzido 0, e os arcos reversos criados pelo aumento também, o que mantém os custos reduzidos não negativos na próxima iteração;

g) linhas 15–17: o caminho é recuperado a partir das distâncias, e o aumento do fluxo segue exatamente as linhas 10–11 do Algoritmo 13.

A complexidade do algoritmo utilizando Dijkstra com a técnica de potenciais é $O(V(E + V \log V))$, onde V é o número de vértices e E o número de arestas do grafo. Isso ocorre porque, em cada iteração do laço principal, executa-se o algoritmo de Dijkstra, que tem complexidade $O(E + V \log V)$ com filas de prioridade (*heap* de Fibonacci), e o cálculo dos custos reduzidos e a atualização dos potenciais custam apenas $O(E)$ e $O(V)$. O número de iterações é limitado pelo valor do fluxo, $v = n$, que no problema de atribuição não passa de V, o número de vértices do grafo bipartido.

3.2.3 Heurísticas

Assim como no problema de emparelhamento de cardinalidade máxima, as soluções exatas, apesar de apresentarem tempo polinomial, se tornam extremamente lentas para instâncias muito grandes. A seguir algumas heurísticas que objetivam resolver o problema de atribuição em tempo próximo do linear.

3.2.3.1 Heurística gulosa ordenada

Similar ao método guloso simples descrito na seção 3.1.3.1, com a diferença de que a ordem das arestas não é mais arbitrária, e sim decrescente por peso (ou crescente por custo, na atribuição de custo mínimo). A ordenação das arestas custa $O(E \log E)$; a passada seguinte é a do guloso simples, que examina cada aresta uma vez e, com um vetor de marcas, custa $O(V + E)$. A ordenação domina, e o total é $O(E \log E)$.

Diferentemente do problema de peso máximo (Seção 4.2.5), porém, na atribuição de custo mínimo o método não tem garantia de aproximação. Como a solução precisa ser um emparelhamento perfeito, as arestas baratas escolhidas no início podem obrigar o uso de arestas arbitrariamente caras no final. Por exemplo, na matriz de custos $\begin{bmatrix} 0 & 1 \\ 1 & K \end{bmatrix}$, o método escolhe primeiro a aresta de custo 0 e é forçado a completar a atribuição com a de custo K, enquanto o ótimo custa 2; a razão $K/2$ cresce sem limite com K. Por isso, nesse problema, o método é classificado como heurística (Seção 2.7).

Tabela 2 – Algoritmos para problema de atribuição

Algoritmo	**Complexidade**	**Tipo**	**Avaliado**	**Descrição**
Método Húngaro	$O(n^3)$	Exato	Sim	Método primal-dual que mantém folga complementar para custo mínimo em bipartidos.
Jonker-Volgenant	$O(n^3)$	Exato	Sim	Algoritmo primal-dual eficiente que combina redução de custos inicial e busca de caminhos aumentantes com atualização otimizada de duais.
Custo mínimo (Bellman-Ford)	$O(V^2E)$	Exato	Sim	Método de caminhos sucessivos que usa Bellman-Ford para encontrar caminhos na rede residual, suportando custos negativos iniciais.
Custo mínimo (Dijkstra)	$O(V(E + V \log V))$	Exato	Não	Utiliza potenciais de vértices para manter custos reduzidos não-negativos, permitindo o uso do eficiente Dijkstra para aumentos sucessivos.
Gulosa ordenada	$O(E \log E)$	Heur.	Não	Ordena as arestas por peso decrescente e seleciona iterativamente as disponíveis.

Fonte: Elaborado pelo autor.

Heur.: heurística. *Avaliado*: incluído no ambiente de testes; a origem de cada implementação consta na Tabela 10. As complexidades são justificadas no texto de cada algoritmo.

3.3 PROBLEMA DE ATRIBUIÇÃO GARGALO

O problema de atribuição gargalo, também conhecido como **Problema de Emparelhamento Min-Max** ou ***Bottleneck Assignment Problem***, é uma variação do problema de atribuição (Seção 3.2). Em vez da soma dos custos, minimiza-se o maior deles: dada uma matriz de custos $C = (c_{ij})$ de ordem n, procura-se uma atribuição, isto é, um emparelhamento perfeito no grafo bipartido correspondente, cujo maior custo, chamado de **gargalo**, seja o menor possível (BURKARD; DELL'AMICO; MARTELLO, 2009).

Por exemplo, considere n tarefas e n máquinas que trabalham em paralelo, em que c_{ij} é o tempo que a máquina j leva para concluir a tarefa i. Como todas as tarefas só ficam prontas quando a mais demorada termina, o objetivo é atribuir as tarefas às máquinas de forma a minimizar o maior tempo, e não a soma dos tempos (BURKARD; DELL'AMICO; MARTELLO, 2009). Há também a versão de maximização, em que se maximiza o menor peso, como na escolha de trabalhadores para estações de uma linha de produção cuja eficiência é limitada pelo trabalhador menos eficiente (LAWLER, 1976). As duas versões são equivalentes, pois a solução ótima depende apenas da ordem relativa dos custos, e basta inverter essa ordem, por exemplo trocando o sinal

dos pesos, para passar de uma à outra (BURKARD; DELL'AMICO; MARTELLO, 2009). Este trabalho adota a versão de minimização, seguida pelos algoritmos a seguir.

3.3.1 Soluções exatas

A seguir serão apresentadas alguns dos principais métodos para encontrar uma solução exata para o problema de atribuição gargalo.

3.3.1.1 Métodos de *threshold*

Métodos de *threshold* funcionam alternando entre duas fases. A primeira fase consiste em selecionar um valor limite, chamado de ***threshold***, descrito por $c*$. Na segunda fase, constrói-se um grafo bipartido com todas as arestas cujo peso é menor ou igual a $c*$. Em seguida, verifica-se se existe um emparelhamento perfeito nesse grafo. O menor valor de $c*$ que permite um emparelhamento perfeito é a solução ótima para o problema de atribuição gargalo (BURKARD; DELL'AMICO; MARTELLO, 2009).

Para selecionar o valor limite $c*$, pode-se usar uma busca binária entre o menor e o maior peso das arestas do grafo original. A cada iteração, o valor de $c*$ é ajustado com base na existência ou não de um emparelhamento perfeito no grafo construído. Esse processo continua até que o valor ótimo seja encontrado. Burkard, Dell'Amico e Martello (2009), que descreve esse método, utiliza um algoritmo baseado em matrizes para decidir se um emparelhamento é perfeito ou não, porém qualquer algoritmo clássico de emparelhamento em grafos bipartidos, como os definidos na seção 3.1.2, como o de Hopcroft-Karp, pode ser usado. Para uma matriz de custos $n \times n$, as técnicas descritas pelo autor levam o algoritmo a uma complexidade de tempo $O(n^{2.5}/\sqrt{\log n})$; a versão com Hopcroft-Karp apresentada a seguir tem complexidade $O(n^{2.5} \log n)$.

Lawler (1976) menciona um método de *threshold* para solução do problema de atribuição gargalo, porém a definição de *threshold* dele é levemente diferente, referindo-se ao valor dinâmico do rótulo de um vértice durante busca de caminhos. O algoritmo que ele descreve se assemelha mais aos algoritmos de caminhos aumentantes, que serão discutidos na seção 3.3.1.3.

Algoritmo 15: Algoritmo *threshold* para o LBAP (BURKARD; DELL'AMICO; MARTELLO, 2009)

(1) **seja** $C = (c_{ij})$ a matriz de custos $n \times n$ dada;
(2) $c_0^* := \min_{ij}\{c_{ij}\}, c_1^* := \max_{ij}\{c_{ij}\}$
(3) **se** $c_0^* = c_1^*$ **então**
(4) | $z := c_0^*$ **[comentário: qualquer permutação de** $\{1, 2, \ldots, n\}$ **é ótima]**
(5) **senão**
(6) | **enquanto** $C^* = \{c_{ij} : c_0^* < c_{ij} < c_1^*\} \neq \emptyset$ **faça**
(7) | | **[comentário: encontra a mediana** c^* **de** C^***;]**
(8) | | $c^* := \min\{c \in C^* : |\{c_{ij} \in C^* : c_{ij} \leq c\}| \geq |C^*|/2\}$;
(9) | | Testa_viabilidade(c^*, c_0^*, c_1^*)
(10) | **fim**
(11) | **se** *Testa_viabilidade ainda não foi executado para* c_0^* **então**
(12) | | Testa_viabilidade(c_0^*, c_0^*, c_1^*)
(13) | **fim**
(14) | encontre um emparelhamento perfeito no grafo bipartido atual $G[c_1^*]$
(15) | $z := c_1^*$ **[comentário: valor do emparelhamento ótimo]**
(16) **fim**

(17) **Procedimento** *Testa_viabilidade*(c^*, c_0^*, c_1^*)
(18) | construa o grafo atual $G[c^*]$
(19) | **se** $G[c^*]$ *contém um emparelhamento perfeito* **então**
(20) | | $c_1^* := c^*$
(21) | **senão**
(22) | | $c_0^* := c^*$
(23) | **fim**

O pseudocódigo segue a formulação de Burkard, Dell'Amico e Martello (2009), que minimiza o maior custo c_{ij} da atribuição, e é explicado a seguir com referência às linhas do Algoritmo 15. Nele, $G[c]$ denota o grafo bipartido que contém apenas as arestas $\{i, j\}$ com $c_{ij} \leq c$:

a) **inicialização (linhas 1–4):** o ótimo está sempre entre o menor e o maior custo da matriz, que formam o intervalo inicial de busca $[c_0^*, c_1^*]$ (linha 2). O algoritmo mantém a invariante de que $G[c_1^*]$ contém um emparelhamento perfeito, o que vale de início porque $G[\max c_{ij}]$ é o grafo bipartido completo. Se os dois extremos coincidem (linha 3), todos os custos são iguais e qualquer permutação é ótima (linha 4);

b) **busca binária (linhas 6–9):** enquanto existirem custos estritamente entre os dois extremos (conjunto C^* da linha 6), escolhe-se a mediana c^* desses custos como novo limiar (linha 8) e testa-se esse limiar (linha 9). Usar a mediana, em vez da média dos extremos, garante que cada teste descarte pelo menos metade dos valores candidatos, independentemente de como os custos estão distribuídos;

c) **teste de viabilidade (linhas 18–22):** o procedimento Testa_viabilidade

constrói $G[c^*]$ (linha 18) e verifica se ele tem um emparelhamento perfeito (linha 19), o que pode ser feito com qualquer algoritmo de cardinalidade máxima, como o de Hopcroft-Karp. Se tem, o ótimo é no máximo c^*, e o extremo superior desce para c^* (linha 20); caso contrário, o ótimo é maior que c^*, e o extremo inferior sobe para c^* (linha 22);

d) **finalização (linhas 11–15):** quando C^* fica vazio, o ótimo é c_0^* ou c_1^*. Como c_0^* pode nunca ter sido testado (é o mínimo inicial da matriz), ele é testado nesse momento, se necessário (linha 11); se for viável, o teste rebaixa c_1^* para ele. Por fim, extrai-se um emparelhamento perfeito de $G[c_1^*]$ (linha 14), cujo valor ótimo é $z = c_1^*$ (linha 15);

e) **complexidade:** há no máximo n^2 custos distintos e cada teste descarta metade dos candidatos, de modo que o laço executa $O(\log n^2) = O(\log n)$ vezes. Cada iteração encontra a mediana em tempo linear no tamanho de C^*, $O(n^2)$, e faz um teste de emparelhamento perfeito, que custa $O(E\sqrt{V}) = O(n^{2.5})$ com Hopcroft-Karp, já que $G[c^*]$ tem $2n$ vértices e até n^2 arestas. O total é $O(n^{2.5} \log n)$. O limite de $O(n^{2.5}/\sqrt{\log n})$ citado por Burkard, Dell'Amico e Martello (2009) exige técnicas mais elaboradas: o valor ótimo é localizado com testes baseados em multiplicação de matrizes, e o emparelhamento final é obtido com um algoritmo de cardinalidade máxima mais rápido que o Hopcroft-Karp em grafos densos.

3.3.1.2 Método dual

Assim como os métodos de *threshold*, o método dual também define um valor limite $c*$. No entanto, ao invés de 'chutar' um valor usando busca binária, este método define o valor inicial de $c*$ como sendo o menor valor possível que ele pode assumir. Olhando para a matriz de custos, esse valor é o máximo entre os mínimos de cada linha e cada coluna da matriz:

$$c* = \max \left\{ \max_i (\min_j c_{ik}), \max_j (\min_i c_{kj}) \right\} \tag{3.8}$$

Com o limite definido, verifica-se se é possível encontrar um emparelhamento perfeito no grafo bipartido formado pelas arestas cujo peso é menor ou igual a $c*$, usando os mesmos algoritmos de antes. Se um emparelhamento perfeito for encontrado, então $c*$ é a solução ótima. Caso contrário, é necessário aumentar o valor de $c*$, e para isso usa-se o teorema de Kőnig, definido na seção 3.1.1.3.

Todas as arestas $c_{ij} > c*$ estão conectadas a um conjunto de linhas I e um conjunto de colunas J. Essas linhas e colunas "cobrem" todas as arestas do grafo atual. Para aumentar o valor de $c*$, é preciso adicionar uma nova aresta que não esteja

coberta por esses conjuntos. Procura-se o menor peso entre as arestas não cobertas, ou seja, aquelas que não pertencem às linhas em I nem às colunas em J. Esse valor se torna o novo $c*$:

$$Novoc* = \min_{i \notin I, j \notin J} c_{ij} \tag{3.9}$$

A partir daqui, o processo se repete. Com o novo valor de $c*$ e a nova aresta adicionada ao grafo, verifica-se novamente a existência de um emparelhamento perfeito. Esse ciclo continua até que um emparelhamento perfeito seja encontrado, momento em que o valor atual de $c*$ será a solução ótima para o problema de atribuição gargalo.

Algoritmo 16: Dual_LBAP: algoritmo dual para o LBAP (BURKARD; DELL'AMICO; MARTELLO, 2009)

```
(1)  seja C = (c_ij) a matriz de custos n × n dada;
(2)  c* := max_{k=1,2,...,n}(min_{i=1,2,...,n} c_ik, min_{j=1,2,...,n} c_kj)
(3)  M := ∅
(4)  enquanto |M| < n faça
(5)      construa o grafo bipartido G[c*]
(6)      encontre um emparelhamento máximo M em G[c*]
(7)      se |M| < n então
(8)          seja I ⊆ U e J ⊆ V os conjuntos de vértices de uma cobertura
              mínima de G[c*]
(9)          c* := min_{i∉I, j∉J} c_ij
(10)     fim
(11) fim
```

Com referência às linhas do Algoritmo 16:

a) **limite inferior (linhas 1–3):** toda linha i precisa ser atribuída a alguma coluna, então o ótimo é pelo menos o menor custo dessa linha; o mesmo vale para cada coluna. O maior desses mínimos é, portanto, um limite inferior para o ótimo e é o valor inicial de c^* (linha 2). O emparelhamento começa vazio (linha 3);

b) **teste do limiar (linhas 4–6):** enquanto o emparelhamento não for perfeito (linha 4), constrói-se o grafo $G[c^*]$ com as arestas de custo até c^* (linha 5) e calcula-se nele um emparelhamento máximo (linha 6). Se esse emparelhamento tiver n arestas, o laço termina e c^* é o valor ótimo, porque nenhum valor menor que o atual foi viável;

c) **aumento do limiar (linhas 7–9):** se o emparelhamento não é perfeito (linha 7), toma-se uma cobertura mínima de vértices de $G[c^*]$, formada pelas linhas I e colunas J (linha 8); pelo teorema de Kőnig, ela tem exatamente $|M| < n$ vértices. Só uma aresta fora da cobertura, isto é, com $i \notin I$ e $j \notin J$, pode aumentar o emparelhamento máximo, então o novo limiar é o menor

custo entre essas arestas (linha 9). Como nenhum valor intermediário pode tornar o emparelhamento perfeito, o limiar nunca ultrapassa o ótimo;

d) **complexidade:** o limiar cresce estritamente a cada iteração e só assume valores da matriz, de modo que há no máximo n^2 iterações; cada uma calcula um emparelhamento máximo e uma cobertura mínima de vértices em um grafo com $2n$ vértices e até n^2 arestas. Reaproveitando o emparelhamento da iteração anterior, que continua válido em $G[c^*]$ após o aumento do limiar, cada iteração precisa apenas de uma busca alternante a partir dos vértices livres, em $O(n^2)$, que encontra um caminho aumentante ou, se não houver, a cobertura mínima. Isso dá um limite simples de $O(n^4)$ para o método.

O método dual não foi implementado no ambiente de testes deste trabalho. Para o problema de atribuição gargalo, foram comparados o algoritmo de *threshold* (Algoritmo 15) e o método de caminhos aumentantes (Algoritmo 17), descrito a seguir.

3.3.1.3 Método de caminhos aumentantes

Ao contrário do método dual, que ajusta um limiar global para todo o grafo, o método de caminhos aumentantes é construtivo. Ele inicia com um emparelhamento vazio e busca aumentar sua cardinalidade iterativamente, adicionando um par de vértices de cada vez. O objetivo central em cada passo é encontrar um caminho aumentante P que conecte uma linha livre a uma coluna livre, de tal forma que a capacidade desse caminho seja mínima. A capacidade aqui é definida pelo peso da aresta mais cara contida no caminho:

$$cap(P) = \max_{\{i,j\} \in P} c_{ij} \tag{3.10}$$

Para encontrar tal caminho, utiliza-se uma adaptação do algoritmo de Dijkstra. Em vez de somar os pesos das arestas, mantém-se para cada vértice um valor de rótulo que representa o “gargalo” mínimo necessário para alcançá-lo. Durante a busca, ao tentar estender o caminho de um nó u (com rótulo d_u) para um vizinho v através da aresta $\{u, v\}$, o custo não é somado, mas sim comparado. O novo custo potencial para atingir v é o máximo entre o gargalo já existente até u e o peso da nova aresta:

$$NovoCusto_v = \max(d_u, c_{uv}) \tag{3.11}$$

O algoritmo seleciona, a cada passo, o nó não visitado com o menor rótulo atual, garantindo uma exploração gulosa que minimiza o gargalo. Assim que uma coluna livre é alcançada por essa busca, o caminho aumentante é identificado e o emparelhamento é expandido, invertendo-se as arestas ao longo do caminho. Esse

processo se repete (reiniciando as distâncias) até que um emparelhamento perfeito seja obtido. A solução do problema será determinada pela maior capacidade encontrada entre todos os caminhos aumentantes utilizados na construção.

Algoritmo 17: LBAP usando caminhos aumentantes (BURKARD; DELL'AMICO; MARTELLO, 2009)

(1) **seja** $G = (U, V; E)$ um grafo bipartido com custos c_{ij} nas arestas $[i, j] \in E$;
(2) encontre um limite inferior c^* para o valor ótimo da função objetivo;
(3) **[comentário: por exemplo,** $c^* := \max(\max_{i \in U} \min_{j \in V} c_{ij},\ \max_{j \in V} \min_{i \in U} c_{ij})$**]**
(4) encontre um emparelhamento máximo M no grafo $G[c^*]$, que tem a aresta $[i, j]$ **se e somente se** $c_{ij} \leq c^*$;
(5) **se** $|M| = |U|$ **então**
(6) | **pare [comentário:** M **é um emparelhamento ótimo de custo** c^***]**
(7) **senão**
(8) | **seja** L o conjunto dos vértices livres de U
(9) **fim**
(10) **enquanto** L *não é vazio* **faça**
(11) | escolha um vértice arbitrário $i \in L$;
(12) | $L := L \setminus \{i\}$;
(13) | Dijkstra(i); **[comentário: o procedimento retorna um caminho** P **que começa em** i**]**
(14) | **se** $P \neq \text{nulo}$ **então**
(15) | | $M := M \ominus P$;
(16) | | $c^* := \max(c^*, \ell(P))$
(17) | **fim**
(18) **fim**
(19) **[comentário:** M **é um emparelhamento máximo de custo mínimo** c^***.]**

Com referência às linhas do Algoritmo 17:

a) **ponto de partida (linhas 1–8):** calcula-se um limite inferior c^* para o ótimo (linha 2), o mesmo do método dual: o maior entre os menores custos de cada linha e de cada coluna. Como arestas de custo até c^* não pioram a solução, encontra-se de uma vez um emparelhamento máximo em $G[c^*]$ (linha 4), com qualquer algoritmo de cardinalidade máxima. Se ele já é perfeito (linha 5), o limite inferior foi atingido e a solução é ótima; senão, L recebe os vértices de U que ficaram livres (linha 8);

b) **laço de aumentos (linhas 10–13):** cada vértice livre $i \in L$ é retirado de L uma única vez (linha 11) e, a partir dele, o procedimento Dijkstra (Algoritmo 18) busca o caminho aumentante de menor gargalo, isto é, aquele cuja aresta mais cara é a mais barata possível (linha 13);

c) **atualização (linhas 14–16):** se existe caminho (linha 14), o emparelhamento é aumentado pela diferença simétrica com ele (linha 15) e o valor da solução passa a ser o maior entre o valor atual e o gargalo $\ell(P)$ do caminho usado

(linha 16). Como cada caminho escolhido tem o menor gargalo possível, o valor final c^* é o ótimo;

d) **complexidade:** o emparelhamento inicial custa no máximo $O(n^{2.5})$ com Hopcroft-Karp. O laço executa no máximo n vezes, uma por vértice livre, e cada chamada do Dijkstra modificado custa $O(n^2)$ em uma matriz densa (ver a seguir), de modo que o total é $O(n^3)$.

Algoritmo 18: Dijkstra modificado para caminhos aumentantes em LBAP (BURKARD; DELL'AMICO; MARTELLO, 2009)

```
(1)  Procedimento Dijkstra(i)
(2)      rotule todo vértice j ∈ V com (α(j), β(j)) := (∞, nulo);
(3)      R := V; [comentário: R contém os vértices de V ainda não
          examinados]
(4)      ᾱ(i) := c*, P := nulo;
(5)      Rotula(i);
(6)      enquanto R ≠ ∅ faça
(7)          encontre um vértice j1 ∈ R com α(j1) mínimo;
(8)          se α(j1) = ∞ então
(9)              R := ∅
(10)         senão
(11)             se j1 está livre então
(12)                 obtenha o caminho P dado pela sequência
                      (i, ..., β̄(β(j1)), β(j1), j1);
(13)                 ℓ(P) := α(j1);
(14)                 R := ∅
(15)             senão
(16)                 seja [i1, j1] a aresta do emparelhamento;
(17)                 rotule i1 com (ᾱ(i1), β̄(i1)) = (α(j1), j1);
(18)                 R := R \ {j1};
(19)                 Rotula(i1);
(20)             fim
(21)         fim
(22)     fim

(23) Procedimento Rotula(i)
(24)     para cada vizinho j ∈ R de i faça
(25)         se α(j) > max(ᾱ(i), cij) então
(26)             α(j) := max(ᾱ(i), cij);
(27)             β(j) := i
(28)         fim
(29)     fim
```

O procedimento mantém dois rótulos para cada vértice: para $j \in V$, $\alpha(j)$ é o menor gargalo conhecido de um caminho alternante de i até j, e $\beta(j)$ é o vértice de U que o precede nesse caminho; para $i' \in U$, $\overline{\alpha}(i')$ e $\overline{\beta}(i')$ têm o mesmo papel. Com referência às linhas do Algoritmo 18:

a) **inicialização (linhas 2–5):** todos os vértices de V começam com gargalo infinito e sem predecessor (linha 2) e ficam no conjunto R dos ainda não examinados (linha 3). A raiz i recebe o gargalo c^* (linha 4), e não 0, porque arestas de custo até o valor atual da solução não a pioram; assim, entre caminhos de mesmo efeito sobre o resultado, qualquer um serve. Em seguida, os vizinhos de i são rotulados (linha 5);

b) **escolha do próximo vértice (linhas 6–8):** como no Dijkstra tradicional, escolhe-se o vértice de R de menor rótulo (linha 7). Se esse rótulo é infinito (linha 8), nenhum vértice restante é alcançável a partir de i, a busca termina e o caminho retornado é $P = \mathrm{nulo}$;

c) **coluna livre encontrada (linhas 11–13):** se j_1 não está emparelhado (linha 11), o caminho aumentante foi encontrado. Ele é reconstruído de trás para frente, seguindo os predecessores β e $\overline{\beta}$ até i (linha 12), e seu gargalo é o rótulo de j_1 (linha 13);

d) **extensão pela aresta emparelhada (linhas 16–19):** se j_1 está emparelhado com i_1 (linha 16), o caminho alternante segue obrigatoriamente pela aresta $\{i_1, j_1\}$, que já pertence ao emparelhamento e não altera o gargalo. Por isso, i_1 herda o rótulo de j_1 e o tem como predecessor (linha 17); j_1 sai de R e os vizinhos de i_1 são rotulados (linha 19);

e) **procedimento Rotula (linhas 24–27):** para cada vizinho j de i ainda em R (linha 24), o gargalo de chegar a j por i é o maior entre o gargalo até i e o custo c_{ij}. Se esse valor é menor que o rótulo atual de j (linha 25), o rótulo é atualizado e i passa a ser o predecessor de j (linha 27). É o relaxamento do Dijkstra, com o máximo no lugar da soma;

f) **complexidade:** cada vértice de V sai de R no máximo uma vez, e cada vértice de U é rotulado no máximo uma vez. Com a matriz densa, a busca do mínimo (linha 7) percorre R em $O(n)$ e cada chamada de Rotula percorre os $O(n)$ vizinhos, o que dá $O(n^2)$ por chamada do procedimento.

3.3.2 Heurísticas

Assim como na atribuição linear, os métodos gulosos para o problema de atribuição gargalo não têm garantia de aproximação e são, portanto, heurísticas (Seção 2.7). Esta seção apresenta duas heurísticas construtivas gulosas, ambas avaliadas no ambiente de testes: a simples, que serve de ponto de comparação, e a por arrependimento, que adapta o critério de escolha ao objetivo de minimizar o maior custo.

3.3.2.1 Heurística gulosa simples

A heurística gulosa simples percorre as n^2 posições da matriz de custos em ordem crescente e atribui a linha i à coluna j sempre que ambas ainda estão livres. Como a matriz é completa, o resultado é sempre uma atribuição perfeita. O defeito do método está no final do processo: as últimas linhas recebem as colunas que sobraram, cujos custos podem ser altos, e, como o objetivo é o *maior* custo da atribuição, uma única escolha ruim no fim determina o valor da solução, criando um "gargalo" que as escolhas baratas do início não compensam.

3.3.2.2 Heurística gulosa por arrependimento

A heurística por arrependimento evita esse defeito decidindo primeiro as linhas que têm mais a perder. A cada passo, para cada linha livre i, sejam $c_i^{(1)}$ e $c_i^{(2)}$ o menor e o segundo menor custo de i entre as colunas ainda livres. O **arrependimento** (*regret*) da linha é

$$r_i = c_i^{(2)} - c_i^{(1)}, \tag{3.12}$$

isto é, o quanto o custo de i aumenta se a sua melhor coluna for ocupada por outra linha. Esse valor é o *custo de oportunidade* de não lhe dar essa coluna agora. Escolhe-se a linha de maior arrependimento e ela é atribuída à sua melhor coluna livre; se só resta uma coluna livre, o arrependimento é considerado infinito, pois a linha não tem alternativa. O critério é a adaptação, para o problema de gargalo, da heurística HGAP proposta por Martello e Toth (1987) para o problema de atribuição generalizada, que a cada passo atribui a tarefa com a maior diferença entre a sua melhor e a sua segunda melhor opção.

O Algoritmo 19 apresenta as duas heurísticas.

Algoritmo 19: Heurísticas gulosas para o LBAP: simples e por arrependimento (MARTELLO; TOTH, 1987)

```
(1)  Procedimento Guloso(C)
(2)      ordene as n² posições (i, j) por c_ij crescente
(3)      para cada posição (i, j), nessa ordem faça
(4)          se a linha i e a coluna j estão livres então atribua i a j
(5)      fim
(6)      retorne a atribuição φ e seu gargalo max_i c_{iφ(i)}

(7)  Procedimento Arrependimento(C)
(8)      para cada linha i faça ordene as colunas por c_ij crescente
(9)      R := U
(10)     enquanto R ≠ ∅ faça
(11)         para cada i ∈ R faça
(12)             j_1(i), j_2(i) := primeira e segunda colunas livres na ordem da linha i
(13)             r_i := c_{ij_2(i)} − c_{ij_1(i)} [comentário: r_i := ∞ se j_2(i) não existe]
(14)         fim
(15)         i* := linha de R com r_i máximo [comentário: empate: menor c_{ij_1(i)}]
(16)         atribua i* a j_1(i*); R := R \ {i*}
(17)     fim
(18)     retorne a atribuição φ e seu gargalo max_i c_{iφ(i)}
```

O Algoritmo 19 funciona da seguinte forma:

a) **guloso simples (linhas 2–6):** as posições são ordenadas por custo (linha 2) e examinadas uma única vez, da mais barata para a mais cara (linha 3). Uma posição é aceita se sua linha e sua coluna estão livres (linha 4); uma posição rejeitada nunca é reconsiderada. O gargalo é o maior custo entre as posições aceitas (linha 6);

b) **preparação do arrependimento (linhas 8–9):** cada linha guarda suas colunas em ordem crescente de custo, e o conjunto R começa com todas as linhas;

c) **cálculo do arrependimento (linhas 11–13):** para cada linha livre, a melhor e a segunda melhor coluna livre são as duas primeiras colunas livres na sua ordem (linha 12), e o arrependimento é a diferença entre os seus custos, conforme a Equação (3.12) (linha 13);

d) **escolha (linhas 15–16):** a linha de maior arrependimento é atribuída à sua melhor coluna livre e sai de R (linha 16). Os empates são desfeitos pelo menor custo e, depois, pelo menor índice de linha;

e) **complexidade:** no guloso simples, a ordenação das n^2 posições custa $O(n^2 \log n)$ e domina a passada, que é $O(n^2)$. No guloso por arrependimento, a ordenação das linhas também custa $O(n^2 \log n)$. Como uma coluna ocu-

pada nunca volta a ficar livre, cada linha mantém um ponteiro para a sua primeira coluna livre, que só avança; o total de avanços é $O(n^2)$, e cada uma das n iterações do laço examina $O(n)$ linhas. O custo total é, portanto, $O(n^2 \log n)$ para as duas heurísticas.

Exemplo. Considere a matriz de custos

$$C = \begin{bmatrix} 3 & 8 & 6 \\ 7 & 2 & 9 \\ 5 & 1 & 4 \end{bmatrix}, \tag{3.13}$$

com linhas $1, 2, 3$ e colunas $1, 2, 3$. O guloso simples escolhe primeiro a posição mais barata, $(3, 2)$, de custo 1. A posição seguinte, $(2, 2)$, de custo 2, é rejeitada, pois a coluna 2 já está ocupada; aceita-se então $(1, 1)$, de custo 3. Restam apenas a linha 2 e a coluna 3, e a atribuição termina com $(2, 3)$, de custo 9, que é o gargalo da solução.

O guloso por arrependimento calcula, no primeiro passo, $r_1 = 6 - 3 = 3$, $r_2 = 7 - 2 = 5$ e $r_3 = 4 - 1 = 3$. A linha 2 é a que mais perde se não ficar com a coluna 2 e é atribuída a ela, com custo 2. No segundo passo, com as colunas 1 e 3 livres, $r_1 = 6 - 3 = 3$ e $r_3 = 5 - 4 = 1$, e a linha 1 recebe a coluna 1, com custo 3. Por fim, a linha 3 recebe a coluna 3, com custo 4. O gargalo é 4, que é ótimo: toda atribuição usa uma posição da coluna 3, cujo menor custo é 4, de modo que nenhuma atribuição tem gargalo menor.

O exemplo mostra por que o critério funciona: a linha 3 também preferia a coluna 2, mas tinha uma alternativa barata (a coluna 3, de custo 4), enquanto a linha 2 não tinha. Ainda assim, o critério olha apenas um passo à frente e não oferece garantia: há matrizes em que também ele termina com um gargalo alto, como mostram os resultados do Capítulo 6.

Tabela 3 – Algoritmos para problema de atribuição gargalo

Algoritmo	**Complexidade**	**Tipo**	**Avaliado**	**Descrição**
Threshold	$O(n^{2.5} \log n)$	Exato	Sim*	Aplica busca binária sobre os pesos das arestas, testando a existência de emparelhamento perfeito no subgrafo restrito ao limiar.
Método Dual	$O(n^4)$	Exato	Não	Expande um limiar inferior iterativamente baseado no Teorema de Kőnig, adicionando apenas arestas necessárias para cobrir componentes.
Caminhos aumentantes	$O(n^3)$	Exato	Sim	Abordagem construtiva que busca caminhos aumentantes minimizando a aresta de peso máximo (gargalo) no trajeto (variação de Dijkstra).
Gulosa simples	$O(n^2 \log n)$	Heur.	Sim	Percorre as posições em ordem crescente de custo, atribuindo linha e coluna quando ambas estão livres.
Gulosa por arrependimento	$O(n^2 \log n)$	Heur.	Sim	A cada passo, atribui a linha com a maior diferença entre a melhor e a segunda melhor coluna livre à sua melhor coluna.

Fonte: Elaborado pelo autor.

Heur.: heurística. *Avaliado*: incluído no ambiente de testes; a origem de cada implementação consta na Tabela 10. As complexidades são justificadas no texto de cada algoritmo. * A implementação avaliada testa cada limiar por caminhos aumentantes, com custo $O(n^3)$ por teste e $O(n^3 \log n)$ no total; com técnicas mais elaboradas, o limite cai para $O(n^{2.5}/\sqrt{\log n})$ (BURKARD; DELL'AMICO; MARTELLO, 2009).

3.4 PROBLEMA DO EMPARELHAMENTO ESTÁVEL

O problema do emparelhamento estável, também conhecido como *Stable Marriage Problem* (SMP), é um problema clássico na teoria dos grafos e na ciência da computação, proposto inicialmente por Gale e Shapley em 1962 (KLEINBERG; TARDOS, 2005). Ele envolve a combinação de dois conjuntos distintos de elementos e, apesar de semelhante aos problemas de emparelhamento em grafos bipartidos estudados anteriormente, possui características e objetivos diferentes.

Imagine dois conjuntos distintos de mesmo tamanho, N homens e N mulheres. Cada indivíduo em ambos os conjuntos tem uma lista de preferências ordenadas para todos os membros do outro conjunto. O objetivo do SMP é encontrar um emparelhamento entre homens e mulheres de tal forma que não existam dois indivíduos, um homem e uma mulher, que prefeririam estar juntos em vez de com seus parceiros atuais. Se tal par existir, o emparelhamento é considerado instável.

O problema pode ser resolvido utilizando o algoritmo de Gale-Shapley, que usa um processo iterativo de propostas e rejeições para garantir que o emparelhamento

final seja estável.

3.4.1 Propriedades

a) **estabilidade:** um emparelhamento é estável se não houver dois indivíduos que prefeririam estar juntos em vez de com seus parceiros atuais. A estabilidade é a característica central do problema (LAWLER, 1976);

b) **existência de solução:** Gale e Shapley provaram que sempre existe pelo menos um emparelhamento estável para qualquer conjunto de preferências (AHUJA; MAGNANTI; ORLIN, 1993);

c) **otimalidade para quem propõe:** o emparelhamento resultante do algoritmo de Gale-Shapley é ótimo para o conjunto que faz as propostas (por exemplo, os homens), significando que cada indivíduo nesse conjunto recebe o melhor parceiro possível dentro dos emparelhamentos estáveis (AHUJA; MAGNANTI; ORLIN, 1993);

d) **pessimismo para quem recebe propostas:** por outro lado, o emparelhamento é o pior possível para o conjunto que recebe as propostas (por exemplo, as mulheres), significando que cada indivíduo nesse conjunto recebe o pior parceiro possível dentro dos emparelhamentos estáveis (AHUJA; MAGNANTI; ORLIN, 1993);

e) **não-unicidade:** pode haver múltiplos emparelhamentos estáveis para um dado conjunto de preferências, dependendo das listas de preferências dos indivíduos (KLEINBERG; TARDOS, 2005).

3.4.2 Algoritmo de Gale-Shapley

A solução clássica para o problema do emparelhamento estável é o algoritmo de Gale-Shapley, também conhecido como o algoritmo de casamento estável. O algoritmo funciona sob a lógica de propostas e rejeições, onde um dos conjuntos (por exemplo, os homens) faz propostas às mulheres com base em suas listas de preferências.

O Algoritmo 20 apresenta o pseudocódigo, em que M é o conjunto dos homens e W o das mulheres, cada um com n elementos:

Algoritmo 20: Algoritmo de Gale-Shapley para o problema do emparelhamento estável (KLEINBERG; TARDOS, 2005)

```
(1)  inicialmente, todo m ∈ M e toda w ∈ W estão livres
(2)  enquanto existe um homem m livre que ainda não propôs a todas as
       mulheres faça
(3)      escolha um tal homem m
(4)      seja w a mulher mais bem colocada na lista de m a quem m ainda não
           propôs
(5)      se w está livre então
(6)          (m, w) ficam noivos
(7)      senão
(8)          w está noiva de m'
(9)          se w prefere m' a m então
(10)             m continua livre
(11)         senão
(12)             (m, w) ficam noivos
(13)             m' fica livre
(14)         fim
(15)     fim
(16) fim
(17) retorne o conjunto S dos pares noivos
```

O algoritmo funciona sob a lógica de propostas e rejeições (KLEINBERG; TARDOS, 2005):

a) linha 1: todos começam livres, sem nenhum par formado;

b) linhas 2–3: enquanto houver um homem m livre que ainda não propôs a todas as mulheres, escolhe-se um deles. A ordem de escolha não altera o resultado final;

c) linha 4: m propõe à mulher w mais bem colocada na sua lista de preferências entre as que ainda não recebeu proposta dele. Assim, cada homem percorre sua lista em ordem e nunca propõe duas vezes à mesma mulher;

d) linhas 5–6: se w está livre, ela aceita a proposta e os dois ficam noivos. Uma mulher que recebeu alguma proposta nunca volta a ficar livre;

e) linhas 8–10: se w já está noiva de m', ela compara os dois segundo a sua lista. Se prefere m', rejeita m, que continua livre e, numa próxima iteração, proporá à mulher seguinte da sua lista;

f) linhas 12–13: se w prefere m, ela troca de noivo: m e w ficam noivos e m' volta a ficar livre. Por isso, o parceiro de cada mulher só melhora ao longo da execução;

g) linha 17: o laço termina quando todos os homens estão noivos, e o conjunto S dos pares noivos é devolvido. S é um emparelhamento perfeito e estável:

se um homem m preferisse uma mulher w ao seu par final, ele teria proposto a w antes, e w só o teria rejeitado ou trocado por alguém que ela prefere; logo, não existe par instável (KLEINBERG; TARDOS, 2005);

h) **complexidade:** cada homem propõe no máximo uma vez a cada mulher, de modo que há no máximo n^2 iterações. Cada iteração custa $O(1)$ quando se mantém: uma lista dos homens livres, um ponteiro para a próxima mulher da lista de cada homem, o noivo atual de cada mulher e uma matriz de posições $\mathrm{rank}[w][m]$, calculada uma vez em $O(n^2)$, que permite comparar dois homens em tempo constante. O total é $O(n^2)$, linear no tamanho da entrada, que é formada pelas $2n$ listas de n preferências (KLEINBERG; TARDOS, 2005).

Neste trabalho, o algoritmo de Gale-Shapley foi avaliado em três implementações, cuja origem consta na Tabela 10.

4 PROBLEMAS DE EMPARELHAMENTO EM GRAFOS GERAIS

Ao contrário dos problemas em grafos bipartidos, problemas de emparelhamento em grafos gerais podem ser consideravelmente mais complexos. Alguns dos problemas apresentados neste capítulo, como o emparelhamento de cardinalidade máxima e o de peso máximo, são resolvidos por algoritmos exatos em tempo polinomial. Outros, como o emparelhamento induzido máximo, são NP-difíceis: não se conhece algoritmo de tempo polinomial que os resolva, e a existência de um implicaria P = NP.

4.1 EMPARELHAMENTO DE CARDINALIDADE MÁXIMA

A definição do problema de emparelhamento de cardinalidade máxima é a mesma da sua versão bipartida (Seção 3.1). A diferença está nos ciclos de comprimento ímpar, que impedem a busca simples de caminhos aumentantes usada no caso bipartido; ainda assim, o problema é resolvido em tempo polinomial.

4.1.1 Propriedades

A seguir serão apresentadas algumas propriedades importantes para a compreensão dos algoritmos relacionados ao problema de emparelhamento de cardinalidade máxima em grafos gerais.

4.1.1.1 Ciclos ímpares

Os caminhos aumentantes e o lema de Berge (Seção 2.5.1) fundamentam também a solução em grafos gerais: um emparelhamento M é máximo se, e somente se, não existe caminho M-aumentante (JUNGNICKEL, 2008). A dificuldade está em encontrar esses caminhos.

Em grafos bipartidos, ciclos sempre têm tamanho par. Isso garante que, ao realizar uma busca (BFS ou DFS) a partir de um vértice livre, nunca se encontra uma aresta que conecte dois vértices que estejam à mesma distância (“paridade”) da raiz na árvore de busca alternante (AHUJA; MAGNANTI; ORLIN, 1993).

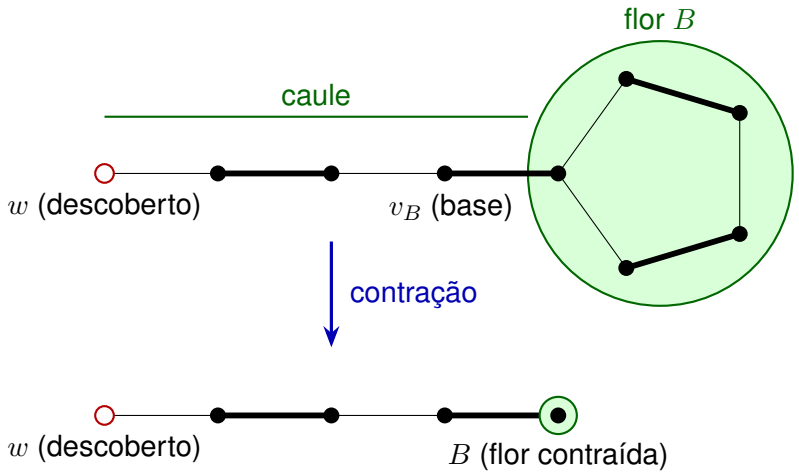
No entanto, em grafos gerais, a presença de ciclos de comprimento ímpar quebra essa lógica. Schrijver (2004) explica que, ao explorar o grafo, o algoritmo pode encontrar uma aresta conectando dois vértices que possuem paridade “par” em relação à raiz da busca. Essa estrutura forma um **ciclo ímpar** que “confunde” a identificação de um caminho aumentante simples, pois um vértice poderia ser alcançado por dois caminhos alternantes de paridades diferentes.

4.1.1.2 Flor (*blossom*)

A solução para lidar com ciclos ímpares foi proposta por Edmonds (1965), e consiste em uma estrutura denominada **flor** (*blossom*).

Uma flor B é definida como um ciclo de comprimento ímpar $2k+1$, onde k arestas pertencem ao emparelhamento M, de tal forma que existe apenas um vértice v_B no ciclo (a base da flor) que não é coberto por uma aresta de M dentro do próprio ciclo. A base v_B é conectada ao resto do grafo por um caminho alternante de comprimento par (o **caule** ou *stem*). A Figura 3 mostra uma flor com seu caule e o resultado da sua contração, descrita a seguir.

Figura 3 – Uma flor B com caule e base v_B, antes e depois da contração



Fonte: Adaptado de *Edmonds_blossom.svg*, de A3nm, Wikimedia Commons (domínio público, CC0). Arestas grossas pertencem ao emparelhamento.

Edmonds provou que uma flor pode ser contraída em um único vértice, com base no seguinte teorema:

> Existe um caminho aumentante no grafo original G se, e somente se, existe um caminho aumentante no grafo contraído $G' = G/B$, onde a flor B foi reduzida a um único vértice. (SCHRIJVER, 2004)

4.1.2 O algoritmo de Edmonds

Baseando-se nas flores e no teorema da contração, Lawler (1976) descreve o algoritmo para encontrar o emparelhamento máximo em grafos gerais da seguinte forma:

1. **busca:** inicie uma busca (geralmente BFS) a partir dos vértices livres para encontrar um caminho aumentante, construindo uma Floresta de Árvores Alternantes.

Na versão de Jungnickel (2008) (Algoritmo 21), a busca parte de um vértice livre r de cada vez (linha 12) e cresce a árvore alternando uma aresta não emparelhada $\{x, y\}$ com a aresta emparelhada $\{y, mate(y)\}$ (linhas 33–35);

2. **detecção:** se a busca encontrar uma aresta que fecha um ciclo ímpar, uma **flor** foi identificada. Isso ocorre quando a aresta $\{x, y\}$ liga dois vértices de profundidade par da mesma árvore (linha 23). O procedimento BLOSSOM (Algoritmo 22) identifica o ciclo, subindo de x e de y até a raiz e tomando como base w o ancestral comum mais profundo;

3. **contração:** contraia todos os vértices da **flor** em um único super-vértice e modifique o grafo temporariamente. O procedimento CONTRACT (Algoritmo 23) cria o super-vértice $b = n + m$, que herda o pai, a profundidade e o parceiro da base, recebe a união das adjacências da flor e desativa os vértices originais;

4. **recursão:** continue a busca no grafo contraído. Na versão de Jungnickel (2008), isso é feito sem recursão explícita: o super-vértice entra na fila de busca (linha 4 do Algoritmo 23) e passa a ser tratado como um vértice comum, podendo ele próprio fazer parte de novas flores;

5. **expansão:** se um caminho aumentante for encontrado no grafo contraído passando pelo super-vértice, "abra" (expanda) a flor novamente para traduzir esse caminho para o grafo original. O caminho dentro da flor será roteado de forma a manter a alternância correta. É o primeiro laço do procedimento AUGMENT (Algoritmo 24, linha 6), que substitui cada super-vértice do caminho, do mais recente para o mais antigo, por um caminho alternante de comprimento par dentro da flor;

6. **aumento:** use o caminho encontrado para aumentar o emparelhamento através da diferença simétrica (inversão das arestas). O AUGMENT é chamado quando a busca alcança um vértice livre y (linha 30 do Algoritmo 21), e seu último laço (linha 16) inverte as arestas ao longo do caminho.

Schrijver (2004) detalha que, a depender da forma como o algoritmo é implementado, principalmente no que trata da contração, a complexidade do algoritmo ingênuo pode chegar a $O(V^3)$. No entanto, melhorias subsequentes nesse algoritmo culminaram em uma implementação em $O(E\sqrt{V})$, descrita por Micali e Vazirani (1980). Ela segue o esquema de fases do Hopcroft-Karp (Seção 3.1.2): cada fase encontra um conjunto maximal de caminhos aumentantes de comprimento mínimo e disjuntos em vértices, agora também na presença de flores, em tempo $O(E)$, e bastam $O(\sqrt{V})$ fases, pelo mesmo argumento do caso bipartido. No entanto, por conta da complexidade de

implementação da solução mais rápida, a maioria das implementações práticas do algoritmo utilizam variantes com complexidade próxima a $O(V^3)$.

Os pseudocódigos a seguir, de Jungnickel (2008), organizam esses passos em quatro procedimentos: MAXMATCH, que conduz a busca; BLOSSOM, que identifica a flor; CONTRACT, que a contrai; e AUGMENT, que expande as flores e aumenta o emparelhamento. Cada passo acima indica a parte correspondente.

Algoritmo 21: Procedimento MAXMATCH (JUNGNICKEL, 2008)

```
(1)  Procedimento MAXMATCH(G; mate, nrex)
(2)      INMATCH(G; mate, nrex)
(3)      r ← 0
(4)      enquanto nrex ≥ 2 e r < n faça
(5)          r ← r + 1
(6)          se mate(r) = 0 então
(7)              Q ← ∅, aug ← falso, m ← 0
(8)              para v ∈ V faça
(9)                  p(v) ← 0, d(v) ← −1, a(v) ← verdadeiro
(10)                 CA(v) ← A_v
(11)             fim
(12)             d(r) ← 0; acrescente r ao fim de Q
(13)             enquanto aug = falso e Q ≠ ∅ faça
(14)                 remova o primeiro vértice x de Q
(15)                 se a(x) = verdadeiro então
(16)                     cont ← falso
(17)                     para y ∈ CA(x) faça
(18)                         u(y) ← falso
(19)                     fim
(20)                     repita
(21)                         escolha y ∈ CA(x) com
                              u(y) = falso; u(y) ← verdadeiro
(22)                         se a(y) = verdadeiro então
(23)                             se d(y) ≡ 0 (mod 2) então
(24)                                 m ← m + 1
(25)                                 BLOSSOM(x, y; B(m), w(m))
(26)                                 CONTRACT(B(m), m, w)
(27)                             fim
(28)                             senão se d(y) = −1 então
(29)                                 se mate(y) = 0 então
(30)                                     AUGMENT(x, y)
(31)                                 senão
(32)                                     z ← mate(y)
(33)                                     p(y) ← x; d(y) ← d(x) + 1
(34)                                     p(z) ← y; d(z) ← d(y) + 1
(35)                                     insira z em Q com prioridade d(z)
(36)                                 fim
(37)                             fim
(38)                         fim
(39)                     até que u(y) = verdadeiro para todo y ∈ CA(x) ou
                          aug = verdadeiro ou cont = verdadeiro
(40)                 fim
(41)             fim
(42)         fim
(43)     fim
```

Algoritmo 22: Algoritmo de BLOSSOM (JUNGNICKEL, 2008)

(1) **Procedimento** *BLOSSOM*$(x, y; B, w)$
(2) $P \leftarrow \{x\}; P' \leftarrow \{y\}; u \leftarrow x; v \leftarrow y$
(3) **repita**
(4) $P \leftarrow P \cup \{p(u)\}; u \leftarrow p(u)$
(5) **até que** $p(u) = r$
(6) **repita**
(7) $P' \leftarrow P' \cup \{p(v)\}; v \leftarrow p(v)$
(8) **até que** $v = r$
(9) $S \leftarrow P \cap P'$
(10) **seja** w o elemento de S com $d(w) \geq d(z)$ para todo $z \in S$
(11) $B \leftarrow ((P \cup P') \setminus S) \cup \{w\}$

O procedimento BLOSSOM é chamado pelo MAXMATCH quando a aresta $\{x, y\}$ liga dois vértices de profundidade par da mesma árvore alternante, de raiz r (linha 23 do Algoritmo 21). Seu papel é identificar o conjunto de vértices B da flor e a sua base w:

a) **linha 2:** os conjuntos P e P' guardarão os caminhos de x e de y até a raiz, e começam contendo apenas o próprio vértice de partida;

b) **linhas 4 e 7:** dois laços sobem na árvore pelos ponteiros de pai $p(\cdot)$, o primeiro a partir de x e o segundo a partir de y, até alcançar a raiz r. Ao final, P e P' contêm todos os vértices dos caminhos de x e de y até r;

c) **linha 9:** a interseção S dos dois caminhos é o trecho que eles têm em comum, de algum vértice até a raiz;

d) **linha 10:** a base w é o vértice de S de maior profundidade $d(\cdot)$, ou seja, o ancestral comum mais profundo de x e y: é nele que os dois caminhos se encontram e se fecha o ciclo ímpar;

e) **linha 11:** a flor B é formada pelos vértices dos dois caminhos que estão abaixo de w, mais a própria base. Os vértices de S acima de w ficam de fora, pois pertencem ao caule, e não ao ciclo. Em seguida, o MAXMATCH chama o CONTRACT (Algoritmo 23) com B e w;

f) **complexidade:** cada caminho até a raiz tem no máximo $O(V)$ vértices, e a interseção e a união dos conjuntos podem ser feitas em tempo linear no tamanho deles; cada chamada custa, portanto, $O(V)$. Como cada contração reduz o número de vértices ativos, há no máximo $O(V)$ flores por busca, o que é compatível com o custo total $O(V^3)$ do algoritmo citado acima.

Algoritmo 23: Procedimento CONTRACT (JUNGNICKEL, 2008)

(1) **Procedimento** *CONTRACT*(B, m, w)
(2) $b \leftarrow n + m; a(b) \leftarrow$ **verdadeiro**
(3) $p(b) \leftarrow p(w); d(b) \leftarrow d(w); mate(b) \leftarrow mate(w)$
(4) insira b em Q com prioridade $d(b)$
(5) $CA(b) \leftarrow \bigcup_{z \in B} CA(z)$
(6) **para** $z \in CA(b)$ **faça**
(7) $CA(z) \leftarrow CA(z) \cup \{b\}$
(8) **fim**
(9) **para** $z \in B$ **faça**
(10) $a(z) \leftarrow$ **falso**
(11) **fim**
(12) **para** $z \in CA(b)$ **faça**
(13) **se** $a(z) =$ **verdadeiro e** $p(z) \in B$ **então**
(14) $d(z) \leftarrow d(b) + 1; p(z) \leftarrow b$
(15) $d(mate(z)) \leftarrow d(z) + 1$
(16) **fim**
(17) **fim**
(18) $cont \leftarrow$ **verdadeiro**

Algoritmo 24: Procedimento AUGMENT (JUNGNICKEL, 2008)

(1) **Procedimento** *AUGMENT*(x, y)
(2) $P \leftarrow \{y, x\}; v \leftarrow x$
(3) **enquanto** $p(v) \neq 0$ **faça**
(4) $P \leftarrow P \cup \{p(v)\}; v \leftarrow p(v)$
(5) **fim**
(6) **enquanto** *existe* $b \in P$ *com* $b > n$ **faça**
(7) escolha o maior $b \in P$ com $b > n$
(8) $B \leftarrow B(b - n); w \leftarrow w(b - n); z \leftarrow mate(w)$
(9) **seja** q o vizinho de b em P diferente de z
(10) escolha algum $q' \in B \cap CA(q)$
(11) determine o caminho alternante B' de comprimento par em B de w a q'
(12) substitua b por w em P
(13) insira B' em P entre w e q
(14) **fim**
(15) $u \leftarrow y; v \leftarrow x$
(16) **enquanto** $v \neq r$ **faça**
(17) $z \leftarrow mate(v); mate(v) \leftarrow u; mate(u) \leftarrow v$
(18) $u \leftarrow z$; **seja** v o sucessor de z em P
(19) **fim**
(20) $mate(v) \leftarrow u; mate(u) \leftarrow v$
(21) $nrex \leftarrow nrex - 2; aug \leftarrow$ **verdadeiro**

A complexidade $O(V^3)$ do conjunto resulta da contagem de Jungnickel (2008). Cada fase constrói uma árvore alternante até encontrar um caminho aumentante ou esgotar a busca, e há no máximo $O(V)$ fases, pois cada uma termina com um aumento

ou encerra o algoritmo. Dentro de uma fase, cada vértice externo é examinado uma vez, percorrendo seus $O(V)$ vizinhos, em $O(V^2)$ no total; cada chamada do BLOSSOM custa $O(V)$, e há $O(V)$ contrações por fase; e o CONTRACT e o AUGMENT, implementados como no texto, somam $O(V^2)$ por fase. Cada fase custa, portanto, $O(V^2)$, e o algoritmo, $O(V^3)$.

4.1.2.1 Teorema de Tutte-Berge

O teorema de Tutte-Berge, apesar de não aparecer explicitamente na descrição do algoritmo, é fundamental para sua corretude, pois ele fornece um certificado de otimalidade. Por exemplo, suponha que a etapa de busca do algoritmo de Blossom não encontrou nenhum caminho aumentante. Como saber se o emparelhamento atual é máximo? Para isso, usa-se a fórmula de Tutte-Berge, descrita por Jungnickel (2008) da seguinte forma:

$$v(G) = \frac{1}{2} \min_{U \subseteq V} (|V| + |U| - \mathrm{odd}(G - U)) \tag{4.1}$$

Onde $v(G)$ é o tamanho do emparelhamento máximo, e $\mathrm{odd}(G - U)$ é o número de componentes conexos com número ímpar de vértices no grafo resultante após a remoção de U. Se o grafo possui um emparelhamento perfeito, o mínimo desta equação é $|V|/2$, o que ocorre se e somente se $odd(G - U) \leq |U|$ para todo U.

4.1.3 Algoritmos aproximados

Alguns dos algoritmos aproximados que resolvem este problema são os mesmos vistos na seção 3.1, como o método guloso simples e o algoritmo de Karp-Sipser, que também funcionam para grafos gerais e mantêm a garantia de metade da cardinalidade máxima, já que ambos produzem um emparelhamento maximal. A análise de complexidade feita naquela seção não usa a bipartição, e os dois continuam lineares. Além desses, existem outros métodos que podem ser utilizados neste problema.

4.1.3.1 Algoritmo de crescimento de caminho (Path Growing)

Uma variação inteligente do método guloso, descrita por Drake e Hougardy (2003), que usa DFS e tenta evitar a “miopia” de escolher uma aresta isolada. Assim como os anteriores, garante um emparelhamento com pelo menos metade da cardinalidade máxima, caso particular da garantia de metade do peso máximo da versão ponderada (Seção 4.2.5).

1. escolha um vértice livre inicial v;

2. inicie uma busca em profundidade (DFS) para construir um caminho simples o mais longo possível;
3. ao longo desse caminho, selecione arestas alternadas para o emparelhamento (a 1ª sim, a 2ª não, a 3ª sim...);
4. remova os vértices usados e repita.

Ao contrário do guloso simples (que escolhe arestas desconexas), o Path Growing tende a cobrir cadeias longas de vértices, o que é estruturalmente vantajoso. Sua complexidade é linear, $O(V + E)$: cada vértice entra em um único caminho e é removido em seguida, e cada aresta é examinada um número constante de vezes ao estender os caminhos, a mesma análise da versão ponderada (Algoritmo 26).

Tabela 4 – Algoritmos para problema de emparelhamento de cardinalidade máxima em grafos gerais

Algoritmo	**Complexidade**	**Tipo**	**Avaliado**	**Descrição**
Edmonds	$O(V^3)$	Exato	Sim	Algoritmo exato (Blossom) que contrai ciclos ímpares temporariamente em super-vértices para identificar caminhos aumentantes.
Micali e Vazirani	$O(E\sqrt{V})$	Exato	Não	Variação otimizada do algoritmo de Edmonds que utiliza estruturas de dados avançadas para reduzir drasticamente a complexidade.
Guloso simples	$O(E)$	Aprox.	Não	Itera sobre arestas arbitrariamente, selecionando aquelas que conectam dois vértices livres.
Karp-Sipser	$O(E)$	Aprox.	Não	Prioriza remoção de vértices de grau 1; usa escolha aleatória quando não há folhas.
Crescimento de caminho	$O(E)$	Aprox.	Não	Método linear que constrói caminhos simples via DFS e seleciona arestas alternadas para garantir um emparelhamento maximal.

Fonte: Elaborado pelo autor.

Aprox.: aproximado. *Avaliado*: incluído no ambiente de testes; a origem de cada implementação consta na Tabela 10. As complexidades são justificadas no texto de cada algoritmo.

4.2 EMPARELHAMENTO PONDERADO MÁXIMO

Enquanto o problema de cardinalidade máxima busca o maior número de arestas, o problema do **emparelhamento de peso máximo** (*maximum weight matching*) introduz uma função de peso $w : E \to \mathbb{R}$ nas arestas, e o objetivo torna-se encon-

trar um emparelhamento M que maximize $w(M) = \sum_{e \in M} w(e)$. Este problema é a generalização natural do problema de atribuição (Seção 3.2) para grafos não bipartidos.

Assim como no problema de cardinalidade máxima (Seção 4.1), a dificuldade em grafos gerais decorre dos ciclos ímpares. No caso ponderado, ela aparece de forma clara quando o problema é escrito como um modelo de programação linear (Seção 2.6), que é também o ponto de partida do algoritmo de Edmonds.

4.2.1 Formulação poliédrica e desigualdades de flor

O problema pode ser escrito como um modelo de programação linear inteira (SCHRIJVER, 2004):

a) **variáveis:** uma variável $x_e \in \{0, 1\}$ para cada aresta $e \in E$, com $x_e = 1$ se, e somente se, e pertence ao emparelhamento;

b) **função objetivo:** maximizar o peso total das arestas escolhidas, $\sum_{e \in E} w(e)\, x_e$;

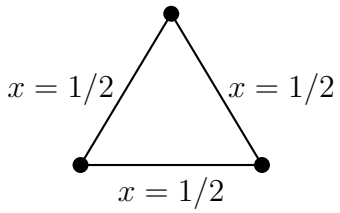
c) **restrições de grau:** cada vértice é coberto por no máximo uma aresta escolhida. Sendo $\delta(v)$ o conjunto das arestas incidentes a v, exige-se $\sum_{e \in \delta(v)} x_e \leq 1$ para todo $v \in V$.

Em resumo:

$$\begin{aligned} \max \quad & \sum_{e \in E} w(e)\, x_e \\ \text{sujeito a} \quad & \sum_{e \in \delta(v)} x_e \leq 1 \quad \forall\, v \in V, \\ & x_e \in \{0, 1\} \quad \forall\, e \in E. \end{aligned} \tag{4.2}$$

Em grafos bipartidos, a relaxação linear desse modelo, com $0 \leq x_e \leq 1$, já tem ótimo inteiro, pois a matriz de restrições é totalmente unimodular (Seção 2.6); é o que torna o problema de atribuição solúvel pela programação linear. Em grafos gerais, isso falha. No triângulo da Figura 4, com peso 1 nas três arestas, a solução $x_e = 1/2$ para cada aresta satisfaz todas as restrições de grau, pois cada vértice recebe $1/2 + 1/2 = 1$, e tem valor $3/2$. Porém, qualquer emparelhamento do triângulo tem no máximo uma aresta e, portanto, peso 1: a relaxação admite uma solução fracionária melhor que todas as inteiras.

Figura 4 – Solução fracionária da relaxação linear em um triângulo



Fonte: Elaborado pelo autor. Os três pesos valem 1; a solução tem valor $3/2$, enquanto o maior emparelhamento tem peso 1.

Para eliminar essas soluções, Edmonds (1965) acrescentou as **desigualdades de flor** (*blossom inequalities*), uma para cada subconjunto $U \subseteq V$ com número ímpar de vértices. Sendo $E(U)$ o conjunto das arestas com os dois extremos em U:

$$\sum_{e \in E(U)} x_e \leq \frac{|U| - 1}{2}, \quad \forall\, U \subseteq V,\ |U| \text{ ímpar},\ |U| \geq 3. \tag{4.3}$$

Essas desigualdades são válidas para todo emparelhamento: cada aresta escolhida dentro de U cobre dois vértices de U, de modo que cabem no máximo $\lfloor |U|/2 \rfloor = (|U| - 1)/2$ delas. E elas cortam a solução fracionária do triângulo: com U igual aos três vértices, a desigualdade exige soma no máximo 1, e a solução $x_e = 1/2$ soma $3/2$.

O resultado central, conhecido como **teorema do poliedro do emparelhamento** (*matching polytope theorem*), é que essas desigualdades bastam. O **poliedro do emparelhamento** de G é o conjunto de todas as combinações convexas dos vetores de emparelhamentos, isto é, dos vetores $x \in \{0,1\}^E$ com $x_e = 1$ exatamente nas arestas de algum emparelhamento. Edmonds (1965) provou que esse poliedro é descrito exatamente pelas restrições $x \geq 0$, de grau e de flor (SCHRIJVER, 2004, Corolário 25.1a). Como consequência, todo vértice do poliedro definido por essas restrições é inteiro, e o PL

$$\begin{aligned} \max \quad & \sum_{e \in E} w(e)\, x_e & & \\ \text{sujeito a} \quad & \sum_{e \in \delta(v)} x_e \leq 1 & & \forall\, v \in V, \\ & \sum_{e \in E(U)} x_e \leq \frac{|U| - 1}{2} & & \forall\, U \subseteq V,\ |U| \text{ ímpar}, \\ & x_e \geq 0 & & \forall\, e \in E \end{aligned} \tag{4.4}$$

tem sempre um emparelhamento de peso máximo como solução ótima. O número de desigualdades de flor, no entanto, é exponencial em $|V|$, de modo que esse PL não é resolvido diretamente: o algoritmo de Edmonds trabalha com o seu dual, descrito a seguir.

4.2.2 A abordagem primal-dual

Diferente do caso de cardinalidade, em que se buscam apenas caminhos aumentantes, o algoritmo para o caso ponderado é um método **primal-dual** (Seção 2.6). Ele é uma generalização do método Húngaro, mas adaptado para lidar com as flores.

O dual do PL (4.4), construído como na Seção 2.6, tem uma variável para cada restrição primal (SCHRIJVER, 2004):

a) $y_v \geq 0$ para a restrição de grau do vértice v;

b) $z_B \geq 0$ para a desigualdade de flor do conjunto ímpar B.

E tem uma restrição para cada variável primal, isto é, para cada aresta:

$$\begin{aligned} \min \quad & \sum_{v \in V} y_v + \sum_{B} \frac{|B|-1}{2} z_B \\ \text{sujeito a} \quad & y_u + y_v + \sum_{B\,:\,\{u,v\} \subseteq B} z_B \geq w(\{u,v\}) \quad \forall \{u,v\} \in E, \\ & y_v \geq 0,\ z_B \geq 0. \end{aligned} \tag{4.5}$$

Na restrição de cada aresta $\{u, v\}$, aparecem o potencial dos seus dois extremos e o dual de todo conjunto ímpar B que contém os dois extremos, pois são exatamente as desigualdades de flor em que a variável x_{uv} aparece. A diferença entre os dois lados é a **folga** da aresta:

$$\pi_{uv} = y_u + y_v + \sum_{B\,:\,\{u,v\} \subseteq B} z_B - w(\{u,v\}) \geq 0, \tag{4.6}$$

e a aresta é **justa** ou **admissível** (*tight*) quando $\pi_{uv} = 0$. Pela folga complementar (Seção 2.6), um emparelhamento M e duais viáveis (y, z) são ótimos se, e somente se:

1. toda aresta de M é justa;
2. todo vértice com $y_v > 0$ é coberto por M;
3. todo conjunto com $z_B > 0$ contém exatamente $(|B| - 1)/2$ arestas de M, isto é, M emparelha todos os vértices de B menos um.

O algoritmo de Edmonds é primal-dual (LAWLER, 1976): ele mantém os duais viáveis e as condições 1 e 3 durante toda a execução e busca satisfazer a condição 2. Na prática, só recebem $z_B > 0$ os conjuntos que formam flores, que satisfazem a condição 3 por definição (Seção 4.1). O algoritmo alterna dois estágios, descritos por Jungnickel (2008) e Schrijver (2004):

1. **estágio primal (busca):** usando apenas arestas justas, o algoritmo busca um caminho aumentante a partir dos vértices livres, com a técnica de contração de

flores do caso de cardinalidade. Se encontrado, o emparelhamento é aumentado ao longo dele, e as condições 1 e 3 continuam valendo;

2. **estágio dual (ajuste de preços):** se a busca falha, o algoritmo não termina, ao contrário do caso de cardinalidade. Em vez disso, ajusta os duais:
    a) calcula o maior passo δ que mantém todas as folgas (4.6) e todos os duais não negativos;
    b) diminui em δ os potenciais dos vértices externos da árvore de busca e aumenta em δ os dos internos, com o ajuste correspondente nos z_B das flores;
    c) com isso, uma nova aresta se torna justa, uma flor pode ser expandida ou o potencial de um vértice livre chega a zero, o que satisfaz a condição 2 para ele.

4.2.3 O algoritmo de Edmonds Ponderado

O procedimento resultante é frequentemente chamado de **Algoritmo de Blossom Ponderado** ou simplesmente Algoritmo de Edmonds para Emparelhamento Ponderado.

A implementação original de Edmonds era polinomial, $O(V^4)$: calculando δ diretamente a cada ajuste dual, em $O(E)$, ela custa $O(V^2E)$, que em grafos densos é $O(V^4)$, como detalhado ao final da explicação do Algoritmo 25 (GALIL; MICALI; GABOW, 1986). Lawler (1976) apresentou uma implementação $O(V^3)$, que por muito tempo foi o padrão em livros didáticos.

A variante $O(V^3)$ descrita por Lawler (1976) para o emparelhamento ponderado utiliza uma abordagem primal-dual rigorosa. O algoritmo mantém um conjunto de arestas admissíveis (custo reduzido nulo) baseadas em variáveis duais de vértices (y_i) e de subconjuntos ímpares (z_B). A cada iteração onde a busca por caminhos aumentantes falha, o algoritmo calcula um escalar crítico δ baseado nas folgas das arestas incidentes à árvore alternante atual (conjunto S). A atualização dual subsequente ($y_i \leftarrow y_i \pm \delta$, $z_B \leftarrow z_B \pm 2\delta$) garante o surgimento de novas arestas admissíveis ou a expansão de **flores** com dual nulo, mantendo a complexidade cúbica através do gerenciamento eficiente dos valores de folga mínima (***slack***) para vértices fora da árvore.

Lawler também destaca que a manipulação das variáveis duais das flores (z_B) é o que permite ao algoritmo "pagar" o custo de usar arestas dentro de estruturas cíclicas ímpares. Quando uma flor é formada durante a busca, ela começa com dual $z_B = 0$, que cresce nos ajustes em que a flor é externa; quando ela é interna e seu dual volta a zero, a flor pode ser desfeita (expandida) sem violar a viabilidade dual.

O Algoritmo 25 resume esse esquema primal-dual em alto nível, omitindo as estruturas de dados de contração e expansão de flores. Nele, π_{uv} é a folga da aresta $\{u, v\}$, definida na Equação (4.6); uma aresta é justa quando $\pi_{uv} = 0$.

Algoritmo 25: Esquema primal-dual do algoritmo de Edmonds ponderado, em alto nível (LAWLER, 1976)

Entrada: grafo $G = (V, E)$ com pesos $w : E \to \mathbb{R}$
Saída: emparelhamento de peso máximo M

(1) $M := \emptyset$; $y_v := \frac{1}{2} \max_{e \in E} w(e)$ para todo $v \in V$; $z_B := 0$ para toda flor B
(2) **enquanto verdadeiro faça**
(3) cresça árvores alternantes enraizadas nos vértices livres usando só arestas justas, rotulando os vértices como externos (S) ou internos (T)
(4) **se** *uma aresta justa liga vértices externos de duas árvores diferentes* **então**
(5) aumente M pelo caminho aumentante encontrado; apague todos os rótulos
(6) **senão se** *uma aresta justa liga dois vértices externos da mesma árvore* **então**
(7) contraia a flor B formada pela aresta, com $z_B := 0$
(8) **senão**
(9) $\delta_1 := \min\{y_v : v \text{ externo}\}$
(10) $\delta_2 := \min\{\pi_{uv} : u \text{ externo}, v \text{ sem rótulo}\}$
(11) $\delta_3 := \min\{\pi_{uv}/2 : u, v \text{ externos, em flores diferentes}\}$
(12) $\delta_4 := \min\{z_B/2 : B \text{ flor interna}\}$
(13) $\delta := \min(\delta_1, \delta_2, \delta_3, \delta_4)$
(14) $y_v := y_v - \delta$ para v externo; $y_v := y_v + \delta$ para v interno
(15) $z_B := z_B + 2\delta$ nas flores externas; $z_B := z_B - 2\delta$ nas internas
(16) **se** $\delta = \delta_1$ **então pare [comentário:** M **é ótimo]**
(17) expanda toda flor interna B com $z_B = 0$
(18) **fim**
(19) **fim**
(20) **retorne** M, após expandir todas as flores restantes

O Algoritmo 25 alterna entre o estágio primal e o estágio dual descritos acima, e funciona da seguinte forma:

a) **linha 1:** o emparelhamento começa vazio, todos os vértices recebem o mesmo dual y_v, igual à metade do maior peso, e nenhuma flor tem dual. Com essa escolha, $y_u + y_v \geq w_{uv}$ para toda aresta, ou seja, todas as folgas π_{uv} começam não negativas, e a solução dual é viável desde o início;

b) **linhas 2–3:** a cada iteração, cresce-se uma floresta de árvores alternantes, enraizadas nos vértices livres, usando apenas arestas justas ($\pi_{uv} = 0$). Os vértices a distância par da raiz são rotulados como externos (S) e os a distância ímpar, como internos (T), como na busca do caso de cardinalidade;

c) **linhas 4–5:** uma aresta justa entre vértices externos de árvores diferentes liga duas raízes livres por um caminho alternante, isto é, um caminho au-

mentante. O emparelhamento é aumentado ao longo dele, e os rótulos são apagados para uma nova busca;

d) **linhas 6–7:** uma aresta justa entre dois vértices externos da mesma árvore fecha um ciclo ímpar, que é contraído em uma flor, como no Algoritmo 21. A nova flor começa com dual $z_B = 0$ e se comporta como um vértice externo;

e) **linhas 9–13:** se nenhuma das situações anteriores ocorre, a busca está travada e é preciso ajustar os duais. Calcula-se o maior passo δ que mantém a solução dual viável, como o menor de quatro limites: δ_1 é o menor dual de vértice externo, que não pode ficar negativo; δ_2 é a menor folga de aresta entre um vértice externo e um não rotulado, que diminui em δ; δ_3 é a metade da menor folga entre vértices externos de flores diferentes, pois essa folga diminui em 2δ, uma vez que os dois extremos são externos; e δ_4 é a metade do menor dual de flor interna, que diminui em 2δ e também não pode ficar negativo;

f) **linhas 14–15:** os duais são atualizados: os vértices externos perdem δ e os internos ganham δ, de modo que as arestas justas da árvore (entre um externo e um interno) continuam justas; as flores externas ganham 2δ e as internas perdem 2δ, o que compensa a variação dos duais dos vértices dentro delas;

g) **linha 16:** se o passo foi limitado por δ_1, algum vértice externo chegou a dual zero. Como os vértices livres são raízes, e portanto externos, e todos os externos perdem o mesmo δ a cada ajuste, os vértices livres têm o menor dual e chegam a zero; nesse ponto, as condições de folga complementar valem e M é ótimo;

h) **linha 17:** uma flor interna cujo dual chegou a zero (limite δ_4) é expandida, devolvendo seus vértices à busca. Nos casos δ_2 e δ_3, o ajuste torna justa uma nova aresta, e a busca da próxima iteração consegue crescer a árvore, contrair uma flor ou aumentar o emparelhamento;

i) **linha 20:** ao final, as flores que restaram contraídas são expandidas para que o emparelhamento seja expresso em termos das arestas do grafo original;

j) **complexidade:** há no máximo $V/2$ aumentos. Entre dois aumentos consecutivos, cada ajuste dual rotula um novo vértice, cria uma flor, expande uma flor ou encerra o algoritmo, de modo que ocorrem $O(V)$ ajustes por aumento. Calculando δ diretamente pelas definições das linhas 9–12, cada ajuste custa $O(E)$, o que dá $O(V^2E)$ no total. A implementação de Lawler (1976) mantém, para cada vértice fora da árvore, a menor folga até ela (*slack*), o que reduz o cálculo de δ a $O(V)$ e leva ao total de $O(V^3)$.

4.2.4 Melhorias

Desenvolvimentos posteriores melhoraram as estruturas de dados que gerenciam as folgas e a contração de flores. Galil, Micali e Gabow (1986) mantêm as folgas em filas de prioridade generalizadas, em que cada operação custa $O(\log V)$; como há $O(V)$ estágios, um por aumento, e cada estágio realiza $O(E)$ operações nessas filas, o total é $O(EV \log V)$, melhor que $O(V^3)$ em grafos esparsos. Gabow (1990) reduziu o custo de cada estágio para $O(E + V \log V)$, o mesmo de um Dijkstra com *heap* de Fibonacci, o que leva a $O(V(E + V \log V))$. Para pesos inteiros, algoritmos de escalonamento de custos atingem limites ainda menores, que dependem também do maior peso (GABOW, 1990).

Apesar de polinomial, o algoritmo é difícil de implementar corretamente: ele combina a contração de flores do caso de cardinalidade com o ajuste das variáveis duais. Um reflexo disso é que poucas implementações públicas independentes foram encontradas; a do NetworkX, por exemplo, é uma adaptação da de van Rantwijk (Seção 5.7).

4.2.5 Algoritmos aproximados

Aqui também pode ser usado o método guloso ordenado, descrito na seção 3.2.3.1, com a mesma complexidade $O(E \log E)$, dominada pela ordenação. No problema de peso máximo, ao contrário da atribuição de custo mínimo, ele tem garantia de aproximação: o emparelhamento obtido tem pelo menos metade do peso máximo, pois cada aresta da solução ótima que fica de fora é bloqueada por uma aresta escolhida antes e, portanto, de peso maior ou igual, e cada aresta escolhida bloqueia no máximo duas arestas da solução ótima (DRAKE; HOUGARDY, 2003). Além dele, há:

4.2.5.1 Algoritmo de Crescimento de Caminho (Path Growing)

Similar ao algoritmo descrito na seção 4.1.3.1, esta também faz uso de Path Growing para encontrar um emparelhamento. A vantagem desta é que não é necessário ordenação, tornando possível a execução em tempo linear ($O(E)$). Foi descrito por Drake e Hougardy (2003):

1. o algoritmo constrói caminhos simples disjuntos no grafo;
2. comece em um vértice livre v qualquer. Estenda o caminho escolhendo a aresta de maior peso conectada a v que leve a um vértice ainda não visitado neste caminho;
3. repita até que o caminho não possa crescer mais;

4. dado um caminho $P = (e_1, e_2, e_3, \ldots, e_k)$, há dois emparelhamentos possíveis formados por arestas alternadas:
   a) $M_1 = \{e_1, e_3, e_5, \ldots\}$ (arestas ímpares);
   b) $M_2 = \{e_2, e_4, e_6, \ldots\}$ (arestas pares);
5. compare o peso total de M_1 e M_2. Adicione o conjunto mais pesado à solução final e remova os vértices do grafo.

A diferença para a versão de emparelhamento de cardinalidade máxima é o passo 5, onde os pesos são somados para escolher o melhor conjunto. Garante emparelhamento de pelo menos $1/2$ do peso máximo (DRAKE; HOUGARDY, 2003).

O Algoritmo 26 corresponde à versão original de Drake e Hougardy (2003), que é a implementada neste trabalho. Nela, os conjuntos M_1 e M_2 são mantidos ao longo de todos os caminhos e o mais pesado é retornado ao final, em vez de a escolha ser feita caminho a caminho como na descrição acima; ambas as versões têm a mesma garantia de aproximação.

Algoritmo 26: Algoritmo Path Growing (DRAKE; HOUGARDY, 2003)

Entrada: grafo $G = (V, E)$ com pesos $w : E \to \mathbb{R}$
Saída: emparelhamento M com $w(M) \geq \frac{1}{2} w(M^*)$

```
(1)  M_1 := ∅; M_2 := ∅; i := 1
(2)  enquanto E ≠ ∅ faça
(3)      escolha um vértice x com deg(x) ≥ 1
(4)      enquanto x tem algum vizinho faça
(5)          seja {x, y} a aresta mais pesada incidente a x
(6)          M_i := M_i ∪ {{x, y}}; i := 3 − i
(7)          remova de G o vértice x e todas as arestas incidentes a ele
(8)          x := y
(9)      fim
(10) fim
(11) retorne o mais pesado entre M_1 e M_2
```

As etapas do Algoritmo 26 são as seguintes:

a) **linha 1:** os dois emparelhamentos candidatos começam vazios, e o índice i indica em qual deles entra a próxima aresta;

b) **linhas 2–3:** enquanto restarem arestas no grafo, inicia-se um novo caminho a partir de qualquer vértice que ainda tenha vizinhos;

c) **linhas 4–5:** o caminho cresce a partir do vértice atual x pela aresta mais pesada incidente a ele, que leva ao vizinho y;

d) **linha 6:** a aresta escolhida entra em M_i, e o índice alterna entre 1 e 2 ($i := 3 - i$). Assim, as arestas do caminho são distribuídas alternadamente

entre M_1 e M_2; como duas arestas consecutivas do caminho vão para conjuntos diferentes, cada um deles continua sendo um emparelhamento;

e) **linhas 7–8:** o vértice x é removido do grafo com todas as suas arestas, o que impede que o caminho volte a ele, e o caminho continua a partir de y. Quando y não tem mais vizinhos, o laço interno termina e um novo caminho é iniciado na linha 3;

f) **linha 11:** retorna-se o mais pesado dos dois emparelhamentos. Para a garantia de aproximação, cada aresta do grafo é removida junto com algum vértice x na linha 7, e a aresta escolhida nesse passo é a mais pesada entre as que são removidas com ele. Como cada vértice é removido uma única vez e cada aresta da solução ótima M^* pode ser atribuída a um extremo distinto removido, $w(M_1) + w(M_2) \geq w(M^*)$, e o mais pesado dos dois tem pelo menos metade do peso ótimo (DRAKE; HOUGARDY, 2003);

g) **complexidade:** cada vértice é removido uma vez, e a escolha da aresta mais pesada percorre a lista de adjacência do vértice atual, de modo que cada aresta é examinada um número constante de vezes. Mantendo uma lista dos vértices com grau positivo para a linha 3, o custo total é $O(V + E)$, linear no tamanho do grafo, sem a ordenação $O(E \log E)$ do método guloso ordenado.

Tabela 5 – Algoritmos para problema de emparelhamento ponderado máximo em grafos gerais

Algoritmo	**Complexidade**	**Tipo**	**Avaliado**	**Descrição**
Edmonds	$O(V^3)$	Exato	Sim	Método primal-dual que gerencia variáveis duais para vértices e flores, ajustando preços para encontrar caminhos no grafo de igualdade.
Edmonds otimizado	$O(EV \log V)$	Exato	Não	Implementação de Galil, Micali e Gabow, que mantém as folgas em filas de prioridade generalizadas.
Guloso ordenado	$O(E \log E)$	Aprox.	Não	Ordena as arestas por peso decrescente e seleciona iterativamente as disponíveis.
Crescimento de caminho	$O(E)$	Aprox.	Sim	Método que estende caminhos pela aresta mais pesada local e seleciona o subconjunto de arestas (par ou ímpar) de maior soma total.

Fonte: Elaborado pelo autor.

Aprox.: aproximado. *Avaliado*: incluído no ambiente de testes; a origem de cada implementação consta na Tabela 10. As complexidades são justificadas no texto de cada algoritmo.

4.3 EMPARELHAMENTO INDUZIDO MÁXIMO

Diferentemente dos problemas de emparelhamento em grafos gerais vistos até o momento, que pertencem à classe de complexidade P, o problema do Emparelhamento Induzido Máximo (MIM - *Maximum Induced Matching*), ou emparelhamento induzido de cardinalidade máxima, frequentemente referido na literatura como **Emparelhamento Forte** (*Strong Matching*), pertence à classe dos problemas NP-difíceis. Apesar de ter uma variação estruturalmente simples quando comparado aos problemas clássicos, esse problema impõe uma restrição topológica severa sobre quais arestas podem coexistir na solução.

4.3.1 Definição

Seja $G = (V, E)$ um grafo geral. Um subconjunto de arestas $M \subseteq E$ é um **emparelhamento induzido** se satisfaz duas condições:

1. **condição de Emparelhamento:** nenhuma aresta em M compartilha um vértice (são disjuntas par a par);
2. **condição Induzida:** o subgrafo induzido pelos vértices saturados por M, denotado por $G[V(M)]$, contém **apenas** as arestas de M.

Em termos mais simples, se tomarmos duas arestas quaisquer $\{u, v\}$ e $\{x, y\}$ pertencentes ao emparelhamento induzido, não pode existir no grafo original nenhuma aresta conectando um vértice do par $\{u, v\}$ a um vértice do par $\{x, y\}$. Isso implica que as arestas do emparelhamento devem estar "topologicamente isoladas" umas das outras.

Cameron (1989) oferece uma caracterização alternativa baseada em distância: um emparelhamento induzido é um conjunto de arestas onde a distância entre quaisquer duas arestas distintas é de pelo menos 2 (ou seja, não há aresta de ligação entre elas).

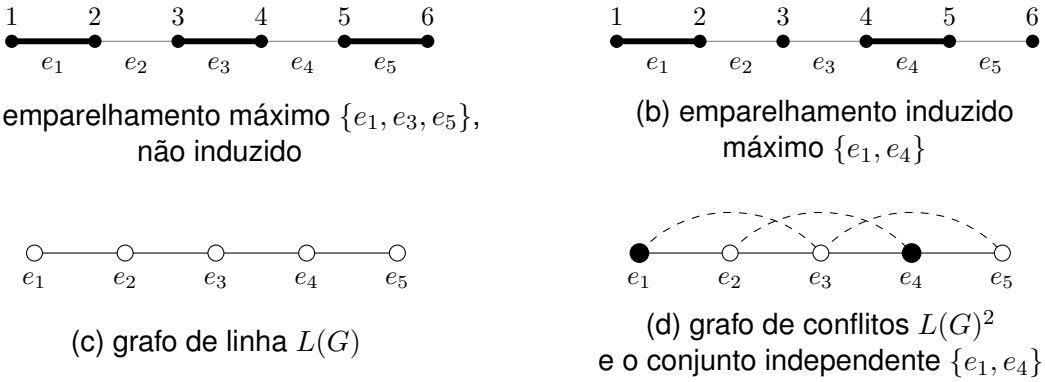
O **problema do emparelhamento induzido máximo** consiste em, dado um grafo $G = (V, E)$, encontrar um emparelhamento induzido de maior cardinalidade possível, isto é, que atinja

$$\max\{\, |M| : M \subseteq E \text{ é um emparelhamento induzido de } G \,\}. \tag{4.7}$$

Todo emparelhamento induzido é, em particular, um emparelhamento; por isso, o valor de (4.7) nunca supera a cardinalidade de um emparelhamento máximo de G, e pode ser bem menor que ela.

A Figura 5 ilustra a diferença em um caminho com seis vértices e arestas $e_1, \ldots, e_5$. Em (a), $M = \{e_1, e_3, e_5\}$ é um emparelhamento máximo, mas não é induzido: a aresta $e_2 = \{2, 3\}$ liga e_1 a e_3, e e_4 liga e_3 a e_5. Em (b), $\{e_1, e_4\}$ é um emparelhamento induzido, pois nenhuma aresta liga os vértices $\{1, 2\}$ aos vértices $\{4, 5\}$. Ele é máximo: o único emparelhamento com três arestas desse grafo é o de (a), que não é induzido. Os painéis (c) e (d) são discutidos na Seção 4.3.3.

Figura 5 – Emparelhamento máximo e emparelhamento induzido máximo em um caminho, e os grafos $L(G)$ e $L(G)^2$ usados na redução ao conjunto independente



(a) emparelhamento máximo $\{e_1, e_3, e_5\}$, não induzido

(b) emparelhamento induzido máximo $\{e_1, e_4\}$

(c) grafo de linha $L(G)$

(d) grafo de conflitos $L(G)^2$ e o conjunto independente $\{e_1, e_4\}$

Fonte: Elaborado pelo autor. Em (a) e (b), arestas grossas pertencem ao emparelhamento. Em (d), as ligações tracejadas são as acrescentadas ao quadrar $L(G)$, e os vértices cheios formam o conjunto independente correspondente ao emparelhamento de (b).

Uma aplicação prática apontada por Golumbic e Lewenstein (2000) é a escolha de canais de comunicação seguros. Em um grafo bipartido $G = (U, V; E)$, U é o conjunto dos transmissores, V o dos receptores, e cada aresta indica que o receptor consegue captar as mensagens do transmissor. Deseja-se escolher pares transmissor–receptor (os canais) de modo que a mensagem de cada canal chegue apenas ao receptor do próprio canal, sem poder ser vazada ou interceptada pelos demais receptores escolhidos. Isso exige que nenhum receptor escolhido capte outro transmissor escolhido, ou seja, que nenhuma aresta ligue dois canais: os canais formam um emparelhamento induzido, e o maior número de canais seguros simultâneos é o tamanho de um emparelhamento induzido máximo. Os autores mencionam aplicações semelhantes em projeto de circuitos VLSI e em problemas de fluxo em redes.

4.3.2 Complexidade computacional

Diferentemente do emparelhamento clássico (cardinalidade ou ponderado), que possui algoritmos polinomiais eficientes, o problema de encontrar o emparelhamento induzido de cardinalidade máxima é **NP-difícil**.

Stockmeyer e Vazirani (1982) provaram esse resultado e mostraram que o problema continua NP-difícil mesmo quando restrito a grafos bipartidos de grau máximo

4. Ou seja, ao contrário do que acontece no emparelhamento comum, ser bipartido não torna o problema fácil.

4.3.3 Redução ao problema do conjunto independente

Um **conjunto independente** em um grafo é um conjunto de vértices dois a dois não adjacentes, e o problema do **Conjunto Independente Máximo** (MIS, *Maximum Independent Set*) consiste em encontrar um de maior cardinalidade. O MIM em G pode ser reescrito como um MIS em um grafo construído a partir de G, em dois passos:

1. constrói-se o **grafo de linha** $L(G)$, que tem um vértice para cada aresta de G; dois vértices são adjacentes se as arestas correspondentes compartilham um extremo em G. Um conjunto independente em $L(G)$ é, portanto, um emparelhamento em G;

2. constrói-se o **quadrado do grafo de linha**, $L(G)^2$. O quadrado de um grafo tem os mesmos vértices que ele e liga dois vértices quando a distância entre eles, isto é, o número de arestas do menor caminho que os une, é 1 ou 2. Em $L(G)^2$, duas arestas e e f de G ficam adjacentes em dois casos:
    a) **distância 1 em** $L(G)$**:** e e f têm um extremo em comum;
    b) **distância 2 em** $L(G)$**:** existe uma terceira aresta g que compartilha um extremo com e e outro com f, ou seja, g liga e a f em G.

Esses dois casos são exatamente as situações que impedem e e f de estarem juntas em um emparelhamento induzido. Por isso, $L(G)^2$ é chamado neste trabalho de **grafo de conflitos** e denotado por H, e a **vizinhança** $N_H(e)$ de uma aresta e é o conjunto das arestas de G que conflitam com e. Um conjunto de arestas de G é um emparelhamento induzido quando nenhum par delas conflita, isto é, quando forma um conjunto independente em H; assim, encontrar um emparelhamento induzido máximo em G equivale a encontrar um conjunto independente máximo em $L(G)^2$ (CAMERON, 1989).

Na Figura 5, $L(G)$ é o caminho $e_1e_2e_3e_4e_5$ (c). Em $L(G)^2$ (d), e_1 e e_3 passam a ser adjacentes, pois estão a distância 2 em $L(G)$, por meio de e_2; já e_1 e e_4 estão a distância 3 e não conflitam. A vizinhança de e_1 em H é $N_H(e_1) = \{e_2, e_3\}$, e o conjunto independente $\{e_1, e_4\}$ corresponde ao emparelhamento induzido de (b).

A redução não prova, por si só, que o MIM é difícil: ela transforma o MIM em um problema NP-difícil (GAREY; JOHNSON, 1990), e não o contrário, e a NP-dificuldade vem do resultado de Stockmeyer e Vazirani (1982) visto acima. Sua utilidade é outra: ela permite aproveitar algoritmos de conjunto independente, exatos e heurísticos, como fazem os métodos a seguir.

4.3.4 Abordagens de solução e heurísticas

Dada a natureza NP-difícil do problema e a ineficácia de métodos exatos para grafos densos ou de grande escala, a literatura concentra-se majoritariamente em algoritmos construtivos gulosos e metaheurísticas.

4.3.4.1 Algoritmo exato

Para instâncias pequenas, a redução da Seção 4.3.3 permite resolver o MIM de forma exata. Constrói-se o grafo de conflitos $H = L(G)^2$ e busca-se nele um conjunto independente máximo por *branch-and-bound*: a cada passo, escolhe-se uma aresta candidata e exploram-se dois ramos, incluí-la ou não na solução. Um ramo é podado quando, mesmo incluindo todas as candidatas restantes, não superaria a melhor solução já encontrada. É a abordagem usada neste trabalho como referência exata (Algoritmo 27), viável apenas para algumas dezenas de vértices.

Algoritmo 27: Emparelhamento induzido máximo exato, via conjunto independente máximo em $L(G)^2$ (CAMERON, 1989)

Entrada: grafo $G = (V, E)$
Saída: emparelhamento induzido máximo M^*
(1) construa $H = L(G)^2$: um vértice por aresta de G; $e \sim f$ em H **se e somente se** e e f têm um vértice em comum ou são ligadas por uma aresta de G
(2) $M^* := \emptyset$
(3) RAMIFICA$(\emptyset, E)$
(4) **retorne** M^*

(5) **Procedimento** RAMIFICA(M, C)
(6) | **[comentário: M: solução atual; C: arestas candidatas sem conflito com M]**
(7) | **se** $|M| + |C| \leq |M^*|$ **então retorne [comentário: poda]**
(8) | **se** $C = \emptyset$ **então**
(9) | | $M^* := M$
(10) | | **retorne**
(11) | **fim**
(12) | escolha $e \in C$
(13) | RAMIFICA$(M \cup \{e\}, C \setminus (N_H(e) \cup \{e\}))$ **[comentário: inclui e]**
(14) | RAMIFICA$(M, C \setminus \{e\})$ **[comentário: exclui e]**

As etapas do Algoritmo 27 são as seguintes:

a) **linha 1:** constrói-se o grafo de conflitos $H = L(G)^2$, com um vértice para cada aresta de G e uma aresta entre duas arestas de G que não podem estar juntas em um emparelhamento induzido: as que compartilham um vértice ou as que são ligadas por uma terceira aresta. Um emparelhamento induzido de G é exatamente um conjunto independente de H;

b) **linhas 2–4:** a melhor solução conhecida M^* começa vazia, e a busca parte

de uma solução vazia com todas as arestas como candidatas. Ao final, M^* contém o emparelhamento induzido máximo;

c) **linha 7:** poda (*bound*): o procedimento RAMIFICA recebe a solução parcial M e o conjunto C das arestas que ainda podem ser adicionadas a ela sem conflito. Mesmo que todas as candidatas fossem incluídas, a solução teria no máximo $|M|+|C|$ arestas; se isso não supera a melhor solução já encontrada, o ramo é abandonado;

d) **linhas 8–9:** sem candidatas restantes, a solução parcial está completa e, como passou pela poda, é maior que M^*, que é então substituída;

e) **linhas 12–14:** ramificação (*branch*): escolhe-se uma candidata e e exploram-se os dois casos possíveis. No primeiro, e entra na solução, e saem das candidatas e e todos os seus vizinhos em H, que passariam a conflitar com ela. No segundo, e é descartada e as demais candidatas são mantidas. Todo emparelhamento induzido cai em exatamente um dos dois ramos, o que garante que o ótimo é encontrado;

f) **complexidade:** a construção de H compara pares de arestas, com custo $O(E^2)$. A árvore de busca tem profundidade no máximo E, pois cada chamada remove ao menos uma candidata, e até 2^E folhas no pior caso; cada chamada faz operações de conjunto de custo $O(E)$. O total é exponencial, $O(E \cdot 2^E)$ no pior caso, o que é esperado para um problema NP-difícil; a poda reduz bastante a busca na prática, mas não altera esse limite, e o algoritmo só é viável em instâncias pequenas.

4.3.4.2 Heurísticas gulosas

Dada a equivalência entre o problema do Emparelhamento Induzido Máximo em G e o Conjunto Independente Máximo no grafo transformado $L(G)^2$, as heurísticas gulosas clássicas da literatura de conjuntos independentes são naturalmente adaptadas para este contexto.

O procedimento geral consiste em selecionar iterativamente uma aresta candidata e, adicioná-la à solução e retirar das candidatas a própria e e as arestas que conflitam com ela, isto é, seus vizinhos $N_H(e)$ no grafo de conflitos (Seção 4.3.3). As variantes diferem no critério de seleção da aresta:

a) **guloso aleatório (*random greedy*):** seleciona a próxima aresta uniformemente ao acaso dentre as disponíveis. Duckworth, Wormald e Zito (2002) analisaram um algoritmo guloso aleatório em grafos cúbicos aleatórios e mostraram que, quase certamente, ele obtém um emparelhamento induzido com pelo menos $0{,}270n$ arestas, enquanto o máximo tem menos de $0{,}282n$;

b) **guloso de grau mínimo (*min-degree greedy*):** a heurística escolhe a candidata com **menos conflitos**, isto é, de menor grau no subgrafo $H[C]$ do grafo de conflitos induzido pelas candidatas C: é a aresta cuja escolha elimina o menor número de outras candidatas. Esta abordagem é uma adaptação direta da heurística *Min-Degree* (ou *Greedy*) para o problema do Conjunto Independente Máximo. Halldórsson e Radhakrishnan (1994) estabeleceram os fundamentos teóricos para essa estratégia, demonstrando que priorizar vértices de baixo grau fornece garantias de aproximação superiores em grafos esparsos e de grau limitado. No contexto do MIM, essa lógica se traduz em escolher a aresta com a menor vizinhança em $L(G)^2$, contada apenas entre as candidatas restantes. No caminho da Figura 5, os graus iniciais em H são 2, 3, 4, 3 e 2 para $e_1, \ldots, e_5$; a heurística escolhe e_1 (empatada com e_5) e descarta e_2 e e_3; restam e_4 e e_5, que conflitam entre si, e a escolha de e_4 leva ao emparelhamento induzido máximo $\{e_1, e_4\}$.

As duas variantes compartilham a mesma estrutura e diferem apenas no critério de seleção, conforme o Algoritmo 28. Ambas são classificadas como heurísticas (Seção 2.7): as garantias conhecidas para os gulosos de conjunto independente dependem do grau máximo do grafo (HALLDóRSSON; RADHAKRISHNAN, 1994) e, em $L(G)^2$, esse grau cresce com o quadrado do grau de G, de modo que não há razão de aproximação constante para grafos gerais.

Algoritmo 28: Heurísticas gulosas aleatória e de grau mínimo para emparelhamento induzido (DUCKWORTH; WORMALD; ZITO, 2002; HALLDóRSSON; RADHAKRISHNAN, 1994)

Entrada: grafo $G = (V, E)$; regra de escolha ALEATÓRIA ou GRAUMÍNIMO
Saída: emparelhamento induzido maximal M

(1) construa $H = L(G)^2$
(2) $M := \emptyset$; $C := E$
(3) **enquanto** $C \neq \emptyset$ **faça**
(4) | **se** *a regra é* ALEATÓRIA **então**
(5) | | escolha $e \in C$ uniformemente ao acaso
(6) | **senão**
(7) | | escolha $e \in C$ de grau mínimo em $H[C]$
(8) | **fim**
(9) | $M := M \cup \{e\}$
(10) | $C := C \setminus (N_H(e) \cup \{e\})$
(11) **fim**
(12) **retorne** M

O Algoritmo 28 funciona da seguinte forma:

a) **linha 1:** constrói-se o grafo de conflitos $H = L(G)^2$, o mesmo do Algoritmo 27;

b) **linha 2:** a solução começa vazia, e todas as arestas de G são candidatas;

c) **linhas 3–7:** enquanto houver candidatas, escolhe-se uma delas segundo a regra da variante: ao acaso, no guloso aleatório (linha 5), ou a de menor grau no subgrafo de H induzido pelas candidatas, no guloso de grau mínimo (linha 7). O grau de e em $H[C]$ é o número de candidatas que deixarão de estar disponíveis se e for escolhida; minimizá-lo preserva o maior número possível de opções para os passos seguintes;

d) **linhas 9–10:** a aresta escolhida entra na solução e, junto com todos os seus vizinhos em H, deixa de ser candidata, o que mantém M um emparelhamento induzido a cada passo;

e) **linha 12:** quando não há mais candidatas, nenhuma aresta pode ser adicionada a M sem violar a restrição induzida: o resultado é um emparelhamento induzido maximal, mas não necessariamente máximo;

f) **complexidade:** a construção de H custa $O(E^2)$, e H tem $O(E^2)$ arestas no pior caso. O laço executa no máximo E iterações, e cada aresta de H é percorrida um número constante de vezes ao remover os vizinhos das escolhidas, com custo total $O(E^2)$. No guloso aleatório, cada escolha custa $O(1)$; no de grau mínimo, mantendo os graus em $H[C]$ atualizados a cada remoção, a escolha do mínimo custa $O(E)$ por iteração, também $O(E^2)$ no total. As duas variantes têm, portanto, complexidade $O(E^2)$, dominada pelo grafo de conflitos, como indicado na Tabela 6.

4.3.4.3 Metaheurísticas

Para superar os ótimos locais frequentemente encontrados pelos métodos gulosos, abordagens iterativas de busca local têm sido aplicadas.

Fürst, Leichter e Rautenbach (2017) investigaram formalmente o poder da busca local para o Emparelhamento Induzido Máximo. A estratégia analisada consiste em iniciar com um emparelhamento induzido qualquer (ou vazio) e tentar aumentá-lo iterativamente através de melhorias locais simples. Eles focaram na análise de grafos k-regulares e demonstraram que, embora a busca local possa ficar presa em ótimos locais longe da solução global em grafos gerais, ela oferece garantias de desempenho interessantes para classes específicas (como grafos livres de garras ou C_4-free). O algoritmo de busca local proposto tenta adicionar arestas que não violem a restrição induzida e, se necessário, remover um número pequeno de arestas existentes para acomodar a nova inclusão, um processo análogo às trocas (*k-swaps*) em outros problemas combinatórios.

Tabela 6 – Algoritmos para problema de emparelhamento induzido máximo em grafos gerais

Algoritmo	**Complexidade**	**Tipo**	**Avaliado**	**Descrição**
Guloso Aleatório	$O(E^2)$*	Heur.	Sim	Seleciona arestas uniformemente ao acaso e remove suas vizinhanças induzidas.
Guloso de grau mínimo	$O(E^2)$*	Heur.	Sim	Seleciona a aresta cuja remoção elimina o menor número de arestas vizinhas.
Exato (conjunto independente)	exponencial	Exato	Sim	Busca por conjunto independente máximo em $L(G)^2$ via *branch-and-bound*; viável apenas em instâncias pequenas.

Fonte: Elaborado pelo autor.

Heur.: heurística. *Avaliado*: incluído no ambiente de testes; a origem de cada implementação consta na Tabela 10. As complexidades são justificadas no texto de cada algoritmo. * Complexidade das implementações avaliadas, que constroem explicitamente o grafo de conflitos $L(G)^2$.

5 METODOLOGIA

Este capítulo descreve o ambiente de testes construído para implementar e comparar os algoritmos dos capítulos anteriores. Todo o código do ambiente, os geradores de instâncias e os resultados brutos estão disponíveis no repositório do trabalho[1]. São apresentados a arquitetura do ambiente, a interface padrão de cada problema, os geradores de instância, o protocolo de medição, os critérios de comparação, a máquina utilizada e a origem e a adaptação de cada algoritmo, para que os resultados do capítulo seguinte possam ser reproduzidos.

5.1 ARQUITETURA DO AMBIENTE DE TESTES

O ambiente é separado em três camadas:

a) **repositório de código de terceiros:** contém os códigos de algoritmos obtidos de repositórios públicos, em sua maioria do GitHub. Esses códigos são usados exatamente como foram publicados, sem nenhuma alteração, nem mesmo para corrigir defeitos (Seção 6.8). As bibliotecas maduras usadas como referência (NetworkX, SciPy, igraph e lap) não ficam nesta camada: são instaladas pelo gerenciador de pacotes do Python, com versões fixadas;

b) **adaptadores/*wrappers*:** como os algoritmos divergem quanto aos formatos de entrada e saída, e até mesmo quanto à linguagem, essa camada foi criada com o intuito de traduzir cada um dos algoritmos para o formato padrão do trabalho, para que todos sejam testados nas mesmas condições. Quando o código original não pode ser usado diretamente, a reimplementação também fica nesta camada, de modo que o original permanece intacto no repositório;

c) **módulo de medição:** é a parte que executa e mede os testes, responsável por cronometragem, verificação e gravação dos resultados. Para cada problema, um *script* de *benchmark* gera as instâncias e aciona este módulo, que executa todos os algoritmos por meio dos seus *wrappers*. Isso garante que todos sejam submetidos ao mesmo protocolo, e que possam ser feitas comparações entre algoritmos sob condições idênticas.

5.2 INTERFACE PADRÃO DOS PROBLEMAS

Cada problema possui uma interface padrão à qual todos os seus algoritmos são adaptados (Tabela 7). Com ela, todo algoritmo de um mesmo problema recebe

[1] <https://github.com/talisbreda/TCC>

exatamente a mesma instância e produz a saída no mesmo formato.

Tabela 7 – Interface padrão de entrada e saída por problema

Problema	**Entrada**	**Saída**
Cardinalidade máxima (bipartido)	vértices de cada lado e lista de arestas	tamanho e emparelhamento
Atribuição linear	matriz de custos $n \times n$	custo total e atribuição
Atribuição gargalo	matriz de custos $n \times n$	custo gargalo e atribuição
Casamento estável	listas de preferência de ambos os lados	emparelhamento
Cardinalidade máxima (geral)	número de vértices e lista de arestas	tamanho e emparelhamento
Peso máximo (geral)	número de vértices e arestas com peso	peso total e emparelhamento
Emparelhamento induzido máximo	número de vértices e lista de arestas	tamanho e emparelhamento

Fonte: Elaborado pelo autor.

5.3 GERADORES DE INSTÂNCIA

As instâncias são produzidas por construtores determinísticos, um por família, parametrizados pelo tamanho n. Cada construtor que usa aleatoriedade cria, a cada chamada, um gerador pseudoaleatório próprio, iniciado com a semente fixa 42 (`random.Random(42)`, do Python). Como esse gerador não é compartilhado com o restante do programa, uma mesma chamada produz sempre a mesma instância, independentemente da ordem em que os algoritmos são executados. Além disso, a instância de cada tamanho é construída uma única vez e entregue a todos os algoritmos da célula, de modo que todos resolvem exatamente a mesma entrada. Instâncias de tamanhos diferentes partem da mesma semente, mas não são aninhadas: a de tamanho 100 não contém a de tamanho 50.

Para cada problema, definiram-se famílias com características distintas, de modo a expor o comportamento dos algoritmos sob diferentes estruturas de entrada. Sempre que possível, a família foi construída de forma que o valor ótimo seja conhecido de antemão, o que permite conferir as soluções sem depender de outro algoritmo. A Tabela 8 resume as famílias, e os geradores são descritos a seguir.

Tabela 8 – Famílias de instâncias por problema

Família	**Construção e propriedade**	**Tamanhos n**
Cardinalidade máxima em grafos bipartidos (Algoritmo 29)		
Grafo 1: esparso, sem perfeito	dois blocos fixos, grau médio 2,2; $\lvert M^*\rvert = 0{,}8n$	50–250
Grafo 2: esparso, com perfeito	diagonal mais um vizinho $(7i+3) \bmod n$; $\lvert M^*\rvert = n$	50–250
Grafo 3: denso, com perfeito	diagonal mais arestas aleatórias até grau médio 15; $\lvert M^*\rvert = n$	50–250
Atribuição linear (Algoritmo 30)		
Matriz 1: densa uniforme	custos inteiros uniformes em $[1, 100]$	10–100; 50–250[a]
Matriz 2: permutação barata	permutação aleatória de custo 1, demais em $[50, 100]$; ótimo $= n$	idem
Matriz 3: estruturada	$c_{ij} = \lvert i-j\rvert + 1$; ótimo $= n$	idem
Atribuição gargalo (Algoritmo 30)		
Matriz 1: densa uniforme	custos inteiros uniformes em $[1, 100]$	10–200
Matriz 2: estruturada	$c_{ij} = \lvert i-j\rvert + 1$; gargalo ótimo $= 1$	10–200
Matriz 3: poucos valores	custos sorteados em $\{1, 5, 10, 50\}$; muitos empates	10–200
Casamento estável (Algoritmo 31)		
Perfil 1: aleatório	listas independentes e uniformes	25–100; 100–400[b]
Perfil 2: correlacionado	uma única lista para todos os homens e outra para todas as mulheres	idem
Perfil 3: cíclico	m prefere $m, m+1, \ldots$; w prefere $w, w-1, \ldots$ (módulo n)	idem
Grafos gerais: cardinalidade e peso máximo (Algoritmo 32)		
Esparso (grau $\sim$3)	$G(n,p)$ com $p = 3/n$; na versão ponderada, pesos em $[1, 100]$	10–100
Denso ($p = 0{,}3$)	$G(n,p)$ com $p = 0{,}3$; idem	10–100
Emparelhamento induzido máximo (Algoritmo 32)		
Esparso, médio e denso	$G(n,p)$ com grau médio esperado 3, 6 e 12	10–40; 50–400[c]

Fonte: Elaborado pelo autor.

Nota: (a) 10 a 100 com todos os algoritmos e 50 a 250 com todos exceto os caminhos mínimos sucessivos; (b) 25 a 100 com todos e 100 a 400 apenas com o Gale-Shapley numérico e o de Lattas; (c) 10 a 40 com o algoritmo exato e 50 a 400 apenas com as heurísticas. n é o número de vértices de cada lado (bipartidos e matrizes $n \times n$), o número de homens e de mulheres (casamento estável) ou o número de vértices (grafos gerais).

5.3.1 Grafos bipartidos

Para o emparelhamento de cardinalidade máxima, as três famílias diferem na densidade e na existência de emparelhamento perfeito, e o valor ótimo de todas é conhecido por construção (Algoritmo 29). Os vértices são $u_0, \ldots, u_{n-1}$ do lado U e $v_0, \ldots, v_{n-1}$ do lado V.

Algoritmo 29: Geradores de grafos bipartidos para cardinalidade máxima

```
(1)  Procedimento Grafo1(n)
(2)      a_U := ⌊0,8n⌋; a_V := ⌊0,6n⌋; b_U := n − a_U; b_V := n − a_V
(3)      E := ∅
(4)      para i := 0 até a_U − 1 faça
(5)          E := E ∪ {{u_i, v_{i mod a_V}}, {u_i, v_{(i+1) mod a_V}}}
(6)      fim
(7)      para k := 0 até b_U − 1 faça
(8)          para o := 0 até 2 faça
(9)              E := E ∪ {{u_{a_U+k}, v_{a_V+(2k+o) mod b_V}}}
(10)         fim
(11)     fim
(12)     retorne E

(13) Procedimento Grafo2(n)
(14)     E := ∅
(15)     para i := 0 até n − 1 faça
(16)         j := (7i + 3) mod n
(17)         se j = i então j := (j + 1) mod n
(18)         E := E ∪ {{u_i, v_i}, {u_i, v_j}}
(19)     fim
(20)     retorne E

(21) Procedimento Grafo3(n, d = 15)
(22)     rng := novo gerador pseudoaleatório com semente 42
(23)     E := {{u_i, v_i} : 0 ≤ i < n}
(24)     enquanto |E| < d · n faça
(25)         sorteie i e j uniformemente em {0, ..., n − 1} com rng
(26)         E := E ∪ {{u_i, v_j}} [comentário: arestas repetidas são
              descartadas]
(27)     fim
(28)     retorne E
```

a) **grafo 1 (esparso, sem emparelhamento perfeito; linhas 2–9):** o grafo é a união de dois blocos sem arestas entre si. No bloco A, os primeiros $0{,}8n$ vértices de U ligam-se, cada um, a dois vértices consecutivos dos primeiros $0{,}6n$ vértices de V (linha 4). Como o bloco tem só $0{,}6n$ vértices em V, no máximo $0{,}6n$ de suas arestas podem estar num emparelhamento, e esse valor é atingido pelas arestas $\{u_i, v_i\}$, $i < a_V$. No bloco B, os $0{,}2n$ vértices restantes de U ligam-se a três dos $0{,}4n$ vértices restantes de V (linhas 7–9); como $2k < b_V$ para todo $k < b_U$, as arestas $\{u_{a_U+k}, v_{a_V+2k}\}$ cobrem todo o lado U do bloco. O emparelhamento máximo tem, portanto, exatamente $0{,}6n + 0{,}2n = 0{,}8n$ arestas, e nenhum é perfeito. O grau médio dos vértices de U é $(2 \cdot 0{,}8n + 3 \cdot 0{,}2n)/n = 2{,}2$. A construção não usa aleatoriedade;

b) **grafo 2 (esparso, com emparelhamento perfeito; linhas 15–18):** cada u_i

liga-se a v_i e a um segundo vizinho v_j, com $j = (7i + 3) \bmod n$ (linha 16), deslocado em uma posição quando coincidiria com i. As arestas $\{u_i, v_i\}$ formam um emparelhamento perfeito, logo $|M^*| = n$ (linha 18). Como 7 não divide nenhum dos tamanhos usados, $i \mapsto (7i + 3) \bmod n$ é uma permutação, e os segundos vizinhos ficam espalhados por todo o lado V, sem a estrutura em blocos do Grafo 1. A construção também é determinística;

c) **grafo 3 (denso, com emparelhamento perfeito; linhas 22–26):** parte da diagonal $\{u_i, v_i\}$, que garante um emparelhamento perfeito (linha 23), e acrescenta arestas sorteadas pelo gerador com semente fixa (linha 22) até o grafo ter $d \cdot n = 15n$ arestas (linha 24), isto é, grau médio 15. Sorteios repetidos não alteram o conjunto (linha 26). A densidade relativa é $15/n$, de 30% em $n = 50$ a 6% em $n = 250$; a família é "densa" em comparação com as duas anteriores, cujo grau médio fica entre 2 e 2,2;

d) **complexidade:** os Grafos 1 e 2 são gerados em tempo $O(n)$, com um número constante de arestas por vértice. No Grafo 3, a fração de sorteios repetidos é no máximo d/n, de modo que o número esperado de sorteios é $O(d \cdot n)$.

5.3.2 Matrizes de custo

Os problemas de atribuição linear e de gargalo recebem uma matriz de custos C de dimensão $n \times n$, gerada por um dos quatro procedimentos do Algoritmo 30. A atribuição linear usa as famílias uniforme, permutação barata e estruturada; o gargalo usa as famílias uniforme, estruturada e de poucos valores.

Algoritmo 30: Geradores de matrizes de custo para atribuição linear e gargalo

```
(1)  Procedimento Uniforme(n)
(2)      rng := novo gerador pseudoaleatório com semente 42
(3)      para i, j := 0 até n − 1 faça c_ij := inteiro sorteado uniformemente em
           [1, 100]
(4)      retorne C

(5)  Procedimento PermutacaoBarata(n)
(6)      rng := novo gerador pseudoaleatório com semente 42
(7)      π := permutação aleatória de {0, ..., n − 1} com rng
(8)      para i, j := 0 até n − 1 faça c_ij := inteiro sorteado uniformemente em
           [50, 100]
(9)      para i := 0 até n − 1 faça c_iπ(i) := 1
(10)     retorne C

(11) Procedimento Estruturada(n)
(12)     para i, j := 0 até n − 1 faça c_ij := |i − j| + 1
(13)     retorne C

(14) Procedimento PoucosValores(n)
(15)     rng := novo gerador pseudoaleatório com semente 42
(16)     para i, j := 0 até n − 1 faça c_ij := valor sorteado uniformemente em
           {1, 5, 10, 50}
(17)     retorne C
```

a) **matriz uniforme (linhas 2–3):** cada custo é um inteiro sorteado de modo uniforme e independente em $[1, 100]$. É a família sem estrutura, em que o ótimo não é conhecido de antemão e é obtido pelo algoritmo de referência;

b) **permutação barata (linhas 7–9):** sorteia-se uma permutação π (linha 7), todos os custos são preenchidos com valores entre 50 e 100 (linha 8) e, por fim, as posições $(i, \pi(i))$ recebem custo 1 (linha 9). A atribuição π custa n, e qualquer outra usa ao menos uma posição de custo maior ou igual a 50, custando no mínimo $(n-1) + 50 > n$. Logo, π é a única atribuição ótima e o valor ótimo n é conhecido por construção;

c) **matriz estruturada (linha 12):** o custo cresce com a distância à diagonal, $c_{ij} = |i - j| + 1$, sem aleatoriedade. A diagonal tem custo 1 em todas as linhas, de modo que a identidade é ótima tanto para a atribuição linear (custo n) quanto para o gargalo (custo máximo 1);

d) **poucos valores (linha 16):** cada custo é sorteado entre apenas quatro valores. Com isso, há muitos empates: muitas atribuições têm o mesmo gargalo, e a busca pelo limiar do algoritmo de *threshold* (Algoritmo 15) tem só quatro candidatos distintos;

e) **complexidade:** todos os procedimentos preenchem n^2 posições em tempo constante cada, totalizando $O(n^2)$; o sorteio da permutação custa $O(n)$.

5.3.3 Perfis de preferência

No casamento estável, uma instância é formada pelas listas de preferência P_m de cada homem m (uma ordenação das mulheres) e Q_w de cada mulher w (uma ordenação dos homens). As três famílias do Algoritmo 31 variam o grau de concordância entre as listas.

Algoritmo 31: Geradores de perfis de preferência para o casamento estável

```
(1)  Procedimento Aleatorio(n)
(2)      rng := novo gerador pseudoaleatório com semente 42
(3)      para m := 0 até n − 1 faça P_m := permutação aleatória de {0, ..., n − 1}
          com rng
(4)      para w := 0 até n − 1 faça Q_w := permutação aleatória de {0, ..., n − 1}
          com rng
(5)      retorne (P, Q)

(6)  Procedimento Correlacionado(n)
(7)      rng := novo gerador pseudoaleatório com semente 42
(8)      π := permutação aleatória de {0, ..., n − 1} com rng [comentário:
          ranking das mulheres]
(9)      σ := permutação aleatória de {0, ..., n − 1} com rng [comentário:
          ranking dos homens]
(10)     para m := 0 até n − 1 faça P_m := π
(11)     para w := 0 até n − 1 faça Q_w := σ
(12)     retorne (P, Q)

(13) Procedimento Ciclico(n)
(14)     para m := 0 até n − 1 faça P_m := (m, m + 1, ..., m + n − 1) mod n
(15)     para w := 0 até n − 1 faça Q_w := (w, w − 1, ..., w − n + 1) mod n
(16)     retorne (P, Q)
```

a) **perfil aleatório (linhas 3–4):** cada lista é uma permutação uniforme e independente das demais. É o caso médio, em que as preferências não têm relação entre si;

b) **perfil correlacionado (linhas 8–11):** sorteiam-se apenas duas permutações: π, adotada por todos os homens (linha 10), e σ, adotada por todas as mulheres (linha 11). É o extremo da contenção: todos os homens disputam as mesmas mulheres na mesma ordem. No Gale-Shapley, a cada rodada só um homem é aceito pela mulher mais disputada que resta, e o total de propostas é $n + (n-1) + \cdots + 1 = n(n+1)/2$, o pior caso quadrático do algoritmo;

c) **perfil cíclico (linhas 14–15):** as listas são deslocamentos circulares, sem aleatoriedade: o homem m prefere $m, m+1, m+2, \ldots$ e a mulher w prefere $w, w-1, w-2, \ldots$, sempre módulo n. A primeira escolha de cada homem m é a mulher m, cuja primeira escolha é ele próprio; o Gale-Shapley termina, assim, com n propostas e devolve o emparelhamento $\{(m, m)\}$, o melhor caso do algoritmo;

d) **complexidade:** cada procedimento escreve $2n$ listas de tamanho n, em tempo $O(n^2)$.

5.3.4 Grafos gerais aleatórios

Para os problemas em grafos gerais, inclusive o emparelhamento induzido máximo, as instâncias são grafos aleatórios no modelo $G(n, p)$ de Erdős–Rényi, em que cada um dos $\binom{n}{2}$ pares de vértices é ligado de forma independente com probabilidade p (Algoritmo 32).

Algoritmo 32: Gerador de grafos gerais aleatórios no modelo $G(n, p)$

```
(1)  Procedimento GrafoAleatorio(n, p, ponderado)
(2)      rng := novo gerador pseudoaleatório com semente 42
(3)      E := ∅
(4)      para u := 0 até n − 1 faça
(5)          para v := u + 1 até n − 1 faça
(6)              se um número sorteado uniformemente em [0, 1) com rng for < p
                 então E := E ∪ {{u, v}}
(7)          fim
(8)      fim
(9)      se ponderado então
(10)         rng′ := novo gerador pseudoaleatório com semente 43
(11)         para cada e ∈ E, na ordem de inserção faça w(e) := inteiro sorteado
                 uniformemente em [1, 100] com rng′
(12)     fim
(13)     retorne E (e w, se ponderado)
```

a) **sorteio das arestas (linhas 2–6):** os pares $\{u, v\}$ com $u < v$ são percorridos em ordem fixa (linha 4), e cada um vira aresta com probabilidade p (linha 6). O grau esperado de cada vértice é $p(n-1)$. As famílias usam: $p = 3/n$ ("esparso, grau $\sim$3") e $p = 0{,}3$ ("denso") para cardinalidade e peso máximo; e $p = d/(n-1)$, com grau médio esperado d igual a 3, 6 e 12 (grafos esparso, médio e denso), para o emparelhamento induzido máximo;

b) **pesos (linhas 9–11):** na versão ponderada, os pesos são inteiros uniformes em $[1, 100]$, sorteados por um segundo gerador, com semente 43 (linha 10). Como as arestas continuam sendo sorteadas pelo primeiro gerador, a instância ponderada tem exatamente as mesmas arestas da instância

de cardinalidade de mesmo tamanho e densidade; muda apenas a existência dos pesos;

c) **propriedades:** nenhuma propriedade de emparelhamento é imposta: o grafo pode ter vértices isolados e não ter emparelhamento perfeito. O valor ótimo é obtido pelo algoritmo exato de referência (Blossom, van Rantwijk ou o exato do emparelhamento induzido) ou, nos tamanhos em que o exato não é executado, comparado ao melhor resultado conhecido;

d) **complexidade:** todos os $\binom{n}{2}$ pares são testados, independentemente de p, o que leva a tempo $\Theta(n^2)$; o sorteio dos pesos acrescenta $O(|E|)$.

5.4 PROTOCOLO DE MEDIÇÃO

Um protocolo de medição foi criado a fim de reduzir o quanto fontes de ruído externas afetam os resultados dos testes. A unidade de medição é a **célula**: a combinação de um algoritmo, uma instância e um tamanho n. Cada célula é executada uma vez para aquecimento e, em seguida, cinco vezes com cronometragem. Algumas das decisões que compõem esse protocolo:

a) **execução de aquecimento:** a primeira execução de cada célula é descartada da cronometragem, para que as repetições medidas não paguem custos de importação, alocação inicial e *caches* frios. O resultado dessa execução é o utilizado na verificação de qualidade;

b) **coletor de lixo:** é desligado durante a execução de uma célula inteira, e religado entre células, a fim de não comprometer o resultado da execução;

c) **mediana:** cada célula reporta a mediana dos tempos, ao invés da média, para dar mais robustez com relação a interrupções momentâneas;

d) **limite de tempo por célula:** impede que um algoritmo defeituoso inviabilize toda a suíte de testes. Ele foi necessário por causa de um defeito discutido na Seção 6.8. O limite, de 120 segundos, é aplicado à execução de aquecimento: se ela o excede, é interrompida, a célula é marcada como estourada e os tamanhos maiores daquele algoritmo não são executados, pois também estourariam. A exceção é o problema de atribuição, em que todos os tamanhos são executados mesmo após um estouro, pois um dos algoritmos falha de forma não-monótona no tamanho da entrada. O limite é verificado apenas em torno do aquecimento, e não a cada operação do algoritmo, para não adicionar custo à região cronometrada.

5.5 CRITÉRIOS DE COMPARAÇÃO

O tempo de execução de implementações em linguagens diferentes não é diretamente comparável, porque parte da diferença vem da linguagem. Por isso, adotaram-se quatro critérios complementares.

1. implementações em linguagem interpretada (ex: Python) e as de núcleo compilado (ex: C++) não têm o tempo absoluto comparado entre si: as tabelas de tempo trazem apenas as interpretadas. Manter as duas linguagens, em vez de uma só, foi necessário por dois motivos. Primeiro, não há implementações públicas confiáveis de todos os algoritmos em uma mesma linguagem, e portá-las significaria reimplementá-las, o que contraria o objetivo de avaliar o código como foi publicado (camada intacta, Seção 5.1). Segundo, as bibliotecas maduras usadas como referência de correção e de patamar de desempenho (igraph, SciPy e lap) têm núcleo compilado. O conjunto principal de comparação é o das implementações interpretadas, cujas tabelas de tempo compõem o Capítulo 6; as compiladas entram nas tabelas de qualidade, e a comparação entre as duas linguagens é feita apenas pelo expoente empírico (critério 3). Bibliotecas escritas inteiramente em linguagem interpretada, como o NetworkX, entram nas tabelas de tempo, pois nesse caso a comparação de tempo com elas é legítima. Há ainda casos intermediários: algoritmos escritos como laços em Python sobre vetores da biblioteca NumPy, cujo núcleo é compilado, como os Húngaros `hunalgorithm` e `mayorx` e o Gale-Shapley numérico. Estes são classificados como interpretados, pois o algoritmo em si é executado pelo interpretador;

2. as tabelas mostram a complexidade assintótica da implementação avaliada ao lado do tempo medido, permitindo a comparação do teórico vs real, principalmente entre grafos de diferentes densidades;

3. para cada algoritmo, é estimado o **expoente empírico do crescimento**. Supondo que o tempo cresça como $t(n) \approx C \cdot n^k$, aplicar o logaritmo resulta em

$$\log t(n) = \log C + k \log n, \tag{5.1}$$

isto é, uma reta de inclinação k no gráfico do logaritmo do tempo pelo logaritmo do tamanho. O expoente é estimado pela inclinação da reta ajustada por mínimos quadrados aos pontos medidos $(x_i, y_i) = (\log n_i, \log t_i)$:

$$k = \frac{\sum_i (x_i - \bar{x})(y_i - \bar{y})}{\sum_i (x_i - \bar{x})^2}. \tag{5.2}$$

Esse dado, ao contrário do tempo absoluto, é comparável entre linguagens: a linguagem altera apenas a constante C, o que desloca a reta verticalmente

sem mudar sua inclinação. Junto ao expoente é reportado o coeficiente de determinação R^2, que indica o quanto os pontos de fato seguem uma reta; um R^2 baixo sinaliza que o crescimento não é bem descrito por uma única potência de n na faixa medida;

4. em problemas com apenas soluções exatas, a qualidade da solução é idêntica entre todos, sendo o método de comparação o tempo de execução. Já nos que têm soluções aproximadas ou heurísticas, a tabela de qualidade apresenta o valor absoluto da solução de cada algoritmo (cardinalidade, custo ou peso), ao lado do valor do algoritmo exato de referência (ou do melhor resultado conhecido, quando o exato não é executado); a razão entre os dois é calculada na discussão dos resultados.

5.6 AMBIENTE DE EXECUÇÃO E REPRODUTIBILIDADE

Todos os resultados foram obtidos numa única máquina (Tabela 9). Três fatores exigiram cuidados, dois da máquina e um da linguagem, todos documentados para permitir reprodução.

1. por ser um **processador híbrido** (núcleos de desempenho e de eficiência, não equivalentes), a execução foi fixada a um núcleo de desempenho, evitando que a migração entre núcleos alterasse o tempo sem mudança no código;

2. como a **frequência varia** dinamicamente com a carga, o regulador foi fixado no modo de desempenho, com a máquina conectada à energia e sem aplicações concorrentes;

3. em Python, o *hash* de cadeias de caracteres é aleatorizado a cada processo, o que altera a ordem de iteração de conjuntos e dicionários entre execuções. Por isso, a semente dessa aleatorização foi fixada (variável `PYTHONHASHSEED`), tornando as execuções reprodutíveis. Isso foi necessário pois foi notada em um dos algoritmos uma grande sensibilidade a essa ordem, o que será detalhado no capítulo de resultados.

Tabela 9 – Especificação da máquina de medição

Componente	**Especificação**
Processador	Intel Core 7 150U (10 núcleos físicos, 12 *threads*)
Topologia	híbrida: 2 núcleos de desempenho e 8 de eficiência
Memória	33 GB
Sistema operacional	Ubuntu 24.04.2 LTS (*kernel* 7.0.0)
Linguagem	Python 3.12.3
Bibliotecas	NumPy 2.5.2, SciPy 1.18.0, NetworkX 3.6.1, igraph 1.0.0, lap 0.5.13

Fonte: Elaborado pelo autor.

5.7 ORIGEM, ADAPTAÇÃO E VERIFICAÇÃO DOS ALGORITMOS

A maior parte dos algoritmos foi obtida de implementações públicas, em vez de reescrita. Isso é coerente com o objetivo de comparar métodos presentes na literatura, reduz o risco de erros próprios e permite avaliar a qualidade das implementações efetivamente disponíveis. Foram empregadas quatro estratégias de adaptação, conforme natureza do código:

1. carregamento direto, quando o original é utilizável na linguagem do projeto;
2. encapsulamento, para métodos disponíveis em bibliotecas maduras;
3. reimplementação fiel, quando o original não é utilizável diretamente, seja por estar em outra linguagem ou versão, ou por conter efeitos colaterais, seguindo a lógica original com a fonte documentada;
4. implementação própria a partir da fonte bibliográfica, para os métodos aproximados, as heurísticas e alguns exatos sem implementação pública adequada, algoritmos de descrição curta cuja reimplementação é mais confiável que um repositório de qualidade incerta.

A Tabela 10 registra o tipo e a origem de cada algoritmo, e aponta o pseudocódigo correspondente nos capítulos anteriores.

Tabela 10 – Proveniência dos algoritmos avaliados

Algoritmo	**Tipo**	**Alg.**	**Origem**
Cardinalidade máxima em grafos bipartidos			
Caminhos aumentantes	Exato	4	<wbchristerson/perfect-matchings>
Hopcroft-Karp	Exato	6 e 7	<sofiat-olaosebikan/hopcroftkarp>
Edmonds-Karp (fluxo)	Exato	5	reimpl. de `Maxflow-Algorithms`
Hopcroft-Karp (NetworkX)	Referência	6 e 7	NetworkX (interpretada)
Emparelhamento bipartido (igraph)	Referência	—	igraph (compilada)
Guloso simples	Aproximado	8	própria (CORMEN et al., 2009)
Karp-Sipser	Aproximado	9	própria (KARP; SIPSER, 1981)
Atribuição linear			
Húngaro (munkres)	Exato	10	<bmc/munkres>
Húngaro (benchaplin)	Exato	10	<benchaplin/hungarian-algorithm>
Húngaro (hunalgorithm)	Exato	10	<pbertoni/HungarianAlgorithm>
Húngaro (mayorx)	Exato	10	<mayorx/hungarian-algorithm>
Caminhos mínimos sucessivos	Exato	13	reimpl. a partir de repositório
SciPy	Referência	12	SciPy (compilada)
Jonker-Volgenant	Referência	12	lap (compilada)
Atribuição gargalo			
Threshold	Exato	15	reimpl. (original em JavaScript)
Caminhos aumentantes	Exato	17	própria (BURKARD; DELL'AMICO; MARTELLO, 2009)
Gulosa simples	Heurística	19	própria
Gulosa por arrependimento	Heurística	19	própria (MARTELLO; TOTH, 1987)
Casamento estável			
Gale-Shapley (orientado a objetos)	Exato	20	pacote `gale-shapley-algorithm`
Gale-Shapley (numérico)	Exato	20	pacote `gale-shapley-algorithm`
Gale-Shapley (Lattas)	Exato	20	reimpl. de `StableMarriages`
Grafos gerais			
Blossom/Edmonds (cardinalidade)	Exato	21	<adharshkamath/Edmonds-Algorithm>
van Rantwijk (peso máximo)	Exato	25	`mwmatching.py` de J. van Rantwijk
NetworkX (cardinalidade e peso)	Referência	21 e 25	NetworkX (interpretada)
Path Growing	Aproximado	26	própria (DRAKE; HOUGARDY, 2003)
Emparelhamento induzido máximo			
Exato (conjunto independente)	Exato	27	própria (CAMERON, 1989)
Guloso aleatório	Heurística	28	própria
Guloso de grau mínimo	Heurística	28	própria

Fonte: Elaborado pelo autor.

Nota: **Alg.**: número do pseudocódigo correspondente. **Origem**: `usuário/nome` indica um repositório do GitHub; NetworkX, igraph, SciPy e lap são bibliotecas, com núcleo interpretado (Python) ou compilado; "própria" indica implementação deste trabalho a partir da referência citada; "reimpl." indica código reimplementado a partir do original indicado.

Os endereços completos constam no cabeçalho de cada adaptador, no código-fonte. Uma observação sobre a origem do código: a rotina de emparelhamento de

peso máximo em grafos gerais do NetworkX é uma adaptação do mesmo código de van Rantwijk também avaliado de forma independente; compará-las mede o efeito das alterações feitas na biblioteca sobre um mesmo código, e não duas abordagens distintas.

Por fim, nenhuma implementação própria ou reimplementada foi incorporada sem **verificação independente**: os métodos exatos foram confrontados com soluções por força bruta (em instâncias pequenas) e com bibliotecas consolidadas; os métodos aproximados e as heurísticas, quanto à validade da solução e a não superarem o ótimo, e os aproximados também quanto a respeitarem suas garantias de aproximação. Além disso, os *benchmarks* já existentes ao início do trabalho foram migrados para o ambiente unificado, e conferiu-se que a qualidade das soluções de cada um continuou exatamente a mesma após a migração.

6 RESULTADOS E DISCUSSÃO

Este capítulo apresenta e discute os resultados obtidos com o ambiente de testes descrito no capítulo anterior. Para cada problema, apresentam-se **todas as famílias de instância** definidas na Seção 5.3, de modo a expor como a estrutura da entrada afeta o desempenho e a qualidade. As tabelas de tempo deste capítulo trazem as implementações em linguagem interpretada (Python); conforme a Seção 5.5, as implementações de núcleo compilado, que servem de referência, aparecem nas tabelas de qualidade e na análise de crescimento (Seção 6.9). Para cada instância, a tabela de tempo é seguida da tabela de qualidade. Todos os valores são gerados diretamente a partir dos dados medidos. A Tabela 10 relaciona cada algoritmo destas tabelas ao seu pseudocódigo e à sua origem. Ao final, discutem-se os defeitos encontrados em implementações públicas e o crescimento empírico dos tempos frente à complexidade teórica.

6.1 LEITURA DAS TABELAS

Todas as tabelas de tempo e de qualidade deste capítulo seguem o mesmo formato. Cada linha corresponde a uma implementação e cada coluna $n = \ldots$ a um tamanho de instância, com o significado de n definido na Tabela 8. As demais colunas são as seguintes:

a) **algoritmo:** nome do algoritmo e, entre parênteses, a origem da implementação, detalhada na Tabela 10;

b) **tipo:** *exato*, *aproximado* ou *heurística*, conforme a Seção 2.7; *referência* indica uma biblioteca madura (NetworkX, igraph, SciPy ou lap), usada como referência de correção e de desempenho. Todas elas implementam métodos exatos;

c) **tempo** e **Espaço:** complexidade assintótica de pior caso da implementação avaliada, que nem sempre coincide com a melhor complexidade conhecida para o algoritmo.

Nas tabelas de tempo, cada célula é a mediana, em milissegundos, das cinco execuções cronometradas descritas na Seção 5.4. Nas tabelas de qualidade, cada célula é o valor absoluto da solução, cuja grandeza (cardinalidade, custo total, custo gargalo ou peso total) consta na legenda da tabela; o valor do algoritmo exato aparece na mesma tabela, e as razões citadas no texto são calculadas a partir dele. As células e as complexidades podem trazer os seguintes marcadores:

a) **—:** célula não executada, pois o tamanho está fora da faixa prevista para aquele algoritmo (nota da Tabela 8). Na rodada definitiva, nenhuma célula excedeu o limite de tempo de 120 segundos;

b) **BugAttr:** a implementação `benchaplin` do método Húngaro termina com erro de atributo (`AttributeError`) do Python;

c) **BugPerc:** a implementação `hunalgorithm` do método Húngaro termina com erro (`OSError`) ao exceder um limite interno de iterações. Os dois defeitos são discutidos na Seção 6.8;

d) **0 =ref:** no casamento estável, a solução tem zero pares bloqueantes, ou seja, é estável, e coincide com o emparelhamento ótimo para os homens calculado pela implementação numérica, usada como referência;

e) *** (na complexidade):** a implementação avaliada tem complexidade maior que a do algoritmo apresentado nos Capítulos 3 e 4. O caminho mínimo sucessivo usa o SPFA, uma variante do Bellman-Ford, em vez do Dijkstra com potenciais; o Karp-Sipser localiza os vértices de grau 1 por varredura; o *threshold* testa cada limiar por caminhos aumentantes, e não pelo Hopcroft-Karp; e o Gale-Shapley de Lattas busca a posição de cada pretendente percorrendo a lista de preferências da mulher;

f) **† (na complexidade):** a implementação tem a complexidade indicada, mas um sobrecusto de implementação faz o tempo medido crescer mais rápido que ela. É o caso do Gale-Shapley orientado a objetos, que reconstrói suas estruturas a cada rodada (Seção 6.9).

6.2 CARDINALIDADE MÁXIMA EM GRAFOS BIPARTIDOS

As Tabelas 11 a 16 apresentam tempo e qualidade para os três grafos: dois esparsos, um sem e um com emparelhamento perfeito, e um denso.

Tabela 11 – Cardinalidade máxima bipartida, grafo 1 (esparso, sem emparelhamento perfeito, máximo com $0{,}8n$ arestas): tempo de execução em Python (mediana, em ms)

Algoritmo	**Tipo**	**Tempo**	**Espaço**	$n = 50$	$n = 100$	$n = 150$	$n = 200$	$n = 250$
Aug. Paths (wbchristerson)	exato	$O(V \cdot E)$	$O(V + E)$	3.65	13.93	30.60	54.24	83.43
Hopcroft-Karp (sofiat)	exato	$O(E \cdot \sqrt{V})$	$O(V + E)$	0.55	1.10	1.64	2.16	2.73
Edmonds-Karp (Maxflow-Algs)	exato	$O(V \cdot E^2)$	$O(V^2)$	9.56	65.27	216.18	519.03	1024.37
Hopcroft-Karp (NetworkX)	referência	$O(E \cdot \sqrt{V})$	$O(V + E)$	0.57	1.20	1.55	2.02	2.80
Gulosa	aproximado	$O(E)$	$O(V)$	0.01	0.01	0.02	0.03	0.03
Karp-Sipser	aproximado	$O(V \cdot E)$*	$O(V + E)$	0.16	0.44	0.88	1.50	2.30

Fonte: Elaborado pelo autor.

Tabela 12 – Cardinalidade máxima bipartida, grafo 1 (esparso, sem emparelhamento perfeito, máximo com $0{,}8n$ arestas): qualidade da solução (cardinalidade)

Algoritmo	**Tipo**	**Tempo**	$n = 50$	$n = 100$	$n = 150$	$n = 200$	$n = 250$
Aug. Paths (wbchristerson)	exato	$O(V \cdot E)$	40	80	120	160	200
Hopcroft-Karp (sofiat)	exato	$O(E \cdot \sqrt{V})$	40	80	120	160	200
Edmonds-Karp (Maxflow-Algs)	exato	$O(V \cdot E^2)$	40	80	120	160	200
Hopcroft-Karp (NetworkX)	referência	$O(E \cdot \sqrt{V})$	40	80	120	160	200
Bipartite Match. (igraph)	referência	$O(E \cdot \sqrt{V})$	40	80	120	160	200
Gulosa	aproximado	$O(E)$	37	76	116	156	195
Karp-Sipser	aproximado	$O(V \cdot E)$*	40	80	120	160	200

Fonte: Elaborado pelo autor.

Tabela 13 – Cardinalidade máxima bipartida, grafo 2 (esparso, com emparelhamento perfeito): tempo de execução em Python (mediana, em ms)

Algoritmo	**Tipo**	**Tempo**	**Espaço**	$n = 50$	$n = 100$	$n = 150$	$n = 200$	$n = 250$
Aug. Paths (wbchristerson)	exato	$O(V \cdot E)$	$O(V + E)$	6.08	25.24	58.92	75.27	419.70
Hopcroft-Karp (sofiat)	exato	$O(E \cdot \sqrt{V})$	$O(V + E)$	0.58	1.08	1.67	2.17	3.72
Edmonds-Karp (Maxflow-Algs)	exato	$O(V \cdot E^2)$	$O(V^2)$	9.12	62.41	208.19	498.99	984.10
Hopcroft-Karp (NetworkX)	referência	$O(E \cdot \sqrt{V})$	$O(V + E)$	0.47	0.93	1.36	1.76	2.91
Gulosa	aproximado	$O(E)$	$O(V)$	0.01	0.01	0.02	0.02	0.03
Karp-Sipser	aproximado	$O(V \cdot E)$*	$O(V + E)$	0.20	0.59	1.23	2.11	2.53

Fonte: Elaborado pelo autor.

Tabela 14 – Cardinalidade máxima bipartida, grafo 2 (esparso, com emparelhamento perfeito): qualidade da solução (cardinalidade)

Algoritmo	**Tipo**	**Tempo**	$n = 50$	$n = 100$	$n = 150$	$n = 200$	$n = 250$
Aug. Paths (wbchristerson)	exato	$O(V \cdot E)$	50	100	150	200	250
Hopcroft-Karp (sofiat)	exato	$O(E \cdot \sqrt{V})$	50	100	150	200	250
Edmonds-Karp (Maxflow-Algs)	exato	$O(V \cdot E^2)$	50	100	150	200	250
Hopcroft-Karp (NetworkX)	referência	$O(E \cdot \sqrt{V})$	50	100	150	200	250
Bipartite Match. (igraph)	referência	$O(E \cdot \sqrt{V})$	50	100	150	200	250
Gulosa	aproximado	$O(E)$	43	86	130	170	216
Karp-Sipser	aproximado	$O(V \cdot E)$*	50	100	150	200	250

Fonte: Elaborado pelo autor.

Tabela 15 – Cardinalidade máxima bipartida, grafo 3 (denso, com emparelhamento perfeito): tempo de execução em Python (mediana, em ms)

Algoritmo	**Tipo**	**Tempo**	**Espaço**	$n = 50$	$n = 100$	$n = 150$	$n = 200$	$n = 250$
Aug. Paths (wbchristerson)	exato	$O(V \cdot E)$	$O(V + E)$	2.08	19.12	34.10	39.79	259.82
Hopcroft-Karp (sofiat)	exato	$O(E \cdot \sqrt{V})$	$O(V + E)$	1.14	2.41	3.99	6.19	7.53
Edmonds-Karp (Maxflow-Algs)	exato	$O(V \cdot E^2)$	$O(V^2)$	12.19	75.08	238.34	556.37	1077.90
Hopcroft-Karp (NetworkX)	referência	$O(E \cdot \sqrt{V})$	$O(V + E)$	1.51	3.15	4.84	6.94	8.66
Gulosa	aproximado	$O(E)$	$O(V)$	0.03	0.06	0.08	0.11	0.14
Karp-Sipser	aproximado	$O(V \cdot E)$*	$O(V + E)$	0.49	1.35	3.87	4.65	6.86

Fonte: Elaborado pelo autor.

Tabela 16 – Cardinalidade máxima bipartida, grafo 3 (denso, com emparelhamento perfeito): qualidade da solução (cardinalidade)

Algoritmo	**Tipo**	**Tempo**	$n = 50$	$n = 100$	$n = 150$	$n = 200$	$n = 250$
Aug. Paths (wbchristerson)	exato	$O(V \cdot E)$	50	100	150	200	250
Hopcroft-Karp (sofiat)	exato	$O(E \cdot \sqrt{V})$	50	100	150	200	250
Edmonds-Karp (Maxflow-Algs)	exato	$O(V \cdot E^2)$	50	100	150	200	250
Hopcroft-Karp (NetworkX)	referência	$O(E \cdot \sqrt{V})$	50	100	150	200	250
Bipartite Match. (igraph)	referência	$O(E \cdot \sqrt{V})$	50	100	150	200	250
Gulosa	aproximado	$O(E)$	47	93	142	191	235
Karp-Sipser	aproximado	$O(V \cdot E)$*	50	100	150	200	249

Fonte: Elaborado pelo autor.

Entre os algoritmos exatos, a hierarquia de desempenho é a mesma nas três tabelas de tempo (Tabelas 11, 13 e 15): o Edmonds-Karp, que reduz o emparelhamento a um problema de fluxo, é o mais lento, e o Hopcroft-Karp, que agrupa os caminhos aumentantes em fases, o mais rápido. Em $n = 250$, a diferença entre os dois é de 375 vezes no grafo 1, 265 vezes no grafo 2 e 143 vezes no grafo 3. A diferença diminui no grafo denso porque o tempo do Edmonds-Karp praticamente não muda entre os três grafos (cerca de 1 s em $n = 250$): a implementação guarda as capacidades em uma matriz $V \times V$ e cada busca percorre essa matriz inteira, independentemente do número de arestas. O Hopcroft-Karp, ao contrário, percorre apenas as arestas existentes, e seu tempo cresce com a densidade. As duas implementações de Hopcroft-Karp, a de terceiros (`sofiat`) e a do NetworkX, ficam muito próximas em todas as instâncias. O método de caminhos aumentantes simples fica entre os dois extremos, mas com crescimento irregular: nos grafos 2 e 3, o tempo salta entre $n = 200$ e $n = 250$, de 75 para 420 ms e de 40 para 260 ms. A implementação de núcleo compilado (igraph) não entra nas tabelas de tempo; o seu crescimento é discutido na Seção 6.9.

Quanto aos algoritmos aproximados, as tabelas de qualidade (Tabelas 12, 14 e 16) mostram que a qualidade dos métodos aproximados varia com a instância. O

método guloso, o mais rápido de todo o conjunto, atinge de 92 a 98% do ótimo no grafo 1 e cerca de 94% no grafo denso, mas tem sua pior qualidade no grafo 2, esparso e com emparelhamento perfeito, em que fica em torno de 86%: nesse grafo, a ordem de varredura das arestas mais facilmente o prende em um emparelhamento maximal pequeno. O algoritmo de Karp-Sipser encontra o ótimo em todas as instâncias esparsas e só o perde por uma aresta no grafo denso, em $n = 250$ (249 de 250), resultado da regra dos vértices de grau um, que domina em grafos esparsos. Em tempo, porém, a implementação avaliada do Karp-Sipser, de complexidade $O(V \cdot E)$, fica próxima da do Hopcroft-Karp, enquanto o guloso é de cinquenta a cem vezes mais rápido que ambos.

6.3 ATRIBUIÇÃO LINEAR

As Tabelas 17 a 22 apresentam as três matrizes de custo: densa uniforme (aleatória), permutação barata e estruturada.

Tabela 17 – Atribuição linear, matriz 1 (densa uniforme, custos em $[1, 100]$): tempo de execução em Python (mediana, em ms)

Algoritmo	**Tipo**	**Tempo**	**Espaço**	$n = 10$	$n = 20$	$n = 30$	$n = 50$	$n = 75$	$n = 100$	$n = 150$	$n = 200$	$n = 250$
Húngaro (munkres)	exato	$O(n^3)$	$O(n^2)$	0.39	1.98	4.82	15.43	41.61	97.23	239.96	428.17	679.84
Húngaro (benchaplin)	exato	$O(n^3)$	$O(n^2)$	11.11	92.32	391.64	BugAttr	BugAttr	BugAttr	BugAttr	BugAttr	BugAttr
Húngaro (hunalgorithm)	exato	$O(n^3)$	$O(n^2)$	2.10	BugPerc	BugPerc	BugPerc	BugPerc	BugPerc	BugPerc	BugPerc	BugPerc
Húngaro (mayorx/KM)	exato	$O(n^3)$	$O(n^2)$	0.99	2.25	7.49	12.30	21.11	29.30	58.44	58.55	86.71
SSP (flows)	exato	$O(n^4)^\star$	$O(n^2)$	0.45	2.65	6.92	29.97	98.01	235.13	—	—	—

Fonte: Elaborado pelo autor.

Tabela 18 – Atribuição linear, matriz 1 (densa uniforme, custos em $[1, 100]$): qualidade da solução (custo total)

Algoritmo	**Tipo**	**Tempo**	$n = 10$	$n = 20$	$n = 30$	$n = 50$	$n = 75$	$n = 100$	$n = 150$	$n = 200$	$n = 250$
Húngaro (munkres)	exato	$O(n^3)$	102	146	168	217	238	244	258	275	300
Húngaro (benchaplin)	exato	$O(n^3)$	102	146	168	BugAttr	BugAttr	BugAttr	BugAttr	BugAttr	BugAttr
Húngaro (hunalgorithm)	exato	$O(n^3)$	102	BugPerc	BugPerc	BugPerc	BugPerc	BugPerc	BugPerc	BugPerc	BugPerc
Húngaro (mayorx/KM)	exato	$O(n^3)$	102	146	168	217	238	244	258	275	300
SSP (flows)	exato	$O(n^4)^\star$	102	146	168	217	238	244	—	—	—
SciPy (linear_sum_assg)	referência	$O(n^3)$	102	146	168	217	238	244	258	275	300
Jonker-Volgenant (lap)	referência	$O(n^3)$	102	146	168	217	238	244	258	275	300

Fonte: Elaborado pelo autor.

Tabela 19 – Atribuição linear, matriz 2 (permutação barata, ótimo igual a n): tempo de execução em Python (mediana, em ms)

Algoritmo	**Tipo**	**Tempo**	**Espaço**	$n=10$	$n=20$	$n=30$	$n=50$	$n=75$	$n=100$	$n=150$	$n=200$	$n=250$
Húngaro (munkres)	exato	$O(n^3)$	$O(n^2)$	0.11	0.32	0.62	1.61	3.44	5.87	13.12	23.18	35.94
Húngaro (benchaplin)	exato	$O(n^3)$	$O(n^2)$	2.13	7.57	15.76	41.53	91.41	170.38	398.76	728.52	1163.23
Húngaro (hunalgorithm)	exato	$O(n^3)$	$O(n^2)$	0.14	0.37	0.72	1.81	4.35	7.42	16.75	28.39	44.60
Húngaro (mayorx/KM)	exato	$O(n^3)$	$O(n^2)$	0.42	0.80	1.23	2.12	3.39	4.84	8.22	12.34	17.08
SSP (flows)	exato	$O(n^4)$*	$O(n^2)$	0.40	2.15	6.23	25.72	86.22	212.71	—	—	—

Fonte: Elaborado pelo autor.

Tabela 20 – Atribuição linear, matriz 2 (permutação barata, ótimo igual a n): qualidade da solução (custo total)

Algoritmo	**Tipo**	**Tempo**	$n=10$	$n=20$	$n=30$	$n=50$	$n=75$	$n=100$	$n=150$	$n=200$	$n=250$
Húngaro (munkres)	exato	$O(n^3)$	10	20	30	50	75	100	150	200	250
Húngaro (benchaplin)	exato	$O(n^3)$	10	20	30	50	75	100	150	200	250
Húngaro (hunalgorithm)	exato	$O(n^3)$	10	20	30	50	75	100	150	200	250
Húngaro (mayorx/KM)	exato	$O(n^3)$	10	20	30	50	75	100	150	200	250
SSP (flows)	exato	$O(n^4)$*	10	20	30	50	75	100	—	—	—
SciPy (linear_sum_assg)	referência	$O(n^3)$	10	20	30	50	75	100	150	200	250
Jonker-Volgenant (lap)	referência	$O(n^3)$	10	20	30	50	75	100	150	200	250

Fonte: Elaborado pelo autor.

Tabela 21 – Atribuição linear, matriz 3 (estruturada, custo $|i-j|+1$): tempo de execução em Python (mediana, em ms)

Algoritmo	**Tipo**	**Tempo**	**Espaço**	$n=10$	$n=20$	$n=30$	$n=50$	$n=75$	$n=100$	$n=150$	$n=200$	$n=250$
Húngaro (munkres)	exato	$O(n^3)$	$O(n^2)$	0.10	0.32	0.62	1.64	3.38	5.96	13.21	23.29	36.16
Húngaro (benchaplin)	exato	$O(n^3)$	$O(n^2)$	2.15	7.58	15.80	41.51	91.39	170.36	396.75	726.02	1157.10
Húngaro (hunalgorithm)	exato	$O(n^3)$	$O(n^2)$	0.13	0.36	0.71	1.78	4.31	7.31	16.45	27.90	43.83
Húngaro (mayorx/KM)	exato	$O(n^3)$	$O(n^2)$	0.41	0.80	1.21	2.12	3.40	4.83	8.27	12.35	17.01
SSP (flows)	exato	$O(n^4)$*	$O(n^2)$	0.39	2.17	6.28	26.00	87.68	214.55	—	—	—

Fonte: Elaborado pelo autor.

Tabela 22 – Atribuição linear, matriz 3 (estruturada, custo $|i-j|+1$): qualidade da solução (custo total)

Algoritmo	**Tipo**	**Tempo**	$n=10$	$n=20$	$n=30$	$n=50$	$n=75$	$n=100$	$n=150$	$n=200$	$n=250$
Húngaro (munkres)	exato	$O(n^3)$	10	20	30	50	75	100	150	200	250
Húngaro (benchaplin)	exato	$O(n^3)$	10	20	30	50	75	100	150	200	250
Húngaro (hunalgorithm)	exato	$O(n^3)$	10	20	30	50	75	100	150	200	250
Húngaro (mayorx/KM)	exato	$O(n^3)$	10	20	30	50	75	100	150	200	250
SSP (flows)	exato	$O(n^4)$*	10	20	30	50	75	100	—	—	—
SciPy (linear_sum_assg)	referência	$O(n^3)$	10	20	30	50	75	100	150	200	250
Jonker-Volgenant (lap)	referência	$O(n^3)$	10	20	30	50	75	100	150	200	250

Fonte: Elaborado pelo autor.

As tabelas de qualidade (Tabelas 18, 20 e 22) mostram que todos os algoritmos que concluem atingem o custo ótimo, de modo que a comparação recai sobre o tempo.

Nas matrizes 2 e 3, o ótimo é conhecido de antemão e vale n, pois a permutação barata e a diagonal da matriz estruturada têm custo 1 em cada linha; na matriz 1, ele é dado pelos algoritmos exatos, que concordam entre si.

Entre as quatro implementações do método Húngaro, obtidas de autores distintos para exatamente o mesmo algoritmo, observa-se variação de mais de uma ordem de grandeza: nas matrizes 2 e 3, em $n = 250$, a `mayorx` leva 17 ms e a `benchaplin` cerca de 1,2 s, uma diferença de quase setenta vezes. A estrutura da matriz também pesa, mas de forma desigual entre as implementações. Na matriz aleatória (Tabela 17), a `munkres` leva 680 ms em $n = 250$, cerca de dezenove vezes o seu tempo nas matrizes estruturadas (Tabelas 19 e 21), enquanto a `mayorx` fica apenas cinco vezes mais lenta. O caminho mínimo sucessivo, por sua vez, praticamente não é afetado pela estrutura (de 213 a 235 ms em $n = 100$), pois o custo do SPFA depende do grafo residual, e não dos valores dos custos; ainda assim, a partir de $n = 50$ é mais lento que a `munkres`, a `hunalgorithm` e a `mayorx` sempre que elas concluem. As matrizes 2 e 3 produzem tempos quase idênticos em todas as implementações. As implementações de núcleo compilado (SciPy e Jonker-Volgenant) ficam bem abaixo de todas as interpretadas, como mostra a Figura 7 para a matriz 1.

Os defeitos das implementações `benchaplin` e `hunalgorithm`, marcados como `BugAttr` e `BugPerc` nas Tabelas 17 e 18, manifestam-se **exclusivamente na matriz densa aleatória**. Nas matrizes estruturadas, que produzem padrões de custo mais regulares, ambas concluem normalmente. Os dois defeitos são discutidos na Seção 6.8.

6.4 ATRIBUIÇÃO GARGALO

As Tabelas 23 a 28 apresentam as três matrizes de custo, para os dois algoritmos exatos e as duas heurísticas gulosas.

Tabela 23 – Atribuição gargalo, matriz 1 (densa uniforme, custos em $[1, 100]$): tempo de execução em Python (mediana, em ms)

Algoritmo	**Tipo**	**Tempo**	**Espaço**	$n = 10$	$n = 20$	$n = 30$	$n = 50$	$n = 75$	$n = 100$	$n = 150$	$n = 200$
Threshold (busca binária)	exato	$O(n^3 \log n)^\star$	$O(n^2)$	0.10	0.50	1.43	4.44	13.57	32.18	110.40	259.80
Caminhos aumentantes	exato	$O(n^3)$	$O(n^2)$	0.05	0.22	0.60	2.11	5.37	11.19	32.26	67.60
Gulosa simples	heurística	$O(n^2 \log n)$	$O(n^2)$	0.03	0.12	0.31	0.99	2.41	4.33	10.58	19.00
Gulosa por arrependimento	heurística	$O(n^2 \log n)$	$O(n^2)$	0.05	0.18	0.39	1.08	2.44	4.37	9.73	17.74

Fonte: Elaborado pelo autor.

Tabela 24 – Atribuição gargalo, matriz 1 (densa uniforme, custos em $[1, 100]$): qualidade da solução (custo gargalo)

Algoritmo	**Tipo**	**Tempo**	$n = 10$	$n = 20$	$n = 30$	$n = 50$	$n = 75$	$n = 100$	$n = 150$	$n = 200$
Threshold (busca binária)	exato	$O(n^3 \log n)^\star$	26	18	18	13	8	7	5	4
Caminhos aumentantes	exato	$O(n^3)$	26	18	18	13	8	7	5	4
Gulosa simples	heurística	$O(n^2 \log n)$	82	71	47	91	90	94	99	75
Gulosa por arrependimento	heurística	$O(n^2 \log n)$	49	18	30	16	40	59	49	49

Fonte: Elaborado pelo autor.

Tabela 25 – Atribuição gargalo, matriz 2 (estruturada, custo $|i - j| + 1$): tempo de execução em Python (mediana, em ms)

Algoritmo	**Tipo**	**Tempo**	**Espaço**	$n = 10$	$n = 20$	$n = 30$	$n = 50$	$n = 75$	$n = 100$	$n = 150$	$n = 200$
Threshold (busca binária)	exato	$O(n^3 \log n)^\star$	$O(n^2)$	0.10	0.54	1.40	6.48	23.58	52.01	198.04	449.78
Caminhos aumentantes	exato	$O(n^3)$	$O(n^2)$	0.03	0.10	0.22	0.60	1.36	2.44	5.64	10.13
Gulosa simples	heurística	$O(n^2 \log n)$	$O(n^2)$	0.03	0.10	0.24	0.65	1.48	2.47	5.58	10.04
Gulosa por arrependimento	heurística	$O(n^2 \log n)$	$O(n^2)$	0.05	0.16	0.32	0.88	1.78	3.19	6.81	11.86

Fonte: Elaborado pelo autor.

Tabela 26 – Atribuição gargalo, matriz 2 (estruturada, custo $|i - j| + 1$): qualidade da solução (custo gargalo)

Algoritmo	**Tipo**	**Tempo**	$n = 10$	$n = 20$	$n = 30$	$n = 50$	$n = 75$	$n = 100$	$n = 150$	$n = 200$
Threshold (busca binária)	exato	$O(n^3 \log n)^\star$	1	1	1	1	1	1	1	1
Caminhos aumentantes	exato	$O(n^3)$	1	1	1	1	1	1	1	1
Gulosa simples	heurística	$O(n^2 \log n)$	1	1	1	1	1	1	1	1
Gulosa por arrependimento	heurística	$O(n^2 \log n)$	1	1	1	1	1	1	1	1

Fonte: Elaborado pelo autor.

Tabela 27 – Atribuição gargalo, matriz 3 (poucos valores distintos, muitos empates): tempo de execução em Python (mediana, em ms)

Algoritmo	**Tipo**	**Tempo**	**Espaço**	$n = 10$	$n = 20$	$n = 30$	$n = 50$	$n = 75$	$n = 100$	$n = 150$	$n = 200$
Threshold (busca binária)	exato	$O(n^3 \log n)^\star$	$O(n^2)$	0.05	0.27	0.79	2.87	9.74	22.76	77.67	185.59
Caminhos aumentantes	exato	$O(n^3)$	$O(n^2)$	0.06	0.42	1.32	5.22	15.52	34.85	110.13	250.72
Gulosa simples	heurística	$O(n^2 \log n)$	$O(n^2)$	0.03	0.12	0.27	0.73	1.71	3.12	7.71	13.47
Gulosa por arrependimento	heurística	$O(n^2 \log n)$	$O(n^2)$	0.05	0.17	0.38	1.03	2.31	4.19	9.21	16.63

Fonte: Elaborado pelo autor.

Tabela 28 – Atribuição gargalo, matriz 3 (poucos valores distintos, muitos empates): qualidade da solução (custo gargalo)

Algoritmo	**Tipo**	**Tempo**	$n = 10$	$n = 20$	$n = 30$	$n = 50$	$n = 75$	$n = 100$	$n = 150$	$n = 200$
Threshold (busca binária)	exato	$O(n^3 \log n)$*	5	1	1	1	1	1	1	1
Caminhos aumentantes	exato	$O(n^3)$	5	1	1	1	1	1	1	1
Gulosa simples	heurística	$O(n^2 \log n)$	50	50	50	5	5	5	50	10
Gulosa por arrependimento	heurística	$O(n^2 \log n)$	5	5	5	50	5	5	5	1

Fonte: Elaborado pelo autor.

Os dois algoritmos exatos produzem sempre o mesmo custo gargalo ótimo, o que também serve como verificação cruzada de corretude. No tempo, porém, **a ordem entre os dois algoritmos se inverte conforme a matriz**. Nas matrizes densa e estruturada (Tabelas 23 e 25), o método de caminhos aumentantes, construtivo, é muito mais rápido que o de *threshold*: cerca de quatro vezes na matriz densa e mais de quarenta vezes na estruturada, em $n = 200$. Na matriz com poucos valores distintos (Tabela 27), contudo, o *threshold* passa a ser o mais rápido: como sua busca binária opera sobre o conjunto de valores distintos da matriz, poucos valores tornam essa busca curtíssima, enquanto o método construtivo não se beneficia da mesma forma. Assim, o método mais rápido depende da estrutura da entrada.

As heurísticas gulosas só encontram o ótimo na matriz estruturada (Tabela 26), pois a diagonal é a posição mais barata de cada linha e de cada coluna. Na matriz densa uniforme (Tabela 24), porém, o guloso simples termina com gargalos entre 47 e 99, enquanto o ótimo cai de 26 para 4 à medida que n cresce: as últimas linhas ficam com as colunas que sobraram, e uma única posição cara determina o valor da solução. O critério de arrependimento reduz esse efeito (gargalos entre 16 e 59), mas só atinge o ótimo em $n = 20$ e chega a ficar doze vezes acima dele em $n = 200$. Na matriz com poucos valores (Tabela 28), o guloso simples oscila entre 5, 10 e 50 sem relação com n, e o arrependimento costuma parar no segundo menor valor (5), e não no ótimo (1), chegando a 50 em $n = 50$; só acerta o ótimo em $n = 10$ e $n = 200$, o que ilustra a ausência de garantia. Quanto ao tempo, as heurísticas são cerca de quatro vezes mais rápidas que o método de caminhos aumentantes na matriz densa, equivalem a ele na estruturada e só se destacam na matriz com poucos valores, em que os dois métodos exatos ficam mais lentos. Como a qualidade é instável justamente nas instâncias aleatórias, o método exato de caminhos aumentantes é, neste problema, a escolha mais segura, ao contrário do que ocorre na cardinalidade máxima, em que o algoritmo de Karp-Sipser é quase sempre ótimo.

6.5 CASAMENTO ESTÁVEL

As Tabelas 29 a 34 apresentam os três perfis de preferência: aleatório, correlacionado e cíclico.

Tabela 29 – Casamento estável, perfil 1 (aleatório): tempo de execução em Python (mediana, em ms)

Algoritmo	**Tipo**	**Tempo**	**Espaço**	$n = 25$	$n = 50$	$n = 75$	$n = 100$	$n = 200$	$n = 300$	$n = 400$
Gale-Shapley (OOP/pip)	exato	$O(n^2)$†	$O(n^2)$	7.54	94.14	321.96	692.09	—	—	—
Gale-Shapley (numérico/pip)	exato	$O(n^2)$	$O(n^2)$	0.44	1.57	3.36	5.52	21.70	50.59	95.89
Gale-Shapley (Lattas/dict)	exato	$O(n^3)$*	$O(n^2)$	0.31	1.29	2.85	5.08	20.07	52.20	100.25

Fonte: Elaborado pelo autor.

Tabela 30 – Casamento estável, perfil 1 (aleatório): qualidade da solução (pares bloqueantes e concordância com a referência)

Algoritmo	**Tipo**	**Tempo**	$n = 25$	$n = 50$	$n = 75$	$n = 100$	$n = 200$	$n = 300$	$n = 400$
Gale-Shapley (OOP/pip)	exato	$O(n^2)$†	0 =ref	0 =ref	0 =ref	0 =ref	—	—	—
Gale-Shapley (numérico/pip)	exato	$O(n^2)$	0 =ref	0 =ref	0 =ref	0 =ref	0 =ref	0 =ref	0 =ref
Gale-Shapley (Lattas/dict)	exato	$O(n^3)$*	0 =ref	0 =ref	0 =ref	0 =ref	0 =ref	0 =ref	0 =ref

Fonte: Elaborado pelo autor.

Tabela 31 – Casamento estável, perfil 2 (correlacionado): tempo de execução em Python (mediana, em ms)

Algoritmo	**Tipo**	**Tempo**	**Espaço**	$n = 25$	$n = 50$	$n = 75$	$n = 100$	$n = 200$	$n = 300$	$n = 400$
Gale-Shapley (OOP/pip)	exato	$O(n^2)$†	$O(n^2)$	43.60	589.68	2826.56	8665.93	—	—	—
Gale-Shapley (numérico/pip)	exato	$O(n^2)$	$O(n^2)$	0.75	2.76	6.22	10.87	43.05	101.47	188.56
Gale-Shapley (Lattas/dict)	exato	$O(n^3)$*	$O(n^2)$	0.66	3.48	10.24	21.99	144.99	482.24	1160.66

Fonte: Elaborado pelo autor.

Tabela 32 – Casamento estável, perfil 2 (correlacionado): qualidade da solução (pares bloqueantes e concordância com a referência)

Algoritmo	**Tipo**	**Tempo**	$n = 25$	$n = 50$	$n = 75$	$n = 100$	$n = 200$	$n = 300$	$n = 400$
Gale-Shapley (OOP/pip)	exato	$O(n^2)$†	0 =ref	0 =ref	0 =ref	0 =ref	—	—	—
Gale-Shapley (numérico/pip)	exato	$O(n^2)$	0 =ref	0 =ref	0 =ref	0 =ref	0 =ref	0 =ref	0 =ref
Gale-Shapley (Lattas/dict)	exato	$O(n^3)$*	0 =ref	0 =ref	0 =ref	0 =ref	0 =ref	0 =ref	0 =ref

Fonte: Elaborado pelo autor.

Tabela 33 – Casamento estável, perfil 3 (cíclico): tempo de execução em Python (mediana, em ms)

Algoritmo	**Tipo**	**Tempo**	**Espaço**	$n = 25$	$n = 50$	$n = 75$	$n = 100$	$n = 200$	$n = 300$	$n = 400$
Gale-Shapley (OOP/pip)	exato	$O(n^2)$†	$O(n^2)$	2.44	14.89	46.06	104.25	—	—	—
Gale-Shapley (numérico/pip)	exato	$O(n^2)$	$O(n^2)$	0.39	1.35	3.00	5.16	20.25	47.17	88.20
Gale-Shapley (Lattas/dict)	exato	$O(n^3)$*	$O(n^2)$	0.21	0.74	1.60	2.80	10.95	27.22	51.22

Fonte: Elaborado pelo autor.

Tabela 34 – Casamento estável, perfil 3 (cíclico): qualidade da solução (pares bloqueantes e concordância com a referência)

Algoritmo	**Tipo**	**Tempo**	$n = 25$	$n = 50$	$n = 75$	$n = 100$	$n = 200$	$n = 300$	$n = 400$
Gale-Shapley (OOP/pip)	exato	$O(n^2)$†	0 =ref	0 =ref	0 =ref	0 =ref	—	—	—
Gale-Shapley (numérico/pip)	exato	$O(n^2)$	0 =ref	0 =ref	0 =ref	0 =ref	0 =ref	0 =ref	0 =ref
Gale-Shapley (Lattas/dict)	exato	$O(n^3)$*	0 =ref	0 =ref	0 =ref	0 =ref	0 =ref	0 =ref	0 =ref

Fonte: Elaborado pelo autor.

Pela unicidade do emparelhamento estável ótimo para os pretendentes, as três variantes produzem exatamente o mesmo resultado em todos os perfis, o que as tabelas de qualidade (Tabelas 30, 32 e 34) confirmam, com estabilidade e concordância em todas as células. A qualidade, portanto, não as distingue, e a comparação recai sobre o tempo.

O perfil de preferências muda o tempo de forma acentuada, porque determina o número de propostas que o algoritmo faz. No perfil correlacionado (Tabela 31), todos os homens têm a mesma lista: a primeira mulher recebe n propostas, a segunda $n - 1$, e assim por diante, num total de $n(n + 1)/2$, o pior caso do algoritmo. No perfil cíclico (Tabela 33), cada homem m prefere primeiro a mulher m, que também o prefere, e todas as propostas iniciais são aceitas, num total de n. O perfil aleatório (Tabela 29) fica entre os dois. Em $n = 400$, o Gale-Shapley de Lattas leva 51 ms no perfil cíclico, 100 ms no aleatório e 1,2 s no correlacionado. É justamente no perfil correlacionado que a sua complexidade $O(n^3)$ se manifesta: com muitas rejeições, a busca linear na lista de preferências a cada proposta passa a dominar, e a implementação fica seis vezes mais lenta que a numérica, enquanto no perfil aleatório as duas se equivalem e no cíclico a de Lattas é a mais rápida. A variante numérica é a menos sensível ao perfil, de 88 a 189 ms em $n = 400$.

A variante orientada a objetos, embora teoricamente quadrática, é a mais lenta em todos os perfis, com 692 ms em $n = 100$ no perfil aleatório e 8,7 s no correlacionado, contra cerca de 5 e 11 ms da numérica. Por isso, ela só foi executada até $n = 100$. Seu sobrecusto de reconstruir estruturas a cada rodada é quantificado na Seção 6.9.

As variantes que operam sobre vetores e dicionários escalam sem dificuldade até os maiores tamanhos avaliados.

6.6 EMPARELHAMENTO EM GRAFOS GERAIS

Cobrem-se os dois problemas de grafos gerais, cardinalidade máxima e peso máximo, cada um em uma instância esparsa e uma densa. Como cada tamanho usa um grafo sorteado diferente, o tempo nem sempre cresce de forma monótona com n.

Tabela 35 – Cardinalidade máxima em grafos gerais, grafo esparso (grau médio ≈ 3): tempo de execução em Python (mediana, em ms)

Algoritmo	**Tipo**	**Tempo**	**Espaço**	$n = 10$	$n = 20$	$n = 30$	$n = 50$	$n = 75$	$n = 100$
Blossom (Edmonds)	exato	$O(V^3)$	$O(V^2)$	1.66	3.21	3.97	20.36	43.90	103.46
NetworkX (cardinalidade)	referência	$O(V^3)$	$O(V+E)$	0.40	0.63	0.74	1.41	2.28	3.15

Fonte: Elaborado pelo autor.

Tabela 36 – Cardinalidade máxima em grafos gerais, grafo esparso (grau médio ≈ 3): qualidade da solução (cardinalidade)

Algoritmo	**Tipo**	**Tempo**	$n = 10$	$n = 20$	$n = 30$	$n = 50$	$n = 75$	$n = 100$
Blossom (Edmonds)	exato	$O(V^3)$	5	9	13	23	31	43
NetworkX (cardinalidade)	referência	$O(V^3)$	5	9	13	23	31	43

Fonte: Elaborado pelo autor.

Tabela 37 – Cardinalidade máxima em grafos gerais, grafo denso ($p = 0{,}3$): tempo de execução em Python (mediana, em ms)

Algoritmo	**Tipo**	**Tempo**	**Espaço**	$n = 10$	$n = 20$	$n = 30$	$n = 50$	$n = 75$	$n = 100$
Blossom (Edmonds)	exato	$O(V^3)$	$O(V^2)$	1.60	13.79	35.81	342.60	2862.65	9526.65
NetworkX (cardinalidade)	referência	$O(V^3)$	$O(V+E)$	0.38	0.47	1.07	1.94	12.25	7.46

Fonte: Elaborado pelo autor.

Tabela 38 – Cardinalidade máxima em grafos gerais, grafo denso ($p = 0{,}3$): qualidade da solução (cardinalidade)

Algoritmo	**Tipo**	**Tempo**	$n = 10$	$n = 20$	$n = 30$	$n = 50$	$n = 75$	$n = 100$
Blossom (Edmonds)	exato	$O(V^3)$	5	10	15	25	37	50
NetworkX (cardinalidade)	referência	$O(V^3)$	5	10	15	25	37	50

Fonte: Elaborado pelo autor.

Na cardinalidade máxima (Tabelas 35 a 38), as duas implementações do algoritmo de Edmonds concordam em todas as instâncias. No grafo denso, o emparelhamento é sempre perfeito ($\lfloor n/2 \rfloor$ arestas); no esparso, os vértices isolados e as componentes pequenas do grafo aleatório em geral o impedem, e o máximo tem entre 41 e 50% de n arestas. O tempo, porém, separa as duas implementações de forma drástica. A implementação avaliada do Blossom é 33 vezes mais lenta que a do NetworkX no grafo esparso e cerca de 1 300 vezes mais lenta no denso, em $n = 100$. No grafo denso, seu tempo vai de 0,34 s em $n = 50$ para 9,5 s em $n = 100$, um fator de 28 ao dobrar o tamanho, muito acima dos 8 esperados para um algoritmo $O(V^3)$. Assim como no Gale-Shapley orientado a objetos, o resultado indica um sobrecusto da implementação, e não do algoritmo, já que o NetworkX implementa o mesmo método e se mantém abaixo de 13 ms em todas as instâncias.

Tabela 39 – Peso máximo em grafos gerais, grafo esparso (grau médio ≈ 3): tempo de execução em Python (mediana, em ms)

Algoritmo	**Tipo**	**Tempo**	**Espaço**	$n = 10$	$n = 20$	$n = 30$	$n = 50$	$n = 75$	$n = 100$
van Rantwijk (mwmatching)	exato	$O(V^3)$	$O(V + E)$	0.26	0.54	0.86	2.19	3.49	6.30
NetworkX (peso máximo)	referência	$O(V^3)$	$O(V + E)$	0.59	1.25	1.98	4.87	7.52	13.58
Path Growing	aproximado	$O(E)$	$O(V + E)$	0.03	0.05	0.07	0.11	0.17	0.23

Fonte: Elaborado pelo autor.

Tabela 40 – Peso máximo em grafos gerais, grafo esparso (grau médio ≈ 3): qualidade da solução (peso total)

Algoritmo	**Tipo**	**Tempo**	$n = 10$	$n = 20$	$n = 30$	$n = 50$	$n = 75$	$n = 100$
van Rantwijk (mwmatching)	exato	$O(V^3)$	309	604	790	1284	1907	2929
NetworkX (peso máximo)	referência	$O(V^3)$	309	604	790	1284	1907	2929
Path Growing	aproximado	$O(E)$	278	510	732	1030	1492	2407

Fonte: Elaborado pelo autor.

Tabela 41 – Peso máximo em grafos gerais, grafo denso ($p = 0{,}3$): tempo de execução em Python (mediana, em ms)

Algoritmo	**Tipo**	**Tempo**	**Espaço**	$n = 10$	$n = 20$	$n = 30$	$n = 50$	$n = 75$	$n = 100$
van Rantwijk (mwmatching)	exato	$O(V^3)$	$O(V + E)$	0.25	0.87	2.20	4.83	16.68	26.68
NetworkX (peso máximo)	referência	$O(V^3)$	$O(V + E)$	0.59	2.38	5.83	13.56	41.85	78.35
Path Growing	aproximado	$O(E)$	$O(V + E)$	0.03	0.08	0.15	0.36	0.78	1.35

Fonte: Elaborado pelo autor.

Tabela 42 – Peso máximo em grafos gerais, grafo denso ($p = 0{,}3$): qualidade da solução (peso total)

Algoritmo	**Tipo**	**Tempo**	$n = 10$	$n = 20$	$n = 30$	$n = 50$	$n = 75$	$n = 100$
van Rantwijk (mwmatching)	exato	$O(V^3)$	309	765	1279	2247	3429	4710
NetworkX (peso máximo)	referência	$O(V^3)$	309	765	1279	2247	3429	4710
Path Growing	aproximado	$O(E)$	278	642	1215	1934	3113	4329

Fonte: Elaborado pelo autor.

No caso ponderado (Tabelas 39 a 42), a implementação de van Rantwijk é, nas duas densidades, de duas a três vezes mais rápida que a rotina correspondente do NetworkX. Como a rotina do NetworkX é uma adaptação desse mesmo código (Seção 5.7), a diferença vem das alterações feitas na biblioteca, e não do algoritmo; quais alterações pesam mais não foi medido. O algoritmo aproximado Path Growing é de vinte a sessenta vezes mais rápido que os exatos em $n = 100$ e entrega uma fração elevada do peso ótimo, sempre bem acima da sua garantia teórica de metade: entre 78 e 93% no grafo esparso e entre 84 e 95% no denso, em que a qualidade é, portanto, um pouco superior.

6.7 EMPARELHAMENTO INDUZIDO MÁXIMO

Sendo NP-difícil, o emparelhamento induzido máximo tem perfil distinto: o algoritmo exato só é viável em instâncias pequenas, e a comparação se concentra na qualidade das heurísticas. As Tabelas 43 a 48 apresentam as três densidades avaliadas. A referência de qualidade depende do tamanho: até $n = 40$, as heurísticas são comparadas ao algoritmo exato; a partir de $n = 50$, em que o exato não é executado, são comparadas entre si, e a melhor delas serve de referência, sem garantia de que seja o ótimo.

Tabela 43 – Emparelhamento induzido máximo, grafo esparso (grau médio ≈ 3): tempo de execução em Python (mediana, em ms)

Algoritmo	**Tipo**	**Tempo**	**Espaço**	$n = 10$	$n = 15$	$n = 20$	$n = 25$	$n = 30$	$n = 40$	$n = 50$	$n = 100$	$n = 200$	$n = 400$
Exato (MIS conflitos)	exato	exponencial	$O(E^2)$	0.16	0.29	1.49	1.99	5.10	74.61	—	—	—	—
Guloso aleatório	heurística	$O(E^2)$	$O(V+E)$	0.05	0.05	0.08	0.13	0.18	0.29	0.47	1.50	8.28	27.29
Guloso grau mínimo	heurística	$O(E^2)$	$O(E^2)$	0.18	0.36	0.78	1.47	1.83	2.78	4.27	18.48	85.90	378.36

Fonte: Elaborado pelo autor.

Tabela 44 – Emparelhamento induzido máximo, grafo esparso (grau médio ≈ 3): qualidade da solução (cardinalidade)

Algoritmo	**Tipo**	**Tempo**	$n = 10$	$n = 15$	$n = 20$	$n = 25$	$n = 30$	$n = 40$	$n = 50$	$n = 100$	$n = 200$	$n = 400$
Exato (MIS conflitos)	exato	exponencial	2	3	5	5	8	10	—	—	—	—
Guloso aleatório	heurística	$O(E^2)$	2	2	3	3	5	7	10	18	41	75
Guloso grau mínimo	heurística	$O(E^2)$	2	3	5	5	8	10	11	25	49	93

Fonte: Elaborado pelo autor.

Tabela 45 – Emparelhamento induzido máximo, grafo médio (grau médio ≈ 6): tempo de execução em Python (mediana, em ms)

Algoritmo	**Tipo**	**Tempo**	**Espaço**	$n = 10$	$n = 15$	$n = 20$	$n = 25$	$n = 30$	$n = 40$	$n = 50$	$n = 100$	$n = 200$	$n = 400$
Exato (MIS conflitos)	exato	exponencial	$O(E^2)$	0.36	1.07	2.50	4.55	10.56	133.00	—	—	—	—
Guloso aleatório	heurística	$O(E^2)$	$O(V+E)$	0.06	0.11	0.17	0.25	0.28	0.40	0.60	2.43	9.02	32.93
Guloso grau mínimo	heurística	$O(E^2)$	$O(E^2)$	0.47	1.55	3.48	5.50	5.88	11.08	21.08	72.77	327.12	1573.84

Fonte: Elaborado pelo autor.

Tabela 46 – Emparelhamento induzido máximo, grafo médio (grau médio ≈ 6): qualidade da solução (cardinalidade)

Algoritmo	**Tipo**	**Tempo**	$n = 10$	$n = 15$	$n = 20$	$n = 25$	$n = 30$	$n = 40$	$n = 50$	$n = 100$	$n = 200$	$n = 400$
Exato (MIS conflitos)	exato	exponencial	2	3	4	4	6	8	—	—	—	—
Guloso aleatório	heurística	$O(E^2)$	1	2	3	3	5	6	7	15	30	55
Guloso grau mínimo	heurística	$O(E^2)$	2	3	3	4	5	7	8	19	39	72

Fonte: Elaborado pelo autor.

Tabela 47 – Emparelhamento induzido máximo, grafo denso (grau médio ≈ 12): tempo de execução em Python (mediana, em ms)

Algoritmo	**Tipo**	**Tempo**	**Espaço**	$n = 10$	$n = 15$	$n = 20$	$n = 25$	$n = 30$	$n = 40$	$n = 50$	$n = 100$	$n = 200$	$n = 400$
Exato (MIS conflitos)	exato	exponencial	$O(E^2)$	0.64	2.82	5.62	9.65	17.19	58.30	—	—	—	—
Guloso aleatório	heurística	$O(E^2)$	$O(V+E)$	0.07	0.14	0.20	0.29	0.38	1.06	0.77	2.82	11.87	39.37
Guloso grau mínimo	heurística	$O(E^2)$	$O(E^2)$	0.85	4.00	8.80	14.85	23.40	48.81	74.74	326.03	1314.14	6086.44

Fonte: Elaborado pelo autor.

Tabela 48 – Emparelhamento induzido máximo, grafo denso (grau médio ≈ 12): qualidade da solução (cardinalidade)

Algoritmo	**Tipo**	**Tempo**	$n = 10$	$n = 15$	$n = 20$	$n = 25$	$n = 30$	$n = 40$	$n = 50$	$n = 100$	$n = 200$	$n = 400$
Exato (MIS conflitos)	exato	exponencial	1	2	3	3	4	5	—	—	—	—
Guloso aleatório	heurística	$O(E^2)$	1	1	1	2	3	4	4	9	20	35
Guloso grau mínimo	heurística	$O(E^2)$	1	2	3	3	4	5	6	14	25	55

Fonte: Elaborado pelo autor.

O algoritmo exato, que reduz o problema a conjunto independente máximo no grafo de conflitos, resolve as instâncias pequenas em poucos milissegundos, inclusive

nas densas, em que o emparelhamento induzido máximo é pequeno e a poda é eficaz. Seu custo, porém, cresce rapidamente: no grafo esparso (Tabela 43), passa de 5 ms em $n = 30$ para 75 ms em $n = 40$, e no médio (Tabela 45), de 11 para 133 ms. Esse crescimento motivou limitar o exato a $n \leq 40$ e justifica empiricamente a necessidade das heurísticas.

A heurística de grau mínimo alcança o ótimo em todos os tamanhos tanto no grafo esparso (Tabela 44) quanto no denso (Tabela 48), mas não na densidade *intermediária* (Tabela 46), em que fica uma aresta abaixo dele em $n = 20$, 30 e 40. Uma explicação provável é que, em grafos muito densos, quase toda aresta conflita com as demais, de modo que o emparelhamento induzido é pequeno e fácil de acertar; é na densidade média que há mais espaço para escolhas localmente boas mas globalmente subótimas. A escolha aleatória fica abaixo da de grau mínimo, ou empata com ela, em todas as células, e a distância cresce com a densidade nos tamanhos maiores: em $n = 400$, a aleatória obtém 81% do resultado da de grau mínimo no grafo esparso, 76% no médio e 64% no denso. A vantagem da heurística de grau mínimo tem um custo em tempo, por manter e atualizar o grafo de conflitos: em $n = 400$, ela leva de 0,4 a 6,1 s, contra menos de 40 ms da aleatória.

6.8 DEFEITOS EM IMPLEMENTAÇÕES PÚBLICAS

Duas das quatro implementações do método Húngaro avaliadas apresentam defeitos, ambos manifestados apenas na matriz densa aleatória, como visto nas Tabelas 17 e 18.

A primeira (`hunalgorithm`, marcador `BugPerc`) falha de forma determinística a partir de $n = 20$, por exceder um limite interno de iterações previsto em seu próprio código.

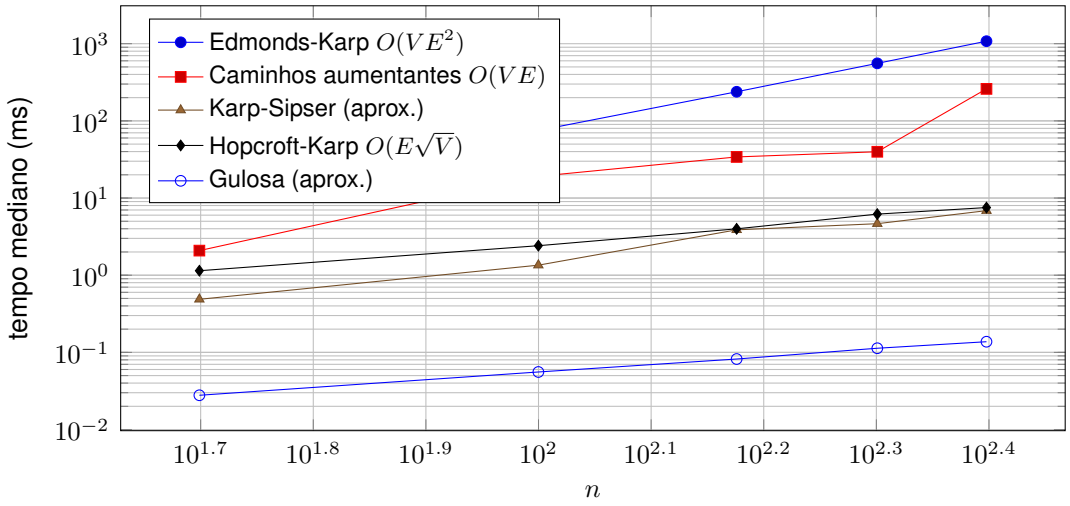
A segunda (`benchaplin`, marcador `BugAttr`) é **não determinística entre execuções**. Sobre exatamente a mesma matriz de entrada, a implementação ora retorna o custo ótimo correto, ora falha com um erro de tipo, ora ingressa em um caminho de execução tão lento que não conclui em tempo praticável. A causa é a dependência do defeito quanto à ordem de iteração de uma coleção de objetos, que a linguagem aleatoriza a cada processo. Por causa desse defeito, foi preciso fixar a semente dessa aleatorização (Seção 5.6) para que os resultados fossem reprodutíveis. Com a semente fixada, a rodada definitiva registra o erro a partir de $n = 50$.

Optou-se por **reportar** esses defeitos, e não corrigi-los: como o objeto de estudo é o conjunto de implementações efetivamente disponíveis, corrigi-los apagaria um resultado legítimo sobre a qualidade do que se encontra publicado.

6.9 CRESCIMENTO EMPÍRICO FRENTE À COMPLEXIDADE TEÓRICA

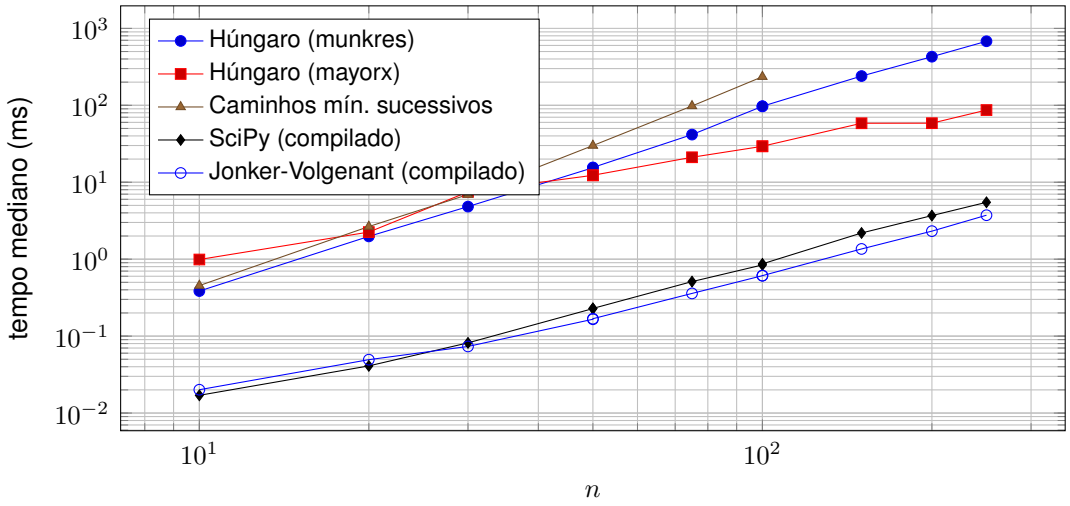
Como o tempo absoluto não é comparável entre linguagens, a análise de crescimento apoia-se no expoente empírico definido na Seção 5.5: a inclinação da reta ajustada ao gráfico do tempo pelo tamanho, em escala logarítmica. As Figuras 6 e 7 apresentam esses gráficos para o grafo e a matriz densos, e as Tabelas 49 a 53 confrontam o expoente medido com a complexidade teórica, cada uma para uma instância representativa do problema. Para comparar os dois, a complexidade é expressa em função de n: no grafo 3 da cardinalidade bipartida, por exemplo, $V = 2n$ e $E = 15n$, de modo que $O(V \cdot E)$ corresponde a n^2 e $O(E\sqrt{V})$ a $n^{1{,}5}$.

Figura 6 – Cardinalidade máxima bipartida, grafo 3 (denso, com emparelhamento perfeito): tempo de execução em escala log-log



Fonte: Elaborado pelo autor. A inclinação de cada reta corresponde ao expoente empírico de crescimento.

Figura 7 – Atribuição linear, matriz 1 (densa uniforme, custos em $[1, 100]$): tempo de execução em escala log-log



Fonte: Elaborado pelo autor. A inclinação de cada reta corresponde ao expoente empírico de crescimento.

Os expoentes medidos são, em geral, coerentes com a teoria. O caso mais nítido é o do Edmonds-Karp (Tabela 49), cujo expoente de 2,79 acompanha o comportamento cúbico previsto e o separa visivelmente dos demais na Figura 6. Os dois Hopcroft-Karp interpretados medem 1,20 e 1,09, abaixo do $1{,}5$ previsto, e o guloso mede exatamente 1, como esperado de um algoritmo linear. Na atribuição (Tabela 50 e Figura 7), as implementações de núcleo compilado situam-se muito abaixo das interpretadas, mas com inclinação semelhante, como esperado, já que a linguagem altera a constante C do modelo $t(n) \approx C \cdot n^k$ (Seção 5.5), mas não o expoente k.

Tabela 49 – Cardinalidade máxima bipartida, grafo 3 (denso, com emparelhamento perfeito): expoente empírico de crescimento

Algoritmo	**Compl. teórica**	**Expoente medido**	R^2
Aug. Paths (wbchristerson)	$O(V \cdot E)$	2.61	0.917
Hopcroft-Karp (sofiat)	$O(E \cdot \sqrt{V})$	1.20	0.996
Edmonds-Karp (Maxflow-Algs)	$O(V \cdot E^2)$	2.79	0.999
Hopcroft-Karp (NetworkX)	$O(E \cdot \sqrt{V})$	1.09	0.999
Bipartite Match. (igraph)	$O(E \cdot \sqrt{V})$	1.05	0.994
Gulosa	$O(E)$	1.00	1.000
Karp-Sipser	$O(V \cdot E)^{\star}$	1.68	0.983

Fonte: Elaborado pelo autor.

Tabela 50 – Atribuição linear, matriz 1 (densa uniforme, custos em $[1, 100]$): expoente empírico de crescimento

Algoritmo	**Compl. teórica**	**Expoente medido**	R^2
Húngaro (munkres)	$O(n^3)$	2.36	0.999
Húngaro (benchaplin)	$O(n^3)$	3.22	0.998
Húngaro (mayorx/KM)	$O(n^3)$	1.39	0.980
SSP (flows)	$O(n^4)$*	2.71	0.998
SciPy (linear_sum_assg)	$O(n^3)$	1.86	0.994
Jonker-Volgenant (lap)	$O(n^3)$	1.65	0.987

Fonte: Elaborado pelo autor.

Observa-se ainda que, nos tamanhos avaliados, o expoente medido frequentemente fica *abaixo* do previsto pela complexidade de pior caso, que é conservadora: o pior caso raramente se materializa nas instâncias típicas. Na atribuição, a `munkres` mede 2,36 e o caminho mínimo sucessivo 2,71, diante de n^3 e n^4. Na atribuição gargalo (Tabela 52), os quatro algoritmos ficam abaixo ou próximos do previsto, com as duas heurísticas perto de 2, coerentes com $O(n^2 \log n)$. No peso máximo em grafos gerais (Tabela 53), medido no grafo esparso, as duas implementações do algoritmo de Edmonds medem cerca de 1,4, muito abaixo do cúbico, e o Path Growing mede 0,88, próximo do linear, já que nesse grafo E cresce proporcionalmente a n.

Tabela 51 – Casamento estável, perfil 1 (aleatório): expoente empírico de crescimento

Algoritmo	**Compl. teórica**	**Expoente medido**	R^2
Gale-Shapley (OOP/pip)	$O(n^2)$†	3.28	0.996
Gale-Shapley (numérico/pip)	$O(n^2)$	1.94	0.999
Gale-Shapley (Lattas/dict)	$O(n^3)$*	2.07	0.999

Fonte: Elaborado pelo autor.

Tabela 52 – Atribuição gargalo, matriz 1 (densa uniforme, custos em $[1, 100]$): expoente empírico de crescimento

Algoritmo	**Compl. teórica**	**Expoente medido**	R^2
Threshold (busca binária)	$O(n^3 \log n)$*	2.61	0.996
Caminhos aumentantes	$O(n^3)$	2.41	0.999
Gulosa simples	$O(n^2 \log n)$	2.18	1.000
Gulosa por arrependimento	$O(n^2 \log n)$	1.95	0.999

Fonte: Elaborado pelo autor.

Tabela 53 – Peso máximo em grafos gerais, grafo esparso (grau médio ≈ 3): expoente empírico de crescimento

Algoritmo	**Compl. teórica**	**Expoente medido**	R^2
van Rantwijk (mwmatching)	$O(V^3)$	1.40	0.989
NetworkX (peso máximo)	$O(V^3)$	1.36	0.990
Path Growing	$O(E)$	0.88	0.998

Fonte: Elaborado pelo autor.

Há três exceções em que o expoente medido supera o teórico. A maior delas é a da variante orientada a objetos do Gale-Shapley (Tabela 51), cujo expoente de 3,28 supera o 2 previsto: o sobrecusto de implementação a torna, na prática, super-quadrática, confirmando por medição a ressalva marcada com † nas tabelas. Na mesma tabela, o Gale-Shapley de Lattas mede 2,07, bem abaixo do seu $O(n^3)$, pois no perfil aleatório o número de rejeições é pequeno. As outras duas exceções têm causa diferente. O método de caminhos aumentantes na cardinalidade bipartida (Tabela 49) mede 2,61 diante de n^2, mas com $R^2 = 0{,}917$, o menor de todas as tabelas, reflexo do salto entre $n = 200$ e $n = 250$ discutido na Seção 6.2: o crescimento não é bem descrito por uma única potência. A `benchaplin` (Tabela 50) mede 3,22 diante de n^3, mas o ajuste usa só os três tamanhos em que ela concluiu ($n \leq 30$), o que torna a estimativa pouco confiável.

7 CONCLUSÕES E TRABALHOS FUTUROS

Este trabalho levantou os principais problemas de emparelhamento em grafos e seus métodos de solução, exatos, aproximados e heurísticos, e os comparou experimentalmente em um único ambiente de testes, com as mesmas instâncias, o mesmo protocolo de medição e os mesmos critérios para todos. Este capítulo retoma os objetivos, resume os principais resultados e as dificuldades encontradas e aponta os trabalhos futuros.

7.1 OBJETIVOS ALCANÇADOS

O primeiro objetivo específico, mapear as variações e características dos principais problemas de emparelhamento, foi cumprido nos Capítulos 3 e 4, que apresentam sete problemas: cardinalidade máxima, atribuição linear, atribuição gargalo e casamento estável, em grafos bipartidos, e cardinalidade máxima, peso máximo e emparelhamento induzido máximo, em grafos gerais. Para cada problema são apresentadas a definição, as propriedades que fundamentam os algoritmos e os principais métodos da literatura, com pseudocódigo, explicação linha a linha e justificativa da complexidade. O Capítulo 2 reúne os conceitos de que esses métodos dependem, como caminhos aumentantes, fluxo em redes e dualidade em programação linear.

O segundo objetivo, classificar os problemas e os métodos, foi atendido pela própria organização do texto e pelas tabelas-resumo. A estrutura do grafo separa os dois capítulos de problemas, o objetivo de otimização distingue os problemas dentro de cada capítulo, e o tipo de método segue a classificação da Seção 2.7, em exato, aproximado ou heurístico, registrada nas tabelas-resumo de cada problema ao lado da complexidade e da indicação de quais algoritmos foram avaliados.

O terceiro objetivo, implementar os algoritmos selecionados, resultou nas implementações relacionadas na Tabela 10: dez implementações de terceiros, usadas sem nenhuma alteração; quatro reimplementações de códigos públicos; nove implementações próprias, escritas a partir da literatura quando não havia código adequado; e cinco bibliotecas maduras, usadas como referência de correção e de desempenho.

O quarto objetivo, criar um ambiente de testes unificado e nele comparar os algoritmos, foi cumprido nos Capítulos 5 e 6: o ambiente mantém intacto o código de terceiros (Seção 5.1), gera famílias de instâncias determinísticas (Seção 5.3) e aplica o mesmo protocolo de medição a todos os algoritmos (Seção 5.4), comparando-os quanto ao tempo de execução, ao crescimento frente à complexidade assintótica (Seção 6.9) e à qualidade das soluções.

O quinto objetivo, organizar os resultados de forma acessível, foi atendido pelas tabelas-resumo de cada problema, pela padronização das tabelas de resultados (Seção 6.1) e pela publicação do código, dos geradores e dos dados brutos no repositório do trabalho.

7.2 PRINCIPAIS RESULTADOS

Os resultados do Capítulo 6 permitem quatro conclusões principais. A primeira é que **a implementação pesa tanto quanto o algoritmo**. As quatro implementações do método Húngaro, todas do mesmo algoritmo e com a mesma complexidade, chegam a diferir em quase setenta vezes no tempo (Seção 6.3), e duas delas apresentam defeitos (Seção 6.8). Em grafos gerais, a implementação avaliada do algoritmo de Edmonds para cardinalidade é cerca de 1 300 vezes mais lenta que a do NetworkX no grafo denso, enquanto a implementação de van Rantwijk é de duas a três vezes mais rápida que a rotina do NetworkX derivada dela (Seção 6.6). A complexidade assintótica, portanto, não basta para escolher um método: a qualidade da implementação disponível faz parte da escolha.

A segunda conclusão é que **a estrutura da instância pode mudar a ordem entre os algoritmos**. Na atribuição gargalo, o método de caminhos aumentantes é o mais rápido nas matrizes densa e estruturada, mas o de *threshold* o supera na matriz com poucos valores distintos (Seção 6.4). No casamento estável, o perfil correlacionado leva ao pior caso do algoritmo de Gale-Shapley, com $n(n+1)/2$ propostas, contra apenas n no perfil cíclico, e só nele a complexidade cúbica da implementação de Lattas se manifesta (Seção 6.5). Na atribuição linear, os defeitos das implementações públicas aparecem apenas na matriz aleatória. Uma avaliação com uma única instância representativa teria ocultado essas diferenças, o que justifica o uso de várias famílias de instâncias por problema.

A terceira conclusão é que **o valor dos métodos aproximados e heurísticos depende do problema**. Os métodos com garantia de aproximação ficaram muito acima dela: na cardinalidade máxima em grafos bipartidos, o algoritmo de Karp-Sipser encontra o ótimo em todas as instâncias esparsas, e o método guloso obtém entre 85 e 98% do ótimo, sendo de cinquenta a cem vezes mais rápido (Seção 6.2); no peso máximo em grafos gerais, o Path Growing entrega entre 78 e 95% do ótimo, diante de uma garantia de metade. Já as heurísticas gulosas da atribuição gargalo, sem garantia, chegam a ficar doze vezes acima do ótimo. No emparelhamento induzido máximo, que é NP-difícil, a heurística de grau mínimo alcança ou quase alcança o ótimo onde o exato foi executado (Seção 6.7).

A quarta conclusão é que **o crescimento medido é, em geral, coerente com a teoria**, e as exceções são informativas (Seção 6.9). O expoente empírico costuma

ficar abaixo do previsto pela complexidade de pior caso, que raramente se materializa nas instâncias avaliadas, e a linguagem altera a constante, mas não a inclinação, o que torna o expoente uma métrica comparável entre implementações interpretadas e compiladas. Quando o expoente supera o teórico, como na variante orientada a objetos do Gale-Shapley, que mede 3,28 diante de um algoritmo quadrático, ele revela um sobrecusto de implementação que o tempo absoluto, sozinho, não deixaria claro.

7.3 DIFICULDADES ENCONTRADAS

A principal dificuldade veio das próprias implementações públicas. Duas das quatro implementações do método Húngaro apresentaram defeitos (Seção 6.8), e o da implementação `benchaplin` era não determinístico: sobre a mesma entrada, ela ora acertava, ora falhava, ora não terminava, o que exigiu ajustes no protocolo de medição para tornar as execuções reprodutíveis (Seções 5.4 e 5.6). Os defeitos foram reportados, e não corrigidos, pelos motivos da Seção 6.8.

A segunda dificuldade foi comparar implementações em linguagens diferentes. Parte dos algoritmos só tinha implementação pública confiável em Python, e as bibliotecas de referência têm núcleo compilado; há ainda casos intermediários, como laços em Python sobre vetores da biblioteca NumPy. A solução foi tabelar o tempo apenas das implementações interpretadas, classificar os casos intermediários como interpretados e comparar as duas linguagens apenas pelo expoente empírico (Seção 5.5).

7.4 TRABALHOS FUTUROS

Algumas extensões ficaram fora do escopo deste trabalho, por limitação de tempo ou por decisão metodológica, e são os próximos passos:

a) **algoritmos descritos e não implementados:** parte dos métodos apresentados nos capítulos de problemas não foi incorporada ao ambiente de testes: o algoritmo de Dinic, para cardinalidade máxima em grafos bipartidos; a variante de caminhos mínimos sucessivos com Dijkstra e potenciais, para a atribuição linear; o método dual, para a atribuição gargalo; o algoritmo de Micali e Vazirani, para cardinalidade máxima em grafos gerais; e a versão otimizada do algoritmo de Edmonds ponderado (GALIL; MICALI; GABOW, 1986). Como o ambiente já define a interface padrão e o protocolo de cada problema, incluí-los exige apenas um novo adaptador por algoritmo;

b) **métodos aproximados e heurísticas para os demais problemas:** a comparação entre métodos exatos, aproximados e heurísticos foi feita para cardinalidade máxima em grafos bipartidos, atribuição gargalo, peso máximo em grafos gerais e emparelhamento induzido máximo. Ficaram de fora a

heurística gulosa descrita para a atribuição linear, o método guloso ordenado para peso máximo em grafos gerais, o método guloso simples e os algoritmos de Karp-Sipser e de crescimento de caminho para cardinalidade máxima em grafos gerais, e as metaheurísticas de busca local para o emparelhamento induzido (FüRST; LEICHTER; RAUTENBACH, 2017);

c) **métricas independentes da linguagem:** o tempo absoluto das implementações compiladas não foi comparado ao das interpretadas. Contar operações elementares, como caminhos aumentantes percorridos e arestas examinadas, ou implementar um mesmo algoritmo nas duas linguagens permitiria separar o efeito da linguagem do efeito do algoritmo. A contagem foi descartada por exigir uma cópia modificada de cada código de terceiros; uma alternativa é a instrumentação externa, por ferramentas de rastreamento da própria linguagem;

d) **instâncias reais:** as instâncias utilizadas são sintéticas, geradas por famílias parametrizadas. Aplicar o ambiente a instâncias provenientes das aplicações citadas na introdução verificaria se as conclusões se mantêm fora dos cenários controlados;

e) **problemas fora do escopo:** as variações excluídas na delimitação do estudo (Seção 1.2), em especial as NP-difíceis, como o emparelhamento tridimensional e a atribuição quadrática.

Disclaimer: foi feito uso de inteligência artificial para auxílio com formatação e a linguagem LaTeX, busca e checagem de referências, revisão e correção de ortografia e concordância, explicação de conceitos, conversão e tradução de pseudocódigos da literatura para um formato padronizado, construção do ambiente de testes, geração de diagramas e orientações gerais quanto à estrutura do texto.

REFERÊNCIAS

AHO, A. V.; HOPCROFT, J. E.; ULLMAN, J. D. *The Design And Analysis of Computer Algorithms*. 1st. ed. Reading, MA: Addison-Wesley, 1974. ISBN 9780201000290.

AHUJA, R. K.; MAGNANTI, T. L.; ORLIN, J. B. *Network flows: theory, algorithms, and applications*. USA: Prentice-Hall, Inc., 1993. ISBN 013617549X.

BURKARD, R.; DELL'AMICO, M.; MARTELLO, S. *Assignment Problems*. USA: Society for Industrial and Applied Mathematics, 2009. ISBN 0898716632.

CAETANO, T. S. et al. Learning graph matching. *IEEE TRANSACTIONS ON PATTERN ANALYSIS AND MACHINE INTELLIGENCE*, IEEE Computer Society, United States, v. 31, n. X, December 2009. ISSN 0162-8828.

CAMERON, K. Induced matchings. *Discrete Applied Mathematics*, v. 24, n. 1, p. 97–102, 1989. ISSN 0166-218X. Disponível em: <https://www.sciencedirect.com/science/article/pii/0166218X9290275F>.

CORMEN, T. H. et al. *Introduction to Algorithms*. 3rd. ed. Cambdrige, MA: The MIT Press, 2009. ISBN 978-0-262-53305-8.

DASGUPTA, C. H. P. S.; VAZIRANI, U. V. *Algorithms*. 1st. ed. New York, NY: McGraw-Hill Education, 2006. ISBN 978-0073523408.

DRAKE, D. E.; HOUGARDY, S. A simple approximation algorithm for the weighted matching problem. *Information Processing Letters*, v. 85, n. 4, p. 211–213, 2003. ISSN 0020-0190. Disponível em: <https://www.sciencedirect.com/science/article/pii/S0020019002003939>.

DUCKWORTH, W.; WORMALD, N.; ZITO, M. Maximum induced matchings of random cubic graphs. *Journal of Computational and Applied Mathematics*, v. 142, n. 1, p. 39–50, 2002. ISSN 0377-0427. Probabilistic Methods in Combinatorics and Combinatorial Optimization. Disponível em: <https://www.sciencedirect.com/science/article/pii/S0377042701004575>.

EDMONDS, J. Paths, trees, and flowers. *Canadian Journal of Mathematics*, v. 17, p. 449–467, 1965.

FüRST, M.; LEICHTER, M.; RAUTENBACH, D. *Locally Searching for Large Induced Matchings*. 2017. Disponível em: <https://arxiv.org/abs/1708.02028>.

GABOW, H. N. Data structures for weighted matching and nearest common ancestors with linking. In: *Proceedings of the First Annual ACM-SIAM Symposium on Discrete Algorithms*. USA: Society for Industrial and Applied Mathematics, 1990. (SODA '90), p. 434–443. ISBN 0898712513.

GALIL, Z.; MICALI, S.; GABOW, H. An $o(ev \log v)$ algorithm for finding a maximal weighted matching in general graphs. *SIAM J. Comput.*, v. 15, p. 120–130, 02 1986.

GAREY, M. R.; JOHNSON, D. S. *Computers and Intractability; A Guide to the Theory of NP-Completeness*. USA: W. H. Freeman & Co., 1990. ISBN 0716710455.

GOLUMBIC, M. C.; LEWENSTEIN, M. New results on induced matchings. *Discrete Applied Mathematics*, v. 101, n. 1-3, p. 157–165, 2000. ISSN 0166-218X.

HALIM, S.; HALIM, F. *Competitive Programming 3: The New Lower Bound of Programming Contests*. 3rd. ed. [S.l.]: Lulu.com, 2013. Self-published by the authors. ISBN 978-1482852483.

HALLDóRSSON, M.; RADHAKRISHNAN, J. Greed is good: approximating independent sets in sparse and bounded-degree graphs. In: *Proceedings of the Twenty-Sixth Annual ACM Symposium on Theory of Computing*. New York, NY, USA: Association for Computing Machinery, 1994. (STOC '94), p. 439–448. ISBN 0897916638. Disponível em: <https://doi.org/10.1145/195058.195221>.

JONKER, R.; VOLGENANT, A. A shortest augmenting path algorithm for dense and sparse linear assignment problems. *Computing*, v. 38, n. 4, p. 325–340, 1987. Disponível em: <https://doi.org/10.1007/BF02278710>.

JUNGNICKEL, D. *Graphs, Networks and Algorithms*. 3rd. ed. Berlin, Germany: Springer, 2008. ISBN 978-354727798.

KARP, R. M.; SIPSER, M. Maximum matching in sparse random graphs. In: *Proceedings of the 22nd Annual Symposium on Foundations of Computer Science*. USA: IEEE Computer Society, 1981. (SFCS '81), p. 364–375. Disponível em: <https://doi.org/10.1109/SFCS.1981.21>.

KLEINBERG, J.; TARDOS Éva. *Algorithm Design*. 1st. ed. Boston, MA: Pearson, 2005. ISBN 978-0321295354.

LAWLER, E. L. *Combinatorial Optimization: Networks and Matroids*. New York, NY: Dover Publications, 1976. Reprint edition. ISBN 978-0486414539.

Basic terminology. In: LOVáSZ, L.; PLUMMER, M. (Ed.). *Matching Theory*. North-Holland, 1986, (North-Holland Mathematics Studies, v. 121). p. xxix–xxxiii. Disponível em: <https://www.sciencedirect.com/science/article/pii/S0304020808736363>.

MANBER, U. *Introduction to Algorithms: A Creative Approach*. 1st. ed. Reading, MA: Addison-Wesley, 1989. ISBN 978-0201120370.

MANDULAK, M. et al. Efficient weighted graph matching on gpus. *SC24*, IEEE Computer Society, United States, November 2024. ISSN 0162-8828.

MARTELLO, S.; TOTH, P. Linear assignment problems. In: MARTELLO, S. et al. (Ed.). *Surveys in Combinatorial Optimization*. North-Holland, 1987, (North-Holland Mathematics Studies, v. 132). p. 259–282. Disponível em: <https://www.sciencedirect.com/science/article/pii/S0304020808732389>.

MICALI, S.; VAZIRANI, V. An O(sqrt(|v|) |E|) Algorithm for Finding Maximum Matching in General Graphs. In: . [S.l.: s.n.], 1980. p. 17–27.

ROSEN, K. H.; KREHER, D. L.; STINSON, D. R. *Discrete Mathematics and Its Applications*. 1st. ed. Boca Raton, FL: CRC Press, 1998. ISBN 978-0849339882.

SCHRIJVER, A. *Combinatorial Optimization: Polyhedra and Efficiency*. 1st. ed. Berlin, Germany: Springer, 2004. ISBN 3540204563.

STOCKMEYER, L. J.; VAZIRANI, V. V. Np-completeness of some generalizations of the maximum matching problem. *Information Processing Letters*, v. 15, n. 1, p. 14–19, 1982. ISSN 0020-0190. Disponível em: <https://www.sciencedirect.com/science/article/pii/0020019082900771>.

TAYLOR, W. R. Protein structure comparison using bipartite graph matching and its application to protein structure classification. *Molecular and Cellular Proteomics*, American Society for Biochemistry and Molecular Biology, United States, v. 1, n. 4, April 2002. ISSN 1535-9476.

VAZIRANI, V. V. *Approximation algorithms*. Berlin, Heidelberg: Springer-Verlag, 2001. ISBN 3540653678.

ZASLAVSKIY, M.; BACH, F.; VERT, J.-P. A path following algorithm for the graph matching problem. *IEEE TRANSACTIONS ON PATTERN ANALYSIS AND MACHINE INTELLIGENCE*, IEEE Computer Society, United States, v. 31, n. 12, December 2009. ISSN 0162-8828.