



UNIVERSIDADE FEDERAL DE SANTA CATARINA
CENTRO TECNOLÓGICO
BACHAREL EM CIÊNCIAS DA COMPUTAÇÃO

Tális Breda

ESTUDO DA FAMÍLIA DE EMPARELHAMENTO EM GRAFOS

Florianópolis
2024

Tális Breda

ESTUDO DA FAMÍLIA DE EMPARELHAMENTO EM GRAFOS

Trabalho de Conclusão do Curso de Graduação em Ciências da Computação do Centro Tecnológico da Universidade Federal de Santa Catarina para a obtenção do título de Bacharel em Ciências da Computação.

Orientador: Prof. Dr. Rafael de Santiago

Florianópolis
2024

RESUMO

Problemas de emparelhamento em grafos, definidos como uma seleção de conjuntos de arestas sem vértices em comum, possuem ampla relevância em áreas da computação, como visão computacional, e também fora dela, como na biologia. São bastante importantes em tarefas que envolvem correspondência de elementos, como a comparação e correspondência de elementos em conjuntos distintos, por exemplo em análise de dados estruturados. Enquanto as formulações clássicas são solúveis eficientemente, variações com restrições adicionais pertencem frequentemente à classe NP-Difícil, exigindo métodos inovadores para equilibrar precisão e eficiência. Considerando a quantidade de algoritmos e métodos presentes na literatura, torna-se difícil encontrar a maneira mais eficiente de resolver um problema específico. Este trabalho busca levantar, comparar e classificar métodos computacionais, destacando suas aplicações e limitações, com o objetivo de fornecer insights úteis para pesquisadores e profissionais na escolha de soluções eficazes para cenários práticos.

Palavras-chave: Emparelhamento em grafos, grafos bipartidos, visão computacional

ABSTRACT

Graph matching problems, defined as a selection of edges sharing no common vertices, hold significant relevance in computational fields such as computer vision, as well as in other domains like biology. They are crucial in tasks involving element correspondence, such as the comparison and matching of elements across distinct sets—for instance, in the analysis of structured data. While classical formulations are efficiently solvable, variations with additional constraints often belong to the NP-Hard class, necessitating innovative methods to balance accuracy and efficiency. Given the vast number of algorithms and methods available in the literature, identifying the most efficient approach for a specific problem becomes challenging. This work aims to survey, compare, and classify computational methods, highlighting their applications and limitations, with the goal of providing valuable insights to assist researchers and practitioners in selecting effective solutions for practical scenarios.

Keywords: Graph matching, bipartite graphs, computer vision

Conteúdo

1	Introdução	8
1.1	Objetivos	8
1.1.1	Objetivo geral	8
1.1.2	Objetivos específicos	8
1.2	Delimitação do estudo	9
2	Fundamentação teórica	9
2.1	Definições sobre grafos	9
2.1.1	Grafo direcionado	9
2.1.2	Grafo ponderado	9
2.1.3	Grafo bipartido	9
2.2	Busca em grafos	10
2.2.1	Representação computacional	10
2.2.2	Busca em largura	10
2.2.3	Busca em profundidade	10
2.3	Caminhos mais curtos	11
2.3.1	Princípio do relaxamento e subestrutura ótima	11
2.3.2	Algoritmo de Dijkstra	11
2.3.3	Algoritmo de Bellman-Ford	12
2.3.4	Algoritmo de Floyd-Warshall	12
2.4	Redes de fluxo em grafos	13
2.4.1	Definições básicas	13
2.4.2	O problema do fluxo máximo	13
2.4.2.1	Corte	13
2.4.2.2	Redes residuais	14
2.4.2.3	Caminhos aumentantes	14
2.4.3	Fluxo de custo mínimo	14
2.4.3.1	Condições de otimalidade e ciclos negativos	15
2.4.3.2	Potenciais de vértices e custos reduzidos	15
2.5	Problema Geral do Emparelhamento	15
2.5.1	Matching em grafos bipartidos	16
2.5.2	Formulação geral (emparelhamento e otimização)	16
3	Problemas de emparelhamento em grafos bipartidos	16
3.1	Emparelhamento de cardinalidade máxima	16
3.1.1	Descrição do problema	16
3.1.2	Propriedades	16
3.1.2.1	Emparelhamento máximo vs maximal	16
3.1.2.2	Caminhos aumentantes	16
3.1.2.3	Teorema de Kőnig	17
3.1.2.4	Teorema de Hall	17
3.1.2.5	Teorema de Gallai e Conjunto Independente Máximo	17
3.1.3	Algoritmos exatos	18
3.1.3.1	Algoritmo do caminho aumentante	18
3.1.3.2	Redução ao problema de fluxo máximo	19
3.1.3.3	Algoritmo de Edmonds-Karp	19
3.1.3.4	Algoritmo de Dinic	20
3.1.3.5	Algoritmo de Hopcroft-Karp	21
3.1.4	Heurísticas	23
3.1.4.1	Heurística gulosa simples	23
3.1.4.2	Heurística de Karp-Sipser	23
3.2	Problema de atribuição (Assignment Problem)	24

3.2.1	Descrição do problema	24
3.2.2	Propriedades	24
3.2.3	Algoritmos exatos	24
3.2.3.1	Método Húngaro	24
3.2.3.2	Jonker-Volgenant	26
3.2.3.3	Redução para problema de fluxo de custo mínimo	26
3.2.4	Heurísticas	28
3.2.4.1	Heurística gulosa ordenada	28
3.3	Problema de atribuição gargalo	29
3.3.1	Descrição do problema	29
3.3.2	Soluções exatas	29
3.3.2.1	Métodos de threshold	29
3.3.2.2	Método dual	30
3.3.2.3	Método de caminhos aumentantes	31
3.3.3	Heurísticas	33
3.3.3.1	Heurística Construtiva Gulosa	33
3.4	Problema do emparelhamento estável	34
3.4.1	Descrição do problema	34
3.4.2	Propriedades	34
3.4.3	Algoritmo de Gale-Shapley	35
4	Problemas de emparelhamento em grafos gerais	35
4.1	Emparelhamento de cardinalidade máxima	36
4.1.1	Descrição	36
4.1.2	Propriedades	36
4.1.2.1	Ciclos ímpares	36
4.1.2.2	Flor (Blossom)	36
4.1.3	O algoritmo de Edmonds	36
4.1.3.1	Teorema de Tutte-Berge	40
4.1.4	Heurísticas	40
4.1.4.1	Algoritmo de crescimento de caminho (Path Growing)	40
4.2	Emparelhamento ponderado máximo	41
4.2.1	Formulação poliédrica e Restrições de Blossom	41
4.2.2	A abordagem Primal-Dual	42
4.2.3	O algoritmo de Edmonds Ponderado	42
4.2.4	Otimizações	43
4.2.5	Heurísticas	43
4.2.5.1	Algoritmo de Crescimento de Caminho (Path Growing)	43
4.3	Emparelhamento induzido máximo	43
4.3.1	Propriedades	43
4.3.2	Complexidade computacional	44
4.3.3	Redução ao Problema do Conjunto Independente	44
4.3.4	Abordagens de solução e heurísticas	45
4.3.4.1	Heurísticas gulosas	45
4.3.4.2	Metaheurísticas	45
4.4	Outros problemas	46
5	Metodologia	46
5.1	Arquitetura do ambiente de testes	46
5.2	Interface padrão dos problemas	46
5.3	Geradores de instância	46
5.4	Protocolo de medição	47
5.5	Critérios de comparação	47
5.6	Ambiente de execução e reprodutibilidade	47

5.7	Origem, adaptação e verificação dos algoritmos	48
6	Resultados e discussão	49
6.1	Cardinalidade máxima em grafos bipartidos	50
6.2	Atribuição linear	51
6.3	Atribuição gargalo	52
6.4	Casamento estável	52
6.5	Emparelhamento em grafos gerais	53
6.6	Emparelhamento induzido máximo	53
6.7	Defeitos em implementações públicas	54
6.8	Crescimento empírico frente à complexidade teórica	54
7	Trabalhos futuros	57

1 Introdução

Na teoria dos grafos e otimização combinatória, um emparelhamento em um grafo não-dirigido $G = (V, E)$ é definido formalmente como um subconjunto de arestas $M \subseteq E$ tal que nenhuma aresta em M compartilhe um vértice comum. Em termos precisos, para todo vértice $v \in V$, o grau de v no subgrafo induzido por M é no máximo 1. Esta definição fundamental é apresentada por Lovász e Plummer (1986) em sua obra seminal sobre a teoria dos emparelhamentos, onde também se estabelece a distinção clássica entre emparelhamentos em grafos bipartidos — cujos vértices podem ser divididos em dois conjuntos disjuntos U e V — e em grafos gerais.

Os problemas de emparelhamento têm aplicações significativas em várias áreas, como biologia computacional, onde podem ser empregados na diferenciação e classificação de estruturas proteicas (TAYLOR, 2002); redes sociais, para identificação de comunidades ou grupos (FAN, 2012); e visão computacional, para correspondências entre elementos de conjuntos distintos, como pontos em imagens ou vértices em malhas tridimensionais (HALLER et al., 2022).

É crucial, no entanto, fazer uma distinção precisa quanto à complexidade computacional desses problemas. Ao contrário do que uma análise superficial poderia sugerir, o problema de encontrar um emparelhamento de cardinalidade ou peso máximo pertence à classe de complexidade **P** (tempo polinomial), sendo solúvel por algoritmos clássicos como o Método Húngaro ou o Algoritmo de *Blossom* de Edmonds (SCHRIJVER, 2004). O verdadeiro desafio computacional, frequentemente classificado como **NP-Difícil**, surge em variações estruturais mais complexas, como o Emparelhamento Tridimensional ou o Problema da Atribuição Quadrática (QAP). Segundo Garey e Johnson (1990) e Burkard, Dell'Amico e Martello (2009), o QAP modela situações onde o custo depende da interação entre os pares escolhidos, tornando métodos exatos inviáveis para grandes instâncias e exigindo o uso de relaxações ou heurísticas avançadas.

Diante desse cenário, este trabalho visa sistematizar os principais problemas e métodos computacionais associados ao emparelhamento em grafos. Ele busca oferecer uma comparação detalhada entre suas aplicações e limitações, contribuindo para o entendimento aprofundado das ferramentas disponíveis e identificando oportunidades para o desenvolvimento de novas soluções. Essa abordagem torna-se ainda mais relevante à luz da importância prática desses algoritmos para resolver problemas reais em grande escala, conforme evidenciado por estudos recentes (SUSSMAN; LI, 2021).

1.1 Objetivos

1.1.1 Objetivo geral

Este trabalho tem como objetivo principal levantar, organizar, implementar e comparar problemas de emparelhamento em grafos para diversos casos de uso, além de comparar diferentes métodos computacionais presentes na literatura para a solução desses problemas.

1.1.2 Objetivos específicos

- Mapear as variações e características de diferentes problemas de emparelhamento presentes na literatura.
- Investigar e classificar métodos computacionais presentes na literatura de acordo com suas vantagens, limitações e casos de uso.
- Implementar os algoritmos descritos, a fim de comparar a complexidade de tempo e espaço, bem como a qualidade das soluções encontradas.
- Criar um ambiente de testes unificado para testar os algoritmos implementados, a fim de reduzir variabilidade nos resultados e proporcionar comparações consistentes.
- Organizar os resultados em um formato que facilite o acesso e a compreensão dos tópicos abordados por pesquisadores e profissionais.

1.2 Delimitação do estudo

Os problemas de emparelhamento em grafos podem ser classificados de diversas maneiras, como sendo em grafos bipartidos ou não-bipartidos, ponderados ou não-ponderados, direcionados ou não-direcionados, problemas em multigrafos, problemas em hipergrafos, entre outros. Este trabalho focará em problemas que envolvem grafos menos complexos, excluindo multigrafos e hipergrafos.

2 Fundamentação teórica

2.1 Definições sobre grafos

Um **grafo** G é uma estrutura definida por um par $G = (V, E)$, consistindo de um conjunto finito V de elementos chamados **vértices** (ou **nós** ou **pontos**) e um conjunto (ou família) E de pares não ordenados de vértices, chamados de **arestas** (JUNGnickEL, 2008). O conjunto V é o conjunto de vértices de G e E é a família de arestas de G .

No contexto deste projeto, assumimos que as arestas $e = (u, v)$ são pares não ordenados de vértices distintos. Se uma aresta e conecta os vértices a e b , diz-se que a e b são **adjacentes** ou **vizinhos**, e que a aresta e é **incidente** a a e b (SCHRIJVER, 2004).

O conceito de grafo é amplamente utilizado como uma representação abstrata concisa para estruturas complexas e para codificar relações binárias entre um conjunto de objetos.

2.1.1 Grafo direcionado

Se as relações entre os vértices forem assimétricas, utilizamos um **grafo direcionado** ou **dígrafo**, $D = (V, A)$. Neste caso, A é uma família de pares ordenados de vértices, chamados **arcos** (ou arestas direcionadas). Para um arco $e = (u, v)$, u é chamado o vértice inicial ou **cauda** (tail), e v é o vértice final ou **cabeça** (head) (MANBER, 1989).

2.1.2 Grafo ponderado

Um grafo $G = (V, E)$ é chamado **grafo ponderado** (ou com pesos) se uma **função de peso** (ou função de custo, ou função de comprimento) $w : E \rightarrow R$ está associada às arestas. Formalmente: $G = (V, E, w)$, onde $w : E \rightarrow R$. Geralmente, o peso $w(e)$ de uma aresta e é um valor real não negativo que representa o custo, comprimento ou capacidade associada àquela aresta (ROSEN; KREHER; STINSON, 1998).

Grafos ponderados podem ser representados por matrizes de adjacência de valor real A , onde a entrada A_{ij} é o peso w_{ij} da aresta (ZASLAVSKIY; BACH; VERT, 2009).

2.1.3 Grafo bipartido

Um grafo bipartido é um grafo não direcionado que pode ser facilmente colorido com apenas duas cores (MANBER, 1989).

Formalmente, um grafo $G = (V, E)$ é chamado **grafo bipartido** se o conjunto de vértices V puder ser particionado em dois subconjuntos disjuntos V_1 e V_2 , chamados classes de cor, tais que:

$$V = V_1 \cup V_2 \quad e \quad V_1 \cap V_2 = \emptyset \quad (1)$$

e todas as arestas $e \in E$ conectam um vértice em V_1 a um vértice em V_2 . Ou seja, não existem arestas que conectem vértices dentro do mesmo subconjunto (DASGUPTA; VAZIRANI, 2006).

Observações:

- Um grafo é bipartido se e somente se não contém ciclos de comprimento ímpar (SCHRIJVER, 2004)
- O grafo bipartido completo $K_{m,n}$ possui m vértices em V_1 e n vértices em V_2 , e contém todas as arestas possíveis entre V_1 e V_2 (JUNGnickEL, 2008)

2.2 Busca em grafos

A exploração sistemática dos vértices e arestas de um grafo é uma sub-rotina fundamental para a maioria dos algoritmos em redes, incluindo aqueles utilizados para encontrar emparelhamentos, fluxo máximo e componentes conexos. A busca em grafos consiste em seguir as arestas do grafo para visitar os vértices, permitindo descobrir a estrutura da rede e propriedades de conectividade (CORMEN et al., 2009).

2.2.1 Representação computacional

Antes de discutir os algoritmos de busca, é essencial definir como o grafo $G = (V, E)$ é representado computacionalmente, pois isso impacta diretamente a complexidade temporal das operações. Destacam-se duas representações primárias (AHO; HOPCROFT; ULLMAN, 1974):

- **Matriz de adjacência:** Uma matriz A de dimensão $|V| \times |V|$, onde $A_{ij} = 1$ se existe uma aresta $(i, j) \in E$, e 0 caso contrário. Embora permita verificação de existência de arestas em tempo constante $O(1)$, ela consome espaço $\theta(V^2)$, sendo ineficiente para grafos esparsos.
- **Lista de adjacência:** Consiste em uma lista de $|V|$ listas, onde cada lista $Adj[u]$ contém todos os vértices v tal que $(u, v) \in E$. Esta representação é preferível para grafos esparsos, pois consome espaço $\theta(V + E)$ (CORMEN et al., 2009).

Para os algoritmos de busca descritos a seguir, assume-se geralmente o uso de listas de adjacência, resultando em complexidades lineares em relação ao tamanho do grafo.

2.2.2 Busca em largura

A **busca em largura**, ou Breadth-First Search (BFS) é um dos algoritmos mais simples e fundamentais para a exploração de grafos. A BFS explora o grafo em "camadas" ou níveis. Dado um vértice fonte s , o algoritmo visita primeiro todos os vizinhos de s (camada L_1), depois os vizinhos desses vizinhos (camada L_2), e assim sucessivamente (KLEINBERG; TARDOS, 2005).

O procedimento utiliza uma estrutura de dados do tipo Fila (FIFO) para gerenciar a fronteira de exploração. Cormen et al. (2009) descrevem o uso de um sistema de "cores" para monitorar o estado dos vértices: brancos (não descobertos), cinzas (descobertos, mas com vizinhos ainda não explorados) e pretos (totalmente explorados).

Propriedades e Complexidade: A propriedade mais importante da BFS, destacada por Dasgupta e Vazirani (2006), é que ela calcula o caminho mais curto (em número de arestas) de s a todos os outros vértices alcançáveis em grafos não ponderados. A complexidade de tempo da BFS é $O(V + E)$, pois cada vértice é enfileirado no máximo uma vez e cada lista de adjacência é varrida uma única vez.

2.2.3 Busca em profundidade

A **busca em profundidade** ou Depth-First Search (DFS), ao contrário da estratégia por níveis da BFS, a busca em profundidade explora as arestas a partir do vértice mais recentemente descoberto que ainda possui arestas inexploradas. Conforme Manber (1989), a DFS "aprofunda-se" no grafo tanto quanto possível e, quando não há mais para onde ir, realiza o *backtracking* (retrocesso) para explorar outros caminhos.

Computacionalmente, a DFS pode ser implementada de forma recursiva ou utilizando uma Pilha (LIFO). Uma característica crucial da DFS é a classificação temporal dos eventos. Cormen et al. (2009) sugerem registrar dois carimbos de tempo para cada vértice u :

- $d[u]$: Momento de descoberta (quando o vértice passa de branco para cinza).
- $f[u]$: Momento de finalização (quando o vértice passa de cinza para preto, após toda sua lista de adjacência ser explorada).

Classificação de arestas: a execução da DFS induz uma estrutura de floresta (Floresta DFS) e permite classificar as arestas do grafo original em quatro tipos, fundamentais para entender ciclos e estrutura (CORMEN et al., 2009)

- **Arestas de Árvore:** Arestas (u, v) percorridas pela busca quando v é descoberto.
- **Arestas de Retorno (Back edges):** Conectam um vértice u a um ancestral v na árvore DFS. A existência destas arestas indica a presença de ciclos.
- **Arestas de Avanço (Forward edges):** Conectam u a um descendente v que não é seu filho direto.
- **Arestas de Cruzamento (Cross edges):** Conectam vértices sem relação de ancestralidade.

A complexidade da DFS, assim como a BFS, é $\theta(V + E)$ para grafos representados por listas de adjacência.

2.3 Caminhos mais curtos

O problema de encontrar o caminho mais curto entre dois vértices em um grafo é um dos problemas de otimização combinatória mais estudados, servindo como sub-rotina para diversas aplicações, incluindo roteamento de redes e algoritmos de fluxo.

Seja $G = (V, E)$ um grafo ponderado com uma função de peso $w : E \rightarrow \mathbb{R}$. O peso de um caminho $p = \langle v_0, v_1, \dots, v_k \rangle$ é a soma dos pesos de suas arestas constituintes: $w(p) = \sum_{i=1}^k w(v_{i-1}, v_i)$. O **caminho mais curto** de um vértice u a um vértice v é definido como qualquer caminho p com peso mínimo $\delta(u, v)$ (CORMEN et al., 2009).

2.3.1 Princípio do relaxamento e subestrutura ótima

Os algoritmos de caminho mínimo baseiam-se na propriedade de **subestrutura ótima**: subcaminhos de um caminho mais curto são, por si mesmos, caminhos mais curtos. Além disso, utilizam a técnica de **relaxamento** (KLEINBERG; TARDOS, 2005).

Para cada vértice v , o algoritmo mantém um atributo $d[v]$, que é um limite superior para o peso do caminho mais curto da fonte s até v . O processo de relaxar uma aresta (u, v) consiste em testar se é possível melhorar o caminho para v passando por u :

$$\text{Se } d[v] > d[u] + w(u, v), \text{ então } d[v] \leftarrow d[u] + w(u, v) \quad (2)$$

Algorithm 1: Método de relaxamento (CORMEN et al., 2009)

```

(1) Procedure Relax( $u, v, w$ )
(2)   if  $v.d > u.d + w(u, v)$  then
(3)      $v.d \leftarrow u.d + w(u, v)$ 
(4)      $v.\pi \leftarrow u$ 
(5)   end
```

A diferença entre os algoritmos reside na ordem e na frequência com que as arestas são relaxadas.

2.3.2 Algoritmo de Dijkstra

Para grafos onde os pesos das arestas são não-negativos ($w(u, v) \geq 0$), o Algoritmo de Dijkstra é a abordagem mais eficiente. Ele utiliza uma estratégia gulosa, mantendo um conjunto de vértices cujos pesos finais dos caminhos mais curtos já foram determinados (AHO; HOPCROFT; ULLMAN, 1974).

O algoritmo seleciona repetidamente o vértice u com a menor estimativa de caminho mais curto $d[u]$ de uma fila de prioridade, adiciona-o ao conjunto de visitados e relaxa todas as arestas que saem de u . Dasgupta e Vazirani (2006) destacam que a eficiência do Dijkstra depende da estrutura de dados utilizada. Com um Heap Binário, a complexidade é $O((V + E) \log V)$. Cormen et al. (2009) apontam que, ao utilizar um Heap de Fibonacci, a complexidade amortizada pode ser reduzida para $O(E + V \log V)$, o que é crucial para grafos densos.

Algorithm 2: Algoritmo de Dijkstra (CORMEN et al., 2009)

```
(1) Procedure Dijkstra( $G, w, s$ )
(2)   Initialize-Single-Source( $G, s$ )
(3)    $S \leftarrow \emptyset$ 
(4)    $Q \leftarrow G.V$ 
(5)   while  $Q \neq \emptyset$  do
(6)      $u \leftarrow \text{Extract-Min}(Q)$ 
(7)      $S \leftarrow S \cup \{u\}$ 
(8)     foreach vertex  $v \in G.Adj[u]$  do
(9)       Relax( $u, v, w$ )
(10)    end
(11)  end
```

2.3.3 Algoritmo de Bellman-Ford

Quando o grafo contém arestas com pesos negativos, o algoritmo de Dijkstra não garante a corretude. Nesses casos, utiliza-se o Algoritmo de Bellman-Ford. Segundo Manber (1989), este algoritmo baseia-se em programação dinâmica, relaxando todas as arestas do grafo $|V| - 1$ vezes.

A propriedade fundamental do Bellman-Ford é sua capacidade de detectar ciclos negativos. Se, após $|V| - 1$ iterações, ainda for possível relaxar alguma aresta, o grafo contém um ciclo com peso total negativo acessível a partir da fonte, o que implica que $\delta(s, v) = -\infty$ para alguns vértices (KLEINBERG; TARDOS, 2005). Sua complexidade é $O(VE)$.

Algorithm 3: Algoritmo de Bellman-Ford (CORMEN et al., 2009)

```
(1) Procedure Bellman-Ford( $G, w, s$ )
(2)   Initialize-Single-Source( $G, s$ )
(3)   for  $i = 1$  to  $|G.V| - 1$  do
(4)     foreach edge  $(u, v) \in G.E$  do
(5)       Relax( $u, v, w$ )
(6)     end
(7)   end
(8)   foreach edge  $(u, v) \in G.E$  do
(9)     if  $v.d > u.d + w(u, v)$  then
(10)      return false
(11)    end
(12)  end
(13)  return true
```

2.3.4 Algoritmo de Floyd-Warshall

Enquanto Dijkstra e Bellman-Ford resolvem o problema de fonte única (Single-Source), o algoritmo de Floyd-Warshall resolve o problema de caminhos mais curtos entre todos os pares de vértices (All-Pairs).

Aho, Hopcroft e Ullman (1974) explicam que o algoritmo utiliza programação dinâmica baseada na numeração dos vértices. Seja $d_{ij}^{(k)}$ o peso do caminho mais curto de i a j utilizando apenas vértices do conjunto $1, 2, \dots, k$ como intermediários. A recorrência é dada por:

$$d_{ij}^{(k)} = \min(d_{ij}^{(k-1)}, d_{ik}^{(k-1)} + d_{kj}^{(k-1)}) \quad (3)$$

A complexidade temporal é $\theta(V^3)$. Jungnickel (2008) observa que, para grafos densos, este método é geralmente mais eficiente do que executar o algoritmo de Bellman-Ford a partir de cada vértice.

Algorithm 4: Algoritmo de Floyd-Warshall (CORMEN et al., 2009)

```
(1) Procedure Floyd-Warshall( $W$ )
(2)    $n \leftarrow W.rows$ 
(3)    $D^{(0)} \leftarrow W$ 
(4)   for  $k = 1$  to  $n$  do
(5)     let  $D^{(k)} = (d_{ij}^{(k)})$  be a new  $n \times n$  matrix
(6)     for  $i = 1$  to  $n$  do
(7)       for  $j = 1$  to  $n$  do
(8)          $d_{ij}^{(k)} \leftarrow \min \left( d_{ij}^{(k-1)}, d_{ik}^{(k-1)} + d_{kj}^{(k-1)} \right)$ 
(9)       end
(10)    end
(11)  end
(12)  return  $D^{(n)}$ 
```

2.4 Redes de fluxo em grafos

A teoria dos fluxos em redes é um ramo fundamental da otimização combinatória que modela problemas de transporte de recursos através de um sistema conectado. Esta seção define os conceitos preliminares e apresenta os teoremas centrais que sustentam os algoritmos utilizados neste trabalho.

2.4.1 Definições básicas

Uma rede de fluxo é definida por um grafo direcionado $G = (V, E)$, onde V é o conjunto de vértices e E é o conjunto de arestas. Distinguem-se dois vértices especiais: a **fonte** $s \in V$, que produz o fluxo, e o **sorvedouro** $t \in V$, que o consome. Para cada aresta $(u, v) \in E$, associa-se uma capacidade não-negativa $c(u, v) \geq 0$, que limita a quantidade de fluxo que pode atravessar aquela aresta. Um **fluxo** em G é uma função $f : E \rightarrow \mathbb{R}^+$ que satisfaz as seguintes propriedades (CORMEN et al., 2009):

- **Restrição de capacidade:** O fluxo em uma aresta não pode exceder a sua capacidade.

$$0 \leq f(u, v) \leq c(u, v), \quad \forall (u, v) \in E \quad (4)$$

- **Conservação de fluxo:** para todo vértice $v \in V - \{s, t\}$, a quantidade total de fluxo que entra deve ser igual à que sai

$$\sum_{v \in V} f(v, u) = \sum_{v \in V} f(u, v) \quad (5)$$

2.4.2 O problema do fluxo máximo

O **problema do fluxo máximo** consiste em encontrar um fluxo f tal que $|f|$ seja o maior possível. Para entender a limitação desse fluxo, precisamos entender os conceitos de corte, redes residuais e caminhos aumentantes.

2.4.2.1 Corte

Um **corte** (S, T) é uma partição do conjunto de vértices V em dois subconjuntos disjuntos S e T , tal que $s \in S$ e $t \in T$. A **capacidade do corte**, denotada por $c(S, T)$, é a soma das capacidades das arestas que partem de S para T (CORMEN et al., 2009):

$$c(S, T) = \sum_{u \in S, v \in T} c(u, v) \quad (6)$$

O **corte mínimo** de uma rede N é um corte cuja capacidade é a menor entre todos os cortes possíveis nessa rede (CORMEN et al., 2009). Isso nos leva ao **teorema do fluxo máximo e corte mínimo (Max-flow Min-cut)**

O valor máximo do fluxo de uma rede N é igual à capacidade do corte mínimo em N (JUNGNICKEL, 2008)

Este teorema é fundamental para a compreensão e correteude dos algoritmos de caminhos aumentantes.

2.4.2.2 Redes residuais

A maioria dos algoritmos de resolução de problemas de fluxo máximo se baseia no conceito de redes residuais. Uma **rede residual** G_f consiste em arestas com capacidades que representam como podemos alterar o fluxo das arestas em G . A capacidade das arestas da rede residual G_f corresponde à diferença entre a capacidade da aresta original de G e o fluxo f que está passando pela aresta (CORMEN et al., 2009). Ou seja:

$$c_f(u, v) = c(u, v) - f(u, v) \quad (7)$$

Quando a aresta (u, v) possui fluxo igual à sua capacidade, então $c_f(u, v) = 0$ e a aresta não é incluída no grafo residual G_f

2.4.2.3 Caminhos aumentantes

Dado um grafo $G = (V, E)$ e um fluxo f , um **caminho aumentante** é um caminho de s para t na rede residual G_f . Por definição, podemos aumentar o fluxo em uma aresta (u, v) de um caminho aumentante em até $c_f(u, v)$ sem violar a capacidade da aresta original em G (CORMEN et al., 2009).

O método de Ford-Fulkerson, que é base dos principais algoritmos de resolução do problema do fluxo máximo, iterativamente encontra um caminho aumentante, calcula sua capacidade residual e adiciona esse fluxo à solução atual até que não existam mais caminhos aumentantes (AHUJA; MAGNANTI; ORLIN, 1993).

Algorithm 5: Ford-Fulkerson Algorithm

```

(1) Procedure FORD-FULKERSON( $G, s, t$ )
(2)   foreach  $edge (u, v) \in G.E$  do
(3)      $(u, v).f \leftarrow 0$ 
(4)   end
(5)   while there exists a path  $p$  from  $s$  to  $t$  in the residual network  $G_f$  do
(6)      $c_f(p) \leftarrow \min\{c_f(u, v) : (u, v) \text{ is in } p\}$ 
(7)     foreach  $edge (u, v) \in p$  do
(8)       if  $(u, v) \in E$  then
(9)          $(u, v).f \leftarrow (u, v).f + c_f(p)$ 
(10)      else
(11)         $(v, u).f \leftarrow (v, u).f - c_f(p)$ 
(12)      end
(13)   end
(14) end

```

2.4.3 Fluxo de custo mínimo

Uma outra variação dos problemas em redes de fluxo em grafos é o problema do fluxo de custo mínimo. Essa variação considera, além das capacidades disponíveis, uma dimensão econômica. Seja $G = (V, E)$ uma rede direcionada onde cada aresta (u, v) possui uma capacidade $c(u, v)$ e um custo unitário $w(u, v)$. O objetivo é transmitir uma quantidade de fluxo pré-determinada F da fonte s ao sorvedouro t com o menor custo total possível.

A formulação linear do problema é dada por Ahuja, Magnanti e Orlin (1993). O primeiro objetivo é minimizar o custo total do fluxo, que segue a fórmula:

$$\text{Minimizar o custo do fluxo: } z(f) = \sum_{(u,v) \in A} w(u,v) \cdot f(u,v) \quad (8)$$

A função a seguir assegura que o nó fonte s gere exatamente a demanda F , e que o nó sorvedouro t absorva-a integralmente.

$$\sum_{i,j \in V} f(i,j) - \sum_{k,i \in V} f(k,i) = \begin{cases} F & \text{se } i = s \\ -F & \text{se } i = t \\ 0 & \text{caso contrário} \end{cases} \quad (9)$$

Além desta, é importante lembrar da equação 4, que define que o fluxo em uma aresta não pode exceder a sua capacidade.

2.4.3.1 Condições de otimalidade e ciclos negativos

O critério fundamental para verificar se uma solução é ótima é o **teorema dos ciclos negativos**:

Um fluxo f é uma solução viável para o problema do fluxo de custo mínimo se e somente se ele satisfaz a condição de otimalidade de ciclo negativo: a rede residual $G(f)$ não contém um ciclo de custo negativo (AHUJA; MAGNANTI; ORLIN, 1993)

Este teorema é a base dos algoritmos de **cancelamento de ciclos** (Cycle Canceling), que iterativamente identificam ciclos negativos na rede residual e enviam fluxo através deles para reduzir o custo total da função objetivo até que nenhum ciclo negativo reste.

2.4.3.2 Potenciais de vértices e custos reduzidos

Embora o cancelamento de ciclos seja teoricamente sólido, a detecção de ciclos negativos (via Bellman-Ford) pode ser computacionalmente custosa. Para permitir o uso de algoritmos mais eficientes como o de Dijkstra, a literatura introduz o conceito de **potenciais de vértices**, baseando-se na teoria de dualidade da programação linear.

A ideia é manter um **potencial** para cada vértice v do grafo, chamado de $h(v)$, com valor inicial 0. Definimos o **custo reduzido** de uma aresta (u,v) como $\gamma'(u,v) = \gamma(u,v) + h(u) - h(v)$. Se os potenciais forem escolhidos de forma adequada, todos os custos reduzidos podem ser garantidos como não-negativos, permitindo o uso do algoritmo de Dijkstra. Além disso, é garantido que os caminhos de custo mínimo no grafo original e no grafo com custos reduzidos são os mesmos. (JUNGnickel, 2008).

O conceito de potenciais e de custo reduzido será utilizado em algoritmos como o de caminhos sucessivos para resolução do problema de atribuição na seção 3.2.3.3.

2.5 Problema Geral do Emparelhamento

O problema de **matching** (emparelhamento) em grafos é um problema fundamental na otimização combinatória

Um **matching** M em um grafo não-direcionado $G = (V, E)$ é um subconjunto de arestas $M \subseteq E$ tal que nenhum par de arestas em M compartilha um vértice comum (KLEINBERG; TARDOS, 2005). Em outras palavras, cada nó aparece em no máximo uma aresta de M .

- Um vértice é chamado **coberto** (*matched*) se for incidente a uma aresta em M ; caso contrário, é **descoberto** (*unmatched* ou *exposed*) (CORMEN et al., 2009)
- Um **matching de cardinalidade máxima** (Maximum Matching) é um matching com o maior número possível de arestas (CORMEN et al., 2009). A cardinalidade máxima de um matching é denotada por $\nu(G)$ (SCHRIJVER, 2004)

- Um **matching perfeito** é um matching que cobre todos os vértices do grafo (KLEINBERG; TARDOS, 2005)
- O **problema de matching ponderado** (Weighted Matching Problem) envolve encontrar um matching para o qual a soma dos pesos das arestas é máxima. Em um grafo ponderado $G = (V, E, w)$, busca-se um $M \subseteq E$ que maximize $w(M)$ (MANDULAK et al., 2024)

2.5.1 Matching em grafos bipartidos

O problema de **Matching Bipartido** é o caso clássico de encontrar um matching de cardinalidade máxima em um grafo bipartido $G = (V, E)$, onde $V = X \cup Y$ (KLEINBERG; TARDOS, 2005)

- O matching em grafos bipartidos pode modelar situações de atribuição, como associar empregos (X) a máquinas (Y), ou professores (X) a cursos (Y), onde uma aresta indica uma capacidade de atribuição (KLEINBERG; TARDOS, 2005)
- O problema de matching ponderado em grafos bipartidos é equivalente ao **problema de atribuição** (LAWLER, 1976), que historicamente motivou o desenvolvimento do **método Húngaro** (SCHRIJVER, 2004)

2.5.2 Formulação geral (emparelhamento e otimização)

Em um contexto mais amplo, o emparelhamento de grafos pode ser formalizado como um problema de otimização que busca maximizar a compatibilidade entre dois grafos G e G' (CAETANO et al., 2009).

- O problema de graph matching é frequentemente abordado como um **problema de atribuição quadrática (QAP)**. Essa formulação busca maximizar uma função objetivo que combina termos de compatibilidade unária (nó-nó, $c_{ii'}$) e compatibilidade par a par (aresta-aresta, $d_{ii'jj'}$), sujeito a restrições de atribuição binária ($y_{ii'} \in \{0, 1\}$). O termo quadrático codifica a preservação das relações (arestas) entre os nós (CAETANO et al., 2009)
- Para grafos bipartidos, a determinação de um matching máximo pode ser resolvida de maneira eficiente e está intimamente ligada a problemas de *network flow* (fluxo em redes) (KLEINBERG; TARDOS, 2005)

3 Problemas de emparelhamento em grafos bipartidos

3.1 Emparelhamento de cardinalidade máxima

3.1.1 Descrição do problema

Dado um grafo não-direcionado $G = (V, E)$, o problema de emparelhamento de cardinalidade máxima (MCM) busca encontrar um emparelhamento $M \subseteq E$ tal que o número de arestas em M seja maximizado, ou seja, $|M|$ é o maior entre todos os emparelhamentos possíveis em G .

Um caso especial, mas importante, do MCM é o **Emparelhamento perfeito**, que é um emparelhamento onde todos os vértices do grafo são cobertos por exatamente uma aresta do emparelhamento. Para que um emparelhamento perfeito exista, o grafo deve ter um número par de vértices e o emparelhamento máximo deve ter cardinalidade igual a $|V|/2$ (JUNGNICKEL, 2008).

3.1.2 Propriedades

Antes de continuar para os algoritmos e soluções, é necessário entender algumas propriedades importantes

3.1.2.1 Emparelhamento máximo vs maximal

Um emparelhamento máximo é aquele que contém o maior número possível de arestas, enquanto um emparelhamento maximal é aquele que não pode ser aumentado adicionando mais arestas, mas não necessariamente é o maior possível (MANBER, 1989).

3.1.2.2 Caminhos aumentantes

Um caminho aumentante P em um grafo G é chamado de caminho aumentante se P tem tamanho ímpar, começa e termina em vértices livres (não cobertos por nenhuma aresta do emparelhamento atual) e alterna entre arestas que pertencem a M e arestas que não pertencem a M . A existência de um caminho aumentante indica que o emparelhamento atual não é máximo (SCHRIJVER, 2004).

3.1.2.3 Teorema de König

O teorema de König estabelece uma relação fundamental entre emparelhamentos e coberturas em grafos bipartidos. Ele afirma que, em qualquer grafo bipartido, o tamanho do maior emparelhamento é igual ao tamanho da menor cobertura de vértices (JUNGnickel, 2008).

A cobertura de vértices é um conjunto de vértices tal que cada aresta do grafo é incidente a pelo menos um vértice desse conjunto. O teorema de König é uma ferramenta poderosa para resolver problemas de emparelhamento, utilizado nos algoritmos de Hopcroft-Karp e no método Húngaro. A seguir será detalhado um método algorítmico para encontrar a cobertura de vértices mínima a partir de um emparelhamento máximo.

O método é definido pelos seguintes passos (JUNGnickel, 2008):

1. Identifica-se o conjunto de vértices livres (não saturados por M) na partição esquerda U .
2. A partir desses vértices, inicia-se uma travessia no grafo (utilizando Busca em Largura ou Profundidade) com regras estritas de alternância: transições do conjunto U para V devem ocorrer exclusivamente através de arestas que **não** pertencem ao emparelhamento ($E \setminus M$), enquanto as transições de V de volta para U devem utilizar obrigatoriamente as arestas do emparelhamento (M).
3. Registra-se em um conjunto Z todos os vértices que foram alcançados durante essa busca, tanto da partição U quanto da partição V .
4. A Cobertura Mínima de Vértices C é construída selecionando-se os vértices de U que **não** foram visitados e os vértices de V que **foram** visitados. Matematicamente, a cobertura é dada por $C = (U \setminus Z) \cup (V \cap Z)$.

Essa extração algorítmica possui complexidade linear em relação ao tamanho do grafo, $O(V + E)$, visto que requer apenas uma travessia simples após o cálculo do emparelhamento. Sua implementação é uma sub-rotina fundamental para métodos exatos de problemas mais complexos, como a atualização de limiares no Método Dual para o problema de atribuição gargalo (CORMEN et al., 2009).

3.1.2.4 Teorema de Hall

O Teorema de Hall, frequentemente referido como Teorema do Casamento de Hall, é outro resultado estrutural para grafos bipartidos. Enquanto o teorema de König determina a cardinalidade do emparelhamento máximo, o teorema de Hall estabelece a condição necessária e suficiente para a existência de um emparelhamento que cubra integralmente um dos subconjuntos da partição (SCHRIJVER, 2004).

Para um grafo bipartido $G = (U \cup V, E)$, o teorema afirma que existe um emparelhamento cobrindo todo o conjunto U se, e somente se, para qualquer subconjunto $S \subseteq U$, o tamanho de sua vizinhança $N(S)$ (o conjunto de vértices em V adjacentes a pelo menos um vértice em S) for maior ou igual ao tamanho de S . Matematicamente, exige-se que $|N(S)| \geq |S|$ para todo $S \subseteq U$ (JUNGnickel, 2008). Essa propriedade, conhecida como Condição de Hall, é essencial para provar matematicamente a viabilidade de atribuições e identificar gargalos estruturais que impedem a formação de um emparelhamento perfeito, relacionando-se intimamente com os conceitos de cortes mínimos em redes de fluxo.

3.1.2.5 Teorema de Gallai e Conjunto Independente Máximo

Um conjunto independente em um grafo é um subconjunto de vértices no qual não existem duas extremidades adjacentes, ou seja, nenhuma aresta conecta dois vértices desse conjunto. O problema de encontrar o Conjunto Independente Máximo (*Maximum Independent Set* - MIS) é classicamente conhecido por pertencer à classe NP-Difícil para grafos gerais (GAREY; JOHNSON, 1990). No entanto, quando o grafo é restrito à classe dos grafos bipartidos, o problema pode ser resolvido em tempo polinomial graças à sua profunda relação com os emparelhamentos e coberturas.

A base dessa resolução é o Teorema de Gallai, proposto em 1959. O teorema estabelece que, para qualquer grafo $G = (V, E)$ que não possua vértices isolados, a soma do tamanho da Cobertura Mínima de Vértices (MVC) com o tamanho do Conjunto Independente Máximo (MIS) é sempre igual ao número total de vértices do grafo (SCHRIJVER, 2004).

Matematicamente:

$$|MVC| + |MIS| = |V| \quad (10)$$

Pelo Teorema de König, detalhado anteriormente, sabemos que em grafos bipartidos o tamanho da Cobertura Mínima de Vértices é exatamente igual ao tamanho do Emparelhamento Máximo ($|MVC| = |M|$). Consequentemente, o tamanho do Conjunto Independente Máximo pode ser deduzido diretamente do emparelhamento: $|MIS| = |V| - |M|$ (JUNGNICKEL, 2008).

Além da equivalência de cardinalidade, o Teorema de Gallai também fornece a dualidade estrutural: o Conjunto Independente Máximo é exatamente o complemento da Cobertura Mínima de Vértices. Portanto, para construir algoritmicamente o Conjunto Independente Máximo em um grafo bipartido, basta executar o seguinte procedimento:

1. Calcula-se o Emparelhamento Máximo utilizando algoritmos como o de Hopcroft-Karp.
2. Extrai-se a Cobertura Mínima de Vértices C através do método de busca por caminhos alternantes a partir dos vértices livres, definido na seção 3.1.2.3.
3. O Conjunto Independente Máximo I será composto por todos os vértices do grafo que não pertencem à cobertura. Ou seja, $I = V \setminus C$.

3.1.3 Algoritmos exatos

Por ser em um ambiente mais restrito, o problema de emparelhamento de cardinalidade máxima tem diversas soluções em tempo polinomial. A seguir listadas algumas delas:

3.1.3.1 Algoritmo do caminho aumentante

O algoritmo de caminho aumentante se baseia em um lema proposto por Claude Berge, que afirma que um grafo G é máximo se e somente se não existe nenhum caminho aumentante em G . Este algoritmo é uma implementação direta deste lema, onde se busca repetidamente por caminhos aumentantes e se aumenta o emparelhamento até que nenhum caminho aumentante possa ser encontrado (LAWLER, 1976).

Começamos com um emparelhamento vazio $M = \emptyset$. Escolhemos um vértice livre u no lado esquerdo do grafo bipartido e tentamos encontrar um caminho aumentante P que começa em u e termina em um vértice livre no lado direito do grafo, respeitando a regra da alternância entre arestas em M e arestas fora de M . Se um caminho aumentante for encontrado, atualizamos o emparelhamento M invertendo as arestas ao longo do caminho P . Repetimos esse processo até que não seja possível encontrar mais caminhos aumentantes. O emparelhamento resultante será o emparelhamento de cardinalidade máxima (HALIM; HALIM, 2013).

Em seguida o algoritmo em pseudo-código:

Algorithm 6: Algoritmo de caminhos aumentantes (MCBM) (HALIM; HALIM, 2013)

(1) **Global:** *match* (vetor de emparelhamento), *vis* (vetor de visitados), *AdjList*

```
(2) Procedure Aug(l)
(3)   if vis[l] = 1 then
(4)     return 0
(5)   end
(6)   vis[l]  $\leftarrow$  1
(7)   for each r  $\in$  AdjList[l] do
(8)     if match[r] = -1 or Aug(match[r]) then
(9)       match[r]  $\leftarrow$  l
(10)      return 1 [comment: found 1 matching]
(11)    end
(12)  end
(13)  return 0 [comment: no matching]
```

```
(14) Procedure MCBM_Algorithm(n)
(15)   MCBM  $\leftarrow$  0
(16)   match  $\leftarrow$  -1 (initialize for all V)
(17)   for l  $\leftarrow$  0 to n - 1 do
(18)     vis  $\leftarrow$  0 (reset before each recursion)
(19)     MCBM  $\leftarrow$  MCBM + Aug(l)
(20)   end
(21)   return MCBM
```

Como o algoritmo repete a busca por caminhos aumentantes para cada vértice do lado esquerdo do grafo, o tempo de execução total do algoritmo é $O(VE)$, onde V é o número de vértices e E é o número de arestas no grafo bipartido (HALIM; HALIM, 2013).

3.1.3.2 Redução ao problema de fluxo máximo

O problema de emparelhamento de cardinalidade máxima em grafos bipartidos pode ser eficientemente resolvido através de uma redução ao problema de fluxo máximo em redes. A ideia central é construir uma rede de fluxo a partir do grafo bipartido original, onde cada aresta do grafo bipartido é convertida em uma aresta com capacidade unitária na rede de fluxo. (LAWLER, 1976)

Primeiro, adicionamos um vértice fonte s e um vértice sumidouro t à rede. Conectamos o vértice fonte s a todos os vértices do conjunto esquerdo do grafo bipartido com arestas de capacidade 1. Em seguida, conectamos todos os vértices do conjunto direito do grafo bipartido ao vértice sumidouro t , também com arestas de capacidade 1. As arestas entre os conjuntos esquerdo e direito do grafo bipartido são mantidas na rede de fluxo, cada uma com capacidade 1 (HALIM; HALIM, 2013).

Com isso, temos agora um grafo de fluxo onde o objetivo é encontrar o fluxo máximo do vértice fonte s para o vértice sumidouro t . O valor do fluxo máximo encontrado nesta rede corresponde ao tamanho do emparelhamento máximo no grafo bipartido original. (LAWLER, 1976). Para encontrar o fluxo máximo, podemos utilizar algoritmos clássicos como o de Edmonds-Karp.

3.1.3.3 Algoritmo de Edmonds-Karp

O algoritmo de **Edmonds-Karp** é o principal método para resolver esse tipo de problema. Ele é uma especialização do método de Ford-Fulkerson descrito na seção 2.4.2.3 que utiliza uma busca em largura (BFS) para encontrar sempre o caminho aumentante mais curto em número de arestas. Tem complexidade de tempo $O(VE^2)$:

Algorithm 7: Algoritmo de Edmonds-Karp (HALIM; HALIM, 2013)

(1) **Global:** res (matriz de capacidade residual), mf , f , s , t , p (vetor de pais da BFS)

```
(2) Procedure Augment( $v$ ,  $minEdge$ )
(3)   if  $v = s$  then
(4)      $f \leftarrow minEdge$ 
(5)     return
(6)   else
(7)     if  $p[v] \neq -1$  then
(8)       Augment( $p[v]$ ,  $\min(minEdge, res_{p[v],v})$ )
(9)        $res_{p[v],v} \leftarrow res_{p[v],v} - f$ 
(10)       $res_{v,p[v]} \leftarrow res_{v,p[v]} + f$ 
(11)     end
(12)   end

(13) Procedure EdmondsKarp( $s$ ,  $t$ )
(14)    $mf \leftarrow 0$ 
(15)   while true do
(16)      $f \leftarrow 0$ 
(17)      $dist \leftarrow \infty$ ;  $dist[s] \leftarrow 0$ 
(18)      $Q \leftarrow \{s\}$ ;  $p \leftarrow \text{nil}$  (init vector with -1)
(19)     while  $Q \neq \emptyset$  do
(20)        $u \leftarrow Q.\text{front}()$ ;  $Q.\text{pop}()$ 
(21)       if  $u = t$  then
(22)         break (stop BFS)
(23)       end
(24)       for each  $v \in V$  do
(25)         if  $res_{u,v} > 0$  and  $dist[v] = \infty$  then
(26)            $dist[v] \leftarrow dist[u] + 1$ 
(27)            $Q.\text{push}(v)$ 
(28)            $p[v] \leftarrow u$ 
(29)         end
(30)       end
(31)     end
(32)     Augment( $t$ ,  $\infty$ ); [comment: find min edge weight  $f$  in path]
(33)     if  $f = 0$  then
(34)       break (terminate)
(35)     end
(36)      $mf \leftarrow mf + f$ 
(37)   end
(38)   return  $mf$ 
```

3.1.3.4 Algoritmo de Dinic

Outra opção para resolver o problema de fluxo máximo é o algoritmo de Dinic, que é mais eficiente em muitos casos práticos, especialmente em grafos densos. O algoritmo de Dinic utiliza uma combinação de buscas em largura (BFS) para construir níveis na rede residual e buscas em profundidade (DFS) para encontrar caminhos aumentantes dentro desses níveis. O tempo de execução do algoritmo de Dinic é $O(E\sqrt{V})$ para grafos gerais, tornando-o uma escolha preferida para muitos problemas de fluxo máximo (HALIM; HALIM, 2013).

Este trabalho não tem uma implementação do algoritmo de Dinic. Ao invés disso, será apresentado o algoritmo de Hopcroft-Karp, que é uma variação especializada do algoritmo de Dinic para o problema de

emparelhamento em grafos bipartidos, oferecendo uma solução mais eficiente para este caso específico.

3.1.3.5 Algoritmo de Hopcroft-Karp

O algoritmo de Hopcroft-Karp é um algoritmo eficiente para encontrar o emparelhamento máximo em grafos bipartidos. Ele melhora o desempenho do algoritmo de caminhos aumentantes ao encontrar múltiplos caminhos aumentantes em cada iteração, em vez de apenas um. O tempo de execução do algoritmo de Hopcroft-Karp é $O(E\sqrt{V})$, tornando-o significativamente mais rápido do que o algoritmo de caminhos aumentantes simples, especialmente em grafos grandes (HALIM; HALIM, 2013).

O algoritmo consiste em duas fases principais: a fase de construção de níveis e a fase de busca de caminhos aumentantes. Na fase de construção de níveis, uma busca em largura (BFS) é realizada a partir dos vértices livres no lado esquerdo do grafo bipartido para construir uma camada de níveis que ajuda a identificar os caminhos aumentantes mais curtos. Na fase de busca de caminhos aumentantes, uma busca em profundidade (DFS) é realizada para encontrar todos os caminhos aumentantes possíveis dentro da camada de níveis construída na fase anterior. Esses caminhos são então usados para aumentar o emparelhamento (HALIM; HALIM, 2013).

A seguir, o pseudo-código do algoritmo de Hopcroft-Karp:

Algorithm 8: Algoritmo de Hopcroft-Karp (BURKARD; DELL'AMICO; MARTELLO, 2009)

```
(1) let  $G = (U, V; E)$  be a bipartite graph with initial (possibly empty) matching  $M$ ;  
(2) let  $U_0$  contain all unmatched vertices of  $U$ ;  
(3) let  $V_0$  contain all unmatched vertices of  $V$ ;  
(4) while  $U_0 \neq \emptyset$  do  
(5)   Construct_layered_graph;  
(6)   Find_set_ΔM;  
(7)    $M := M \oplus \Delta M$ ;  
(8)   update sets  $U_0, V_0$  of unmatched vertices  
(9) end
```

(10) **Procedure** *Construct_layered_graph*

```
(11)    $L_0 := U_0, k^* := k := 0$ ;  
(12)   while  $L_k \neq \emptyset$  do  
(13)     for each  $i \in L_k$  do  
(14)        $N(i) := \{j : [i, j] \in E \setminus M, j \notin L_1 \cup L_3 \cup \dots \cup L_{k-1}\}$ ;  
(15)     end  
(16)      $L_{k+1} := \bigcup_{i \in L_k} N(i)$ ;  
(17)     if  $L_{k+1} = \emptyset$  then  
(18)       stop [comment:  $M$  is a maximum matching]  
(19)     end  
(20)     if  $L_{k+1} \cap V_0 \neq \emptyset$  then  
(21)        $k^* := k + 1$ ;  
(22)        $L_{k+2} := \emptyset$   
(23)     else  
(24)        $L_{k+2} := \{\bar{i} : [\bar{i}, j] \in M, j \in L_{k+1}\}$ ;  
(25)     end  
(26)      $k := k + 2$   
(27)   end
```

(28) **Procedure** *Find_set_ΔM*

```
(29)   [comment: find a maximal set  $\Delta M$  of disjoint augmenting paths]  
(30)   delete all vertices in  $L_{k^*} \setminus V_0$ ;  
(31)   mark all remaining vertices as unscanned;  
(32)    $k := 1$ ; [comment: path counter]  
(33)   while  $L_0 \neq \emptyset$  do  
(34)     choose  $x_0 := i \in L_0$  and delete it in  $L_0$ ;  
(35)      $\ell := 0$ ;  
(36)     while  $\ell \geq 0$  do  
(37)       while  $x_\ell$  has an unscanned neighbor in  $L_{\ell+1}$  do  
(38)         choose unscanned neighbor  $x_{\ell+1}$ ;  
(39)         mark  $x_{\ell+1}$  as scanned;  
(40)          $\ell := \ell + 1$ ;  
(41)         if  $\ell = k^*$  then  
(42)            $P_k := (x_0, x_1, \dots, x_{k^*})$ ;  
(43)            $k := k + 1$   
(44)         end  
(45)       end  
(46)       if  $\ell < k^*$  then  
(47)          $\ell := \ell - 1$   
(48)       else  
(49)          $\ell := -1$   
(50)       end  
(51)     end  
(52)   end  
(53)   return  $\Delta M := (P_1, P_2, \dots, P_{k-1})$ 
```

3.1.4 Heurísticas

Por mais que o algoritmo de Hopcroft-Karp descrito em 8 seja considerado relativamente eficiente, com complexidade $O(E\sqrt{V})$, ele ainda não é tão viável para instâncias muito grandes do problema de emparelhamento de cardinalidade máxima. Por isso, foram propostos alguns métodos aproximados (heurísticas) com o objetivo de resolver o problema com complexidade linear $O(E)$.

3.1.4.1 Heurística gulosa simples

Um método que itera sobre as arestas do grafo em ordem arbitrária. Se a aresta (u, v) conecta dois vértices livres, adicione essa aresta ao emparelhamento e remova os vértices u e v . Tem complexidade de tempo linear $O(E)$ e garante um emparelhamento maximal, que conforme visto na seção 3.1.2.1, é um emparelhamento ao qual não é possível adicionar mais arestas, mas que não é necessariamente o de maior cardinalidade. A solução também garante um emparelhamento de pelo menos $1/2$ (metade) da cardinalidade máxima (VAZIRANI, 2001)

3.1.4.2 Heurística de Karp-Sipser

Heurística descrita por Karp e Sipser (1981) para grafos esparsos que toma decisões com base na topologia do grafo ao invés de decisões aleatórias, tornando essas decisões mais seguras.

O algoritmo funciona reduzindo dinamicamente o grafo $G = (V, E)$ através da aplicação repetida de duas regras, nesta ordem de prioridade:

1. **Redução de folhas de grau 1:** Se existir algum vértice v no grafo atual com **grau 1** (apenas um vizinho u), a aresta (u, v) é selecionada imediatamente para o emparelhamento. Isso é seguro pois, se u é o único vizinho de v , ele também é a única opção para emparelhar v . Se isso não for feito, v ficará isolado.
2. **Escolha Aleatória:** Se **não** existirem vértices de grau 1 (ou seja, todos os vértices têm grau ≥ 2), o algoritmo escolhe uma aresta (u, v) aleatoriamente, adiciona ao emparelhamento e remove u e v do grafo.

Em grafos esparsos, isso tende a quebrar ciclos e formar novas folhas (vértices de grau 1), permitindo que o algoritmo volte a usar a regra 1. Porém, em grafos densos, essa escolha aleatória pode comprometer a precisão da solução.

Para grafos esparsos, a regra 2 é raramente aplicada, pois a remoção de vértices na regra 1 frequentemente cria novas folhas, provocando um efeito cascata, fazendo com que a maior parte do grafo seja resolvida de maneira ótima. A complexidade do algoritmo é linear ($O(E)$).

Tabela 1: Algoritmos para emparelhamento de cardinalidade máxima em grafos bipartidos

Algoritmo	Complexidade de tempo	Tipo	Descrição
Caminhos aumentantes	$O(VE)$	Exato	Busca iterativa (DFS/BFS) por caminhos alternantes entre vértices livres, invertendo arestas para aumentar a cardinalidade.
Edmonds-Karp	$O(VE^2)$	Exato	Implementação de Ford-Fulkerson que usa BFS para encontrar sempre o caminho aumentante mais curto (em nº de arestas) na rede residual.
Dinic	$O(E\sqrt{V})$	Exato	Algoritmo de fluxo que constrói grafos de níveis (BFS) e satura múltiplos caminhos simultaneamente via fluxo de bloqueio (DFS).
Hopcroft-Karp	$O(E\sqrt{V})$	Exato	Busca múltiplos caminhos aumentantes disjuntos por fase usando BFS e DFS.
Gulosa simples	$O(E)$	Heurística	Itera sobre arestas arbitrariamente, selecionando aquelas que conectam dois vértices livres.
Karp-Sipser	$O(E)$	Heurística	Prioriza remoção de vértices de grau 1; usa escolha aleatória quando não há folhas.

3.2 Problema de atribuição (Assignment Problem)

3.2.1 Descrição do problema

O problema de atribuição, também conhecido como problema do emparelhamento ponderado, consiste em encontrar uma combinação ótima de atribuições entre dois conjuntos disjuntos, minimizando o custo total associado a essas atribuições. Exemplo: Considere N trabalhadores e N tarefas, onde cada trabalhador pode ser designado a exatamente uma tarefa, e cada tarefa deve ser atribuída a exatamente um trabalhador. O custo de atribuir o trabalhador i à tarefa j é representado por uma matriz de custos $W = [w_{ij}]$ (LAWLER, 1976). O objetivo é encontrar um conjunto de atribuições que minimize o custo total.

3.2.2 Propriedades

3.2.3 Algoritmos exatos

3.2.3.1 Método Húngaro

O método Húngaro é um algoritmo eficiente para resolver o problema de atribuição em tempo polinomial. Ele foi desenvolvido por Harold Kuhn em 1955 e é baseado no trabalho de Dénes Kőnig e Jenő Egerváry sobre emparelhamentos em grafos bipartidos (JUNGnickel, 2008).

O método se baseia em manter um conjunto de potenciais para os vértices dos dois conjuntos do grafo bipartido, sendo u_i o potencial do vértice i no conjunto esquerdo e v_j o potencial do vértice j no conjunto direito. A regra que o algoritmo mantém é que para cada aresta (i, j) , a soma dos potenciais deve ser maior ou igual ao custo da aresta, ou seja, $u_i + v_j \geq w_{ij}$.

Cria-se um subgrafo de igualdade $H_{u,v}$ contendo apenas as arestas onde a soma dos potenciais é

igual ao custo da aresta, ou seja, $u_i + v_j = w_{ij}$. O algoritmo então tenta encontrar um emparelhamento máximo neste subgrafo de igualdade. Se o emparelhamento encontrado cobre todos os vértices do conjunto esquerdo, então ele é ótimo para o problema de atribuição original. Caso contrário, o algoritmo ajusta os potenciais para criar novas arestas de igualdade e repete o processo até encontrar um emparelhamento máximo que cubra todos os vértices do conjunto esquerdo (JUNGnickEL, 2008).

Em seguida o pseudo-código do método Húngaro:

Algorithm 9: Algoritmo Húngaro (JUNGnickEL, 2008)

```

(1) Procedure HUNGARIAN( $n, w; \text{mate}$ )
(2)   for  $v \in V$  do  $\text{mate}(v) \leftarrow 0$ 
(3)   for  $i = 1$  to  $n$  do  $u_i \leftarrow \max\{w_{ij} : j = 1, \dots, n\}; v_i \leftarrow 0$ 
(4)    $nrex \leftarrow n$ 
(5)   while  $nrex \neq 0$  do
(6)     for  $i = 1$  to  $n$  do  $m(i) \leftarrow \text{false}; p(i) \leftarrow 0; \delta_i \leftarrow \infty$ 
(7)      $\text{aug} \leftarrow \text{false}; Q \leftarrow \{i \in S : \text{mate}(i) = 0\}$ 
(8)     repeat
(9)       remove an arbitrary vertex  $i$  from  $Q$ ;  $m(i) \leftarrow \text{true}; j \leftarrow 1$ 
(10)      while  $\text{aug} = \text{false}$  and  $j \leq n$  do
(11)        if  $\text{mate}(i) \neq j'$  then
(12)          if  $u_i + v_j - w_{ij} < \delta_j$  then
(13)             $\delta_j \leftarrow u_i + v_j - w_{ij}; p(j) \leftarrow i$ 
(14)            if  $\delta_j = 0$  then
(15)              if  $\text{mate}(j') = 0$  then
(16)                AUGMENT( $\text{mate}, p, j'; \text{mate}$ )
(17)                 $\text{aug} \leftarrow \text{true}; nrex \leftarrow nrex - 1$ 
(18)              else
(19)                 $Q \leftarrow Q \cup \{\text{mate}(j')\}$ 
(20)              end
(21)            end
(22)          end
(23)        end
(24)         $j \leftarrow j + 1$ 
(25)      end
(26)      if  $\text{aug} = \text{false}$  and  $Q = \emptyset$  then
(27)         $J \leftarrow \{i \in S : m(i) = \text{true}\}; K \leftarrow \{j' \in T : \delta_j = 0\}$ 
(28)         $\delta \leftarrow \min\{\delta_j : j' \in T \setminus K\}$ 
(29)        for  $i \in J$  do  $u_i \leftarrow u_i - \delta$ 
(30)        for  $j' \in K$  do  $v_j \leftarrow v_j + \delta$ 
(31)        for  $j' \in T \setminus K$  do  $\delta_j \leftarrow \delta_j - \delta$ 
(32)         $X \leftarrow \{j' \in T \setminus K : \delta_j = 0\}$ 
(33)        if  $\text{mate}(j') \neq 0$  for all  $j' \in X$  then
(34)          for  $j' \in X$  do  $Q \leftarrow Q \cup \{\text{mate}(j')\}$ 
(35)        else
(36)          choose  $j' \in X$  with  $\text{mate}(j') = 0$ 
(37)          AUGMENT( $\text{mate}, p, j'; \text{mate}$ )
(38)           $\text{aug} \leftarrow \text{true}; nrex \leftarrow nrex - 1$ 
(39)        end
(40)      end
(41)    until  $\text{aug} = \text{true}$ 
(42)  end

```

Algorithm 10: Método AUGMENT (JUNGnickel, 2008)

```
(1) Procedure AUGMENT(mate, p, j'; mate)  
(2)   repeat  
(3)      $i \leftarrow p(j); \text{mate}(j') \leftarrow i; \text{next} \leftarrow \text{mate}(i); \text{mate}(i) \leftarrow j'$   
(4)     if  $\text{next} \neq 0$  then  
(5)        $j' \leftarrow \text{next}$   
(6)     end  
(7)   until  $\text{next} = 0$ 
```

3.2.3.2 Jonker-Volgenant

O algoritmo de Jonker-Volgenant é uma evolução otimizada para a resolução do problema de atribuição linear, proposto por Roy Jonker e Anton Volgenant em 1987. Ele foi desenvolvido para superar o desempenho prático do método Húngaro, especialmente em grafos densos, combinando a teoria de dualidade com estratégias de inicialização e busca mais eficientes (JONKER; VOLGENANT, 1987).

Assim como o método Húngaro, este algoritmo baseia-se na manutenção de potenciais duais (u_i e v_j) e respeita as condições de folga complementar. No entanto, sua principal distinção conceitual é o uso da estratégia de Caminho Aumentante Mais Curto (Shortest Augmenting Path). Ao invés de construir emparelhamentos máximos em fases distintas, o algoritmo foca em encontrar o caminho de custo mínimo que conecta uma linha não atribuída a uma coluna livre.

O processo inicia com heurísticas avançadas (conhecidas como redução de colunas e transferência de redução) para resolver rapidamente as atribuições triviais. Para os vértices restantes, o algoritmo realiza uma busca similar ao algoritmo de Dijkstra: ele explora o grafo para encontrar o caminho aumentante mais curto, atualizando os potenciais duais simultaneamente durante a busca. Isso garante que, a cada iteração, o emparelhamento seja aumentado pelo menor custo possível até que a solução ótima completa seja atingida.

A implementação deste algoritmo é bastante complexa, e portanto não será detalhada aqui. No entanto, sua eficiência prática o torna uma escolha preferida para muitos problemas de atribuição em aplicações reais, especialmente quando comparado ao método Húngaro tradicional (JUNGnickel, 2008).

3.2.3.3 Redução para problema de fluxo de custo mínimo

Similarmente ao que foi feito para o problema de emparelhamento de cardinalidade máxima, o problema de atribuição pode ser resolvido através de uma redução ao problema de fluxo de custo mínimo. Assim como para o problema anterior, essa redução é feita criando dois novos vértices: um vértice fonte s e um vértice sorvedouro t . Em seguida, são adicionadas arestas do vértice fonte s para cada vértice de um dos conjuntos do grafo bipartido, com capacidade 1 e custo 0. Também são adicionadas arestas de cada vértice do outro conjunto para o vértice sorvedouro t , também com capacidade 1 e custo 0. Finalmente, as arestas do grafo bipartido original são adicionadas com capacidade 1 e custo igual ao custo de atribuição correspondente.

Para resolver problemas de fluxo podemos utilizar algoritmos como o de caminhos de custo mínimo sucessivos (Successive Shortest Paths) ou o algoritmo de cancelamento de ciclos (Cycle canceling) (SCHRIJVER, 2004).

O primeiro algoritmo, o de caminhos de custo mínimo sucessivos, foi inicialmente proposto por Jewell, Busacker e Gowen e é uma adaptação do algoritmo de Ford-Fulkerson para incorporar o custo das arestas. Em poucas palavras, ele encontra o caminho de s para t de custo mínimo, envia o máximo fluxo possível ao longo desse caminho, e repete esse processo até que não seja mais possível aumentar o fluxo sem violar as capacidades das arestas (SCHRIJVER, 2004).

Algorithm 11: Algoritmo de caminhos de custo mínimo sucessivos (JUNGNICKEL, 2008)

```
(1) Procedure OPTFLOW( $G, c, s, t, \gamma, v; f, sol$ )
(2)   for  $e \in E$  do  $f(e) \leftarrow 0$ 
(3)    $sol \leftarrow true, val \leftarrow 0$ 
(4)   while  $sol = true$  and  $val < v$  do
(5)     construct the auxiliary network  $N' = (G', c', s, t)$  with cost function  $\gamma'$ 
(6)     if  $t$  is not accessible from  $s$  in  $G'$  then
(7)        $sol \leftarrow false$ 
(8)     else
(9)       determine a shortest path  $P$  from  $s$  to  $t$  in  $(G', \gamma')$ 
(10)       $\delta \leftarrow \min\{c'(e) : e \in P\}; \delta' \leftarrow \min(\delta, v - val); val \leftarrow val + \delta'$ 
(11)      augment  $f$  along  $P$  by  $\delta'$ 
(12)    end
(13)  end
```

A complexidade do algoritmo é dependente do método utilizado para encontrar o caminho P . A implementação padrão utilizaria o algoritmo de Dijkstra, que tem uma complexidade de $O(E + V \log V)$ em uma implementação com filas de prioridade, onde V é o número de vértices e E o número de arestas. Porém, como o grafo residual pode conter arestas com custos negativos, essa implementação não funcionaria corretamente. Para contornar esse problema, temos duas opções principais:

- **Utilizar Bellman-Ford:** A solução mais simples e direta é utilizar, ao invés do algoritmo de Dijkstra, o algoritmo de Bellman-Ford para encontrar o caminho de custo mínimo P . O Bellman-Ford é mais lento, com uma complexidade de $O(VE)$, mas lida corretamente com arestas de custo negativo.
- **Utilizar a técnica de Potenciais:** Permite que utilizemos o algoritmo de Dijkstra mesmo na presença de arestas de custo negativo.

A cada iteração do loop, encontra-se o caminho de custo mínimo P utilizando Dijkstra com os custos reduzidos. Após encontrar o caminho, os potenciais são atualizados para todos os vértices v alcançáveis a partir de s no grafo residual, ajustando-os conforme a distância mínima encontrada pelo Dijkstra, de acordo com a fórmula $h(v) \leftarrow h(v) + d(s, v)$, onde $d(s, v)$ é a distância mínima de s até v no grafo residual com custos reduzidos.

Abaixo uma adaptação do algoritmo 11 utilizando a técnica de potenciais:

Algorithm 12: Adaptação do algoritmo 11 utilizando Dijkstra com técnica de potenciais

```
(1) Procedure OPTFLOW_DIKJSTRA( $G, c, s, t, \gamma, v; f, sol$ )
(2)   for  $e \in E$  do  $f(e) \leftarrow 0$ 
(3)   for  $x \in V$  do  $\pi(x) \leftarrow 0$ 
(4)    $sol \leftarrow true, val \leftarrow 0$ 
(5)   while  $sol = true$  and  $val < v$  do
(6)     construct the auxiliary network  $N' = (G', c', s, t)$ 
(7)     for  $e = (u, v) \in E(G')$  do
(8)       define reduced cost:  $w(e) \leftarrow \gamma(e) + \pi(u) - \pi(v)$ 
(9)     end
(10)    Run Dijkstra on  $N'$  using weights  $w$  to find shortest path distances  $d(\cdot)$  from  $s$ 
(11)    if  $t$  is not accessible from  $s$  (i.e.,  $d(t) = \infty$ ) then
(12)       $sol \leftarrow false$ 
(13)    else
(14)      for  $x \in V$  such that  $d(x) < \infty$  do  $\pi(x) \leftarrow \pi(x) + d(x)$ 
(15)      Identify shortest path  $P$  from  $s$  to  $t$  based on  $d(\cdot)$ 
(16)       $\delta \leftarrow \min\{c'(e) : e \in P\}; \delta' \leftarrow \min(\delta, v - val); val \leftarrow val + \delta'$ 
(17)      augment  $f$  along  $P$  by  $\delta'$ 
(18)    end
(19)  end
```

A complexidade do algoritmo utilizando Dijkstra com a técnica de potenciais é $O(V(E + V \log V))$, onde V é o número de vértices e E o número de arestas do grafo. Isso ocorre porque, em cada iteração do loop principal, executamos o algoritmo de Dijkstra, que tem complexidade $O(E + V \log V)$, e o número máximo de iterações é limitado por V , o número de vértices no grafo bipartido.

3.2.4 Heurísticas

Assim como no problema de emparelhamento de cardinalidade máxima, as soluções exatas, apesar de apresentarem tempo polinomial, são inviáveis para instâncias muito grandes. A seguir algumas heurísticas que objetivam resolver o problema de atribuição em tempo até mesmo linear ($O(E)$).

3.2.4.1 Heurística gulosa ordenada

Similar à heurística gulosa simples descrita na seção 3.1.4.1, com a diferença de que a ordem das arestas não é mais arbitrária, e sim decrescente por peso. Tem a mesma garantia de metade do peso ótimo, mas tem complexidade $O(E \log E)$ por conta da ordenação.

Tabela 2: Algoritmos para problema de atribuição

Algoritmo	Complexidade de tempo	Tipo	Descrição
Método Húngaro	$O(n^3)$	Exato	Método primal-dual que mantém folga complementar para custo mínimo em bipartidos.
Jonker-Volgenant	$O(n^3)$	Exato	Algoritmo primal-dual eficiente que combina redução de custos inicial e busca de caminhos aumentantes com atualização otimizada de duais.
Custo mínimo (Bellman-Ford)	$O(V^2E)$	Exato	Método de caminhos sucessivos que usa Bellman-Ford para encontrar caminhos na rede residual, suportando custos negativos iniciais.
Custo mínimo (Dijkstra)	$O(V(E + V \log V))$	Exato	Utiliza potenciais de vértices para manter custos reduzidos não-negativos, permitindo o uso do eficiente Dijkstra para aumentos sucessivos.
Gulosa ordenada	$O(E \log E)$	Heurística	Ordena as arestas por peso decrescente e seleciona iterativamente as disponíveis.

3.3 Problema de atribuição gargalo

3.3.1 Descrição do problema

O problema de atribuição gargalo, também conhecido como **Problema de Emparelhamento Min-Max** ou **Bottleneck Assignment problem**, é uma variação do problema de atribuição tradicional. O objetivo deste problema é encontrar, em um grafo bipartido ponderado, um emparelhamento de cardinalidade máxima (maior número possível de arestas) no qual o mínimo dos pesos das arestas do emparelhamento seja maximizado (LAWLER, 1976).

Por exemplo. Considere N trabalhadores e N estações de trabalho. w_{ij} representa a eficiência do trabalhador i na estação de trabalho j . A eficiência total da produção é limitada pela eficiência do trabalhador menos eficiente. O objetivo é atribuir trabalhadores às estações de trabalho de forma a maximizar a eficiência mínima entre todas as atribuições. (LAWLER, 1976).

3.3.2 Soluções exatas

3.3.2.1 Métodos de threshold

Métodos de threshold funcionam alternando entre duas fases. A primeira fase consiste em selecionar um valor limite, chamado de **threshold**, descrito por c^* . Na segunda fase, constrói-se um grafo bipartido com todas as arestas cujo peso é menor ou igual a c^* . Em seguida, verifica-se se existe um emparelhamento perfeito nesse grafo. O menor valor de c^* que permite um emparelhamento perfeito é a solução ótima para o problema de atribuição gargalo (BURKARD; DELL'AMICO; MARTELLO, 2009).

Para selecionar o valor limite c^* , podemos utilizar uma busca binária entre o menor e o maior peso das arestas do grafo original. A cada iteração, ajustamos o valor de c^* com base na existência ou não de um

emparelhamento perfeito no grafo construído. Esse processo continua até que o valor ótimo seja encontrado. Burkard, Dell'Amico e Martello (2009), que descreve esse método, utiliza um algoritmo baseado em matrizes para decidir se um emparelhamento é perfeito ou não, porém podemos utilizar qualquer algoritmo clássico de emparelhamento em grafos bipartidos, como os definidos na seção 3.1.3, como por exemplo o algoritmo de Hopcroft-Karp. Também segundo o autor, o algoritmo tem uma complexidade de tempo de $O(V^{2.5}/\sqrt{\log V})$.

Lawler (1976) menciona um método de threshold para solução do problema de atribuição gargalo, porém a definição de threshold dele é levemente diferente, referindo-se ao valor dinâmico do rótulo de um vértice durante busca de caminhos. O algoritmo que ele descreve se assemelha mais aos algoritmos de caminhos aumentantes, que serão discutidos na seção 3.3.2.3.

Algorithm 13: Threshold algorithm for the LBAP (BURKARD; DELL'AMICO; MARTELLO, 2009)

```

(1) let  $C = (c_{ij})$  be a given  $n \times n$  cost matrix;
(2)  $c_0^* := \min_{ij} \{c_{ij}\}, c_1^* := \max_{ij} \{c_{ij}\}$ 
(3) if  $c_0^* = c_1^*$  then
(4)    $z := c_0^*$  [comment: any permutation of  $\{1, 2, \dots, n\}$  is optimal]
(5) else
(6)   while  $C^* = \{c_{ij} : c_0^* < c_{ij} < c_1^*\} \neq \emptyset$  do
(7)     [comment: find the median,  $c^*$ , of  $C^*$ ;]
(8)      $c^* := \min\{c \in C^* : |\{c_{ij} \in C^* : c_{ij} \leq c\}| \geq |C^*|/2\}$ ;
(9)     Feasibility_check( $c^*, c_0^*, c_1^*$ )
(10)  end
(11)  if Feasibility_check has not yet been executed for  $c_0^*$  then
(12)    Feasibility_check( $c_0^*, c_0^*, c_1^*$ )
(13)  end
(14)  find a perfect matching in the current bipartite graph  $G[c_1^*]$ 
(15)   $z := c_1^*$  [comment: value of the optimal matching]
(16) end

(17) Procedure Feasibility_check( $c^*, c_0^*, c_1^*$ )
(18)   define the current graph  $G[c^*]$ 
(19)   if  $G[c^*]$  contains a perfect matching then
(20)      $c_1^* := c^*$ 
(21)   else
(22)      $c_0^* := c^*$ 
(23)   end

```

3.3.2.2 Método dual

Assim como os métodos de threshold, o método dual também define um valor limite c^* . No entanto, ao invés de 'chutar' um valor usando busca binária, este método define o valor inicial de c^* como sendo o menor valor possível que ele pode assumir. Olhando para a matriz de custos, esse valor é o máximo entre os mínimos de cada linha e cada coluna da matriz:

$$c^* = \max \left\{ \max_i (\min_j c_{ij}), \max_j (\min_i c_{kj}) \right\} \quad (11)$$

Com o limite definido, verificamos se é possível encontrar um emparelhamento perfeito no grafo bipartido formado pelas arestas cujo peso é menor ou igual a c^* , usando os mesmos algoritmos de antes. Se um emparelhamento perfeito for encontrado, então c^* é a solução ótima. Caso contrário, é necessário aumentar o valor de c^* , e para isso nos baseamos no teorema de Kőnig, definido na seção 3.1.2.3.

Sabemos que todas as arestas $c_{ij} > c^*$ estão conectadas a um conjunto de linhas I e um conjunto de colunas J . Essas linhas e colunas "cobrem" todas as arestas do grafo atual. Para aumentar o valor de c^* , precisamos adicionar uma nova aresta que não esteja coberta por esses conjuntos. Procuramos o menor peso entre as arestas não cobertas, ou seja, aquelas que não pertencem às linhas em I nem às colunas em J . Esse valor se torna o novo c^* :

$$Novoc* = \min_{i \notin I, j \notin J} c_{ij} \quad (12)$$

A partir daqui, o processo se repete. Com o novo valor de c^* e a nova aresta adicionada ao grafo, verificamos novamente a existência de um emparelhamento perfeito. Esse ciclo continua até que um emparelhamento perfeito seja encontrado, momento em que o valor atual de c^* será a solução ótima para o problema de atribuição gargalo.

Algorithm 14: Dual_LBAP. Dual algorithm for the LBAP (BURKARD; DELL'AMICO; MARTELLO, 2009).

```

(1) let  $C = (c_{ij})$  be a given  $n \times n$  cost matrix;
(2)  $c^* := \max_{k=1,2,\dots,n} (\min_{i=1,2,\dots,n} c_{ik}, \min_{j=1,2,\dots,n} c_{kj})$ 
(3)  $M := \emptyset$ 
(4) while  $|M| < n$  do
(5)   define the bipartite graph  $G[c^*]$ 
(6)   find a maximum matching  $M$  in  $G[c^*]$ 
(7)   if  $|M| < n$  then
(8)     let  $I \subseteq U$  and  $J \subseteq V$  be vertex sets in a minimum vertex cover of  $G[c^*]$ 
(9)      $c^* := \min_{i \notin I, j \notin J} c_{ij}$ 
(10)  end
(11) end

```

3.3.2.3 Método de caminhos aumentantes

Ao contrário do método dual, que ajusta um limiar global para todo o grafo, o método de caminhos aumentantes é construtivo. Ele inicia com um emparelhamento vazio e busca aumentar sua cardinalidade iterativamente, adicionando um par de vértices de cada vez. O objetivo central em cada passo é encontrar um caminho aumentante P que conecte uma linha livre a uma coluna livre, de tal forma que a capacidade desse caminho seja mínima. A capacidade aqui é definida pelo peso da aresta mais cara contida no caminho:

$$cap(P) = \max_{(i,j) \in P} c_{ij} \quad (13)$$

Para encontrar tal caminho, utiliza-se uma adaptação do algoritmo de Dijkstra. Em vez de somar os pesos das arestas, mantemos para cada vértice um valor de rótulo que representa o "gargalo" mínimo necessário para alcançá-lo. Durante a busca, ao tentar estender o caminho de um nó u (com rótulo d_u) para um vizinho v através da aresta (u, v) , o custo não é somado, mas sim comparado. O novo custo potencial para atingir v é o máximo entre o gargalo já existente até u e o peso da nova aresta:

$$NovoCusto_v = \max(d_u, c_{uv}) \quad (14)$$

O algoritmo seleciona, a cada passo, o nó não visitado com o menor rótulo atual, garantindo uma exploração gulosa que minimiza o gargalo. Assim que uma coluna livre é alcançada por essa busca, o caminho aumentante é identificado e o emparelhamento é expandido, invertendo-se as arestas ao longo do caminho. Esse processo se repete (reiniciando as distâncias) até que um emparelhamento perfeito seja obtido. A solução do problema será determinada pela maior capacidade encontrada entre todos os caminhos aumentantes utilizados na construção.

Algorithm 15: LBAP usando caminhos aumentantes (BURKARD; DELL'AMICO; MARTELLO, 2009)

```
(1) let  $G = (U, V; E)$  be a bipartite graph with edge lengths  $c_{ij}$  for  $[i, j] \in E$ ;  
(2) find a lower bound  $c^*$  for the optimum objective function value;  
(3) [comment: e.g.,  $c^* := \max(\max_{i \in U} \min_{j \in V} c_{ij}, \max_{j \in V} \min_{i \in U} c_{ij})$ ]  
(4) find a maximum matching  $M$  in the graph  $G[c^*]$  having an edge  $[i, j]$  iff  $c_{ij} \leq c^*$ ;  
(5) if  $|M| = |U|$  then  
(6) | stop [comment:  $M$  is an optimum matching of cost  $c^*$ ]  
(7) else  
(8) | let  $L$  be the set of unmatched vertices of  $U$   
(9) end  
(10) while  $L$  is nonempty do  
(11) | choose an arbitrary vertex  $i \in L$ ;  
(12) |  $L := L \setminus \{i\}$ ;  
(13) | Dijkstra( $i$ ); [comment: the procedure returns a path  $P$  starting in  $i$ ]  
(14) | if  $P \neq \text{nil}$  then  
(15) | |  $M := M \oplus P$ ;  
(16) | |  $c^* := \max(c^*, \ell(P))$   
(17) | end  
(18) end  
(19) [comment:  $M$  is a maximum matching with minimum cost  $c^*$ .]
```

Algorithm 16: Dijkstra modificado para caminhos aumentantes em LBAP (BURKARD; DELL'AMICO; MARTELLO, 2009)

```
(1) Procedure Dijkstra(i)
(2)   label all vertices  $j \in V$  by  $(\alpha(j), \beta(j)) := (\infty, \text{nil})$ ;
(3)    $R := V$ ; [comment:  $R$  contains the unscanned vertices of  $V$ ]
(4)    $\bar{\alpha}(i) := c^*$ ,  $P := \text{nil}$ ;
(5)   Label(i);
(6)   while  $R \neq \emptyset$  do
(7)     find a vertex  $j_1 \in R$  with minimum  $\alpha(j_1)$ ;
(8)     if  $\alpha(j_1) = \infty$  then
(9)        $R := \emptyset$ 
(10)    else
(11)      if  $j_1$  is unmatched then
(12)        find the path  $P$  induced by the vertex sequence  $(i, \dots, \bar{\beta}(\beta(j_1)), \beta(j_1), j_1)$ ;
(13)         $\ell(P) := \alpha(j_1)$ ;
(14)         $R := \emptyset$ 
(15)      else
(16)        let  $[i_1, j_1]$  be the matching edge;
(17)        label  $i_1$  with  $(\bar{\alpha}(i_1), \bar{\beta}(i_1)) = (\alpha(j_1), j_1)$ ;
(18)         $R := R \setminus \{j_1\}$ ;
(19)        Label( $i_1$ );
(20)      end
(21)    end
(22)  end

(23) Procedure Label(i)
(24)   for each neighbor  $j \in R$  of i do
(25)     if  $\alpha(j) > \max(\bar{\alpha}(i), c_{ij})$  then
(26)        $\alpha(j) := \max(\bar{\alpha}(i), c_{ij})$ ;
(27)        $\beta(j) := i$ 
(28)     end
(29)  end
```

3.3.3 Heurísticas

3.3.3.1 Heurística Construtiva Gulosa

Diferente do problema de atribuição, onde o guloso simples funciona bem, no problema de gargalo o guloso deve ser adaptado para evitar criar "bicos de garrafa" muito altos no final do processo.

O algoritmo seleciona arestas iterativamente. Para cada vértice livre, ele verifica não apenas a aresta de menor peso incidente, mas também o "custo de oportunidade" de não escolhê-la.

Se não escolhermos a aresta (u, v) de peso 10, a próxima melhor opção para u tem peso 100? Se sim, a prioridade de (u, v) aumenta drasticamente (MARTELLO; TOTH, 1987).

Tabela 3: Algoritmos para problema de atribuição gargalo

Algoritmo	Complexidade de tempo	Tipo	Descrição
Threshold	$O(V^{2.5}/\sqrt{\log V})$	Exato	Aplica busca binária sobre os pesos das arestas, testando a existência de emparelhamento perfeito no subgrafo restrito ao limiar.
Método Dual	$O(K \cdot E\sqrt{V})$	Exato	Expandem um limiar inferior iterativamente baseado no Teorema de König, adicionando apenas arestas necessárias para cobrir componentes.
Caminhos aumentantes	$O(EV)$	Exato	Abordagem construtiva que busca caminhos aumentantes minimizando a aresta de peso máximo (gargalo) no trajeto (variação de Dijkstra).
Construtiva Gulosa	$O(E \log E)$	Heurística	Constrói a solução selecionando arestas de baixo peso, usando critérios locais ou de "arrependimento" para evitar gargalos futuros.

3.4 Problema do emparelhamento estável

3.4.1 Descrição do problema

O problema do emparelhamento estável, também conhecido como *Stable Marriage Problem* (SMP), é um problema clássico na teoria dos grafos e na ciência da computação, proposto inicialmente por Gale e Shapley em 1962 (KLEINBERG; TARDOS, 2005). Ele envolve a combinação de dois conjuntos distintos de elementos e, apesar de semelhante aos problemas de emparelhamento em grafos bipartidos estudados anteriormente, possui características e objetivos diferentes.

Imagine dois conjuntos distintos de mesmo tamanho, N homens e N mulheres. Cada indivíduo em ambos os conjuntos tem uma lista de preferências ordenadas para todos os membros do outro conjunto. O objetivo do SMP é encontrar um emparelhamento entre homens e mulheres de tal forma que não existam dois indivíduos, um homem e uma mulher, que prefeririam estar juntos em vez de com seus parceiros atuais. Se tal par existir, o emparelhamento é considerado instável.

O problema pode ser resolvido utilizando o algoritmo de Gale-Shapley, que usa um processo iterativo de propostas e rejeições para garantir que o emparelhamento final seja estável.

3.4.2 Propriedades

- **Estabilidade:** Um emparelhamento é estável se não houver dois indivíduos que prefeririam estar juntos em vez de com seus parceiros atuais. A estabilidade é a característica central do problema (LAWLER, 1976).
- **Existência de solução:** Gale e Shapley provaram que sempre existe pelo menos um emparelhamento estável para qualquer conjunto de preferências (AHUJA; MAGNANTI; ORLIN, 1993).
- **Otimidade para quem propõe:** O emparelhamento resultante do algoritmo de Gale-Shapley é ótimo para o conjunto que faz as propostas (por exemplo, os homens), significando que cada indivíduo nesse conjunto recebe o melhor parceiro possível dentro dos emparelhamentos estáveis (AHUJA; MAGNANTI; ORLIN, 1993).
- **Pessimismo para quem recebe propostas:** Por outro lado, o emparelhamento é o pior possível para o conjunto que recebe as propostas (por exemplo, as mulheres), significando que cada indivíduo nesse

conjunto recebe o pior parceiro possível dentro dos emparelhamentos estáveis (AHUJA; MAGNANTI; ORLIN, 1993).

- **Não-unicidade:** Pode haver múltiplos emparelhamentos estáveis para um dado conjunto de preferências, dependendo das listas de preferências dos indivíduos (KLEINBERG; TARDOS, 2005).

3.4.3 Algoritmo de Gale-Shapley

A solução clássica para o problema do emparelhamento estável é o algoritmo de Gale-Shapley, também conhecido como o algoritmo de casamento estável. O algoritmo funciona sob a lógica de propostas e rejeições, onde um dos conjuntos (por exemplo, os homens) faz propostas às mulheres com base em suas listas de preferências.

O algoritmo pode ser descrito de forma simples da seguinte maneira:

Enquanto existir um homem h que ainda não propôs a todas as mulheres em sua lista:

1. O homem h propõe à primeira mulher m da sua lista de preferências a quem ele ainda não propôs.
2. A decisão da mulher m é tomada com base em suas preferências:
 - Se m não estiver comprometida, ela aceita a proposta de h . Eles ficam "noivos".
 - Se m já estiver comprometida com outro homem h' , ela compara h e h' . Se m preferir h a h' , ela rejeita h' (que fica livre) e aceita a proposta de h . Caso contrário, ela rejeita h (que continua livre e tenta a próxima da sua lista).

O algoritmo continua até que todos os homens estejam comprometidos. O resultado final é um emparelhamento estável, onde não existem pares instáveis (KLEINBERG; TARDOS, 2005).

Segue um exemplo em pseudocódigo do algoritmo:

Algorithm 17: Algoritmo de Gale-Shapley para o problema do emparelhamento estável (KLEINBERG; TARDOS, 2005)

```
(1) Initially all  $m \in M$  and  $w \in W$  are free
(2) while there is a man  $m$  who is free and hasn't proposed to every woman do
(3)   Choose such a man  $m$ 
(4)   Let  $w$  be the highest-ranked woman in  $m$ 's preference list to whom  $m$  has not yet proposed
(5)   if  $w$  is free then
(6)      $(m, w)$  become engaged
(7)   else
(8)      $w$  is currently engaged to  $m'$ 
(9)     if  $w$  prefers  $m'$  to  $m$  then
(10)       $m$  remains free
(11)     else
(12)       $(m, w)$  become engaged
(13)       $m'$  becomes free
(14)     end
(15)   end
(16) end
(17) Return the set  $S$  of engaged pairs
```

4 Problemas de emparelhamento em grafos gerais

Ao contrário dos problemas em grafos bipartidos, problemas de emparelhamento em grafos gerais podem ser consideravelmente mais complexos. Alguns dos exemplos apresentados nesta seção são resolvíveis por algoritmo exatos em tempo polinomial, apesar de apresentarem uma complexidade de tempo considerada alta. Outros problemas pertencem à classe NP, o que significa que não foi proposto um algoritmo que pudesse resolver esses problemas em tempo polinomial.

4.1 Emparelhamento de cardinalidade máxima

4.1.1 Descrição

A definição do problema de emparelhamento de cardinalidade máxima é, fundamentalmente, a mesma da sua contraparte bipartida, descrita na seção 3.1. No entanto, a solução deste problema é significativamente mais complexa que a versão bipartida, mesmo ainda sendo em tempo polinomial.

4.1.2 Propriedades

4.1.2.1 Ciclos ímpares

Previamente, na seção 3.1.2.2, vimos a definição de caminhos aumentantes, que vieram a ser fundamentais para a solução de grande parte dos problemas de emparelhamento em grafos bipartidos. Em grafos gerais, a base da solução ainda é a mesma, se baseando no lema de Berge, descrito por Jungnickel (2008) como:

Um emparelhamento M em um grafo G é máximo se, e somente se, não existe nenhum caminho aumentante em G relativo a M .

Em grafos bipartidos, ciclos sempre têm tamanho par. Isso garante que, ao realizar uma busca (BFS ou DFS) a partir de um vértice livre, nunca encontraremos uma aresta que conecte dois vértices que estejam à mesma distância ("paridade") da raiz na árvore de busca alternante (AHUJA; MAGNANTI; ORLIN, 1993).

No entanto, em grafos gerais, a presença de ciclos de comprimento ímpar quebra essa lógica. Schrijver (2004) explica que, ao explorar o grafo, o algoritmo pode encontrar uma aresta conectando dois vértices que possuem paridade "par" em relação à raiz da busca. Essa estrutura forma um **ciclo ímpar** que "confunde" a identificação de um caminho aumentante simples, pois um vértice poderia ser alcançado por dois caminhos alternantes de paridades diferentes.

4.1.2.2 Flor (Blossom)

A solução para lidar com ciclos ímpares foi proposta por Edmonds (1965), e consiste em uma estrutura denominada **Blossom**.

Uma Blossom B é definida como um ciclo de comprimento ímpar $2k + 1$, onde k arestas pertencem ao emparelhamento M , de tal forma que existe apenas um vértice v_B no ciclo (a base da flor) que não é coberto por uma aresta de M dentro do próprio ciclo. A base v_B é conectada ao resto do grafo por um caminho alternante de comprimento par (o **caule** ou *stem*).

Edmonds provou que uma *blossom* pode ser contraída em um único vértice, com base no seguinte teorema:

Existe um caminho aumentante no grafo original G se, e somente se, existe um caminho aumentante no grafo contraído $G' = G/B$, onde a flor B foi reduzida a um único vértice. (SCHRIJVER, 2004)

4.1.3 O algoritmo de Edmonds

Baseando-se na propriedade de Blossom e no teorema da contração, Lawler (1976) descreve o algoritmo para encontrar o emparelhamento máximo em grafos gerais da seguinte forma:

1. **Busca:** Inicie uma busca (geralmente BFS) a partir dos vértices livres para encontrar um caminho aumentante, construindo uma Floresta de Árvores Alternantes.
2. **Deteção:** Se a busca encontrar uma aresta que fecha um ciclo ímpar, uma **blossom** foi identificada.
3. **Contração:** Contraia todos os vértices da **blossom** em um único super-vértice e modifique o grafo temporariamente.

4. **Recursão:** Continue a busca no grafo contraído.
5. **Expansão:** Se um caminho aumentante for encontrado no grafo contraído passando pelo super-vértice, "abra" (expand) a flor novamente para traduzir esse caminho para o grafo original. O caminho dentro da flor será roteado de forma a manter a alternância correta.
6. **Aumento:** Use o caminho encontrado para aumentar o emparelhamento através da diferença simétrica (inversão das arestas).

Schrijver (2004) detalha que, a depender da forma como o algoritmo é implementado, principalmente no que trata da contração, a complexidade do algoritmo ingênuo pode chegar a $O(V^3)$. No entanto, melhorias subsequentes nesse algoritmo culminaram em uma implementação em $O(E\sqrt{V})$, descrita por Micali e Vazirani (1980). No entanto, por conta da complexidade de implementação da solução mais rápida, a maioria das implementações práticas do algoritmo utilizam variantes com complexidade próxima a $O(V^3)$.

Algorithm 18: Procedimiento MAXMATCH (JUNGNICKEL, 2008)

```
(1) Procedure MAXMATCH( $G; mate, nrex$ )
(2)   INMATCH( $G; mate, nrex$ )
(3)    $r \leftarrow 0$ 
(4)   while  $nrex \geq 2$  and  $r < n$  do
(5)      $r \leftarrow r + 1$ 
(6)     if  $mate(r) = 0$  then
(7)        $Q \leftarrow \emptyset, aug \leftarrow \text{false}, m \leftarrow 0$ 
(8)       for  $v \in V$  do
(9)          $p(v) \leftarrow 0, d(v) \leftarrow -1, a(v) \leftarrow \text{true}$ 
(10)         $CA(v) \leftarrow A_v$ 
(11)       end
(12)        $d(r) \leftarrow 0$ ; append  $r$  to  $Q$ 
(13)       while  $aug = \text{false}$  and  $Q \neq \emptyset$  do
(14)         remove the first vertex  $x$  of  $Q$ 
(15)         if  $a(x) = \text{true}$  then
(16)            $cont \leftarrow \text{false}$ 
(17)           for  $y \in CA(x)$  do
(18)              $u(y) \leftarrow \text{false}$ 
(19)           end
(20)           repeat
(21)             choose  $y \in CA(x)$  with  $u(y) = \text{false}$ ;  $u(y) \leftarrow \text{true}$ 
(22)             if  $a(y) = \text{true}$  then
(23)               if  $d(y) \equiv 0 \pmod{2}$  then
(24)                  $m \leftarrow m + 1$ 
(25)                 BLOSSOM( $x, y; B(m), w(m)$ )
(26)                 CONTRACT( $B(m), m, w$ )
(27)               end
(28)               else if  $d(y) = -1$  then
(29)                 if  $mate(y) = 0$  then
(30)                   AUGMENT( $x, y$ )
(31)                 else
(32)                    $z \leftarrow mate(y)$ 
(33)                    $p(y) \leftarrow x; d(y) \leftarrow d(x) + 1$ 
(34)                    $p(z) \leftarrow y; d(z) \leftarrow d(y) + 1$ 
(35)                   insert  $z$  with priority  $d(z)$  into  $Q$ 
(36)                 end
(37)               end
(38)             end
(39)             until  $u(y) = \text{true}$  for all  $y \in CA(v)$  or  $aug = \text{true}$  or  $cont = \text{true}$ 
(40)           end
(41)         end
(42)       end
(43)   end
```

Algorithm 19: Algoritmo de BLOSSOM (JUNGNICKEL, 2008)

```
(1) Procedure BLOSSOM( $x, y; B, w$ )
(2)    $P \leftarrow \{x\}; P' \leftarrow \{y\}; u \leftarrow x; v \leftarrow y$ 
(3)   repeat
(4)      $P \leftarrow P \cup \{p(u)\}; u \leftarrow p(u)$ 
(5)   until  $p(u) = r$ 
(6)   repeat
(7)      $P' \leftarrow P' \cup \{p(v)\}; v \leftarrow p(v)$ 
(8)   until  $v = r$ 
(9)    $S \leftarrow P \cap P'$ 
(10)  let  $w$  be the element of  $S$  for which  $d(w) \geq d(z)$  for all  $z \in S$ 
(11)   $B \leftarrow ((P \cup P') \setminus S) \cup \{w\}$ 
```

Algorithm 20: Procedimento CONTRACT (JUNGNICKEL, 2008)

```
(1) Procedure CONTRACT( $B, m, w$ )
(2)    $b \leftarrow n + m; a(b) \leftarrow \text{true}$ 
(3)    $p(b) \leftarrow p(w); d(b) \leftarrow d(w); \text{mate}(b) \leftarrow \text{mate}(w)$ 
(4)   insert  $b$  into  $Q$  with priority  $d(b)$ 
(5)    $CA(b) \leftarrow \bigcup_{z \in B} CA(z)$ 
(6)   for  $z \in CA(b)$  do
(7)      $CA(z) \leftarrow CA(z) \cup \{b\}$ 
(8)   end
(9)   for  $z \in B$  do
(10)     $a(z) \leftarrow \text{false}$ 
(11)  end
(12)  for  $z \in CA(b)$  do
(13)    if  $a(z) = \text{true}$  and  $p(z) \in B$  then
(14)       $d(z) \leftarrow d(b) + 1; p(z) \leftarrow b$ 
(15)       $d(\text{mate}(z)) \leftarrow d(z) + 1$ 
(16)    end
(17)  end
(18)   $\text{cont} \leftarrow \text{true}$ 
```

Algorithm 21: Procedimento AUGMENT (JUNGnickEL, 2008)

```
(1) Procedure AUGMENT( $x, y$ )
(2)    $P \leftarrow \{y, x\}; v \leftarrow x$ 
(3)   while  $p(v) \neq 0$  do
(4)      $P \leftarrow P \cup \{p(v)\}; v \leftarrow p(v)$ 
(5)   end
(6)   while there exists  $b \in P$  with  $b > n$  do
(7)     choose the largest  $b \in P$  with  $b > n$ 
(8)      $B \leftarrow B(b - n); w \leftarrow w(b - n); z \leftarrow \text{mate}(w)$ 
(9)     let  $q$  be the neighbor of  $b$  on  $P$  which is different from  $z$ 
(10)    choose some  $q' \in B \cap CA(q)$ 
(11)    determine the alternating path  $B'$  of even length in  $B$  from  $w$  to  $q'$ 
(12)    replace  $b$  by  $w$  in  $P$ 
(13)    insert  $B'$  into  $P$  between  $w$  and  $q$ 
(14)  end
(15)   $u \leftarrow y; v \leftarrow x$ 
(16)  while  $v \neq r$  do
(17)     $z \leftarrow \text{mate}(v); \text{mate}(v) \leftarrow u; \text{mate}(u) \leftarrow v$ 
(18)     $u \leftarrow z$ ; let  $v$  be the successor of  $z$  on  $P$ 
(19)  end
(20)   $\text{mate}(v) \leftarrow u; \text{mate}(u) \leftarrow v$ 
(21)   $nrex \leftarrow nrex - 2; aug \leftarrow \text{true}$ 
```

4.1.3.1 Teorema de Tutte-Berge

O teorema de Tutte-Berge, apesar de não aparecer explicitamente na descrição do algoritmo, é fundamental para sua corretude, pois ele fornece um certificado de otimalidade. Por exemplo, digamos que a etapa de busca do algoritmo de Blossom não encontrou nenhum caminho aumentante. Como sabemos que o emparelhamento atual é máximo? Para descobrir isso, utilizamos a fórmula de Tutte-Berge, descrita por Jungnickel (2008) da seguinte forma:

$$v(G) = \frac{1}{2} \min_{U \subseteq V} (|V| + |U| - \text{odd}(G - U)) \quad (15)$$

Onde $v(G)$ é o tamanho do emparelhamento máximo, e $\text{odd}(G - U)$ é o número de componentes conexos com número ímpar de vértices no grafo resultante após a remoção de U . Se o grafo possui um emparelhamento perfeito, o mínimo desta equação é $|V|/2$, o que ocorre se e somente se $\text{odd}(G - U) \leq |U|$ para todo U .

4.1.4 Heurísticas

Algumas das heurísticas que resolvem este problema são as mesmas que vimos na seção 3.1, como a Heurística Gulosa Simples e a Heurística de Karp-Sipser, que também funcionam para grafos gerais. Mas, além dessas, existem outras heurísticas que podem ser utilizadas neste problema.

4.1.4.1 Algoritmo de crescimento de caminho (Path Growing)

Uma variação inteligente do método guloso, descrita por Drake e Hougardy (2003), que usa DFS e tenta evitar a "miopia" de escolher uma aresta isolada.

1. Escolha um vértice livre inicial v .
2. Inicie uma busca em profundidade (DFS) para construir um caminho simples o mais longo possível.

3. Ao longo desse caminho, selecione arestas alternadas para o emparelhamento (a 1ª sim, a 2ª não, a 3ª sim...).
4. Remova os vértices usados e repita.

Ao contrário do guloso simples (que escolhe arestas desconexas), o Path Growing tende a cobrir cadeias longas de vértices, o que é estruturalmente vantajoso.

Tabela 4: Algoritmos para problema de emparelhamento de cardinalidade máxima em grafos gerais

Algoritmo	Complexidade de tempo	Tipo	Descrição
Edmonds	$O(V^3)$	Exato	Algoritmo exato (Blossom) que contrai ciclos ímpares temporariamente em super-vértices para identificar caminhos aumentantes.
Micali e Vazirani	$O(E\sqrt{V})$	Exato	Variação otimizada do algoritmo de Edmonds que utiliza estruturas de dados avançadas para reduzir drasticamente a complexidade.
Gulosa simples	$O(E)$	Heurística	Itera sobre arestas arbitrariamente, selecionando aquelas que conectam dois vértices livres.
Karp-Sipser	$O(E)$	Heurística	Prioriza remoção de vértices de grau 1; usa escolha aleatória quando não há folhas.
Crescimento de caminho	$O(E)$	Heurística	Heurística linear que constrói caminhos simples via DFS e seleciona arestas alternadas para garantir um emparelhamento maximal.

4.2 Emparelhamento ponderado máximo

Enquanto o problema de cardinalidade máxima busca o maior número de arestas, o problema do **Emparelhamento de Peso Máximo** (Maximum Weight Matching) introduz uma função de peso $w : E \rightarrow \mathbb{R}$ nas arestas, e o objetivo torna-se encontrar um emparelhamento M que maximize $\sum_{e \in M} w(e)$. Este problema é a generalização natural do Problema da Atribuição para grafos não-bipartidos, descrito em 3.2.

A complexidade deste problema em grafos gerais decorre, assim como no problema de emparelhamento de cardinalidade máxima descrito em 4.1, da presença de ciclos ímpares. Se tentarmos modelar o problema usando Programação Linear (PL) apenas com restrições de grau ($\sum x_e \leq 1$), a solução ótima do sistema relaxado pode ser fracionária (ex: $x_e = 0.5$ para as três arestas de um triângulo), o que não corresponde a um emparelhamento válido.

4.2.1 Formulação poliédrica e Restrições de Blossom

Conforme detalhado por Schrijver (2004), para descrever o **Poliedro do Emparelhamento** (Matching Polytope) em grafos gerais, Edmonds (1965) provou que é necessário adicionar uma família exponencial de restrições conhecidas como **Desigualdades de Blossom** (ou restrições de subconjuntos ímpares):

$$\sum_{e \in E(U)} x_e \leq \frac{|U| - 1}{2}, \quad \forall U \subseteq V, |U| \text{ ímpar}, |U| \geq 3 \quad (16)$$

Onde $E(U)$ é o conjunto de arestas com ambas as extremidades em U . Essas inequações garantem que, em qualquer subconjunto ímpar de vértices, o número de arestas selecionadas não exceda a capacidade máxima inteira possível.

4.2.2 A abordagem Primal-Dual

Diferente do caso de cardinalidade, onde buscamos apenas caminhos aumentantes, o algoritmo para o caso ponderado é um método **Primal-Dual**. Ele é uma generalização do Método Húngaro, mas adaptado para lidar com as blossoms.

Segundo Lawler (1976), o algoritmo mantém variáveis duais não apenas para os vértices (y_v), mas também para cada subconjunto ímpar de vértices (z_B) que forma uma blossom contraída. A condição de otimalidade baseia-se na folga complementar. Uma aresta (u, v) é considerada "admissível" ou "justa" (*tight*) se a soma dos duais correspondentes iguala o peso da aresta. Simplificadamente:

$$y_u + y_v + \sum_{B:(u,v) \in B} z_B = w_{uv} \quad (17)$$

O algoritmo opera iterativamente em dois estágios, descritos por Jungnickel (2008) e Schrijver (2004):

1. **Estágio Primal (Busca):** Restringindo-se apenas às arestas admissíveis (onde a equação acima é satisfeita), o algoritmo busca um caminho aumentante usando a técnica de contração de blossoms de Edmonds. Se encontrado, o emparelhamento é aumentado.
2. **Estágio Dual (Ajuste de Preços):** Se a busca falha em encontrar um caminho aumentante no grafo de arestas admissíveis, o algoritmo não termina (ao contrário do caso de cardinalidade). Em vez disso, ele realiza uma atualização das variáveis duais y e z .
 - O algoritmo calcula um valor δ (delta), que é a menor "folga" entre as arestas que conectam a árvore de busca atual a vértices externos.
 - Os duais dos vértices na árvore são ajustados por $\pm\delta$ e os duais das blossoms (z_B) também são ajustados.
 - Esse ajuste tem o efeito de "destravar" novas arestas (tornando-as admissíveis) ou permitir a expansão/contração de blossoms, possibilitando que a busca prossiga.

4.2.3 O algoritmo de Edmonds Ponderado

O procedimento resultante é frequentemente chamado de **Algoritmo de Blossom Ponderado** ou simplesmente Algoritmo de Edmonds para Emparelhamento Ponderado.

A implementação original de Edmonds era polinomial, $O(V^4)$. Lawler (1976) apresentou uma implementação $O(V^3)$, que por muito tempo foi o padrão em livros didáticos.

A variante $O(V^3)$ descrita por Lawler (1976) para o emparelhamento ponderado utiliza uma abordagem primal-dual rigorosa. O algoritmo mantém um conjunto de arestas admissíveis (custo reduzido nulo) baseadas em variáveis duais de vértices (y_i) e de subconjuntos ímpares (z_B). A cada iteração onde a busca por caminhos aumentantes falha, o algoritmo calcula um escalar crítico δ baseado nas folgas das arestas incidentes à árvore alternante atual (conjunto S). A atualização dual subsequente ($y_i \leftarrow y_i \pm \delta$, $z_B \leftarrow z_B \pm 2\delta$) garante o surgimento de novas arestas admissíveis ou a expansão de **blossoms** com dual nulo, mantendo a complexidade cúbica através do gerenciamento eficiente dos valores de folga mínima (**slack**) para vértices fora da árvore.

Lawler também destaca que a manipulação das variáveis duais das blossoms (z_B) é o que permite ao algoritmo "pagar" o custo de usar arestas dentro de estruturas cíclicas ímpares. Quando uma blossom é formada durante a busca, ela recebe um valor dual $z_B > 0$; quando ela precisa ser desfeita (expandida) para encontrar um caminho, seu valor dual retorna a zero.

4.2.4 Otimizações

Desenvolvimentos posteriores por Galil, Micali e Gabow (1986) e Gabow (1990) melhoraram a estrutura de dados para gerenciar a prioridade das atualizações duais e a contração de blossoms, atingindo complexidades próximas a $O(EV \log V)$ ou $O(E\sqrt{V\alpha(E, V)})$ em implementações de escalonamento (SCHRIJVER, 2004).

Apesar de ser polinomial (classe P), a implementação de emparelhamento ponderado em grafos gerais é considerada uma das rotinas mais complexas da otimização combinatória clássica, sendo significativamente mais difícil de implementar corretamente do que algoritmos para grafos bipartidos ou fluxo máximo.

4.2.5 Heurísticas

Aqui também podemos utilizar a mesma heurística que usamos para a versão do problema para grafos bipartidos: a Heurística Gulosa Ordenada, descrita na seção 3.2.4.1. Mas além dessas, temos:

4.2.5.1 Algoritmo de Crescimento de Caminho (Path Growing)

Similar à heurística descrita na seção 4.1.4.1, esta também faz uso de Path Growing para encontrar um emparelhamento. A vantagem desta é que não é necessário ordenação, tornando possível a execução em tempo linear ($O(E)$). Foi descrito por Drake e Hougardy (2003):

1. O algoritmo constrói caminhos simples disjuntos no grafo.
2. Comece em um vértice livre v qualquer. Estenda o caminho escolhendo a aresta de maior peso conectada a v que leve a um vértice ainda não visitado neste caminho.
3. Repita até que o caminho não possa crescer mais.
4. Dado um caminho $P = (e_1, e_2, e_3, \dots, e_k)$, temos dois emparelhamentos possíveis formados por arestas alternadas:
 5. $M_1 = \{e_1, e_3, e_5, \dots\}$ (Arestas ímpares)
 - $M_2 = \{e_2, e_4, e_6, \dots\}$ (Arestas pares)
6. Compare o peso total de M_1 e M_2 . Adicione o conjunto mais pesado à solução final e remova os vértices do grafo.

A diferença para a versão de emparelhamento de cardinalidade máxima é o passo 5, onde os pesos são somados para escolher o melhor conjunto. Garante emparelhamento de pelo menos $1/2$ da cardinalidade máxima (DRAKE; HOUGARDY, 2003).

4.3 Emparelhamento induzido máximo

Diferentemente dos problemas de emparelhamento em grafos gerais vistos até o momento, que pertencem à classe de complexidade P, o problema do Emparelhamento Induzido Máximo (MIM - *Maximum Induced Matching*), frequentemente referido na literatura como **Emparelhamento Forte** (*Strong Matching*), pertence à classe dos problemas NP-difíceis. Apesar de ter uma variação estruturalmente simples quando comparado aos problemas clássicos, esse problema impõe uma restrição topológica severa sobre quais arestas podem coexistir na solução.

4.3.1 Propriedades

Seja $G = (V, E)$ um grafo geral. Um subconjunto de arestas $M \subseteq E$ é um **emparelhamento induzido** se satisfaz duas condições:

1. **Condição de Emparelhamento:** Nenhuma aresta em M compartilha um vértice (são disjuntas par a par).

Tabela 5: Algoritmos para problema de emparelhamento ponderado máximo em grafos gerais

Algoritmo	Complexidade de tempo	Tipo	Descrição
Edmonds	$O(V^3)$	Exato	Método primal-dual que gerencia variáveis duais para vértices e blossoms, ajustando preços para encontrar caminhos no grafo de igualdade.
Edmonds otimizado	$O(EV \log V)$	Exato	Melhoria do Edmonds original através de uma série de otimizações
Gulosa ordenada	$O(E \log E)$	Heurística	Ordena as arestas por peso decrescente e seleciona iterativamente as disponíveis.
Crescimento de caminho	$O(E)$	Heurística	Heurística que estende caminhos pela aresta mais pesada local e seleciona o subconjunto de arestas (par ou ímpar) de maior soma total.

2. **Condição Induzida:** O subgrafo induzido pelos vértices saturados por M , denotado por $G[V(M)]$, contém **apenas** as arestas de M .

Em termos mais simples, se tomarmos duas arestas quaisquer (u, v) e (x, y) pertencentes ao emparelhamento induzido, não pode existir no grafo original nenhuma aresta conectando um vértice do par $\{u, v\}$ a um vértice do par $\{x, y\}$. Isso implica que as arestas do emparelhamento devem estar "topologicamente isoladas" umas das outras.

Cameron (1989) oferece uma caracterização alternativa baseada em distância: um emparelhamento induzido é um conjunto de arestas onde a distância entre quaisquer duas arestas distintas é de pelo menos 2 (ou seja, não há aresta de ligação entre elas).

4.3.2 Complexidade computacional

Diferentemente do emparelhamento clássico (cardinalidade ou ponderado), que possui algoritmos polinomiais eficientes, o problema de encontrar o emparelhamento induzido de cardinalidade máxima é **NP-Difícil**.

Este resultado foi estabelecido no trabalho fundamental de Stockmeyer e Vazirani (1982). Eles demonstraram que o problema permanece NP-Difícil mesmo quando restrito a grafos bipartidos com grau máximo 3. Isso é um fato surpreendente e crucial: a propriedade de ser bipartido, que geralmente torna problemas de emparelhamento fáceis (como visto no Teorema de König), **não** ajuda no caso do emparelhamento induzido.

4.3.3 Redução ao Problema do Conjunto Independente

A intratabilidade do MIM pode ser explicada através de uma transformação de grafos. O problema de encontrar um emparelhamento induzido em G é equivalente a encontrar um **Conjunto Independente Máximo** (Maximum Independent Set - MIS) em um grafo transformado.

A transformação ocorre em dois passos:

1. Construímos o **Grafo de Linha** $L(G)$, onde cada vértice representa uma aresta de G e dois vértices são adjacentes se as arestas correspondentes em G compartilham uma ponta. (Emparelhamento clássico em $G \equiv$ Conjunto Independente em $L(G)$).
2. Construímos o **Quadrado do Grafo de Linha** $L(G)^2$. Neste grafo, conectamos dois vértices se a distância entre eles em $L(G)$ for 1 ou 2.

Encontrar um emparelhamento induzido máximo em G equivale exatamente a encontrar um Conjunto Independente Máximo em $L(G)^2$ (CAMERON, 1989). Como o problema do Conjunto Independente é NP-Difícil para grafos gerais (GAREY; JOHNSON, 1990), essa relação estrutural justifica a dificuldade do MIM.

4.3.4 Abordagens de solução e heurísticas

Dada a natureza NP-Difícil do problema e a ineficácia de métodos exatos para grafos densos ou de grande escala, a literatura concentra-se majoritariamente em algoritmos construtivos gulosos e metaheurísticas.

4.3.4.1 Heurísticas gulosas

Dada a equivalência entre o problema do Emparelhamento Induzido Máximo em G e o Conjunto Independente Máximo no grafo transformado $L(G)^2$, as heurísticas gulosas clássicas da literatura de conjuntos independentes são naturalmente adaptadas para este contexto.

O procedimento geral consiste em selecionar iterativamente uma aresta $e \in E$, adicioná-la à solução e remover sua vizinhança induzida do grafo. As variantes diferem no critério de seleção da aresta:

- **Guloso Aleatório (Random Greedy):** Seleciona a próxima aresta uniformemente ao acaso dentre as disponíveis. Duckworth, Wormald e Zito (2002) analisaram o comportamento assintótico desta abordagem em grafos cúbicos aleatórios, demonstrando que, apesar de sua simplicidade, ela fornece uma linha de base (*baseline*) essencial para a avaliação de métodos mais sofisticados.
- **Guloso de Grau Mínimo (Min-Degree Greedy):** A heurística prioriza a seleção da aresta que possui o **menor grau induzido** (ou seja, a aresta cuja remoção implica a eliminação do menor número de outras arestas candidatas). Esta abordagem é uma adaptação direta da heurística *Min-Degree* (ou *Greedy*) para o problema do Conjunto Independente Máximo. Halldórsson e Radhakrishnan (1994) estabeleceram os fundamentos teóricos para essa estratégia, demonstrando que priorizar vértices de baixo grau fornece garantias de aproximação superiores em grafos esparsos e de grau limitado. No contexto do MIM, essa lógica traduz-se em escolher a aresta $e = (u, v)$ que minimiza a soma dos graus de seus extremos ou o tamanho de sua vizinhança em $L(G)^2$.

4.3.4.2 Metaheurísticas

Para superar os ótimos locais frequentemente encontrados pelos métodos gulosos, abordagens iterativas de busca local têm sido aplicadas.

Fürst, Leichter e Rautenbach (2017) investigaram formalmente o poder da busca local para o Emparelhamento Induzido Máximo. A estratégia analisada consiste em iniciar com um emparelhamento induzido qualquer (ou vazio) e tentar aumentá-lo iterativamente através de melhorias locais simples. Eles focaram na análise de grafos k -regulares e demonstraram que, embora a busca local possa ficar presa em ótimos locais longe da solução global em grafos gerais, ela oferece garantias de desempenho interessantes para classes específicas (como grafos livres de garras ou C_4 -free). O algoritmo de busca local proposto tenta adicionar arestas que não violem a restrição induzida e, se necessário, remover um número pequeno de arestas existentes para acomodar a nova inclusão, um processo análogo às trocas (**k-swaps**) em outros problemas combinatórios.

4.4 Outros problemas

No futuro, serão inclusos neste trabalho outros problemas de emparelhamento em grafos gerais, como o de b-emparelhamento, emparelhamento em matroid, e o Stable Roommates Problem.

Tabela 6: Algoritmos para problema de emparelhamento induzido máximo em grafos gerais

Algoritmo	Complexidade de tempo	Tipo	Descrição
Guloso Aleatório	$O(E)$	Heurística	Seleciona arestas uniformemente ao acaso e remove suas vizinhanças induzidas.
Guloso de grau mínimo	$O(E)$	Heurística	Seleciona a aresta cuja remoção elimina o menor número de arestas vizinhas.

5 Metodologia

Este capítulo descreve o ambiente de testes construído para *implementar e comparar* os algoritmos dos capítulos anteriores. São apresentados a arquitetura do ambiente, a interface padrão de cada problema, a origem e a adaptação de cada algoritmo, os geradores de instância, o protocolo de medição, os critérios de comparação e a máquina utilizada, de modo que os resultados do capítulo seguinte sejam reproduzíveis e as comparações, defensáveis.

5.1 Arquitetura do ambiente de testes

O ambiente é organizado em três camadas, com separação estrita entre código de terceiros e código próprio. Na primeira, cada algoritmo obtido de um repositório público é mantido **intacto**, garantindo que o código medido é exatamente o publicado por seus autores — condição essencial para a validade das comparações e para a análise de eventuais defeitos. Na segunda, um **adaptador** (*wrapper*) por algoritmo traduz sua interface particular para a **interface padrão** do problema, documentando em seu cabeçalho a complexidade, o tipo do método e a fonte de origem. Na terceira, um único **módulo de medição** — responsável por geração de instâncias, cronometragem, verificação e gravação — é compartilhado por todos os problemas, o que garante que todos os algoritmos sejam submetidos ao mesmo protocolo. A separação entre as duas primeiras camadas permite ainda comparar, sob condições idênticas, múltiplas implementações de um mesmo algoritmo obtidas de autores diferentes.

5.2 Interface padrão dos problemas

Cada problema possui uma interface padrão à qual todos os seus algoritmos são adaptados (Tabela 7). É ela que torna a comparação justa: todo algoritmo de um mesmo problema recebe exatamente a mesma instância e produz a saída no mesmo formato, de modo que a única variável entre eles é o próprio método.

Tabela 7: Interface padrão de entrada e saída por problema

Problema	Entrada	Saída
Cardinalidade máxima (bipartido)	vértices de cada lado e lista de arestas	tamanho e emparelhamento
Atribuição linear	matriz de custos $n \times n$	custo total e atribuição
Atribuição gargalo	matriz de custos $n \times n$	custo gargalo e atribuição
Casamento estável	listas de preferência de ambos os lados	emparelhamento
Cardinalidade máxima (geral)	número de vértices e lista de arestas	tamanho e emparelhamento
Peso máximo (geral)	número de vértices e arestas com peso	peso total e emparelhamento
Emparelhamento induzido máximo	número de vértices e lista de arestas	tamanho e emparelhamento

5.3 Geradores de instância

As instâncias são geradas por construtores parametrizados pelo tamanho n e por uma semente fixa, o que as torna determinísticas e reproduzíveis. Para cada problema definiram-se famílias com características distintas, de modo a expor o comportamento dos algoritmos sob diferentes estruturas de entrada: para cardinalidade máxima em grafos bipartidos, grafos esparsos (com e sem emparelhamento perfeito) e densos; para atribuição linear e gargalo, matrizes densas aleatórias, matrizes estruturadas (custo em função da distância entre índices) e matrizes com poucos valores distintos (muitos empates); para casamento estável, preferências aleatórias, correlacionadas (*ranking* de popularidade compartilhado, que gera contenção) e cíclicas; e, para grafos gerais e emparelhamento induzido máximo, grafos aleatórios de densidade controlada, ponderados quando aplicável.

5.4 Protocolo de medição

A medição de tempo é sensível a fatores externos ao próprio método; o protocolo a seguir reduz essas fontes de ruído. Uma **execução de aquecimento** é descartada, por pagar custos não recorrentes (importações, alocação inicial, caches frios); ela serve apenas para aferir o orçamento de tempo e fornecer o resultado usado na verificação de qualidade. O **coletor de lixo é desligado** durante as repetições cronometradas — para que uma coleta não apareça como lentidão do algoritmo — e reativado entre as células. Cada célula é medida em várias repetições, das quais se reporta a **mediana**, robusta a interrupções momentâneas do sistema, ao contrário da média. Todos os algoritmos de um problema recebem **as mesmas instâncias**. Por fim, um **limite de tempo por célula** impede que um único algoritmo defeituoso inviabilize toda a suíte — situação efetivamente observada e discutida no capítulo de resultados: se o aquecimento excede o limite, a célula é marcada como estourada e os tamanhos maiores daquele algoritmo são omitidos.

Registra-se uma limitação deliberada: o limite de tempo é aplicado em torno da execução de aquecimento, não a cada operação. Uma célula patológica é interrompida ao ultrapassar o limite, mas não instantaneamente — escolha que evita o sobrecusto de uma verificação passo a passo na própria região cronometrada.

5.5 Critérios de comparação

Comparar tempo de execução entre implementações em linguagens diferentes é intrinsecamente injusto: parte da diferença reflete a linguagem, não o algoritmo. Para que as comparações sejam válidas, adotaram-se quatro critérios complementares.

Primeiro, as implementações em linguagem interpretada e as de núcleo compilado são apresentadas em **tabelas separadas**, nunca num mesmo ranking de tempo; as de núcleo compilado servem para validar a correteza e indicar a ordem de grandeza do estado da prática. Vale notar que nem toda biblioteca é compilada: algumas bibliotecas maduras usadas como referência são escritas na mesma linguagem interpretada dos demais algoritmos, e nesses casos a comparação de tempo contra elas é legítima. Há ainda uma zona intermediária — algoritmos que são laços na linguagem interpretada operando sobre vetores de uma biblioteca numérica de núcleo compilado; classificam-se como interpretados, com essa característica declarada. Segundo, as tabelas trazem a **complexidade assintótica** de tempo e espaço ao lado do tempo medido, permitindo confrontar o previsto com o observado. Terceiro, para cada algoritmo estima-se o **expoente empírico de crescimento** — a inclinação da reta ajustada ao gráfico do logaritmo do tempo pelo logaritmo do tamanho —, que, ao contrário do tempo absoluto, é **comparável entre linguagens**, pois a diferença de linguagem afeta a constante (a posição da reta), não a inclinação; reporta-se também a qualidade do ajuste.

Nos problemas com apenas algoritmos exatos, a qualidade da solução é idêntica entre eles e a comparação recai sobre o tempo. Nos problemas com heurísticas, cada heurística reporta a **razão** entre a qualidade que encontra e a do algoritmo exato de referência, caracterizando o compromisso entre qualidade e tempo.

5.6 Ambiente de execução e reprodutibilidade

Todos os resultados foram obtidos numa única máquina (Tabela 8); medir tudo no mesmo ambiente é o que torna os tempos comparáveis. Três características dela exigiram cuidados, todos documentados para permitir reprodução. Por ser um **processador híbrido** (núcleos de desempenho e de eficiência, não equivalentes), a execução foi fixada a um núcleo de desempenho, evitando que a migração entre núcleos alterasse o tempo sem mudança no código. Como a **frequência varia** dinamicamente com a carga, o regulador foi fixado no modo de desempenho, com a máquina conectada à energia e sem aplicações concorrentes. E, como a **ordem de iteração de coleções de objetos** em Python é aleatorizada por processo — e um dos algoritmos se mostrou sensível a ela, conforme o capítulo de resultados —, a semente de aleatorização foi fixada, tornando as execuções reprodutíveis.

Tabela 8: Especificação da máquina de medição

Componente	Especificação
Processador	Intel Core 7 150U (10 núcleos físicos, 12 <i>threads</i>)
Topologia	híbrida: 2 núcleos de desempenho e 8 de eficiência
Memória	33 GB
Sistema operacional	Ubuntu 24.04.2 LTS (kernel 7.0.0)
Linguagem	Python 3.12.3
Bibliotecas	NumPy 2.5.2, SciPy 1.18.0, NetworkX 3.6.1, igraph 1.0.0, lap 0.5.13

5.7 Origem, adaptação e verificação dos algoritmos

Em coerência com o objetivo de comparar métodos *presentes na literatura*, a maior parte dos algoritmos foi obtida de implementações públicas, e não reescrita: adaptar código consolidado reduz o risco de erros próprios e permite avaliar a qualidade das implementações efetivamente disponíveis. Conforme a natureza do código de origem, empregaram-se quatro estratégias de adaptação: **(i)** carregamento direto, quando o original é utilizável na linguagem do projeto; **(ii)** encapsulamento, para métodos disponíveis em bibliotecas maduras; **(iii)** reimplementação fiel, quando o original não é utilizável diretamente — por estar em outra linguagem ou versão, ou por conter efeitos colaterais —, seguindo a lógica original com a fonte documentada; e **(iv)** implementação própria a partir da fonte bibliográfica, para as heurísticas e alguns exatos sem implementação pública adequada, algoritmos de descrição curta cuja reimplementação é mais confiável que um repositório de qualidade incerta. A Tabela 9 registra o tipo e a origem de cada algoritmo.

Tabela 9: Proveniência dos algoritmos avaliados

Algoritmo	Tipo	Origem
<i>Cardinalidade máxima — grafos bipartidos</i>		
Caminhos aumentantes	Exato	repositório wchristerson/perfect-matchings
Hopcroft-Karp	Exato	repositório sofiat-olaosebikan/hopcroftkarp
Edmonds-Karp (fluxo)	Exato	repositório Maxflow-Algorithms (reimplementado)
Hopcroft-Karp (NetworkX)	Referência	biblioteca NetworkX (interpretada)
Emparelhamento bipartido (igraph)	Referência	biblioteca igraph (núcleo compilado)
Gulosa	Heurística	implementação própria (CORMEN et al., 2009)
Karp-Sipser	Heurística	implementação própria (KARP; SIPSER, 1981)
<i>Atribuição linear</i>		
Húngaro (munkres)	Exato	repositório bmc/munkres
Húngaro (benchaplin)	Exato	repositório benchaplin/hungarian-algorithm
Húngaro (hunalgorithm)	Exato	repositório pbertoni/HungarianAlgorithm
Húngaro (mayorx)	Exato	repositório mayorx/hungarian-algorithm
Caminhos mínimos sucessivos	Exato	reimplementado a partir de repositório
SciPy	Referência	biblioteca SciPy (núcleo compilado)
Jonker-Volgenant	Referência	biblioteca lap (núcleo compilado)
<i>Atribuição gargalo</i>		
Threshold	Exato	reimplementado (original em JavaScript)
Caminhos aumentantes	Exato	implementação própria (BURKARD; DELL'AMICO; MARTELLO, 2009)
<i>Casamento estável</i>		
Gale-Shapley (orientado a objetos)	Exato	pacote gale-shapley-algorithm
Gale-Shapley (numérico)	Exato	pacote gale-shapley-algorithm
Gale-Shapley (Lattas)	Exato	reimplementado (repositório StableMarriages)
<i>Grafos gerais</i>		
Blossom/Edmonds (cardinalidade)	Exato	repositório adharshkamath/Edmonds-Algorithm
van Rantwijk (peso máximo)	Exato	mwmatching.py de J. van Rantwijk
NetworkX (cardinalidade e peso)	Referência	biblioteca NetworkX (interpretada)
Path Growing	Heurística	implementação própria (DRAKE; HOUGARDY, 2003)
<i>Emparelhamento induzido máximo</i>		
Exato (conjunto independente)	Exato	implementação própria (CAMERON, 1989)
Guloso aleatório	Heurística	implementação própria
Guloso de grau mínimo	Heurística	implementação própria

Os endereços completos constam no cabeçalho de cada adaptador, no código-fonte. Cabe uma ressalva de linhagem: a rotina de emparelhamento de peso máximo em grafos gerais do NetworkX é uma adaptação do mesmo código de van Rantwijk também avaliado de forma independente; compará-las mede o efeito da engenharia de biblioteca sobre um mesmo algoritmo, e não duas abordagens distintas.

Por fim, nenhuma implementação própria ou reimplementada foi incorporada sem **verificação independente**: os métodos exatos foram confrontados com soluções por força bruta (em instâncias pequenas) e com bibliotecas consolidadas; as heurísticas, quanto à validade da solução, a não superarem o ótimo e a respeitarem suas garantias de aproximação. Além disso, os benchmarks já existentes ao início do trabalho foram migrados para o ambiente unificado sob uma salvaguarda de não-regressão: a qualidade de saída de cada um foi registrada antes da migração e exigiu-se que a nova execução a reproduzisse exatamente, de modo que a unificação não alterasse nenhuma conclusão.

6 Resultados e discussão

Este capítulo apresenta e discute os resultados obtidos com o ambiente de testes descrito no capítulo anterior. Cada problema é analisado quanto ao tempo de execução e, quando há heurísticas, quanto à

qualidade da solução. As tabelas de tempo separam as implementações em linguagem interpretada das de núcleo compilado, conforme justificado na Seção 5.5, e todos os valores são gerados diretamente a partir dos dados medidos. Ao final, discutem-se os defeitos encontrados em implementações públicas e o crescimento empírico dos tempos frente à complexidade teórica.

6.1 Cardinalidade máxima em grafos bipartidos

As Tabelas 10 e 11 apresentam os tempos dos algoritmos para o grafo denso, separados por linguagem de implementação, e a Tabela 12, a qualidade das soluções.

Tabela 10: Tempo de execução em Python — Grafo 3 — Denso | COM perfeito | MCM = n (mediana, ms)

Algoritmo	Tipo	Tempo	Espaço	$n = 50$	$n = 100$	$n = 150$	$n = 200$	$n = 250$
Aug. Paths (wbchristerson)	exato	$O(V \cdot E)$	$O(V + E)$	2.08	19.12	34.10	39.79	259.8
Hopcroft-Karp (sofiat)	exato	$O(E \cdot \sqrt{V})$	$O(V + E)$	1.14	2.41	3.99	6.19	7.5
Edmonds-Karp (Maxflow-Algs)	exato	$O(V \cdot E^2)$	$O(V^2)$	12.19	75.08	238.34	556.37	1077.9
Hopcroft-Karp (NetworkX)	baseline	$O(E \cdot \sqrt{V})$	$O(V + E)$	1.51	3.15	4.84	6.94	8.6
Gulosa	heurística	$O(E)$	$O(V)$	0.03	0.06	0.08	0.11	0.1
Karp-Sipser	heurística	$O(V \cdot E)$	$O(V + E)$	0.49	1.35	3.87	4.65	6.8

Tabela 11: Tempo de execução em compilado (C/C++) — Grafo 3 — Denso | COM perfeito | MCM = n (mediana, ms)

Algoritmo	Tipo	Tempo	Espaço	$n = 50$	$n = 100$	$n = 150$	$n = 200$	$n = 250$
Bipartite Match. (igraph)	baseline	$O(E \cdot \sqrt{V})$	$O(V + E)$	0.20	0.36	0.61	0.85	1.01

Tabela 12: Qualidade da solução — Grafo 3 — Denso | COM perfeito | MCM = n

Algoritmo	Tipo	Tempo	$n = 50$	$n = 100$	$n = 150$	$n = 200$	$n = 250$
Aug. Paths (wbchristerson)	exato	$O(V \cdot E)$	50	100	150	200	250
Hopcroft-Karp (sofiat)	exato	$O(E \cdot \sqrt{V})$	50	100	150	200	250
Edmonds-Karp (Maxflow-Algs)	exato	$O(V \cdot E^2)$	50	100	150	200	250
Hopcroft-Karp (NetworkX)	baseline	$O(E \cdot \sqrt{V})$	50	100	150	200	250
Bipartite Match. (igraph)	baseline	$O(E \cdot \sqrt{V})$	50	100	150	200	250
Gulosa	heurística	$O(E)$	47	93	142	191	235
Karp-Sipser	heurística	$O(V \cdot E)$	50	100	150	200	249

Entre os algoritmos exatos, a diferença de desempenho é de mais de duas ordens de grandeza: o Edmonds-Karp, que reduz o emparelhamento a um problema de fluxo e reconstrói a busca a cada aumento, é dramaticamente mais lento que o Hopcroft-Karp, que agrupa os caminhos aumentantes em fases. Essa distância confirma na prática o que a complexidade assintótica prevê e ilustra por que, em grafos maiores, a escolha do algoritmo importa muito mais do que a constante de implementação. A implementação de núcleo compilado (igraph), na tabela dos compilados, é a mais rápida de todas, como esperado.

Quanto às heurísticas, os resultados evidenciam o compromisso central entre qualidade e tempo. A heurística gulosa é a mais rápida de todo o conjunto, porém não atinge o ótimo em todas as instâncias. A heurística de Karp-Sipser, ao custo de um tempo comparável ao dos exatos mais eficientes, encontra

o ótimo em todas as instâncias avaliadas — reflexo da regra dos vértices de grau um, que fixa escolhas comprovadamente ótimas e, em grafos esparsos, chega a dispensar o passo guloso.

6.2 Atribuição linear

Os tempos dos algoritmos para a matriz densa constam na Tabela 13 (interpretados) e na Tabela 14 (compilados); a Tabela 15 traz a qualidade, na qual se veem também as células em que dois dos algoritmos falham.

Tabela 13: Tempo de execução em Python — Matriz 1 — Densa uniforme | custo in [1,100] (mediana, ms)

Algoritmo	Tipo	Tempo	Espaço	$n = 10$	$n = 20$	$n = 30$	$n = 50$	$n = 75$	$n = 100$
Húngaro (munkres)	exato	$O(n^3)$	$O(n^2)$	0.39	1.98	4.82	15.43	41.61	97.23
Húngaro (benchaplin)	exato	$O(n^3)$	$O(n^2)$	11.11	92.32	391.64	BugAttr	BugAttr	BugAttr
Húngaro (hunalgorithm)	exato	$O(n^3)$	$O(n^2)$	2.10	BugPerc	BugPerc	BugPerc	BugPerc	BugPerc
Húngaro (mayorx/KM)	exato	$O(n^3)$	$O(n^2)$	0.99	2.25	7.49	12.30	21.11	29.30
SSP (flows)	exato	$O(n^4)^*$	$O(n^2)$	0.45	2.65	6.92	29.97	98.01	235.13

Tabela 14: Tempo de execução em compilado (C/C++) — Matriz 1 — Densa uniforme | custo in [1,100] (mediana, ms)

Algoritmo	Tipo	Tempo	Espaço	$n = 10$	$n = 20$	$n = 30$	$n = 50$	$n = 75$	$n = 100$	$n =$
SciPy (linear_sum_assg)	baseline	$O(n^3)$	$O(n^2)$	0.02	0.04	0.08	0.23	0.51	0.84	2
Jonker-Volgenant (lap)	baseline	$O(n^3)$	$O(n^2)$	0.02	0.05	0.07	0.17	0.36	0.61	1

Tabela 15: Qualidade da solução — Matriz 1 — Densa uniforme | custo in [1,100]

Algoritmo	Tipo	Tempo	$n = 10$	$n = 20$	$n = 30$	$n = 50$	$n = 75$	$n = 100$	$n = 1$
Húngaro (munkres)	exato	$O(n^3)$	102	146	168	217	238	244	2
Húngaro (benchaplin)	exato	$O(n^3)$	102	146	168	BugAttr	BugAttr	BugAttr	BugA
Húngaro (hunalgorithm)	exato	$O(n^3)$	102	BugPerc	BugPerc	BugPerc	BugPerc	BugPerc	BugPe
Húngaro (mayorx/KM)	exato	$O(n^3)$	102	146	168	217	238	244	2
SSP (flows)	exato	$O(n^4)^*$	102	146	168	217	238	244	
SciPy (linear_sum_assg)	baseline	$O(n^3)$	102	146	168	217	238	244	2
Jonker-Volgenant (lap)	baseline	$O(n^3)$	102	146	168	217	238	244	2

Todos os algoritmos que concluem atingem o custo ótimo, de modo que a comparação recai sobre o tempo. Entre as quatro implementações do método Húngaro, obtidas de autores distintos para exatamente o mesmo algoritmo, observa-se uma variação de mais de uma ordem de grandeza — evidência de que a qualidade da implementação, e não apenas o algoritmo, determina o desempenho na prática. As implementações de núcleo compilado (SciPy e Jonker-Volgenant) são, novamente, as mais rápidas.

Duas das implementações do Húngaro apresentam defeitos que impedem sua conclusão em parte das instâncias densas; como esse é um resultado relevante por si só, ele é tratado em conjunto na Seção 6.7.

6.3 Atribuição gargalo

A Tabela 16 compara os tempos dos dois algoritmos exatos para a matriz densa, e a Tabela 17, o custo gargalo que encontram.

Tabela 16: Tempo de execução em Python — Matriz 1 — Densa uniforme | custo in [1,100] (mediana, ms)

Algoritmo	Tipo	Tempo	Espaço	$n = 10$	$n = 20$	$n = 30$	$n = 50$	$n = 75$	$n = 100$	$n = 150$
Threshold (busca binária)	exato	$O(n^3 \log n)$	$O(n^2)$	0.10	0.50	1.44	4.48	13.50	32.06	55.10
Caminhos aumentantes	exato	$O(n^3)$	$O(n^2)$	0.05	0.23	0.62	2.10	5.43	11.32	18.75

Tabela 17: Qualidade da solução — Matriz 1 — Densa uniforme | custo in [1,100]

Algoritmo	Tipo	Tempo	$n = 10$	$n = 20$	$n = 30$	$n = 50$	$n = 75$	$n = 100$	$n = 150$	$n = 200$
Threshold (busca binária)	exato	$O(n^3 \log n)$	26	18	18	13	8	7	5	4
Caminhos aumentantes	exato	$O(n^3)$	26	18	18	13	8	7	5	4

Ambos produzem sempre o mesmo custo gargalo ótimo, o que serve também como verificação cruzada de corretude. O método de caminhos aumentantes, construtivo, mostra-se consistentemente mais rápido que o método de *threshold*, que repete uma verificação de emparelhamento perfeito a cada passo da busca binária sobre o limiar. A vantagem do método construtivo cresce com o tamanho da instância.

6.4 Casamento estável

A Tabela 18 apresenta os tempos das três variantes de Gale-Shapley para preferências aleatórias, e a Tabela 19, a verificação de estabilidade e de concordância entre elas.

Tabela 18: Tempo de execução em Python — Perfil 1 — Aleatório | permutações uniformes (mediana, ms)

Algoritmo	Tipo	Tempo	Espaço	$n = 25$	$n = 50$	$n = 75$	$n = 100$	$n = 200$	$n = 300$
Gale-Shapley (OOP/pip)	exato	$O(n^2)^\dagger$	$O(n^2)$	7.54	94.14	321.96	692.09	—	—
Gale-Shapley (numérico/pip)	exato	$O(n^2)$	$O(n^2)$	0.44	1.57	3.36	5.52	21.70	50.59
Gale-Shapley (Lattas/dict)	exato	$O(n^3)^*$	$O(n^2)$	0.31	1.29	2.85	5.08	20.07	52.20

Tabela 19: Qualidade da solução — Perfil 1 — Aleatório | permutações uniformes

Algoritmo	Tipo	Tempo	$n = 25$	$n = 50$	$n = 75$	$n = 100$	$n = 200$	$n = 300$	$n = 400$
Gale-Shapley (OOP/pip)	exato	$O(n^2)^\dagger$	0 =ref	0 =ref	0 =ref	0 =ref	—	—	—
Gale-Shapley (numérico/pip)	exato	$O(n^2)$	0 =ref	0 =ref	0 =ref	0 =ref	0 =ref	0 =ref	0 =ref
Gale-Shapley (Lattas/dict)	exato	$O(n^3)^*$	0 =ref	0 =ref	0 =ref	0 =ref	0 =ref	0 =ref	0 =ref

Pela unicidade do emparelhamento estável ótimo para os pretendentes, as três variantes produzem exatamente o mesmo resultado; a qualidade, portanto, não as distingue. A variante orientada a objetos, embora teoricamente quadrática, mostra-se substancialmente mais lenta e inviável nos tamanhos maiores, por conta do sobrecusto de reconstruir estruturas a cada rodada — comportamento quantificado adiante, na análise de crescimento empírico. As variantes que operam sobre vetores e dicionários escalam sem dificuldade até os maiores tamanhos avaliados.

6.5 Emparelhamento em grafos gerais

Para cardinalidade máxima, comparam-se o algoritmo de Blossom e a biblioteca NetworkX (Tabelas 20 e 21); para peso máximo, a implementação de van Rantwijk, a mesma biblioteca e a heurística Path Growing (Tabelas 22 e 23).

Tabela 20: Tempo de execução em Python — Cardinalidade — esparso (grau ~ 3) (mediana, ms)

Algoritmo	Tipo	Tempo	Espaço	$n = 10$	$n = 20$	$n = 30$	$n = 50$	$n = 75$	$n = 100$
Blossom (Edmonds)	exato	$O(V^3)$	$O(V^2)$	1.66	3.21	3.97	20.36	43.90	103.46
NetworkX (cardinalidade)	baseline	$O(V^3)$	$O(V + E)$	0.40	0.63	0.74	1.41	2.28	3.15

Tabela 21: Qualidade da solução — Cardinalidade — esparso (grau ~ 3)

Algoritmo	Tipo	Tempo	$n = 10$	$n = 20$	$n = 30$	$n = 50$	$n = 75$	$n = 100$
Blossom (Edmonds)	exato	$O(V^3)$	5	9	13	23	31	43
NetworkX (cardinalidade)	baseline	$O(V^3)$	5	9	13	23	31	43

Tabela 22: Tempo de execução em Python — Peso — esparso (grau ~ 3) (mediana, ms)

Algoritmo	Tipo	Tempo	Espaço	$n = 10$	$n = 20$	$n = 30$	$n = 50$	$n = 75$	$n = 100$
van Rantwijk (mwmatching)	exato	$O(V^3)$	$O(V + E)$	0.26	0.54	0.86	2.19	3.49	6.30
NetworkX (peso máximo)	baseline	$O(V^3)$	$O(V + E)$	0.59	1.25	1.98	4.87	7.52	13.58
Path Growing	heurística	$O(E)$	$O(V + E)$	0.03	0.05	0.07	0.11	0.17	0.23

Tabela 23: Qualidade da solução — Peso — esparso (grau ~ 3)

Algoritmo	Tipo	Tempo	$n = 10$	$n = 20$	$n = 30$	$n = 50$	$n = 75$	$n = 100$
van Rantwijk (mwmatching)	exato	$O(V^3)$	309	604	790	1284	1907	2929
NetworkX (peso máximo)	baseline	$O(V^3)$	309	604	790	1284	1907	2929
Path Growing	heurística	$O(E)$	278	510	732	1030	1492	2407

No caso ponderado, um resultado é digno de nota: a implementação independente de van Rantwijk é mais rápida que a rotina correspondente do NetworkX, ainda que esta última seja uma adaptação daquele mesmo código. A comparação, portanto, não opõe duas abordagens, e sim uma implementação a um descendente empacotado dela; a diferença observada mede o efeito das camadas de generalidade que a biblioteca acrescenta. A heurística Path Growing, por sua vez, é ordens de grandeza mais rápida que os exatos e entrega uma fração elevada do peso ótimo, bem acima da sua garantia teórica de metade — mais um exemplo de que, na prática, a heurística rende muito mais do que o seu pior caso.

6.6 Emparelhamento induzido máximo

Sendo NP-difícil, o emparelhamento induzido máximo tem um perfil distinto dos demais problemas: o algoritmo exato só é viável em instâncias pequenas, e a qualidade das heurísticas passa a ser o eixo central da comparação. A Tabela 24 traz os tempos e a Tabela 25, a qualidade.

Tabela 24: Tempo de execução em Python — Grafo esparso (grau ~3) (mediana, ms)

Algoritmo	Tipo	Tempo	Espaço	$n = 10$	$n = 15$	$n = 20$	$n = 25$	$n = 30$	$n = 40$	$n = 50$
Exato (MIS conflitos)	exato	<i>exp.</i>	$O(E^2)$	0.17	0.31	0.83	2.05	5.23	75.10	—
Guloso aleatório	heurística	$O(E^2)$	$O(V + E)$	0.05	0.06	0.08	0.13	0.18	0.30	0.4
Guloso grau mínimo	heurística	$O(E^2)$	$O(E^2)$	0.19	0.37	0.78	1.48	1.84	2.79	4.3

Tabela 25: Qualidade da solução — Grafo esparso (grau ~3)

Algoritmo	Tipo	Tempo	$n = 10$	$n = 15$	$n = 20$	$n = 25$	$n = 30$	$n = 40$	$n = 50$	$n = 100$
Exato (MIS conflitos)	exato	<i>exp.</i>	2	3	5	5	8	10	—	—
Guloso aleatório	heurística	$O(E^2)$	2	2	3	3	5	7	10	18
Guloso grau mínimo	heurística	$O(E^2)$	2	3	5	5	8	10	11	25

O algoritmo exato, que reduz o problema a conjunto independente máximo no grafo de conflitos, resolve instâncias pequenas em poucos milissegundos, mas seu custo cresce rapidamente e o torna inviável além de algumas dezenas de vértices — o que justifica empiricamente a necessidade das heurísticas. Entre estas, evidencia-se um compromisso claro: a heurística de grau mínimo encontra soluções de qualidade consistentemente superior à da escolha aleatória, ao custo de um tempo bem maior, por manter e atualizar o grafo de conflitos. Nas instâncias pequenas, em que o ótimo é conhecido, a heurística de grau mínimo chega muito próximo dele.

6.7 Defeitos em implementações públicas

Um resultado que só emerge da execução repetida dos algoritmos — e que um levantamento puramente bibliográfico não revelaria — diz respeito à confiabilidade de implementações públicas de algoritmos clássicos. Duas das quatro implementações do método Húngaro avaliadas apresentam defeitos.

A primeira (`hunalgorithm`) falha de forma determinística em matrizes densas a partir de um certo tamanho, por exceder um limite interno de iterações previsto em seu próprio código; matrizes estruturadas, que produzem padrões mais simples, não acionam o problema.

A segunda (`benchaplin`) é mais notável, por ser **não-determinística entre execuções**. Sobre exatamente a mesma matriz de entrada, a implementação ora retorna o custo ótimo correto, ora falha com um erro de tipo, ora ingressa em um caminho de execução tão lento que não conclui em tempo praticável. A causa é a dependência do defeito quanto à ordem de iteração de uma coleção de objetos, que a linguagem aleatoriza a cada processo. Trata-se de três desfechos distintos para a mesma entrada, todos observados. Além de ilustrar de forma vívida o valor de *implementar e medir* sobre apenas catalogar, esse comportamento tem uma consequência metodológica registrada no capítulo anterior: a fixação da semente de aleatorização foi necessária justamente para tornar os resultados reproduzíveis.

Optou-se por **reportar** esses defeitos, e não corrigi-los: como o objeto de estudo é o conjunto de implementações efetivamente disponíveis, corrigi-los apagaria um resultado legítimo sobre a qualidade do que se encontra publicado.

6.8 Crescimento empírico frente à complexidade teórica

Como o tempo absoluto não é comparável entre linguagens, a análise de crescimento apoia-se no expoente empírico definido na Seção 5.5: a inclinação da reta ajustada ao gráfico do tempo pelo tamanho, em escala logarítmica. As Figuras 1 e 2 apresentam esses gráficos para dois problemas representativos, e as Tabelas 26 a 30 confrontam o expoente medido com a complexidade teórica de cada algoritmo.




Figura 1: Tempo de execução em escala log-log para o grafo denso (cardinalidade máxima bipartida). A inclinação de cada reta corresponde ao expoente empírico de crescimento; a de Edmonds-Karp, próxima de 3, destaca-se das demais.




Figura 2: Tempo de execução em escala log-log para a matriz densa (atribuição linear). As duas implementações de núcleo compilado situam-se bem abaixo das interpretadas, mas com inclinação semelhante.

Os expoentes medidos são, em geral, coerentes com a teoria. O caso mais nítido é o do Edmonds-Karp, cujo expoente próximo de três acompanha o comportamento cúbico previsto e o separa visivelmente dos demais na Figura 1. Nas implementações de núcleo compilado, a reta situa-se muito abaixo das interpretadas, mas com inclinação semelhante — exatamente o efeito esperado: a linguagem altera a constante (a posição da reta), não o expoente (a inclinação).

Tabela 26: Expoente empírico de crescimento — Grafo 3 — Denso — COM perfeito — MCM = n

Algoritmo	Compl. teórica	Expoente medido	R^2
Aug. Paths (wbchristerson)	$O(V \cdot E)$	2.61	0.917
Hopcroft-Karp (sofiat)	$O(E \cdot \sqrt{V})$	1.20	0.996
Edmonds-Karp (Maxflow-Algs)	$O(V \cdot E^2)$	2.79	0.999
Hopcroft-Karp (NetworkX)	$O(E \cdot \sqrt{V})$	1.09	0.999
Bipartite Match. (igraph)	$O(E \cdot \sqrt{V})$	1.05	0.994
Gulosa	$O(E)$	1.00	1.000
Karp-Sipser	$O(V \cdot E)$	1.68	0.983

Tabela 27: Expoente empírico de crescimento — Matriz 1 — Densa uniforme — custo in [1,100]

Algoritmo	Compl. teórica	Expoente medido	R^2
Húngaro (munkres)	$O(n^3)$	2.36	0.999
Húngaro (benchaplin)	$O(n^3)$	3.22	0.998
Húngaro (mayorx/KM)	$O(n^3)$	1.39	0.980
SSP (flows)	$O(n^4)^*$	2.71	0.998
SciPy (linear_sum_assg)	$O(n^3)$	1.86	0.994
Jonker-Volgenant (lap)	$O(n^3)$	1.65	0.987

Observa-se ainda que, nos tamanhos avaliados, o expoente medido frequentemente fica *abaixo* do previsto pela complexidade de pior caso, que é conservadora: o pior caso raramente se materializa nas instâncias típicas. A exceção reveladora é a variante orientada a objetos do Gale-Shapley (Tabela 28), cujo expoente medido supera o teórico: o sobrecusto de implementação a torna, na prática, super-quadrática, confirmando por medição a ressalva já registrada sobre ela.

Tabela 28: Expoente empírico de crescimento — Perfil 1 — Aleatório — permutações uniformes

Algoritmo	Compl. teórica	Expoente medido	R^2
Gale-Shapley (OOP/pip)	$O(n^2)$	3.28	0.996
Gale-Shapley (numérico/pip)	$O(n^2)$	1.94	0.999
Gale-Shapley (Lattas/dict)	$O(n^3)^*$	2.07	0.999

Tabela 29: Expoente empírico de crescimento — Matriz 1 — Densa uniforme — custo in [1,100]

Algoritmo	Compl. teórica	Expoente medido	R^2
Threshold (busca binária)	$O(n^3 \log n)$	2.61	0.996
Caminhos aumentantes	$O(n^3)$	2.41	0.999

Tabela 30: Expoente empírico de crescimento — Peso — esparso (grau 3)

Algoritmo	Compl. teórica	Expoente medido	R^2
van Rantwijk (mwmatching)	$O(V^3)$	1.40	0.989
NetworkX (peso máximo)	$O(V^3)$	1.36	0.990
Path Growing	$O(E)$	0.88	0.998

7 Trabalhos futuros

As próximas etapas deste trabalho concentram-se no aprofundamento teórico dos N problemas de emparelhamento previamente delineados, bem como na inclusão de novos problemas e na investigação de M abordagens heurísticas para resolução dos mesmos. O objetivo central é estabelecer uma análise comparativa rigorosa entre estas heurísticas e os algoritmos exatos consagrados na literatura.

Para viabilizar essa análise, será desenvolvido um ambiente computacional padronizado (framework de testes), onde os algoritmos serão implementados e submetidos a um conjunto de X instâncias de teste com topologias e dimensões variadas. A avaliação final buscará classificar as soluções heurísticas considerando a relação entre eficiência computacional (tempo de execução) e a qualidade da solução (proximidade do ótimo), utilizando os resultados dos algoritmos exatos como referência.

Referências

- AHO, A. V.; HOPCROFT, J. E.; ULLMAN, J. D. *The Design And Analysis of Computer Algorithms*. 1st. ed. Reading, MA: Addison-Wesley, 1974. ISBN 9780201000290.
- AHUJA, R. K.; MAGNANTI, T. L.; ORLIN, J. B. *Network flows: theory, algorithms, and applications*. USA: Prentice-Hall, Inc., 1993. ISBN 013617549X.
- BURKARD, R.; DELL'AMICO, M.; MARTELLO, S. *Assignment Problems*. USA: Society for Industrial and Applied Mathematics, 2009. ISBN 0898716632.
- CAETANO, T. S. et al. Learning graph matching. *IEEE TRANSACTIONS ON PATTERN ANALYSIS AND MACHINE INTELLIGENCE*, IEEE Computer Society, United States, v. 31, n. X, December 2009. ISSN 0162-8828.
- CAMERON, K. Induced matchings. *Discrete Applied Mathematics*, v. 24, n. 1, p. 97–102, 1989. ISSN 0166-218X. Disponível em: (<https://www.sciencedirect.com/science/article/pii/0166218X9290275F>).
- CORMEN, T. H. et al. *Introduction to Algorithms*. 3rd. ed. Cambridge, MA: The MIT Press, 2009. ISBN 978-0-262-53305-8.
- DASGUPTA, C. H. P. S.; VAZIRANI, U. V. *Algorithms*. 1st. ed. New York, NY: McGraw-Hill Education, 2006. ISBN 978-0073523408.
- DRAKE, D. E.; HOUGARDY, S. A simple approximation algorithm for the weighted matching problem. *Information Processing Letters*, v. 85, n. 4, p. 211–213, 2003. ISSN 0020-0190. Disponível em: (<https://www.sciencedirect.com/science/article/pii/S0020019002003939>).
- DUCKWORTH, W.; WORMALD, N.; ZITO, M. Maximum induced matchings of random cubic graphs. *Journal of Computational and Applied Mathematics*, v. 142, n. 1, p. 39–50, 2002. ISSN 0377-0427. Probabilistic Methods in Combinatorics and Combinatorial Optimization. Disponível em: (<https://www.sciencedirect.com/science/article/pii/S0377042701004575>).
- EDMONDS, J. Paths, trees, and flowers. *Canadian Journal of Mathematics*, v. 17, p. 449–467, 1965.
- FAN, W. Graph pattern matching revised for social network analysis. In: *Proceedings of the 15th International Conference on Database Theory*. New York, NY, USA: Association for Computing Machinery, 2012. (ICDT '12), p. 8–21. ISBN 9781450307918. Disponível em: (<https://doi.org/10.1145/2274576.2274578>).
- FÜRST, M.; LEICHTER, M.; RAUTENBACH, D. *Locally Searching for Large Induced Matchings*. 2017. Disponível em: (<https://arxiv.org/abs/1708.02028>).
- GABOW, H. N. Data structures for weighted matching and nearest common ancestors with linking. In: *Proceedings of the First Annual ACM-SIAM Symposium on Discrete Algorithms*. USA: Society for Industrial and Applied Mathematics, 1990. (SODA '90), p. 434–443. ISBN 0898712513.
- GALIL, Z.; MICALI, S.; GABOW, H. An $o(ev \log v)$ algorithm for finding a maximal weighted matching in general graphs. *SIAM J. Comput.*, v. 15, p. 120–130, 02 1986.
- GAREY, M. R.; JOHNSON, D. S. *Computers and Intractability; A Guide to the Theory of NP-Completeness*. USA: W. H. Freeman & Co., 1990. ISBN 0716710455.
- HALIM, S.; HALIM, F. *Competitive Programming 3: The New Lower Bound of Programming Contests*. 3rd. ed. [S.l.]: Lulu.com, 2013. Self-published by the authors. ISBN 978-1482852483.
- HALLDÓRSSON, M.; RADHAKRISHNAN, J. Greed is good: approximating independent sets in sparse and bounded-degree graphs. In: *Proceedings of the Twenty-Sixth Annual ACM Symposium on Theory of Computing*. New York, NY, USA: Association for Computing Machinery, 1994. (STOC '94), p. 439–448. ISBN 0897916638. Disponível em: (<https://doi.org/10.1145/195058.195221>).

HALLER, S. et al. *A Comparative Study of Graph Matching Algorithms in Computer Vision*. 2022. Disponível em: <https://arxiv.org/abs/2207.00291>.

JONKER, R.; VOLGENANT, A. A shortest augmenting path algorithm for dense and sparse linear assignment problems. *Computing*, v. 38, n. 4, p. 325–340, 1987. Disponível em: <https://doi.org/10.1007/BF02278710>.

JUNGNICKEL, D. *Graphs, Networks and Algorithms*. 3rd. ed. Berlin, Germany: Springer, 2008. ISBN 978-354727798.

KARP, R. M.; SIPSER, M. Maximum matching in sparse random graphs. In: *Proceedings of the 22nd Annual Symposium on Foundations of Computer Science*. USA: IEEE Computer Society, 1981. (SFCS '81), p. 364–375. Disponível em: <https://doi.org/10.1109/SFCS.1981.21>.

KLEINBERG, J.; TARDOS Éva. *Algorithm Design*. 1st. ed. Boston, MA: Pearson, 2005. ISBN 978-0321295354.

LAWLER, E. L. *Combinatorial Optimization: Networks and Matroids*. New York, NY: Dover Publications, 1976. Reprint edition. ISBN 978-0486414539.

Basic terminology. In: LOVÁSZ, L.; PLUMMER, M. (Ed.). *Matching Theory*. North-Holland, 1986, (North-Holland Mathematics Studies, v. 121). p. xxix–xxxiii. Disponível em: <https://www.sciencedirect.com/science/article/pii/S0304020808736363>.

MANBER, U. *Introduction to Algorithms: A Creative Approach*. 1st. ed. Reading, MA: Addison-Wesley, 1989. ISBN 978-0201120370.

MANDULAK, M. et al. Efficient weighted graph matching on gpus. *SC24*, IEEE Computer Society, United States, November 2024. ISSN 0162-8828.

MARTELLO, S.; TOTH, P. Linear assignment problems. In: MARTELLO, S. et al. (Ed.). *Surveys in Combinatorial Optimization*. North-Holland, 1987, (North-Holland Mathematics Studies, v. 132). p. 259–282. Disponível em: <https://www.sciencedirect.com/science/article/pii/S0304020808732389>.

MICALI, S.; VAZIRANI, V. An $O(\sqrt{v} \log E)$ Algorithm for Finding Maximum Matching in General Graphs. In: . [S.l.: s.n.], 1980. p. 17–27.

ROSEN, K. H.; KREHER, D. L.; STINSON, D. R. *Discrete Mathematics and Its Applications*. 1st. ed. Boca Raton, FL: CRC Press, 1998. ISBN 978-0849339882.

SCHRIJVER, A. *Combinatorial Optimization: Polyhedra and Efficiency*. 1st. ed. Berlin, Germany: Springer, 2004. ISBN 3540204563.

STOCKMEYER, L. J.; VAZIRANI, V. V. Np-completeness of some generalizations of the maximum matching problem. *Information Processing Letters*, v. 15, n. 1, p. 14–19, 1982. ISSN 0020-0190. Disponível em: <https://www.sciencedirect.com/science/article/pii/0020019082900771>.

SUSSMAN, D. L.; LI, L. *Overview of Graph Matching Challenges and Approaches*. 2021. Acessado em: 26 nov. 2024. Disponível em: <https://www.ll.mit.edu/>.

TAYLOR, W. R. Protein structure comparison using bipartite graph matching and its application to protein structure classification. *Molecular and Cellular Proteomics*, American Society for Biochemistry and Molecular Biology, United States, v. 1, n. 4, April 2002. ISSN 1535-9476.

VAZIRANI, V. V. *Approximation algorithms*. Berlin, Heidelberg: Springer-Verlag, 2001. ISBN 3540653678.

ZASLAVSKIY, M.; BACH, F.; VERT, J.-P. A path following algorithm for the graph matching problem. *IEEE TRANSACTIONS ON PATTERN ANALYSIS AND MACHINE INTELLIGENCE*, IEEE Computer Society, United States, v. 31, n. 12, December 2009. ISSN 0162-8828.